

Open Data Structures (za programski jezik Java)^{v slovenščini}

Izdaja 0.1F

Pat Morin



Kazalo

| | | |
|----------|--|-----------|
| 1 | Uvod | 1 |
| 1.1 | Zahteva po učinkovitosti | 2 |
| 1.2 | Vmesniki | 4 |
| 1.2.1 | Vmesniki Queue, Stack, in Deque | 4 |
| 1.2.2 | Vmesnik seznama: linearne sekvence | 6 |
| 1.2.3 | Vmesnik USet: Neurejena množica | 7 |
| 1.2.4 | Vmesnik SSet: Urejena množica | 8 |
| 1.3 | Matematično ozdaje | 9 |
| 1.3.1 | EkspONENTI in Logaritmi | 9 |
| 1.3.2 | Fakulteta | 11 |
| 1.3.3 | Asimptotična Notacija | 11 |
| 1.3.4 | Naključnost in verjetnost | 15 |
| 1.4 | Model računanja | 18 |
| 1.5 | Pravilnost, časovna in prostorska zahtevnost | 19 |
| 1.6 | Vzorci kode | 21 |
| 1.7 | Seznam Podatkovnih Struktur | 22 |
| 1.8 | Razprava in vaje | 22 |
| 2 | Izvedba seznama s poljem | 29 |
| 2.1 | ArrayStack: Izvedba sklada s poljem | 30 |
| 2.1.1 | Osnove | 30 |
| 2.1.2 | Večanje in krčenje | 33 |
| 2.1.3 | Povzetek | 35 |
| 2.2 | FastArrayStack: Optimiziran ArrayStack | 35 |
| 2.3 | ArrayQueue: Vrsta na osnovi polja | 36 |
| 2.3.1 | Povzetek | 40 |

| | | |
|----------|---|-----------|
| 2.4 | ArrayDeque: Hitra obojestranska vrsta z uporabo polja . . . | 40 |
| 2.4.1 | Povzetek | 43 |
| 2.5 | DualArrayDeque: Gradnja obojestranske vrste z dveh skla- | |
| | dov | 43 |
| 2.5.1 | Uravnoveženje | 46 |
| 2.5.2 | Povzetek | 49 |
| 2.6 | RootishArrayStack: Prostorsko učinkovit ArrayStack . . | 49 |
| 2.6.1 | Analiza rasti in krčenja | 54 |
| 2.6.2 | Poraba prostora | 54 |
| 2.6.3 | Povzetek | 55 |
| 2.6.4 | Računanje Kvadratnih Korenov | 56 |
| 2.7 | Razprava in vaje | 59 |
| 3 | Povezani seznam | 63 |
| 3.1 | SLList: Enostransko povezani seznam | 64 |
| 3.1.1 | Operacije Vrste | 66 |
| 3.1.2 | Povzetek | 67 |
| 3.2 | DLList: Obojestransko povezan seznam | 67 |
| 3.2.1 | Dodajanje in odstranjevanje | 69 |
| 3.2.2 | Povzetek | 71 |
| 3.3 | SEList: Prostorsko učinkovit povezan seznam | 72 |
| 3.3.1 | Prostorske zahteve | 73 |
| 3.3.2 | Iskanje elementov | 73 |
| 3.3.3 | Dodajanje elementov | 75 |
| 3.3.4 | Odstranjevanje elementov | 77 |
| 3.3.5 | Amortizirana analiza širjenja in združevanja | 79 |
| 3.3.6 | Povzetek | 81 |
| 3.4 | Razprave in vaje | 81 |
| 4 | Preskočni sezname | 87 |
| 4.1 | Osnovna struktura | 87 |
| 4.2 | SkiplistSSet: Učinkovit SSet | 90 |
| 4.2.1 | Povzetek | 93 |
| 4.3 | SkiplistList: Učinkovit naključni dostop List | 93 |
| 4.3.1 | Povzetek | 98 |
| 4.4 | Analiza preskočnega seznama | 98 |

| | | |
|----------|--|------------|
| 4.5 | Razprava in vaje | 102 |
| 5 | Zgoščevalne tabele | 107 |
| 5.1 | Zgoščevalna tabela z veriženjem | 107 |
| 5.1.1 | Zgoščevanje z množenjem | 110 |
| 5.1.2 | Povzetek | 114 |
| 5.2 | LinearHashTable: Odprto naslavljanje | 114 |
| 5.2.1 | Analiza odprtega naslavljanja | 118 |
| 5.2.2 | Povzetek | 121 |
| 5.2.3 | Tabelarno zgoščevanje | 121 |
| 5.3 | Zgoščene vrednosti | 122 |
| 5.3.1 | Zgoščene vrednosti osnovnih podatkovnih tipov | 123 |
| 5.3.2 | Zgoščene vrednosti sestavljenih podatkovnih tipov | 123 |
| 5.3.3 | Zgoščevalne funkcije za polja in nize | 126 |
| 5.4 | Razprave in primeri | 128 |
| 6 | Dvojiška drevesa | 133 |
| 6.1 | BinaryTree: Osnovno dvojiško drevo | 135 |
| 6.1.1 | Rekurzivni algoritmi | 136 |
| 6.1.2 | Obhod dvojiškega drevesa | 136 |
| 6.2 | BinarySearchTree: Neuravnoteženo dvojiško iskalno drevo | 139 |
| 6.2.1 | Iskanje | 140 |
| 6.2.2 | Vstavljanje | 141 |
| 6.2.3 | Brisanje | 144 |
| 6.2.4 | Povzetek | 146 |
| 6.3 | BinaryTree: Razprava in vaje | 146 |
| 7 | Naključna iskalna dvojiška drevesa | 151 |
| 7.1 | Naključna iskalna dvojiška drevesa | 151 |
| 7.1.1 | Dokaz 7.1 | 154 |
| 7.1.2 | Povzetek | 156 |
| 7.2 | Treap: Naključno generirano dvojiško iskalno drevo | 157 |
| 7.2.1 | Povzetek | 164 |
| 7.3 | Razprava in vaje | 166 |

| | | |
|-----------|--|------------|
| 8 | Drevesa “grešnega kozla” | 171 |
| 8.1 | ScapegoatTree: Dvojiško iskalno drevo z delno rekonstrukcijo | 172 |
| 8.1.1 | Analiza pravilnosti in časovne kompleksnosti | 175 |
| 8.1.2 | Povzetek | 178 |
| 9 | Rdeče-Črna Drevesa | 179 |
| 9.1 | 2-4 Trees | 180 |
| 9.1.1 | Dodajanje lista | 181 |
| 9.1.2 | Odstranjevanje lista | 181 |
| 9.2 | RedBlackTree: Simulirano 2-4 drevo | 184 |
| 9.2.1 | Rdeče-Črna drevesa in 2-4 Drevesa | 185 |
| 9.2.2 | Levo-poravnana rdece-crna drevesa | 188 |
| 9.2.3 | Dodajanje | 190 |
| 9.2.4 | Odstranitev | 193 |
| 9.3 | Povzetek | 198 |
| 9.4 | Razprava in naloge | 199 |
| 10 | Kopice | 205 |
| 10.1 | BinaryHeap: implicitno dvojiško drevo | 205 |
| 10.1.1 | Povzetek | 211 |
| 10.2 | MeldableHeap: Naključna zlivalna kopica | 211 |
| 10.2.1 | Analiza merge(h_1, h_2) | 213 |
| 10.2.2 | Povzetek | 215 |
| 10.3 | Diskusije in vaje | 215 |
| 11 | Algoritmi za urejanje | 219 |
| 11.1 | Urejanje s primerjanjem | 220 |
| 11.1.1 | Urejanje z zlivanjem (merge-sort) | 220 |
| 11.1.2 | Hitro urejanje (quicksort) | 224 |
| 11.1.3 | Urejanje s kopico (heap-sort) | 227 |
| 11.1.4 | Spodnja meja algoritmov za urejanje, temelječih na primerjavah | 229 |
| 11.2 | Urejanje s štetjem in korensko urejanje | 232 |
| 11.2.1 | Urejanje s štetjem (counting sort) | 233 |
| 11.2.2 | Korensko urejanje (radix sort) | 235 |

| | |
|--|------------|
| 11.3 Diskusija in naloge | 237 |
| 12 Grafi | 241 |
| 12.1 AdjacencyMatrix: Predstavitev grafov z uporabo matrik . | 243 |
| 12.2 AdjacencyLists: Predstavitev grafov s seznamom sose- | |
| dnosti | 246 |
| 12.3 Preiskovanje grafov | 250 |
| 12.3.1 Iskanje v širino | 250 |
| 12.3.2 Iskanje v globino | 252 |
| 12.4 Diskusija in vaje | 255 |
| 13 Podatkovne strukture za cela števila | 259 |
| 13.1 BinaryTrie: digitalno iskalno drevo | 260 |
| 13.2 XFastTrie: Iskanje v dvojnem logaritmičnem času | 266 |
| 13.3 YFastTrie: Dvokratni-Logaritmični Čas SSet | 269 |
| 13.4 Razprava in vaje | 274 |
| 14 Iskanje v zunanjem pomnilniku | 277 |
| 14.1 Bločna shramba | 279 |
| 14.2 B-drevesa | 279 |
| 14.2.1 Iskanje | 282 |
| 14.2.2 Dodajanje | 284 |
| 14.2.3 Odstranjevanje | 289 |
| 14.2.4 Amortizirana analiza B-Dreves | 295 |
| 14.3 Razprave in vaje | 298 |

Poglavje 1

Uvod

Vsak računalniški predmet na svetu vključuje snov o podatkovnih strukturah in algoritmih. Podatkovne strukture so *tako* pomembne; izboljšajo kvaliteto našega življenja in celo vsakodnevno rešujejo življenja. Veliko multimilijonskih in nekaj multimilijardnih družb je bilo ustanovljenih na osnovi podatkovnih struktur.

Kako je to možno? Če dobro pomislimo ugotovimo, da se s podatkovnimi strukturami srečujemo povsod.

- Odpiranje datoteke: podatkovne strukture datotečnega sistema se uporabljajo za iskanje delov datoteke na disku, kar ni preprosto. Diski vsebujejo stotine milijonov blokov, vsebina datoteke pa je lahko spravljena v kateremkoli od njih.
- Imenik na telefonu: podatkovna struktura se uporabi za iskanje telefonske številke v imeniku, glede na delno informacijo še preden končamo z vnosom iskalnega pojma. Naš imenik lahko vsebuje ogromno informacij - vsi, ki smo jih kadarkoli kontaktirali prek telefona ali elektronske pošte - telefon pa nima zelo hitrega procesorja ali veliko pomnilnika.
- Vpis v socialno omrežje: omrežni strežniki uporabljajo naše vpisne podatke za vpogled v naš račun. Največja socialna omrežja imajo stotine milijonov aktivnih uporabnikov.
- Spletno iskanje: iskalniki uporabljajo podatkovne strukture za iskanje spletnih strani, ki vsebujejo naše iskalne pojme. V internetu

je več kot 8.5 milijard spletnih strani, kjer vsaka vsebuje veliko potencialnih iskalnih pojmov, zato iskanje ni preprosto.

- Številke za klice v sili (112, 113): omrežje za storitve klicev v sili poišče našo telefonsko številko v podatkovni strukturi, da lahko gasilna, reševalna in policijska vozila pošlje na kraj nesreče brez zamud. To je pomembno, saj oseba, ki kliče mogoče ni zmožna zagotoviti pravilnega naslova in zamuda lahko pomeni razliko med življenjem in smrtjo.

1.1 Zahteva po učinkovitosti

V tem poglavju bomo pogledali operacije najbolj pogosto uporabljenih podatkovnih struktur. Vsak z vsaj malo programerskega znanja bo videl, da so te operacije lahke za implementacijo. Podatke lahko shranimo v polje ali povezan seznam, vsaka operacija pa je lahko implementirana s sprehodom čez polje ali povezan seznam in morebitnim dodajanjem ali brisanjem elementa.

Takšna implementacija je preprosta vendar ni učinkovita. Ali je to sploh pomembno? Računalniki postajajo vse hitrejši, zato je mogoče takšna implementacija dovolj dobra. Za odgovor naredimo nekaj izračunov.

Število operacij: predstavljajte si program z zmerno velikim naborom podatkov, recimo enim milijonom (10^6) elementov. V večini programov je logično sklepati, da bo program pregledal vsak element vsaj enkrat. To pomeni, da lahko pričakujemo vsaj milijon (10^6) iskanj. Če vsako od teh 10^6 iskanj pregleda vsakega od 10^6 elementov je to skupaj $10^6 \times 10^6 = 10^{12}$ (tisoč milijard) iskanj.

Procesorske hitrosti: v času pisanja celo zelo hiter namizni računalnik ne more opraviti več kot milijardo (10^9) operacij na sekundo.¹ To pomeni, da bo ta program porabil najmanj $10^{12}/10^9 = 1000$ sekund ali na grobo 16 minut in 40 sekund. Šestnajst minut je v računalniškem času

¹Računalniške hitrosti se merijo v nekaj gigaherzih (milijarda ciklov na sekundo), kjer vsaka operacija zahteva nekaj ciklov.

ogromno, človeku pa bo to pomenilo veliko manj (sploh če si vzame odmor).

Večji nabori podatkov: predstavljajte si podjetje kot je Google, ki upravlja z več kot 8.5 milijard spletnimi stranmi. Po naših izračunih bi kakršnakoli poizvedba med temi podatki trajala najmanj 8.5 sekund. Vendar vemo, da ni tako. Spletna iskanja se izvedejo veliko hitreje kot v 8.5 sekundah, hkrati pa opravljajo veliko zahtevnejše poizvedbe kot samo iskanje ali je določena stran na seznamu ali ne. V času našega pisanja Google prejme najmanj 4,500 poizvedb na sekundo kar pomeni, da bi zahtevalo najmanj $4,500 \times 8.5 = 38,250$ zelo hitrih strežnikov samo za vzdrževanje.

Rešitev: ti primeri nam povedo, da preproste implementacije podatkovnih struktur ne delujejo ko sta tako število elementov, n , v podatkovni strukturi kot tudi število operacij, m , opravljenih na podatkovni strukturi, velika. V takih primerih je čas (merjen v korakih) na grobo $n \times m$.

Rešitev je premišljena organizacija podatkov v podatkovni strukturi tako, da vsaka operacija ne zahteva poizvedbe po vsakem elementu. Čeprav se sliši nemogoče bomo spoznali podatkovne strukture, kjer iskanje zahteva primerjavo samo dveh elementov v povprečju, neodvisno od števila elementov v podatkovni strukturi. V našem računalniku, ki opravi milijardo operacij na sekundo, zahteva iskanje v podatkovni strukturi, ki vsebuje milijardo elementov (ali več milijard), samo 0.000000002 sekund.

Pogledali bomo tudi implementacije podatkovnih struktur, ki hranijo elemente v vrstnem redu, kjer število poizvedenih elementov med operacijo raste zelo počasi v odvisnosti od števila elementov v podatkovni strukturi. Na primer, lahko vzdržujemo sortiran niz milijarde elementov, med poizvedbo do največ 60 elementov med katerokoli operacijo. V našem računalniku, ki opravi milijardo operacij na sekundo, zahteva izvajanje vsake izmed njih samo 0.00000006 sekund.

Preostanek tega poglavja vsebuje kratek pregled osnovnih pojmov, uporabljenih skozi celotno knjigo. ?? opisuje vmesnike, ki so implementirani z vsemi podatkovnimi strukturami opisanimi v tej knjigi in je smatran kot obvezno branje. Ostala poglavja so:

- pregled matematičnega dela, ki vključuje eksponente, logaritme, fa-

kultete, asimptotično (veliki O) notacijo, verjetnost in naključnost;

- računski model;
- pravilnost, časovna zahtevnost in prostorska zahtevnost;
- pregled ostalih poglavij;
- vzorčne kode in navodila za pisanje.

Bralec z ali brez podlage na tem področju lahko poglavja za zdaj enostavno preskoči in se vrne pozneje, če bo potrebno.

1.2 Vmesniki


Pri razpravi o podatkovnih strukturah je pomembno poznati razliko med vmesnikom podatkovne strukture in njegovo implementacijo. Vmesnik opisuje kaj podatkovna struktura počne, medtem ko implementacija opisuje kako to počne.

Vmesnik, včasih imenovan tudi *abstrakten podatkovni tip*, definira množico operacij, ki so podprte s strani podatkovne strukture in semantiko oziroma pomenom teh operacij. Vmesnik nam ne pove nič o tem, kako podatkovna struktura implementira te operacije. Pove nam samo, katere operacije so podprte, vključno s specifikacijami o vrstah argumentov, ki jih vsaka operacija sprejme in vrednostmi, ki jih operacije vračajo.


Implementacija podatkovne strukture, po drugi strani, vsebuje notranjo predstavitev podatkovne strukture, vključno z definicijami algoritmov, ki implementirajo operacije, podprte s strani podatkovne strukture. Zato imamo lahko veliko implementacij enega samega vmesnika. Na primer v 2 bomo videli implementacije vmesnika [seznama](#) z uporabo polj in v 3 bomo videli implementacije vmesnikov [seznama](#) z uporabo podatkovnih struktur, katere uporabljajo kazalce. Obe implementirajo isti vmesnik, [seznam](#), vendar na drugačen način.

1.2.1 Vmesniki Queue, Stack, in Deque

Vmesnik Queue predstavlja zbirko elementov med katere lahko dodamo ali izbrišemo naslednji element. Bolj natančno, operacije podprte z vme-



Slika 1.1: FIFO vrsta.




Slika 1.2: Vrsta s prednostjo.

snikom `queue` so

- `add(x)`: dodaj vrednost `x` vrsti
- `remove()`: izbriši naslednjo (prej dodano) vrednost, `y`, iz vrste in vrni `y`

Opazimo lahko da metoda `remove()` ne sprejme nobenega argumenta. Implementacija vrste odloča kateri element bo izbrisan iz vrste. Poznamo veliko implementacij vrste, najbolj pogoste pa so FIFO, LIFO in vrste s prednostjo. *FIFO (first-in-first-out) vrsta*, ki je narisana v 1.1, odstrani elemente v enakem vrstnem redu kot so bili dodani, enako kot vrsta deluje, ko stojimo v vrsti za na blagajno v trgovini. To je najbolj pogosta implementacija vrste, zato je kvalifikant FIFO pogosto izpuščen. V drugih besedilih se `add(x)` in `remove()` operacije na vrsti FIFO pogosto imenujejo `enqueue(x)` oziroma `dequeue(x)`

Vrste s prednostjo, prikazane na 1.2, vedno odstranijo najmanjši element iz vrste. To je podobno sistemu sprejema bolnikov v bolnicah. Ob prihodu zdravniki ocenijo poškodbo/bolezen bolnika in ga napotijo v čakalno sobo. Ko je zdravnik na voljo, prvo zdravi bolnika z najbolj smrtno nevarno poškodbo/bolezniijo. V drugih besedilih je `remove()` operacija na vrsti s prednostjo ponavadi imenovana `deleteMin()`.



Slika 1.3: sklad.


Zelo pogosta implementacija vrste je LIFO (last-in-first-out) prikazana na 1.3. Na *LIFO vrsti* je izbrisan nazadnje dodan element. To je najbolj prikazano s kupom krožnikov. Krožniki so postavljeni na vrh kupa, prav tako so odstranjeni iz vrha kupa. Ta struktura je tako pogosta, da je dobila svoje ime: *sklad*. Pogosto ko govorimo o *skladu*, so imena `add(x)` in `remove()` spremenjena v `push(x)` in `pop()`. S tem se izognemo zamenjavi implementacij vrst LIFO in FIFO.

Deque je generalizacija FIFO *vrste* in LIFO *vrste* (*sklad*). Deque predstavlja sekvenco elementov z začetkom in koncem. Elementi so lahko dodani na začetek ali pa na konec. Imena *deque* so samoumevna: `addFirst(x)`, `removeFirst()`, `addLast(x)` in `removeLast()`. Sklad je lahko implementiran samo z uporabo `addFirst(x)` in `removeFirst()`, medtem ko FIFO *vrsta* je lahko implementirana z uporabo `addLast(x)` in `removeFirst()`.

1.2.2 Vmesnik *seznama*: linearne sekvence

Ta knjiga govori zelo malo o FIFO *vrsti*, *skladu* ali *deque* vmesnikih, ker so vmesniki vključeni z vmesnikom *seznama*. Vmesnik *seznama* vključuje naslednje operacije:

1. `size()`: vrne n , dolžino seznama
2. `get(i)`: vrne vrednost x_i
3. `set(i, x)`: nastavi vrednost x_i na x
4. `add(i, x)`: doda x na mesto i , izrine x_i, \dots, x_{n-1} ;
Nastavi $x_{j+1} = x_j$, za vse $j \in \{n-1, \dots, i\}$, poveča n , in nastavi $x_i = x$



Slika 1.4: Seznam predstavlja sekvenco indeksov $0, 1, 2, \dots, n-1$. V tem seznamu, bi klic `get(2)` vrnil vrednost `c`.

5. `remove(i)`: izbriše vrednost x_i , izrine x_{i+1}, \dots, x_{n-1} ;
Nastavi $x_j = x_{j+1}$, za vse $j \in \{i, \dots, n-2\}$ in zniža n

Opazimo lahko da te operacije enostavno lahko implementirajo `deque` vmesnik:

```

addFirst(x)  ⇒  add(0, x)
removeFirst() ⇒  remove(0)
addLast(x)   ⇒  add(size(), x)
removeLast() ⇒  remove(size() - 1)

```

Čeprav ne bomo razpravljali o vmesnikih `sklada`, `deque` in FIFO `vrste` v podpoglavjih, sta izraza `sklad` in `deque` včasih uporabljena kot imeni podatkovnih struktur, ki implementirajo vmesnik `seznama`. V tem primeru želimo poudariti, da lahko te podatkovne strukture uporabimo za implementacijo vmesnika `sklada` in `deque` zelo učinkovito. Na primer, `ArrayDeque` razred je implementacija vmesnika `seznama`, ki implementira vse `deque` operacije v konstantnem času na operacijo.

1.2.3 Vmesnik `USet`: Neurejena množica

`USet` vmesnik predstavlja neurejen set edinstvenih elementov, ki posnemajo matematični *set*. `USet` vsebuje n različnih elementov; noben element se ne pojavi več kot enkrat; elementi niso v nobenem določenem zaporedju. `USet` podpira naslednje operacije:

1. `size()`: vrne število, n , elementov v setu
2. `add(x)`: doda element x v set, če ta že ni prisoten;
Dodaj x setu, če ne obstaja tak element y v setu, da velja da je x enak y . Vrni `true`, če je bil x dodan v set, drugače `false`.

3. `remove(x)`: odstrani `x` iz seta;
Najdi element `y` v setu, da velja da je `x` enak `y` in odstrani `y`. Vrni `y` ali `null`, če tak element ne obstaja.
4. `find(x)`: najde `x` v setu, če obstaja;
Najdi element `y` v setu, da velja da je `y` enak `x`. Vrni `y` ali `null`, če tak element ne obstaja.

Te definicije se razlikujejo za razpoznavni element `x`, element, ki ga bomo odstranili ali našli, od elementa `y`, element, ki ga bomo verjetno odstranili ali našli. To je zato, ker sta `x` in `y` lahko različna objekta, ki sta lahko tretirana kot enaka.² Tako razlikovanje je uporabno, ker dovoljuje kreiranje *imenikov* ali *map*, ki preslika ključe v vrednosti.

Da naredimo imenik, eden tvori skupino objektov imenovanih *pari*, kateri vsebujejo *ključ* in a *vrednost*. Dva *para* sta si enakovredna, če so njuni ključi enaki. Če spravimo nek par (k, v) v `USet` in kasneje kličemo `find(x)` metodo z uporabo para $x = (k, null)$ bi rezultat bil $y = (k, v)$. Z drugimi besedami povedano, možno je dobiti vrednost `v`, če podamo samo ključ `k`.

1.2.4 Vmesnik SSet: Urejena množica

Vmesnik `SSet` predstavlja urejen set elementov. `SSet` hrani elemente v nekem zaporedju, tako da sta lahko katera koli elementa `x` in `y` primerjana med sabo. V primeru bo to storjeno z metodo imenovano `compare(x, y)` v kateri

$$\text{compare}(x, y) \begin{cases} < 0 & \text{if } x < y \\ > 0 & \text{if } x > y \\ = 0 & \text{if } x = y \end{cases}$$

`SSet` podpira `size()`, `add(x)` in `remove(x)` metode z točno enako semantiko kot vmesnik `USet`. Razlika med `USet` in `SSet` je v metodi `find(x)`:

4. `find(x)`: locira `x` v urejenem setu;
Najde najmanjši element `y` v setu, da velja $y \geq x$. Vrne `y` ali `null` če tak element ne obstaja.

²V Javi je to storjeno z prepisom razredovih `equals(y)` in `hashCode()` metod

Taka verzija metode `find(x)` je imenovana *iskanje naslednika*. Temeljno se razlikuje od `USet.find(x)`, saj vrne smislen rezultat, tudi če v setu ni elementa, ki je enak `x`.

Razlika med `USet` in `SSet` `find(x)` operacijo je zelo pomembna in velikokrat prezrta. Dodatna funkcionalnost priskrbljena s strani `SSet` ponavadi pride s ceno, da metoda porabi več časa za iskanje in večjo kompleksnost kode. Na primer, večina implementacij `SSet` omenjenih v tej knjigi imajo `find(x)` operacije, ki potrebujejo logaritmichen čas glede na velikost podatkov. Na drugi strani ima implementacija `USet` kot `Chained-HashTable` v 5 `find(x)` operacijo, ki potrebuje konstanten pričakovani čas. Ko izbiramo katero od teh struktur bomo uporabili, bi vedno morali uporabiti `USet`, razen če je dodatna funkcionalnost, ki jo ponudi `SSet`, nujna.

1.3 Matematično ozdaje

V tem poglavju so opisane nekatere matematične notacije in orodja, ki so uporabljena v knjigi, vključno z logaritmi, veliko- O notacijo in verjetnostno teorijo. Opis ne bo natančen in ni mišljen kot uvod. Vsi bralci, ki mislijo da jim manjka osnovno znanje, si več lahko preberejo in naredijo nekaj nalog iz ustreznih poglavji zelo dobre in zastoj knjige o znanosti iz matematike in računalništva [?].

1.3.1 Eksponenti in Logaritmi

Izraz b^x označuje število b na potenco x . Če je x pozitivno celo število, potem je to samo število b pomnoženo samo s seboj $x - 1$ krat:

$$b^x = \underbrace{b \times b \times \cdots \times b}_x .$$

Ko je x negativno celo število, je $b^x = 1/b^{-x}$. Ko je $x = 0$, $b^x = 1$. Ko b ni celo število, še vedno lahko definiramo potenciranje v smislu eksponentne funkcije e^x (glej spodaj), ki je definirana v smislu eksponentne serije, vendar jo je najboljšje prepustiti računskemu besedilu.

V tej knjigi se izraz $\log_b k$ označuje *logaritem z osnovo- b* od k . To je edinstvena vrednost x za katero velja

$$b^x = k \ .$$

Večina logaritmov v tej knjigi ima osnovo 2 (*binarni logaritmi*).

Za te logaritme izpustimo osnovo, tako je $\log k$ skrajšan izraz za $\log_2 k$.

Neformalen ampak uporaben način je, da mislimo na $\log_b k$ kot število, koliko krat moramo deliti k z b , preden bo rezultat manjši ali enak 1. Na primer, ko izvedemo binarno iskanje, vsaka primerjava zmanjša število možnih odgovorov za faktor 2. To se ponavlja, dokler nam ne preostane samo en možen odgovor. Zato je število primerjav pri binarnem iskanju nad največ $n + 1$ podatki enako največ $\lceil \log_2(n + 1) \rceil$.

V knjigi se večkrat pojavi tudi *naravni logaritem*. Pri naravnem logaritmu uporabimo notacijo $\ln k$, ki označuje $\log_e k$, kjer je e — *Eulerjeva konstanta* — podan na naslednji način:

$$e = \lim_{n \rightarrow \infty} \left(1 + \frac{1}{n}\right)^n \approx 2.71828 \ .$$

Naravni logaritem pride v poštev pogosto, ker je vrednost zelo pogostega integrala:

$$\int_1^k 1/x \, dx = \ln k \ .$$

Dve najbolj pogosti operaciji, ki jih naredimo nad logaritmi sta, da jih umaknemo iz eksponenta:

$$b^{\log_b k} = k$$

in zamenjamo osnovo logaritma:

$$\log_b k = \frac{\log_a k}{\log_a b} \ .$$

Na primer, te dve operaciji lahko uporabimo za primerjavo naravnih in binarnih logaritmov.

$$\ln k = \frac{\log k}{\log e} = \frac{\log k}{(\ln e)/(\ln 2)} = (\ln 2)(\log k) \approx 0.693147 \log k \ .$$

1.3.2 Fakulteta

V enem ali dveh delih knjige je uporabljena *fakulteta*. Za nenegativna cela števila n je uporabljena notacija $n!$ (izgovorjena kot “ n fakulteta”) in pomeni naslednje:

$$n! = 1 \cdot 2 \cdot 3 \cdots n .$$

Fakulteta se pojavi, ker je $n!$ število različnih permutacij, naprimer zaporedja n različnih elementov.

Za poseben primer $n = 0$, je $0!$ definiran kot 1.

Vrednost $n!$ je lahko približno določena z uporabo *Stirlingovega približka*:

$$n! = \sqrt{2\pi n} \left(\frac{n}{e}\right)^n e^{\alpha(n)} ,$$

kjer je

$$\frac{1}{12n+1} < \alpha(n) < \frac{1}{12n} .$$

Stirlingov približek prav tako približno določa $\ln(n!)$:

$$\ln(n!) = n \ln n - n + \frac{1}{2} \ln(2\pi n) + \alpha(n)$$

(V bistvu je Stirlingov približek najlažje dokazan z približevanjem $\ln(n!) = \ln 1 + \ln 2 + \cdots + \ln n$ z integralom $\int_1^n \ln n \, dn = n \ln n - n + 1$.)

V relaciji s fakultetami so *binomski koeficienti*. Za nenegativna cela števila n in cela števila $k \in \{0, \dots, n\}$, notacija $\binom{n}{k}$ označuje:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} .$$

Binomski koeficient $\binom{n}{k}$ (izgovorjeno kot “ n izbire k ”) šteje, koliko podmnožic elementa n ima velikost k , npr. število različnih možnosti pri izbiranju k različnih celih števil iz seta $\{1, \dots, n\}$.

1.3.3 Asimptotična Notacija

Ko v knjigi analiziramo podatkovne strukture, želimo govoriti o časovnem poteku različnih operacij. Točen čas se bo seveda razlikoval od računalnika

do računalnika, pa tudi od izvedbe do izvedbe na določenem računalniku. Ko govorimo o časovni zahtevnosti operacije, se nanašamo na število inštrukcij opravljenih za določeno operacijo. Tudi za enostavno kodo je lahko to število težko za natančno določiti. Zato bomo namesto analiziranja natančnega časovnega poteka uporabljali tako imenovano *veliko-O notacijo*: Za funkcijo $f(n)$, $O(f(n))$ določi set funkcij

$$O(f(n)) = \left\{ g(n) : \text{obstaja tak } c > 0, \text{ in } n_0 \text{ da velja } \begin{array}{l} g(n) \leq c \cdot f(n) \text{ za vse } n \geq n_0 \end{array} \right\} .$$

Grafično mišljeno ta set sestavljajo funkcije $g(n)$, kjer $c \cdot f(n)$ začne prevladovati nad $g(n)$ ko je n dovolj velik.

Po navadi uporabimo asimptotično notacijo za poenostavitev funkcij. Npr. na mesto $5n \log n + 8n - 200$ lahko zapišemo $O(n \log n)$. To je dokazano na naslednji način:

$$\begin{aligned} 5n \log n + 8n - 200 &\leq 5n \log n + 8n \\ &\leq 5n \log n + 8n \log n \quad \text{za } n \geq 2 \text{ (zato da } \log n \geq 1) \\ &\leq 13n \log n . \end{aligned}$$

To dokazuje da je funkcija $f(n) = 5n \log n + 8n - 200$ v množici $O(n \log n)$ z uporabo konstant $c = 13$ in $n_0 = 2$.

Pri uporabi asimptotične notacije poznamo veliko bližnjic. Prva:

$$O(n^{c_1}) \subset O(n^{c_2}) ,$$

za vsak $c_1 < c_2$. Druga: Za katerokoli konstanto $a, b, c > 0$,

$$O(a) \subset O(\log n) \subset O(n^b) \subset O(c^n) .$$

Te relacije so lahko pomnožene s katerokoli pozitivno vrednostjo, brez da bi se spremenile. Npr. če pomnožimo z n , dobimo:

$$O(n) \subset O(n \log n) \subset O(n^{1+b}) \subset O(nc^n) .$$

Z nadaljevanjem dolge in ugledne tradicije bomo zapisali $f_1(n) = O(f(n))$, medtem ko želimo izraziti $f_1(n) \in O(f(n))$. Uporabili bomo tudi izjave kot so "časovna zahtevnost te operacije je $O(f(n))$ ", vendar pa bi izjava morala biti napisana "časovna zahtevnost te operacije je *element* $O(f(n))$." Te

krajšnjice se uporabljajo zgolj za to, da se izognemo nerodnemu jeziku in da lažje uporabimo asimptotično notacijo v besedilu enačb. Nenavaden primer tega se pojavi, ko napišemo izjavo:

$$T(n) = 2 \log n + O(1) .$$

Bolj pravilno napisano kot

$$T(n) \leq 2 \log n + [\text{član } O(1)] .$$

Izraz $O(1)$ predstavi nov problem. Ker v tem izrazu ni nobene spremenljivke, ni čisto jasno katera spremenljivka se samovoljno povečuje. Brez konteksta ne moremo vedeti. V zgornjem primeru, kjer je edina spremenljivka n , lahko predpostavimo, da bi se izraz moral prebrati kot $T(n) = 2 \log n + O(f(n))$, kjer $f(n) = 1$.

Velika-O notacija ni nova ali edinstvena v računalniški znanosti. Že leta 1894 jo je uporabljal številčni teoretik Paul Bachmann, saj je bila neizmerno uporabna za opis časovne zahtevnosti računalniških algoritmov.

Če upoštevamo naslednji del kode:

Simple

```
void snippet() {  
    for (int i = 0; i < n; i++)  
        a[i] = i;  
}
```

Ena izvedba te metode vključuje

- 1 dodelitev (`int i = 0`),
- $n + 1$ primerjav (`i < n`),
- n povečav (`i++`),
- n izračun odmikov v polju (`a[i]`),
- n posrednih dodelitev (`a[i] = i`).

Zato lahko napišemo časovno zahtevnost kot

$$T(n) = a + b(n + 1) + cn + dn + en ,$$

kjer so a , b , c , d , in e konstante, ki so odvisne od naprave, ki izvaja kodo in predstavlja čas, v katerem se zaporedno izvedejo dodelitve, primerjave, povečevalne operacije, izračuni odmikov v poljih in posredne dodelitve. Če pa izraz predstavlja časovno zahtevnost dveh vrstic kode, potem se taka analiza ne more ujemati z zapleteno kodo ali algoritmi. Časovno zahtevnost lahko poenostavimo z uporabo velike-O notacije, tako dobimo

$$T(n) = O(n) .$$

Tak zapis je veliko bolj kompakten in nam hkrati da veliko informacij. To, da je časovna zahtevnost v zgornjem primeru odvisna od konstante a , b , c , d , in e , pomeni, da v splošnem ne bo mogoče primerjati dveh časov izvedbe, da bi razločili kateri je hitrejši, brez da bi vedeli vrednosti konstant. Tudi če uspemo določiti te konstante (npr. z časovnimi testi), bi naša ugotovitev veljala samo za napravo na kateri smo izvajali teste.

Velika-O notacija daje smisel analiziranju zapletenih funkcij pri višjih stopnjah. Če imata dva algoritma enako veliko-O časovno izvedbo, potem ne moremo točno vedeti, kateri je hitrejši in ni očitnega zmagovalca. En algoritem je lahko hitrejši na eni napravi, drugi pa na drugi napravi. Če imata dva algoritma dokazljivo različno veliko-O časovni izvedbi, potem smo lahko prepričani, da bo algoritem z manjšo časovno zahtevnostjo hitrejši *pri dovolj velikih vrednostih n* .

Kako lahko primerjamo veliko-O notacijo dveh različnih funkcij prikazuje 1.5, ki primerja stopnjo rasti $f_1(n) = 15n$ proti $f_2(n) = 2n \log n$. Npr., da je $f_1(n)$ časovna zahtevnost zapletenega linearnega časovnega algoritma in je $f_2(n)$ časovna zahtevnost bistveno preprostejšega algoritma, ki temelji na vzorcu deli in vladaj. Iz tega je razvidno, da čeprav je $f_1(n)$ večji od $f_2(n)$ pri manjših vrednostih n , velja nasprotno za velike vrednosti n . Po določenem času bo $f_1(n)$ zmagal zaradi stalne povečave širine marže. Analize, ki uporabljajo veliko-O notacijo, kažejo da se bo to zgodilo, ker je $O(n) \subset O(n \log n)$.

V nekaterih primerih bomo uporabili asimptotično notacijo na funkcijah z več kot eno spremenljivko. Predpisan ni noben standard, ampak za naš namen je naslednja definicija zadovoljiva:

$$O(f(n_1, \dots, n_k)) = \left\{ \begin{array}{l} g(n_1, \dots, n_k) : \text{obstaja } c > 0, \text{ in } z \text{ da velja} \\ g(n_1, \dots, n_k) \leq c \cdot f(n_1, \dots, n_k) \\ \text{za vse } n_1, \dots, n_k \text{ da velja } g(n_1, \dots, n_k) \geq z \end{array} \right\} .$$

Ta definicija zajema položaj, ki nas zanima, ko g prevzame višje vrednosti zaradi argumenta n_1, \dots, n_k . Ta definicija se sklada z univarijatno definicijo $O(f(n))$, ko je $f(n)$ naraščujoča funkcija n . Bralci naj bodo pozorni, da je lahko v drugih besedilih uporabljena asimptotična notacija drugače.

1.3.4 Naključnost in verjetnost

Nekatere podatkovne strukture predstavljene v knjigi so *naključne*; odločajo se naključno in neodvisno od podatkov, ki so spravljani v njih in od operacij, ki se izvajajo nad njimi. Zaradi tega, se lahko časi izvajanja razlikujejo med seboj, kljub temu, da uporabimo enako zaporedje operacij nad strukturo. Ko analiziramo podatkovne strukture, nas zanima povprečje oziroma *pričakovani* čas poteka.

Formalno je čas poteka operacije na naključni podatkovni strukturi je naključna spremenljivka, želimo pa preučevati njeno *pričakovano vrednost*.

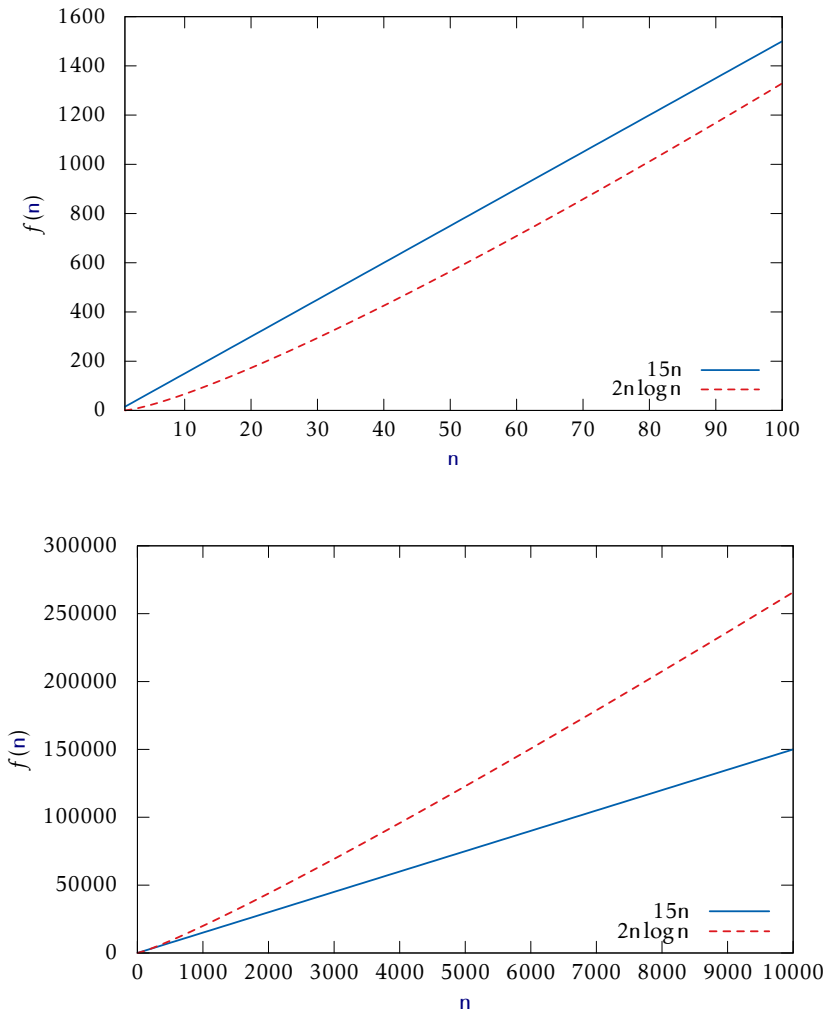
Za diskretno naključno spremenljivko X , ki zavzame vrednosti neke univerzalne množice U , je pričakovana vrednost X označena z $E[X]$ podana z enačbo

$$E[X] = \sum_{x \in U} x \cdot \Pr\{X = x\} .$$

Tukaj $\Pr\{\mathcal{E}\}$ označuje verjetnost, da se pojavi dogodek \mathcal{E} . V vseh primerih v knjigi so te verjetnosti v spoštovanju z naključnimi odločitvami narejenimi s strani podatkovnih struktur. Ne moremo sklepati, da so naključni podatki, ki so shranjeni v strukturi, niti sekvence operacij izvedene na podatkovni strukturi.

Ena pomembnejših lastnosti pričakovane verjetnosti je *linearnost pričakovanja*. Za katerekoli dve naključne spremenljivke X in Y ,

$$E[X + Y] = E[X] + E[Y] .$$



Slika 1.5: Plots of $15n$ versus $2n \log n$.

Bolj splošno, za katerokoli naključno spremenljivko X_1, \dots, X_k ,

$$E\left[\sum_{i=1}^k X_k\right] = \sum_{i=1}^k E[X_i] .$$

Linearnost pričakovanja nam dovoljuje, da razbijemo zapletene naključne spremenljivke (kot leva stran od zgornjih enačb) v vsote enostavnejših naključnih spremenljivk (desna stran).

Uporaben trik, ki ga bomo pogosto uporabljali, je definiranje indikatorja naključnih *spremenljivk*. Te binarne spremenljivke so uporabne, ko želimo nekaj šteti in so najboljše ponazorjene s primerom - vržemo pravičen kovanec k krat in želimo vedeti pričakovano število, koliko krat bo kovanec kazal glavo.

Intuitivno vemo, da je odgovor $k/2$. Če pa želimo to dokazati z definicijo pričakovane vrednosti, dobimo

$$\begin{aligned} E[X] &= \sum_{i=0}^k i \cdot \Pr\{X = i\} \\ &= \sum_{i=0}^k i \cdot \binom{k}{i} / 2^k \\ &= k \cdot \sum_{i=0}^{k-1} \binom{k-1}{i} / 2^k \\ &= k/2 . \end{aligned}$$

To zahteva, da vemo dovolj, da izračunamo, da $\Pr\{X = i\} = \binom{k}{i} / 2^k$ in, da vemo binomske identitete $i \binom{k}{i} = k \binom{k-1}{i}$ in $\sum_{i=0}^k \binom{k}{i} = 2^k$.

Z uporabo indikatorskih spremenljivk in linearnostjo pričakovanja so stvari veliko lažje. Za vsak $i \in \{1, \dots, k\}$ opredelimo indikatorsko naključno spremenljivko.

$$I_i = \begin{cases} 1 & \text{če je } i\text{ti met kovanca glava} \\ 0 & \text{drugače.} \end{cases}$$

Potem

$$E[I_i] = (1/2)1 + (1/2)0 = 1/2 .$$

Sedaj $X = \sum_{i=1}^k I_i$ so

$$\begin{aligned} E[X] &= E\left[\sum_{i=1}^k I_i\right] \\ &= \sum_{i=1}^k E[I_i] \\ &= \sum_{i=1}^k 1/2 \\ &= k/2 . \end{aligned}$$

iiiiiii .mine To je malo bolj zapleteno, vendar za to ne potrebujemo nobenih magičnih identitet ali računanja kakršnih koli ne trivijalnih verjetnosti. Še boljše, strinja se z intuicijo, da pričakujemo polovico kovancev, da pristanejo na glavi točno zato, ker vsak posamezni kovanec pristane na glavi z verjetnostjo 1/2.

1.4 Model računanja

V tej knjigi bomo analizirali teoretično časovno zahtevnost operacij na podatovnih strukturah, ki smo se jih učili. Da bi to natančneje preučili, potrebujemo formalni model računanja. Uporabljali bomo *w-bit besedni-RAM* model. RAM pomeni stroj z naključnim dostopom (Random Access Machine). V tem modelu imamo dostop do naključnega podatkovnega pomnilnika sestavljenega iz *celic*, pri katerih vsaka shranjuje *w*-bitno *besedo*. To pomeni, da lahko vsaka pomnilniška celica predstavlja, npr. vsa števila od $\{0, \dots, 2^w - 1\}$.

V besedni-RAM modelu porabijo osnovne operacije konstanten čas. To so aritmetične operacije (+, −, *, /, %), primerjave (<, >, =, ≤, ≥), in bitwise (vektor bitov) boolean (bitwise - IN, ALI, ekskluzivni ALI.)

V vsako celico lahko pišemo ali beremo v konstantnem času. Računalniški pomnilnik upravlja sistem, preko katerega lahko dodelimo ali ne, pomnilniški blok poljubne velikosti. Dodelitev pomnilniškega bloka velikosti k porabi $O(k)$ časa in vrne referenco (a pointer) do nazadnje dodeljenega pomnilniškega bloka. Ta referenca je dovolj majhna, da je lahko

predstavljena z eno samo besedo (zavzame prostor) v RAM-u.

Velikost besede w je zelo pomemben parameter v tem modelu. Edina predpostavka, ki jo bomo dodelili w -ju je spodnja meja $w \geq \log n$, kjer je n število elementov ki so shranjeni v naši podatkovni strukturi.

Pomnilniški prostor je merjen z besedami, tako, da ko govorimo koliko prostora zavzame podatkovna struktura, se sklicujemo na število besed, ki jih porabi struktura. Vse naše podatkovne strukture shranjujejo generično vrednost tipa T , predvidevamo pa, da element tipa T zasede eno besedo v pomnilniškem prostoru. (V resnici shranjujemo le reference do objekta tipa T in te reference zasedejo samo eno besedo v pomnilniku.)

w -bit besedni-RAM model je približek (32-bitne) JVM (Java Virtual Machine) ko je $w = 32$. Podatkovne strukture, ki so uporabljene v tej knjigi ne uporabljajo nobenih specialnih metod, ki ne bi bile implementirane v JVM in večino drugih arhitektur.

1.5 Pravilnost, časovna in prostorska zahtevnost

Med učenjen uspešnosti podatkovnih struktur so najpomembnejše 3 stvari:

Pravilnost: podatkovna struktura mora pravilno implementirati svoj vmesnik

Časovna zahtevnost: operacijski časi v podatkovni strukturi morajo biti čim manjši

Prostorska zahtevnost: podatkovna struktura mora porabiti čim manj prostora

V tem uvodnem besedilu bomo uporabili pravilnost kot nam je podana; ne bomo predpostavljali, da podatkovne strukture podajajo napačne poizvedbe, ali da ne podajajo pravilnih posodobitev. Videli bomo, da podatkovne strukture stremijo k čim manjši porabi podatkovnega prostora. To ne bo vedno vplivalo na izvedbeni čas operacij, ampak lahko malce upočasnijo podatkovne strukture v praksi.

Med analiziranjem časovne zahtevnosti v kontekstu s podatkovnimi strukturami se nagibamo k 3 različnim možnostim:

Časovna zahtevnost v najslabšem primeru: : je najtrdnjša časovna zahtevnost, saj če imajo operacije v podatkovni strukturi časovno zahtevnost v najslabšem primeru enako $f(n)$, pomeni, da nobena od teh operacij ne bo porabila več kot $f(n)$ časa.

Amortizirana časovna zahtevnost: če predpostavimo, da ima amortizirana časovna zahtevnost operacij v podatkovni strukturi časovno zahtevnost enako $f(n)$, pomeni, da imajo operacije največjo zahtevnost enako $f(n)$. Natančneje pomeni, da če ima podatkovna struktura amortizirano časovno zahtevnost $f(n)$, potem zaporedje m operacij, porabi največ $mf(n)$ časa. Nekatere operacije lahko porabijo tudi več kot $f(n)$ časa, ampak je povprečje celotnega zaporedja operacij največ $f(n)$.

Pričakovana časovna zahtevnost: če predpostavimo, da je pričakovana časovna zahtevnost operacij na podatkovni strukturi enaka $f(n)$, pomeni, da je naključni čas delovanja enak naključni spremenljivki (glej 1.3.4) in pričakovana vrednost naključne spremenljivke je lahko največ $f(n)$. Naključna izbira v tem modelu podpira izbiro, ki jo izbere podatkovna struktura.

Da bi razumeli razliko med temi časovnimi zahtevnostmi, nam najbolj pomaga če si pogledamo primerjavo iz financ, pri nakupu nepremičnine:

Najslabši primer proti amortizirani ceni: Predpostavimo, da je cena nepremičnine \$120 000. Če želimo kupiti nepremičnino vzamemo 120 mesev (10 let) kredit, ki ga odplačujemo po \$1 200 na mesec. V tem primeru je najslabša možnost mesečnega plačila kredita enaka \$1 200 na mesec.

Če pa imamo dovolj denarja, se lahko odločimo za nakup nepremičnine z enkratnim plačilom \$120 000. V tem primeru, v obdobju 10 let, je amortizirana cena pri nakupu nepremičnine enaka:

$$\$120\,000/120 \text{ mesecev} = \$1\,000 \text{ na mesec} .$$

To je pa veliko manj, kot bi plačevali, če bi pri nakupu nepremičnine vzeli kredit.

Najslabši primer proti pričakovani ceni: Sedaj upoštevajmo zavarovanje proti požaru pri naši nepremičnini, ki je vredna \$120 000. Pri proučevanju tisočih primerov so zavarovalnice določile, da je požarna škoda pri taki nepremičnino kot je naša, enaka \$10 na mesec. To je majhna številka, če predpostavimo, da veliko nepremičnin nikoli nima požara, nekatere imajo majhno škodo v primeru požara, najmanjše število pa je tistih, ki pri požaru zgorejo do tal. Upoštevajoč te podatke, zavarovalnice zaračunajo \$15 mesečno za zavarovanje v primeru požara.

Sedaj je pa čas odločitve, ali naj v najslabšem primeru plačujemo \$15 mesečno za zavarovanje v primeru požara, ali pa naj se sami zavarujemo in predpostavimo, da bi v primeru požara znašal \$10 mesečno? Res je, \$10 mesečno je manj kot je pričakovano, ampak moramo pa tudi sprejeti dejstvo, da bo strošek v primeru požara bistveno večji, saj če nepremičnina v primeru požara zgore do tal, bo ta strošek enak \$120 000.

Te finančne primerjave nam prikažejo, zakaj se raje odločimo za amortizirano ali pričakovano časovno zahtevnost, kot časovno zahtevnost v najslabšem primeru. Večkrat je mogoče, da dobimo manjšo aqli amortizirano časovno zahtevnost, kot časovno zahtevnost v najslabšem primeru. Na koncu je pa še velikokrat mogoče, da dobimo preprostejšo podatkovno strukturo, če se odločimo za amortizirano ali pa pričakovano časovno zahtevnost.

1.6 Vzorci kode

Vzorci kode v tej knjigi so napisani v Java .ampak, da bi bila ta knjiga bližje tudi bralcem, ki niso seznanjeni z Javaključnimi besedami so bili izrazi poenostavljeni. Na primer, bralci ne bodo naleteli na ključne besede kot so `public`, `protected`, `private`, or `static`. Bralec tudi ne bo naletel na diskusijo o hierarhiji razredov, razredih in vmesnikih ter podedovanju. Če bo to relevantno za bralca bo jasno razvidno iz teksta.

Ti dogovori bi morali narediti primere razumljive vsem z znanjem algoritemskih jezikov kot so B, C, C++, C#, Objective-C, D, Java, JavaScript, in tako dalje. Bralci, ki želijo vpogled v vse podrobnosti implementacij so dobrodošli, da si pogledajo Java izvirno kodo, ki spremlja knjigo.

Ta knjiga je mešanica matematične analize izvajanja programom v

Java . This means that To pomeni ,da nekatere enačbe vsebujejo spremenljivke, ki jih najdemo v izvorni kodi. Te spremenljivke so povsod uporabljene v istem pomenu, to velja za izvorno kodo kot tudi za enačbe. Na primer, pogosto uporabljena spremenljivka `n` je brez izjeme povsod uporabljena kot število, ki predstavlja število trenutno shranjenih vrednosti v podani podatkovni strukturi.

1.7 Seznam Podatkovnih Struktur

V tabelah 1.1 in 1.2 so povzete učinkovitosti podatkovnih struktur zajetih v tej knjigi, ki implementirajo vsakega od vmesnikov `List`, `USet`, and `SSet`, opisanih v ?? . 1.6 pokaže odvisnosti med različnimi poglavji zajetimi v knjigi. Črtkana puščica kaže le šibko odvisnost znotraj katere je le majhen del poglavja odvisen od prejšnjega poglavja ali samo glavnih rezultatov prejšnjega poglavja.

1.8 Razprava in vaje

Vmesniki `List`, `USet` in `SSet`, ki so opisani v poglavju ?? se kažejo kot vpliv Java Collections Framework [?]

V osnovi gre za poenostavljene vrezije `List`, `Set`, `Map`, `SortedSet` in `SortedMap` vmesnikov, ki jih najdemo v Java Collections Framework. Izvirna koda v slednjem vsebuje enkapsulirane razrede za izdelavo `USet` in `SSet` implementacij v `Set`, `Map`, `SortedSet` in `SortedMap` implementacije.

Za detajlno obravnavo in razumevanje matematične vsebine tega poglavja, ki vsebuje asimptotično notacijo, logaritme, fakulteto, Stirlingovo aproksimacijo, osnove verjetnosti in ostalo, vzemi v roke učbenik Lyman, Leighton in Meyer [?]. Za osnove matematične analize, ki obravnava definicije algoritmov in eksponentnih funkcij, se obrni na (prosto dostopno) besedilo, ki ga je spisal Thompson [?].

Več informacij o osnovah verjetnosti, predvsem področja, ki je tesno povezana z računalništvom, sezi po učbeniku Rossa [?]. Druga priporočljiva referenca, ki pokriva asimptotično notacijo in verjetnost, je učbenik Grahama, Knutha in Patashnika [?].

| List implementacije | | | |
|---------------------|---|---|-------|
| | $\text{get}(\mathbf{i})/\text{set}(\mathbf{i}, \mathbf{x})$ | $\text{add}(\mathbf{i}, \mathbf{x})/\text{remove}(\mathbf{i})$ | |
| ArrayStack | $O(1)$ | $O(1 + \mathbf{n} - \mathbf{i})^{\text{A}}$ | § 2.1 |
| ArrayDeque | $O(1)$ | $O(1 + \min\{\mathbf{i}, \mathbf{n} - \mathbf{i}\})^{\text{A}}$ | § 2.4 |
| DualArrayDeque | $O(1)$ | $O(1 + \min\{\mathbf{i}, \mathbf{n} - \mathbf{i}\})^{\text{A}}$ | § 2.5 |
| RootishArrayStack | $O(1)$ | $O(1 + \mathbf{n} - \mathbf{i})^{\text{A}}$ | § 2.6 |
| DLList | $O(1 + \min\{\mathbf{i}, \mathbf{n} - \mathbf{i}\})$ | $O(1 + \min\{\mathbf{i}, \mathbf{n} - \mathbf{i}\})$ | § 3.2 |
| SEList | $O(1 + \min\{\mathbf{i}, \mathbf{n} - \mathbf{i}\}/\mathbf{b})$ | $O(\mathbf{b} + \min\{\mathbf{i}, \mathbf{n} - \mathbf{i}\}/\mathbf{b})^{\text{A}}$ | § 3.3 |
| SkiplistList | $O(\log \mathbf{n})^{\text{E}}$ | $O(\log \mathbf{n})^{\text{E}}$ | § 4.3 |

| USet implementacije | | | |
|---------------------|---------------------------|--|-------|
| | $\text{find}(\mathbf{x})$ | $\text{add}(\mathbf{x})/\text{remove}(\mathbf{x})$ | |
| ChainedHashTable | $O(1)^{\text{E}}$ | $O(1)^{\text{A}, \text{E}}$ | § 5.1 |
| LinearHashTable | $O(1)^{\text{E}}$ | $O(1)^{\text{A}, \text{E}}$ | § 5.2 |

^A Označuje *amortizacijski* čas izvajanja.

^E Označuje *pričakovani* čas izvajanja.

Tabela 1.1: Povzetek implementacij List in USet.


| SSet implementacije | | | |
|-------------------------|-------------------|----------------------------------|--------|
| | $\text{find}(x)$ | $\text{add}(x)/\text{remove}(x)$ | |
| SkiplistSSet | $O(\log n)^E$ | $O(\log n)^E$ | § 4.2 |
| Treap | $O(\log n)^E$ | $O(\log n)^E$ | § 7.2 |
| ScapegoatTree | $O(\log n)$ | $O(\log n)^A$ | § ?? |
| RedBlackTree | $O(\log n)$ | $O(\log n)$ | § 9.2 |
| BinaryTrie ^I | $O(w)$ | $O(w)$ | § 13.1 |
| XFastTrie ^I | $O(\log w)^{A,E}$ | $O(w)^{A,E}$ | § 13.2 |
| YFastTrie ^I | $O(\log w)^{A,E}$ | $O(\log w)^{A,E}$ | § 13.3 |
| BTree | $O(\log n)$ | $O(B + \log n)^A$ | § ?? |
| BTree ^X | $O(\log_B n)$ | $O(\log_B n)$ | § ?? |

| (Priority) Queue implementations | | | |
|----------------------------------|--------------------|---------------------------------|--------|
| | $\text{findMin}()$ | $\text{add}(x)/\text{remove}()$ | |
| BinaryHeap | $O(1)$ | $O(\log n)^A$ | § 10.1 |
| MeldableHeap | $O(1)$ | $O(\log n)^E$ | § ?? |

^I Ta struktura lahko shrani le w -bitne celoštevilске podatke.

^X Označuje čas delovanja v znanje-pomnilniškem modelu; glej 14.

Tabela 1.2: Povzetek implementacij SSet in priority Queue.



Slika 1.6: Odvisnosti med poglavji v tej knjigi.

Za tiste, ki želite še posebej izpiliti znanje programiranja v Javi, najdete primere vaj na spletu [?].

Naloga 1.1. Naloga je sestavljena tako, da bralca seznani s pravilnim izbiranjem najbolj ustrezne podatkovne strukture za dani primer. Če je del naloge že implementiran, potem je mišljeno, da se naloga reši s smiselno uporabo danega vmesnika (Stack, Queue, Deque, Uset ali SSet), ki ga priskrbi Java Collections Framework.

Problem reši tako, da nad vsako vrstico prebrane tekstovne datoteke izvrši operacijo in pri tem uporabiš najbolj primerno podatkovno strukturo. Implementacija programa mora biti dovolj hitra, da obdela datoteko z milijon vnosi v nekaj sekundah.

1. Preberi vhod vrstico po vrstico in izpiši vrstice v obratnem vrstnem redu tako, da bo zadnji vnos izpisan prvi, predzadnji drugi in tako naprej.
2. Preberi prvih 50 vrstic vhoda in jih nato izpiši v obratnem vrstnem redu. Nato preberi naslednjih 50 vrstic in jih ponovno vrni v obratnem vrstnem redu. Slednje ponavljaj, dokler ne zmanjka vrstic vhoda. Ko program pride do točke, da je na vhodu manj kot 50 vrstic, naj vse preostale izpiše v obratnem vrstnem redu.

Z drugimi besedami povedano, izhod se bo začel z ispisom 50. vrstice, nato 49. , za to 48. in vse tako do prve vrstice. Prvi vrstici bo sledila 100. vrstica vhoda, njej 99. in vse tako do 51. vrstice ter tako naprej.

Tekom izvajanja naj program v pomnilniku ne hrani več kot 50 vrstic naenkrat.

3. Beri vhod vrstico po vrstico. Program bere po 42 vrstic in če je katera od teh prazna (npr. niz dolžine nič), potem izpiše 42. vrstico pred to, ki je prazna. Na primer, če je 242. prazna, potem naj program izpiše 200. vrstico. Program naj bo implementiran tako, da v danem trenutku ne shranjuje več kot 43 vrstic vhoda naenkrat.
4. Beri vhod vrstico po vrstico in na izhod izpiši le tiste, ki so se na vhodu pojavile prvič. Bodi posebno pozoren na to, da datoteka,

četudi ima veliko podvojenih vrstic, ne porabi več pomnilnika, kot je zahtevano za zapis unikatnih vrstic.

5. Beri vhod vrstico po vrstico in izpiši vse vrstice, ki so se vsaj enkrat že pojavile na vhodu (cilj je, da se izločijo unikatne vrstice vhoda). Bodi posebno pozoren na to, da datoteka, četudi ima veliko podvojenih vrstic, ne porabi več pomnilnika, kot je zahtevano za zapis unikatnih vrstic.
6. Preberi celoten vnos vrstico za vrstico in izpiši vse vrstice, razvrščene po velikosti, začenši z najkrajšo. Če sta dve vrstici enake dolžine, naj ju sortira “sorted order.” Podvojene vrstice naj bodo izpisane samo enkrat.
7. Naredi enako kot pri prejšnji nalogi, le da so tokrat podvojene vrstice izpisane tolikokrat kolikor krat so bile vnesene.
8. Preberi celoten vnos vrstico za vrstico in izpiši najprej sode vrstice, začenši s prvo, vrstico 0, katerim naj sledijo lihe vrstice.
9. Preberi celoten vnos vrstico za vrstico, jih naključno premešaj in izpiši. Torej, ne sme se spremeniti vsebina vrstice, le njihov vrstni red naj se zamenja.

Naloga 1.2. *Dyck word* je sekvenca $+1$ in -1 z lastnostjo, da vsota katerekoli prepone zaporedja ni negativna. Na primer, $+1, -1, +1, -1$ je Dyck word, med tem ko $+1, -1, -1, +1$ ni Dyck word ker je predpona $+1 - 1 - 1 < 0$. Opiši katerokoli relacijo med `Sklad push(x)` in `pop()` operacijo.

Naloga 1.3. *Matched string* je zaporedje `{`, `}`, `(`, `)`, `[`, `]` znakov, ki se ustrezno ujemajo. Na primer, `{{(())}}` je matched string, medtem ko `{{(())}` ni, saj se drugi `{` ujema z `]`. Pokaži kako uporabiti sklad, da za niz dolžine n , ugotoviš v $O(n)$ časa ali je matched string ali ne.

Naloga 1.4. Predpostavimo, da imamo `Sklad s`, ki podpira samo operaciji `push(x)` in `pop()`. Pokaži kako lahko samo z uporabo FIFO vrste, `q`, obrnemo vrstni red vseh elementov v `s`.

Naloga 1.5. Z uporabo `USet`, implementiraj `Bag`. `Bag` je podoben `USet`—podpira metode `add(x)`, `remove(x)` in `find(x)`—ampak dovoljuje hrambo

dvojnih elementov. `Find(x)` operacija v `Bag` vrne nekatere (če sploh kateri) element, ki je enak `x`. Poleg tega `Bag` podpira operacijo `findAll(x)`, ki vrne seznam vseh elementov, ki so enaki `x`.

Naloga 1.6. Iz samega začetka implementiraj in testiraj implementacijo vmesnikov `List`, `USet` in `SSet`, za katere ni nujno, da so učinkovite. Lahko so uporabljene za testiranje pravilnosti in zmogljivosti bolj učinkovitih implementacij. (Najlažji način za doseg tega je, da se shrani vse elemente v polje)

Naloga 1.7. Izboljšaj zmogljivost implementacije prejšnjega vprašanja z uporabo kateregakoli trika, ki ti pade na pamet. Eksperimentiraj in razmisli o tem, kako bi lahko izboljšal zmogljivost implementacij `add(i, x)` in `remove(i)` v svoji implementaciji vmesnika `List`. Razmisli, kako bi se dalo izboljšati zmogljivost operacije `find(x)` tvoje implementacije `USet` in `SSet`. Ta naloga je zasnovana tako, da ti predstavi kako težko je doseči učinkovitost v implementaciji teh vmesnikov.

Poglavje 2

Izvedba seznama s poljem

V tem poglavju si bomo pogledali izvedbe vmesnikov Seznama in Vrste, kjer je osnovni podatek hranjen v polju, imenovanem *podporno polje*. V spodnji tabeli imamo prikazane časovne zahtevnosti operacij za podatkovne strukture predstavljene v tem poglavju:

| | $\text{get}(i)/\text{set}(i, x)$ | $\text{add}(i, x)/\text{remove}(i)$ |
|-------------------|----------------------------------|-------------------------------------|
| ArrayStack | $O(1)$ | $O(n - i)$ |
| ArrayDeque | $O(1)$ | $O(\min\{i, n - i\})$ |
| DualArrayDeque | $O(1)$ | $O(\min\{i, n - i\})$ |
| RootishArrayStack | $O(1)$ | $O(n - i)$ |

Podatkovne strukture, kjer podatke shranjujemo v enojno polje imajo veliko prednosti, a tudi omejitve:

- V polju imamo vedno konstantni čas za dostop do kateregakoli podatka. To nam omogoča, da se operaciji $\text{get}(i)$ in $\text{set}(i, x)$ izvedeta v konstantnem času.
- Polja niso dinamična. Če želimo vstaviti ali izbrisati element v sredini polja moramo premakniti veliko elementov, da naredimo prostor za novo vstavljen element oz. da zapolnimo praznino po tem, ko smo element izbrisali. Zato je časovna zahtevnost operacij $\text{add}(i, x)$ in $\text{remove}(i)$ odvisna od spremenljivk n in i .
- Polja ne moremo širiti ali krčiti. Ko imamo večje število elementov, kot je veliko naše podporno polje, moramo ustvariti novo, dovolj

veliko polje, v katerega kopiramo podatke iz prejšnjega polja. Ta operacija pa je zelo draga.

Tretja točka je zelo pomembna, saj časovne zahtevnosti iz zgornje tabele ne vključujejo spreminjanja velikosti polja. V nadaljevanju bomo videli, da širjenje in krčenje polja ne dodata veliko k *povprečni* časovni zahtevnosti, če jih ustrezno upravljamo. Natančneje, če začnemo s prazno podatkovno strukturo in izvedemo zaporedje operacij m `add(i, x)` ali `remove(i)`, potem bo časovna zahtevnost širjenja in krčenja polja za m operacij $O(m)$. Čeprav so nekatere operacije dražje je povprečna časovna zahtevnost nad vsemi m operacijami samo $O(1)$ za operacijo.

2.1 ArrayStack: Izvedba sklada s poljem

Z operacijo `ArrayStack` implementiramo vmesnik za seznam z uporabo polja `a`, imenovanega the *podporno polje*. Element v seznamu na indeksu `i` je hranjen v `a[i]`. V večini primerov je velikost polja `a` večja, kot je potrebno, zato uporabimo število `n` kot števec števila elementov spravljenih v polju `a`. Tako imamo elemente spravljene v `a[0], ..., a[n - 1]` in v vseh primerih velja, `a.length ≥ n`.

ArrayStack

```
T[] a;
int n;
int size() {
    return n;
}
```

2.1.1 Osnove

Dostop in spreminjanje elementov v `ArrayStack` z uporabo operacij `get(i)` in `set(i, x)` je zelo lahko. Po izvedbi potrebnih mejnih preverjanj polja vrnemo množico oz. `a[i]`.

ArrayStack

```
T get(int i) {
    return a[i];
}
```

```

}
T set(int i, T x) {
    T y = a[i];
    a[i] = x;
    return y;
}

```

Operaciji vstavljanja in brisanja elementov iz `ArrayStack` sta predstavljeni v 2.1. Za implementacijo `add(i, x)` operacije najprej preverimo če je polje `a` polno. Če je, kličemo metodo `resize()` za povečanje velikosti polja `a`. Kako je metoda `resize()` implementirana, si bomo pogledali kasneje, saj nas trenutno zanima samo to, da potem, ko kličemo metodo `resize()` še vedno ohranjamo pogoj `a.length > n`. Sedaj lahko premaknemo elemente `a[i], ..., a[n - 1]` za ena v desno, da naredimo prostor za `x`, množico `a[i]` spravimo v `x` in povečamo `n`, saj smo vstavili nov element.

```

ArrayStack
void add(int i, T x) {
    if (n + 1 > a.length) resize();
    for (int j = n; j > i; j--)
        a[j] = a[j-1];
    a[i] = x;
    n++;
}

```

Če zapostavimo časovno zahtevnost ob morebitnem klicanju metode `resize()`, potem je časovna zahtevnost operacije `add(i, x)` sorazmerna številu elementov, ki jih moramo premakniti, da naredimo prostor za novo vstavljen element `x`. Zato je časovna zahtevnost operacije (zanemarimo časovno zahtevnost spreminjanja polja `a`) $O(n - i)$.


Implementacija operacije `remove(i)` je zelo podobna. Premaknemo elemente `a[i + 1], ..., a[n - 1]` za ena v levo (prepišemo `a[i]`) in zmanjšamo vrednost `n`. Potem preverimo, če števec `n` postaja občutno manjši kot `a.length` s preverjanjem `a.length ≥ 3n`. Če je občutno manjši kličemo metodo `resize()` za zmanjšanje velikosti polja `a`.

```

ArrayStack
T remove(int i) {
    T x = a[i];

```

Izvedba seznama s poljem



Slika 2.1: Zaporedje operacij `add(i, x)` in `remove(i)` v `ArrayStack`. Puščice označujejo elemente, ki jih je potrebno kopirati. Operacije, po katerih moramo klicati metodo `resize()` so označene z zvezdico.


```

    for (int j = i; j < n-1; j++)
        a[j] = a[j+1];
    n--;
    if (a.length >= 3*n) resize();
    return x;
}

```

Če zanemarimo časovno zahtevnost metode `resize()` je časovna zahtevnost operacije `remove(i)` sorazmerna s številom elementov, ki jih moramo premakniti. To pomeni, da je časovna zahtevnost $O(n - i)$.

2.1.2 Večanje in krčenje

Metoda `resize()` je dokaj enostavna; alocira novo polje `b` velikosti $2n$ in skopira `n` elementov iz polja `a` v prvih `n` mest polja `b` in nato postavi `a` v `b`. Tako po klicu `resize()`, `a.length = 2n`.

```

ArrayStack
void resize() {
    T[] b = newArray(max(n*2, 1));
    for (int i = 0; i < n; i++) {
        b[i] = a[i];
    }
    a = b;
}

```

Analiza cene operacije `resize()` je lahka. Metoda naredi polje `b` velikosti $2n$ in kopira `n` elementov iz `a` v `b`. To traja $O(n)$ časa.

Pri analizi časa delovanja iz prejšnjega poglavja ni bila všteta cena klica `resize()` funkcije. V tem poglavju bomo analizirali to ceno z uporabo tehnike znane pod imenom *amortizirana analiza*. Ta način ne poskuša ugotoviti cene za spreminjanje velikosti med vsako `add(i, x)` in `remove(i)` operacijo. Namesto tega, se posveti ceni vseh klicev `resize()` med zaporedjem m klicev funkcije `add(i, x)` ali `remove(i)`.

Predvsem pokažemo:

Lema 2.1. *Če je ustvarjen prazen ArrayList in katerokoli zaporedje, ko je $m \geq 1$ kliče `add(i, x)` ali `remove(i)` potem je skupen porabljen čas za vse klice `resize()` enak $O(m)$.*

Dokaz. Pokazali bomo, da vsakič ko je klican `resize()`, je število klicev `add` ali `remove` od zadnjega klica `resize()` funkcije, vsaj $n/2 - 1$. Torej, če n_i označuje vrednost n med i tim klicem metode `resize()` in r označuje število klicev funkcije `resize()`, potem je skupno število klicev `add(i, x)` ali `remove(i)` vsaj

$$\sum_{i=1}^r (n_i/2 - 1) \leq m ,$$

kar je enako kot

$$\sum_{i=1}^r n_i \leq 2m + 2r .$$

Na drugi strani, je skupno število časa uporabljenega med vsem `resize()` klici enako

$$\sum_{i=1}^r O(n_i) \leq O(m + r) = O(m) ,$$

ker r ni več kot m . Vse kar nam ostane je pokazati, da je število klicev `add(i, x)` ali `remove(i)` med $(i - 1)$ tim in i tim klicem za `resize()` enako vsaj $n_i/2$.

Upoštevati moramo dva primera. V prvem primeru, je bila metoda `resize()` klicana s strani funkcije `add(i, x)`, ker je bilo polje `a` polno, t.j., `a.length = n = n_i`. Gledano na prejšnji klic funkcije `resize()`: je bila velikost `a`-ja po klicu enaka `a.length`, vendar je bilo število elementov shranjenih v `a`-ju največ `a.length/2 = n_i/2`. Zdaj pa je število elementov shranjenih v `a` enako $n_i = a.length$, torej se je moralo, od prejšnjega klica `resize()` izvesti vsaj $n_i/2$ klicev `add(i, x)`. Drugi primer se zgodi, ko je `resize()` klicana s strani funkcije `remove(i)`, ker je `a.length ≥ 3n = 3n_i`. Enako kot prej je po prejšnjemu klicu `resize()` bilo število elementov shranjenih v `a` najmanj `a.length/2 - 1`.¹ Zdaj pa je v `a` shranjenih $n_i \leq a.length/3$ elementov. Zato je število `remove(i)` operacij od zadnjega

¹ - 1 v tej formuli pomeni poseben primer ko je $n = 0$ in `a.length = 1`.

resize() klica vsaj

$$\begin{aligned} R &\geq \text{a.length}/2 - 1 - \text{a.length}/3 \\ &= \text{a.length}/6 - 1 \\ &= (\text{a.length}/3)/2 - 1 \\ &\geq n_i/2 - 1 . \end{aligned}$$

V vsakem primeru je število klicev `add(i, x)` ali `remove(i)`, ki se zgodijo med $(i - 1)$ tim klicem za `resize()` in i tim klicem za `resize()` je natanko toliko $n_i/2 - 1$, kot je tudi potrebno za dokončanje dokaza. \square

2.1.3 Povzetek

Naslednji izrek povzema učinkovitost izvedbe podatkovne strukture `ArrayStack`:

Izrek 2.1. *ArrayStack implementira List vmesnik. Z ignoriranjem cene klicev funkcije `resize()` ArrayStack podpira naslednje operacije:*

- `get(i)` in `set(i, x)` v času $O(1)$ a eno operacijo; in
- `add(i, x)` in `remove(i)` v času $O(1 + n - i)$ na operacijo.

Poleg tega, če začnemo z prazno strukturo `ArrayStack` in potem izvajamo katerokoli zaporedje od m `add(i, x)` in `remove(i)` operacij privede v skupno $O(m)$ časa uporabljenega med vsem klici funkcije `resize()`.

`ArrayStack` je učinkovit način za implementiranje Sklada. Funkcijo `push(x)` lahko implementiramo kot `add(n, x)` in funkcijo `pop()` kot `remove(n - 1)`. V tem primeru bodo te operacije potrebovale $O(1)$ amortiziranega časa.

2.2 FastArrayStack: Optimiziran ArrayStack

`ArrayStack` opravi večino dela z zamenjevanjem (s `add(i, x)` in `remove(i)`) in kopiranjem (z `resize()`) podatkov. V izvedbah prikazanih zgoraj, je bilo to narejeno s pomočjo `for` zanke. Izkaže se, da ima veliko programskih okolij posebne funkcije, ki so zelo učinkovite pri kopiranju in premikanju blokov podatkov. V programskem jeziku C, obstajajo funkcije

`memcpy(d,s,n)` in `memmove(d,s,n)`. V C++ jeziku je `std::copy(a0,a1,b)` algoritem. V Javi je metoda `System.arraycopy(s,i,d,j,n)`.

```

FastArrayStack
void resize() {
    T[] b = newArray(max(2*n,1));
    System.arraycopy(a, 0, b, 0, n);
    a = b;
}
void add(int i, T x) {
    if (n + 1 > a.length) resize();
    System.arraycopy(a, i, a, i+1, n-i);
    a[i] = x;
    n++;
}
T remove(int i) {
    T x = a[i];
    System.arraycopy(a, i+1, a, i, n-i-1);
    n--;
    if (a.length >= 3*n) resize();
    return x;
}

```

Te funkcije so ponavadi zelo optimizirane in lahko uporabljajo tudi posebne strojne ukaze, ki lahko kopirajo veliko hitreje, kot z uporabo zanke `for`. Vseeno s pomočjo teh funkcij ne moremo asimptotično zmanjšati izvajalnih časov, a je ta optimizacija še vedno koristna. V Java izvedbah Jave, uporaba nativnega `System.arraycopy(s,i,d,j,n)` povzroči pohitritve za faktor med 2 in 3, odvisno od vrste izvajanih operacij. Izvajane pohitritve se lahko razlikujejo od sistema do sistema.

2.3 ArrayQueue: Vrsta na osnovi polja

V tem poglavju bomo predstavili podatkovno strukturo `ArrayQueue`, ki implementira FIFO vrsto; elemente iz vrste odstranjujemo (z uporabo operacije `remove()`) v istem vrstnem redu, kot so bili dodani (z uporabo operacije `add(x)`).

Opazimo, da `ArrayStack` ni dobra izbira za izvedbo FIFO vrste in si-

cer zato, ker moramo izbrati en konec seznama, na katerega dodajamo elemente, nato pa elemente odstranjujemo z drugega konca. Ena izmed operacij mora delovati na glavi seznama, kar vključuje klicanje `add(i, x)` ali `remove(i)`, kjer je vrednost $i = 0$. To nudi čas izvajanja sorazmeren n .

Da bi dosegli učinkovito implementacijo vrste na osnovi seznama, najprej opazimo, da bi bil problem enostaven, če bi imeli neskočno veliko polje a . Lahko bi hranili indeks j , ki hrani naslednji element za odstranitev ter celo število n , ki šteje število elementov v vrsti. Elementi vrste bi bili vedno shranjeni v

$$a[j], a[j + 1], \dots, a[j + n - 1] .$$

Sprva bi bila j in n nastavljena na 0. Na novo dodan element bi uvrstili v $a[j + n]$ in povečali n . Za odstranitev elementa bi ga odstranili iz $a[j]$, povečali j in zmanjšali n .

Težava te rešitve je potreba po neskončno velikem polju. `ArrayQueue` to simulira z uporabo končnega polja in *kongruence*. To je vrsta aritmetike, ki jo uporabljamo pri izračunu časa. Na primer 10:00 plus pet ur je 3:00. Formalno pravimo, da je

$$10 + 5 = 15 \equiv 3 \pmod{12} .$$

Zadnji del enačbe beremo kot "15 je skladno s 3 po modulu 12." Operator `mod` lahko obravnavamo tudi kot binarni operator, da je

$$15 \bmod 12 = 3 .$$

V splošnem je za celo število a in pozitivno celo število m , $a \bmod m$ enolično celo število $r \in \{0, \dots, m - 1\}$ tako, da velja $a = r + km$ za poljubno celo število k . Poenostavljeno vrednost r predstavlja ostanek pri deljenju a z m . V večini programskih jezikov, vključno z Java, je operator `mod` predstavljen z znakom `%`.²

Modularna aritmetika je uporabna za simulacijo neskončno velikega polja, ker `i mod a.length` vedno vrne vrednost na intervalu $0, \dots, a.length - 1$. Z uporabo kongruence lahko elemente vrste shranimo na naslednja mesta v polju

$$a[j \% a.length], a[(j + 1) \% a.length], \dots, a[(j + n - 1) \% a.length] .$$

²Temu včasih rečemo operator *brain-dead*, ker nepravilno implementira matematični operator `mod`, ko je prvi argument negativno število.

To obravnava polje `a` kot *krožno polje* kjer polje indekse večje kot `a.length-1` “ovije naokrog” na začetek polja.

Paziti moramo le še, da število elementov v `ArrayQueue` ne preseže velikosti `a`.

```

ArrayQueue
T[] a;
int j;
int n;

```

Zaporedje operacij `add(x)` in `remove()` nad `ArrayQueue` je prikazano na 2.2. Za izvedbo `add(x)` moramo najprej preveriti, če je `a` poln, in s klicem `resize()` velikost `a` povečati. Nato `x` shranimo v `a[(j+n)%a.length]` in povečamo `n`.

```

ArrayQueue
boolean add(T x) {
    if (n + 1 > a.length) resize();
    a[(j+n) % a.length] = x;
    n++;
    return true;
}

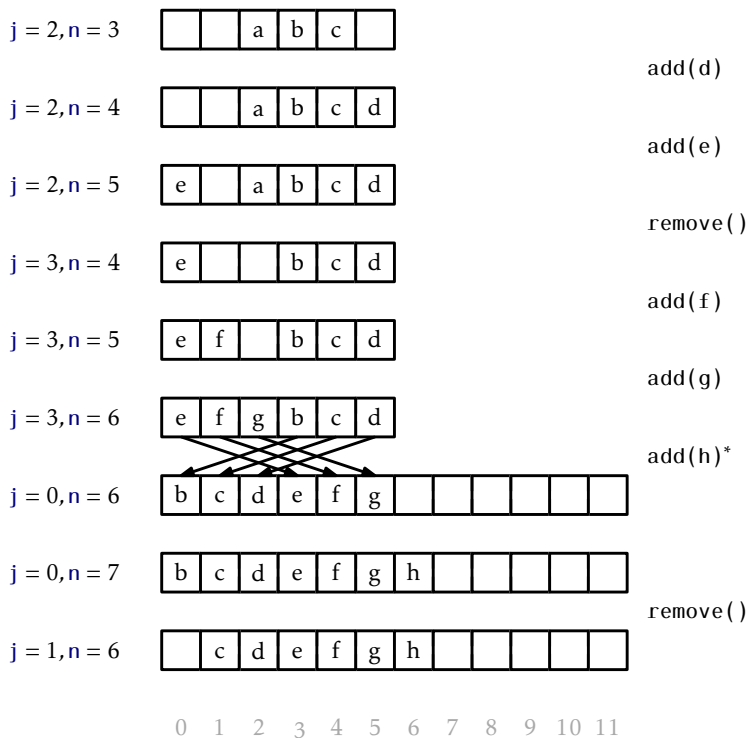
```

Za izvedbo `remove()` moramo najprej za kasnejšo rabo shraniti `a[j]`. Nato zmanjšamo `n` in povečamo `j` (po modulu `a.length`) tako, da nastavimo `j = (j+1) mod a.length`. Na koncu vrnemo shranjeno vrednost `a[j]`. Po potrebi lahko zmanjšamo velikost `a` s klicem `resize()`.

```

ArrayQueue
T remove() {
    if (n == 0) throw new NoSuchElementException();
    T x = a[j];
    j = (j + 1) % a.length;
    n--;
    if (a.length >= 3*n) resize();
    return x;
}

```



Slika 2.2: Zaporedje operacij `add(x)` in `remove(i)` nad `ArrayQueue`. Puščice označujejo kopiranje elementov. Operacije, ki se zaključijo s klicem `resize()` so označene z zvezdico.

Operacija `resize()` je zelo podobna operaciji `resize()` pri `ArrayStack`. Dodeli novo polje `b` velikosti $2n$ in prepíše

$$a[j], a[(j+1)\%a.length], \dots, a[(j+n-1)\%a.length]$$

na

$$b[0], b[1], \dots, b[n-1]$$

in nastavi `j = 0`.

```

ArrayQueue
void resize() {
    T[] b = newArray(max(1,n*2));
    for (int k = 0; k < n; k++)
        b[k] = a[(j+k) % a.length];
    a = b;
    j = 0;
}
    
```

2.3.1 Povzetek

Naslednji izrek povzema učinkovitost podatkovne strukture `ArrayQueue`:

Izrek 2.2. *ArrayQueue implementira vmesnik (FIFO) Vrste. Če izvezamemo ceno klica `resize()`, omogoča `ArrayQueue` izvajanje operacij `add(x)` in `remove()` v času $O(1)$ na operacijo. Poleg tega, začeni s prazno vrsto `ArrayQueue`, vsako zaporedje m operacij `add(i, x)` in `remove(i)` porabi skupno $O(m)$ časa za vse klice `resize()`.*

2.4 ArrayDeque: Hitra obojestranska vrsta z uporabo polja

Struktura `ArrayQueue` iz prejšnjega poglavja je podatkovna struktura za predstavitev zaporedja, ki omogoča učinkovito dodajanje na en konec in odstranjevanje z drugega konca. Podatkovna struktura `ArrayDeque` pa omogoče tako učinkovito dodajanje kot tudi odstranjevanje z obeh koncev. Ta struktura implementira vmesnik `List` z uporabo enake tehnike krožnega polja, ki je uporabljena pri `ArrayQueue`.

ArrayDeque

```
T[] a;  
int j;  
int n;
```

Operaciji `get(i)` in `set(i,x)` nad `ArrayDeque` sta enostavni. Vrneta oziroma nastavita element polja `a[(j + i) mod a.length]`.

ArrayDeque


```
T get(int i) {  
    return a[(j+i)%a.length];  
}  
T set(int i, T x) {  
    T y = a[(j+i)%a.length];  
    a[(j+i)%a.length] = x;  
    return y;  
}
```

Implementacija operacije `add(i,x)` je bolj zanimiva. Kot ponavadi, najprej preverimo, če je `a` poln in ga po potrebi povečamo s klicem `resize()`. Želimo, da je ta operacija hitra tako, ko je `i` majhen (blizu 0), kot tudi, ko je `i` velik (blizu `n`). Zato preverimo, če drži `i < n/2`. Če drži, zamaknemo elemente `a[0], ..., a[i-1]` za eno mesto v levo. Sicer (`i ≥ n/2`), elemente `a[i], ..., a[n-1]` zamaknemo za eno mesto v desno. 2.3 prikazuje operaciji `add(i,x)` in `remove(x)` nad `ArrayDeque`.

ArrayDeque

```
void add(int i, T x) {  
    if (n+1 > a.length) resize();  
    if (i < n/2) { // shift a[0], ..., a[i-1] left one position  
        j = (j == 0) ? a.length - 1 : j - 1; //(j-1)mod a.length  
        for (int k = 0; k <= i-1; k++)  
            a[(j+k)%a.length] = a[(j+k+1)%a.length];  
    } else { // shift a[i], ..., a[n-1] right one position  
        for (int k = n; k > i; k--)  
            a[(j+k)%a.length] = a[(j+k-1)%a.length];  
    }  
    a[(j+i)%a.length] = x;  
    n++;  
}
```

Izvedba seznama s poljem



Slika 2.3: Zaporedje operacij `add(i, x)` in `remove(i)` nad `ArrayDeque`. Puščice označujejo prestavljanje elementov.

S prestavljanjem elementov na tak način zagotovimo, da `add(i, x)` nikoli ne potrebuje prestaviti več kot $\min\{i, n - i\}$ elementov. Čas izvajanja operacije `add(i, x)`, (če ignoriramo ceno operacije `resize()`), je potemtakaem $O(1 + \min\{i, n - i\})$.

Operacija `remove(i)` je izvedena podobno. Odvisno od $i < n/2$, `remove(i)` bodisi zamakne elemente `a[0], ..., a[i - 1]` za eno mesto v desno, bodisi elemente `a[i + 1], ..., a[n - 1]` zamakne za eno mesto v levo. To spet pomeni, da `remove(i)` za zamik elementov nikoli ne potrebuje več kot $O(1 + \min\{i, n - i\})$ časa.

ArrayDeque

```

T remove(int i) {
    T x = a[(j+i)%a.length];
    if (i < n/2) { // shift a[0], ..., [i-1] right one position
        for (int k = i; k > 0; k--)
            a[(j+k)%a.length] = a[(j+k-1)%a.length];
        j = (j + 1) % a.length;
    } else { // shift a[i+1], ..., a[n-1] left one position
        for (int k = i; k < n-1; k++)
            a[(j+k)%a.length] = a[(j+k+1)%a.length];
    }
    n--;
    if (3*n < a.length) resize();
}

```

```
    return x;  
}
```

2.4.1 Povzetek

Naslednji izrek povzema učinkovitost podatkovne strukture `ArrayDeque`:

Izrek 2.3. *`ArrayDeque` implementira vmesnik `List`. Če izvezamemo ceno klica `resize()`, omogoča `ArrayDeque` izvajanje operacij*

- `get(i)` in `set(i, x)` v času $O(1)$ na operacijo; in
- `add(i, x)` in `remove(i)` v času $O(1 + \min\{i, n - i\})$ na operacijo.

Poleg tega, začenši s prazno obojestransko vrsto `ArrayDeque`, vsako zaporedje m operacij `add(i, x)` in `remove(i)` porabi skupno $O(m)$ časa za vse klice `resize()`.

2.5 DualArrayDeque: Gradnja obojestranske vrste z dveh skladov

V sledečem poglavju bomo predstavili podatkovno strukturo `DualArrayDeque`, ki za dosego enakih meja učinkovitosti kot `ArrayDeque`, uporablja dve skladovni polji (`ArrayStack`). Čeprav ni asimptotična učinkovitost `DualArrayDeque` nič boljša kot pri `ArrayDeque`, je struktura vseeno zanimiva, ker nudi dober primer napredne strukture z združitvijo dveh enostavnih.

`DualArrayDeque` predstavlja seznam z uporabo dveh `ArrayStack`ov. Spomnimo se, da `ArrayStack` deluje hitro, ko operacije nad njim spreminjajo elementa z njegovega konca. `DualArrayDeque` sestoji iz dveh `ArrayStack`ov, enega **spredaj** (`front`) in enega **zadaj** (`back`), s konci nasproti, da to operacije hitre na obeh straneh.

```
DualArrayDeque  
List<T> front;  
List<T> back;
```

DualArrayDeque ne hrani eksplicitno števila elementov, n , ki jih vsebuje. Števila ni potrebno hraniti, saj vsebuje $n = \text{front.size()} + \text{back.size()}$ elementov. Vseeno pa bomo pri analizi DualArrayDeque uporabljali n za označevanje števila vsebovanih elementov.

```

DualArrayDeque
int size() {
    return front.size() + back.size();
}

```

Sprednji ArrayStack hrani seznam elementov z indeksi $0, \dots, \text{front.size()} - 1$, vendar jih hrani v obratnem vrstnem redu. Zadnji ArrayStack pa hrani seznam elementov z indeksi $\text{front.size()}, \dots, \text{size()} - 1$ v običajnem vrstnem redu. Na tak način se $\text{get}(i)$ in $\text{set}(i, x)$ prevedeta v primerne klice $\text{get}(i)$ ali $\text{set}(i)$ na bodisi **sprednjem** ali **zadnjem** koncu, kar potrebuje $O(1)$ časa na operacijo.

```


DualArrayDeque
T get(int i) {
    if (i < front.size()) {
        return front.get(front.size() - i - 1);
    } else {
        return back.get(i - front.size());
    }
}

T set(int i, T x) {
    if (i < front.size()) {
        return front.set(front.size() - i - 1, x);
    } else {
        return back.set(i - front.size(), x);
    }
}

```

Če je indeks $i < \text{front.size()}$, potem opazimo da ustreza elementu **spredaj** na položaju $\text{front.size()} - i - 1$, ker so elementi **spredaj** shranjeni v obratnem vrstnem redu.

Dodajanje in odstranjevanje elementov iz DualArrayDeque je prikazano na sliki 2.4. Operacija $\text{add}(i, x)$ doda element **spredaj** ali **zadaj**,



Slika 2.4: Zaporedje operacij `add(i, x)` in `remove(i)` nad `DualArrayDeque`. Puščice označujejo prestavljanje elementov. Operacije, po katerih se seznam uravnoteži s klicem `balance()`, so označene z zvezdico.

odvisno od stanja:

```

DualArrayDeque
void add(int i, T x) {
    if (i < front.size()) {
        front.add(front.size()-i, x);
    } else {
        back.add(i-front.size(), x);
    }
    balance();
}

```

Metoda `add(i, x)` uravnoteži **sprednji** in **zadnji** `ArrayStack` s klicom metode `balance()`. Izvedba `balance()` je prikazana spodaj, za enkrat pa je dovolj, če vemo, da razen če je `size() < 2`, `balance()` poskrbi za to, da se `front.size()` in `back.size()` ne razlikujeta več kot za faktor 3. Natančneje, $3 \cdot \text{front.size()} \geq \text{back.size()}$ in $3 \cdot \text{back.size()} \geq \text{front.size()}$.

Nato, analiziramo ceno metode `add(i, x)`, pri tem ne upoštevamo ceno klicev metode `balance()`. Če `i < front.size()`, potem se `add(i, x)` izvede s

klicem na `front.add(front.size() - i - 1, x)`. Ker je `front` `ArrayStack` je cena tega

$$O(\text{front.size()} - (\text{front.size()} - i - 1) + 1) = O(i + 1) . \quad (2.1)$$

Po drugi strani pa, če drži $i \geq \text{front.size()}$, potem je `add(i, x)` implementirana kot `back.add(i - front.size(), x)`. Cena tega pa je

$$O(\text{back.size()} - (i - \text{front.size()}) + 1) = O(n - i + 1) . \quad (2.2)$$

Opazimo, da se prvi primer (2.1) pojavi, ko velja $i < n/4$. Drugi primer (2.2) se pojavi, ko velja $i \geq 3n/4$. Kadar velja $n/4 \leq i < 3n/4$, ne moremo biti prepričani ali delovanje vpliva na `front` ali `back`, ampak v vsakem primeru se postopek izvaja $O(n) = O(i) = O(n - i)$ časa, saj je $i \geq n/4$ in $n - i > n/4$. Če povzamemo situacijo imamo

$$\text{Čas izvajanja add}(i, x) \leq \begin{cases} O(1 + i) & \text{if } i < n/4 \\ O(n) & \text{if } n/4 \leq i < 3n/4 \\ O(1 + n - i) & \text{if } i \geq 3n/4 \end{cases}$$

Tako je čas izvajanja `add(i, x)`, če zanemarimo ceno klicev metode `balance()` sledeč $O(1 + \min\{i, n - i\})$.

Metoda `remove(i)` in njene analize spominjajo na `add(i, x)` metodo.

```

DualArrayDeque
T remove(int i) {
    T x;
    if (i < front.size()) {
        x = front.remove(front.size() - i - 1);
    } else {
        x = back.remove(i - front.size());
    }
    balance();
    return x;
}

```

2.5.1 Uravnoteženje

Osredotočimo se na metodo `balance()` izvedeno z metodo `add(i, x)` in `remove(i)`. Ta postopek zagotavlja, da niti `front` in niti `back` ne postane prevelika (ali premajhna). Zagotavlja, da razen, če obstajata manj

kot dva elementa, tako `front` in `back` vsebujeta vsaj $n/4$ elementov. Če temu ni tako, potem se premika elemente med njima tako, da `front` in `back` vsebujeta natanko $\lfloor n/2 \rfloor$ elementov in $\lceil n/2 \rceil$ elementov.

```

DualArrayDeque
void balance() {
    int n = size();
    if (3*front.size() < back.size()) {
        int s = n/2 - front.size();
        List<T> l1 = new Stack();
        List<T> l2 = new Stack();
        l1.addAll(back.subList(0,s));
        Collections.reverse(l1);
        l1.addAll(front);
        l2.addAll(back.subList(s, back.size()));
        front = l1;
        back = l2;
    } else if (3*back.size() < front.size()) {
        int s = front.size() - n/2;
        List<T> l1 = new Stack();
        List<T> l2 = new Stack();
        l1.addAll(front.subList(s, front.size()));
        l2.addAll(front.subList(0, s));
        Collections.reverse(l2);
        l2.addAll(back);
        front = l1;
        back = l2;
    }
}

```

Če metoda `balance()` izvede uravnoteženje, potem premakne $O(n)$ elementov in za to potrebuje $O(n)$ časa. To je slabo zato, ker je metoda `balance()` klicana z vsakim `add(i, x)` in `remove(i)` klicem. V vsakem primeru, sledeč dokaz dokazuje, da metoda `balance()` v povprečju porabi samo konstantno količino časa na operacijo.

Lema 2.2. Če ustvarimo prazen `DualArrayDeque`, potem zaporedje $m \geq 1$ izvede klice metode `add(i, x)` in `remove(i)`, potem je skupen porabljen čas za klice metode `balance()` $O(m)$.

Dokaz. Dokazali bomo, da če metoda `balance()` premeša elemente, potem je število `add(i, x)` in `remove(i)` operacij vsaj $n/2 - 1$, od kar so bili elementi nazadnje premešani z metodo `balance()`. Z dokazom v 2.1 lahko dokažemo, da je skupen porabljen čas metode `balance()` $O(m)$.

Izvedli bomo našo analizo z uporabo tehnike, poznane kot *potencialna metoda*. Določimo *potencialni* Φ za `DualArrayDeque` kot razliko v dolžini med `front` in `back`:

$$\Phi = |\text{front.size()} - \text{back.size()}|.$$

Zanimiva stvar glede potenciala je, da klic metode `add(i, x)` ali `remove(i)`, ki ne opravi nobenega uravnoteženja, lahko poveča potencial skoraj največ za 1.

Potrebno je upoštevati, da je takoj po klicu metode `balance()`, ki premeša elemente, potencial Φ_0 največ 1, saj

$$\Phi_0 = \lfloor n/2 \rfloor - \lceil n/2 \rceil \leq 1.$$

Razmislite o trenutku takoj pred klicem funkcije `balance()`, ki premeša elemente in domnevajte, da `balance()` premeša elemente zaradi $3\text{front.size()} < \text{back.size()}()$. To opazimo v sledečem primeru,

$$\begin{aligned} n &= \text{front.size()} + \text{back.size()} \\ &< \text{back.size()}/3 + \text{back.size()} \\ &= \frac{4}{3}\text{back.size()} \end{aligned}$$

Poleg tega je s časom potencial na tem mestu

$$\begin{aligned} \Phi_1 &= \text{back.size()} - \text{front.size()} \\ &> \text{back.size()} - \text{back.size()}/3 \\ &= \frac{2}{3}\text{back.size()} \\ &> \frac{2}{3} \times \frac{3}{4}n \\ &= n/2 \end{aligned}$$

Zato je število klicev metode `add(i, x)` ali `remove(i)`, od kar je metoda `balance()` nazadnje premešala elemente, najmanj $\Phi_1 - \Phi_0 > n/2 - 1$. To zaključuje dokaz. \square

2.5.2 Povzetek

Naslednji izrek povzame lastnosti `DualArrayDeque`:

Izrek 2.4. *`DualArrayDeque` implementira vmesnik `List`. Z ignoriranjem cene klicev metod `resize()` in `balance()` `DualArrayDeque` podpira operacije*

- `get(i)` in `set(i, x)` v času $O(1)$ na operacijo; in
- `add(i, x)` in `remove(i)` v času $O(1 + \min\{i, n - i\})$ na operacijo.

Poleg tega, če začnemo z praznim `DualArrayDeque`, potem zaporedje m `add(i, x)` in `remove(i)` metod, konča z skupnim rezultatom $O(m)$ časa porabljenega med vsemi klici metod `resize()` in `balance()`.

2.6 `RootishArrayStack`: Prostorsko učinkovit `ArrayStack`

Ena izmed slabosti vseh prejšnjih podatkovnih struktur v tem poglavju je ta, da ker se shranjujejo podatki v eni ali dveh tabelah, ki se izogibajo spreminjanju velikosti, se pogosto zgodi, da so tabele precej prazne. Na primer, takoj po operaciji `resize()` nad `ArrayStack`-om, je tabela `a` le na pol polna. Še huje, veliko je primerov, kjer samo $1/3$ tabele `a` vsebuje podatke.


Ta razdelek je namenjen podatkovni strukturi `RootishArrayStack`, ki se posveča problemu zapravljenega prostora. `RootishArrayStack` vsebuje `n` elementov z uporabo $O(\sqrt{n})$ tabel. V teh tabelah je največ $O(\sqrt{n})$ lokacij neuporabljenih v poljubnem času. Vse preostale lokacije v tabeli so uporabljene za shrambo podatkov. Potemtakem te podatkovne strukture napravijo največ $O(\sqrt{n})$ prostora pri shranjevanju `n` elementov.

`RootishArrayStack` shrani svoje elemente v seznam `r` tabel poimenovanih *blocks*, ki so oštevilčene $0, 1, \dots, r - 1$. Glej 2.5. Blok b vsebuje $b + 1$ elemente, zato vsi `r` bloki vsebujejo največ

$$1 + 2 + 3 + \dots + r = r(r + 1)/2$$

elementov. Zgornja formula se izpelje kot je prikazano na 2.6.

Izvedba seznama s poljem



Slika 2.5: Sekvenca `add(i, x)` in `remove(i)` operacij na `RootishArrayStack`. Puščice označujejo kopirane elemente.

```
List<T[]> blocks;
int n;
```


RootishArrayStack

Kot lahko pričakujemo, so elementi v seznamu razvrščeni po vrsti v bloku. Element v seznamu z indeksom 0 je shranjen v blok 0, elementa z indeksoma 1 in 2 sta shranjena v blok 1, elementi z indeksi 3, 4 in 5 so shranjeni v blok 2, itn. Glavni problem ki ga je potrebno nasloviti, je pri odločanju, ko nam je podan indeks `i`, kateri blok vsebuje tako `i`, kot tudi ustrezni indeks do `i` v samem bloku.

Določanje indeksa `i` v njegovem bloku se izkaže kot lahko. Če je indeks `i` v bloku `b`, potem je število elementov v blokih $0, \dots, b-1$ $b(b+1)/2$. Potemtakem je `i` shranjen na lokaciji

$$j = i - b(b+1)/2$$

v bloku `b`. Malo bolj zahteven je problem določanja vrednosti bloku `b`. Število elementov, ki ima indekse manj ali enake `i` je `i + 1`. Na drugi strani pa je število elementov v blokih $0, \dots, b$, ki je enako $(b+1)(b+2)/2$.



Slika 2.6: Število belih kvadratov je $1 + 2 + 3 + \dots + r$. Število osenčenih kvadratov je isto. Beli in osenčeni kvadrati skupaj tvorijo pravokotnik, ki vsebuje $r(r + 1)$ kvadratov.

Potemtakem je b najmanjše število, ki še ustreza

$$(b + 1)(b + 2)/2 \geq i + 1 .$$

To enačbo lahko preoblikujemo tako

$$b^2 + 3b - 2i \geq 0 .$$

Ustrezno kvadratna enačba $b^2 + 3b - 2i = 0$ ima dve rešitvi: $b = (-3 + \sqrt{9 + 8i})/2$ in $b = (-3 - \sqrt{9 + 8i})/2$.

Druga rešitev nima smisla za našo uporabo, ker da vedno negativno rešitev. Zato uporabimo $b = (-3 + \sqrt{9 + 8i})/2$. V splošnem ta rešitev ni število, vendar če se vrnemo k naši neenakosti, hočemo najmanjšo število b , tako, da velja $b \geq (-3 + \sqrt{9 + 8i})/2$. To je preprosto

$$b = \lceil (-3 + \sqrt{9 + 8i})/2 \rceil .$$

```

RootishArrayStack
int i2b(int i) {
    double db = (-3.0 + Math.sqrt(9 + 8*i)) / 2.0;
    int b = (int)Math.ceil(db);
    return b;
}

```

Ko je to jasno, sta tudi metodi `get(i)` in `set(i, x)` jasni. Najprej izračunamo ustrezen blok `b` in ustrezen indeks `j` v bloku. Potem izvedemo primerno operacijo:

```
RootishArrayStack
T get(int i) {
    int b = i2b(i);
    int j = i - b*(b+1)/2;
    return blocks.get(b)[j];
}
T set(int i, T x) {
    int b = i2b(i);
    int j = i - b*(b+1)/2;
    T y = blocks.get(b)[j];
    blocks.get(b)[j] = x;
    return y;
}
```

V primeru, da uporabimo katerokoli podatkovno strukturo v tem poglavju za zastopanje `blocks` seznam, potem se `get(i)` in `set(i, x)` izvajata v konstantnem času.

Metoda `add(i, x)` nam je že poznana. Najprej preverimo, če je naša podatkovna struktura polna tako, da je število blokov `r` tako, da drži $r(r+1)/2 = n$. Če je, pokličemo `grow()`, ki nam doda še en blok. Ko to naredimo, zamaknemo elemente z indeksi `i, ..., n-1` v desno za eno pozicijo, da naredimo prostor za nov element z indeksom `i`:

```
RootishArrayStack
void add(int i, T x) {
    int r = blocks.size();
    if (r*(r+1)/2 < n + 1) grow();
    n++;
    for (int j = n-1; j > i; j--)
        set(j, get(j-1));
    set(i, x);
}
```

Metoda `grow()` naredi pričakovano. Doda nov blok:

RootishArrayStack

```
void grow() {
    blocks.add(newArray(blocks.size()+1));
}
```

Če ignoriramo ceno operacije `grow()`, potem je cena `add(i, x)` dominirana z vrednostjo zamikanja in je potemtakem enaka $O(1 + n - i)$, kar je enako, kot pri `ArrayStack`.

Operacija `remove(i)` je podobna metodi `add(i, x)`. Le ta zamakne elemente z indeksi $i + 1, \dots, n$ levo za eno pozicijo. Za tem, če je več kot en blok še prazen, pokliče metodo `shrink()`, da odstrani vse, razen enega še ne uporabljenega bloka:

RootishArrayStack

```
T remove(int i) {
    T x = get(i);
    for (int j = i; j < n-1; j++)
        set(j, get(j+1));
    n--;
    int r = blocks.size();
    if ((r-2)*(r-1)/2 >= n) shrink();
    return x;
}
```

RootishArrayStack

```
void shrink() {
    int r = blocks.size();
    while (r > 0 && (r-2)*(r-1)/2 >= n) {
        blocks.remove(blocks.size()-1);
        r--;
    }
}
```

Če spet ignoriramo ceno operacije `shrink()`, je cena `remove(i)` dominirana z vrednostjo zamikanja in je potemtakem enaka $O(n - i)$.

2.6.1 Analiza rasti in krčenja

Zgornja analiza `add(i, x)` in `remove(i)` ne vzema v zakup cene metodi `grow()` in `shrink()`. Upoštevajte, da metodi `grow()` in `shrink()` ne kopirata nobenih podatkov, kot to dela operacija `ArrayStack.resize()`, temveč le alocirajo ali izpraznijo tabelo velikosti r . V določenih okoljih se to zgodi v konstantnem času, dočim zna v drugih to zahtevati proporcionalen čas glede na r .

Takoj po klicu `grow()` ali `shrink()` se situacija počisti. Zanj blok je popolnoma prazen, vsi ostali pa so povsem zapolnjeni. Dodaten klic `grow()` ali `shrink()` se ne bo zgodil dokler vsaj $r - 1$ elementov ni bilo dodanih ali odstranjenih. Četudi vzamejo `grow()` in `shrink()` $O(r)$ časa, je lahko vrednost cene `grow()` in `shrink()` amortizirana na $O(1)$ za vsako posamezno operacijo.

2.6.2 Poraba prostora

Sedaj bomo analizirali količino dodatnega prostora, ki ga uporablja `RootishArrayStack`. Bolj natančno, hočemo prešteti ves prostor, ki ga uporablja `RootishArrayStack` in le ta ni element tabele, ki je trenutno uporabljen za držanje elementa seznama. Takemu prostoru rečemo *wasted space*.

Operacija `remove(i)` zagotavlja, da `RootishArrayStack` nikoli nima več kot dva zapolnjena bloka. Število blokov, r , uporabljenih s strani `RootishArrayStack`, ki imajo shranjenih n elementov potemtakem zado-
voljijo

$$(r - 2)(r - 1) \leq n .$$

Če uporabimo kvadratno enačbo nam da

$$r \leq (3 + \sqrt{1 + 4n})/2 = O(\sqrt{n}) .$$

Zadnje dva bloka sta velikosti r in $r - 1$, zato je največ zapravljenega prostora $2r - 1 = O(\sqrt{n})$. Če shranimo bloka v (npr.) `ArrayList`, ima potem `List`, ki shranjuje r bloke, $O(r) = O(\sqrt{n})$ zapravljenega prostora. Ostali prostor, ki ga potrebujemo za shrambo n in ostalih informacij je potemtakem $O(1)$. Skupaj je zapravljenega prostora v `RootishArrayStack` $O(\sqrt{n})$.

Nato trdimo, da je tak način uporabe prostora optimalen za katerokoli podatkovno strukturo, ki je na začetku prazna in podpira seštevanje enega elementa v določenem času. Bolj natančno smo zmožni prikazati, da v točno določenem času med seštevanjem n elementov, podatkovna struktura zapravlja vsaj \sqrt{n} prostora (čeprav je to le za trenutek).

Predpostavimo, da začnemo s prazno podatkovno strukturo in dodamo n elementov vsakega posebej. Na koncu procesa je vseh n elementov shranjenih v strukturi in porazdeljenih med r kolekcijo spominskih blokov. Če velja $r \geq \sqrt{n}$, potem mora podatkovna struktura uporabljati r kazalcev (ali referenc), da sledi vsem r blokom. Te kazalci so zapravljen prostor. Na drugi strani če velja $r < \sqrt{n}$, potem morajo zaradi načela predalčkanja, določeni bloki biti vsaj $n/r > \sqrt{n}$ veliki. Vpoštevajoč moment v katerem je bil blok najprej alociran. Takoj po alociranju, je bil blok prazen in je zato zapravljal \sqrt{n} prostora. Zaradi tega je bilo ob točno določenem času med vstavljanjem n elementov, zapravljenega \sqrt{n} prostora s strani podatkovne strukture.

2.6.3 Povzetek

Sledeč teorem povzema našo diskusijo o podatkovni strukturi `RootishArrayStack`:

Izrek 2.5. *`RootishArrayStack` implementira vmesnik `List`. `RootishArrayStack` ignorira cene klicev metod `grow()` in `shrink()` ter podpira operacije*

- `get(i)` in `set(i, x)` z $O(1)$ časom na operacijo; in
- `add(i, x)` in `remove(i)` z $O(1 + n - i)$ časom na operacijo.

Še več, če začnemo s praznim `RootishArrayStack`, bo katerakoli sekvenca m `add(i, x)` in `remove(i)` operacij potrebovala v celoti $O(m)$ časa za vse klice teh dveh metod.

Prostor (merjen v besedah),³ ki ga `RootishArrayStack` porabi za shrambo n elementov, je $n + O(\sqrt{n})$.

³Spomnimo se 1.4 za diskusijo kako se meri spomin.

2.6.4 Računanje Kvadratnih Korenov

Bralec ki je imel nekaj stika z modeli računanja, morda opazi da zgoraj opisan `RootishArrayStack`, ne spada v običajni model računanja besedni-RAM (1.4, ker zahteva računanje kvadratnih korenov. Operacija kvadratnega korena ni smatrana za navadno operacijo in navadno ni del besednega-RAM modela.

V tej sekciji pokažemo, da se lahko implementacijo kvadratnega korena učinkovito implementira. Še posebej pokažemo, da je vsako število $x \in \{0, \dots, n\}$, $\lfloor \sqrt{x} \rfloor$ lahko izračunano v konstantnem-času, nato ko $O(\sqrt{n})$ predpriprava ustvari dve tabeli dolžine $O(\sqrt{n})$. Sledeča lema kaže, da lahko zmanjšamo problem računanja kvadratnega korena spremenljivke x v kvadratni koren sorodne vrednosti x' .

Lema 2.3. *Naj bo $x \geq 1$ in $x' = x - a$, kjer je $0 \leq a \leq \sqrt{x}$. Potem sledi da $\sqrt{x'} \geq \sqrt{x} - 1$.*

Dokaz. Zadostuje pokazati da

$$\sqrt{x - \sqrt{x}} \geq \sqrt{x} - 1.$$

Kvadriramo obe strani te neenačbe, da dobimo

$$x - \sqrt{x} \geq x - 2\sqrt{x} + 1$$

nato poračunamo do konca, da dobimo

$$\sqrt{x} \geq 1$$

kar drži za vsak $x \geq 1$. □

Začnemo tako, da malo omejimo problem in predpostavimo da je $2^r \leq x < 2^{r+1}$, tako da $\lfloor \log x \rfloor = r$, t.j., x je število z $r + 1$ biti v binarni predstavitvi števil. Uzamemo $x' = x - (x \bmod 2^{\lfloor r/2 \rfloor})$. Sedaj, x' zadošča pogoju 2.3, zato je $\sqrt{x} - \sqrt{x'} \leq 1$. Poleg tega ima x' vse spodnje $\lfloor r/2 \rfloor$ bite enake 0, zato obstaja samo ena

$$2^{r+1-\lfloor r/2 \rfloor} \leq 4 \cdot 2^{r/2} \leq 4\sqrt{x}$$

od možnih vrednosti x' . To pomeni da lahko uporabimo tabelo, `sqrcttab`, ki shrani vrednost od $\lfloor \sqrt{x'} \rfloor$ za vsako možno vrednost spremenljivke x' . Bolj natančno, imamo

$$\text{sqrcttab}[i] = \left\lfloor \sqrt{i 2^{\lfloor r/2 \rfloor}} \right\rfloor.$$

Na ta način je `sqrcttab`[i] znotraj dveh \sqrt{x} za vsak $x \in \{i 2^{\lfloor r/2 \rfloor}, \dots, (i+1) 2^{\lfloor r/2 \rfloor} - 1\}$. Drugače povedano, vhodni niz $s = \text{sqrcttab}[x \gg \lfloor r/2 \rfloor]$ je bodisi enak $\lfloor \sqrt{x} \rfloor$, $\lfloor \sqrt{x} \rfloor - 1$, ali $\lfloor \sqrt{x} \rfloor - 2$. S spremenljivko s lahko določimo vrednost $\lfloor \sqrt{x} \rfloor$ s povečevanjem s dokler $(s+1)^2 > x$.

FastSqrt

```
int sqrt(int x, int r) {
    int s = sqrctab[x >> r/2];
    while ((s+1)*(s+1) <= x) s++; // executes at most twice
    return s;
}
```

Vendarle to deluje samo pri $x \in \{2^r, \dots, 2^{r+1} - 1\}$ in `sqrcttab` je posebna tabela, ki deluje samo za določeno vrednost $r = \lfloor \log x \rfloor$. Da to rešimo, lahko izračunamo $\lfloor \log n \rfloor$ drugačnih `sqrcttab` tabel, eno za vsako možno vrednost od $\lfloor \log x \rfloor$. Velikosti teh tabel oblikujejo eksponentno zaporedje, katerega največja vrednost je kvečjemu $4\sqrt{n}$, tako da skupna velikost vseh tabel je $O(\sqrt{n})$.

Kakorkoli, izkaže se, da ne potrebujemo več kot ene `sqrcttab` tabele; potrebujemo samo eno `sqrcttab` tabelo za vrednost $r = \lfloor \log n \rfloor$. Vsaka vrednost x z $\log x = r' < r$ je lahko *upgraded* z množenjem x z $2^{r-r'}$ in uporabo enačbe

$$\sqrt{2^{r-r'} x} = 2^{(r-r')/2} \sqrt{x}.$$

Količina $2^{r-r'} x$ je v obsegu $\{2^r, \dots, 2^{r+1} - 1\}$ zato lahko pogledamo njen kvadratni koren v `sqrcttab`. Sledeča koda dopolni to idejo za izračun $\lfloor \sqrt{x} \rfloor$ za vsa ne-negativna števila x v obsegu $\{0, \dots, 2^{30} - 1\}$ z uporabo tabele, `sqrcttab`, velikosti 2^{16} .

FastSqrt

```
int sqrt(int x) {
    int rp = log(x);
```

```

int upgrade = ((r-rp)/2) * 2;
int xp = x << upgrade; // xp has r or r-1 bits
int s = sqrtab[xp>>(r/2)] >> (upgrade/2);
while ((s+1)*(s+1) <= x) s++; // executes at most twice
return s;
}

```

Nekaj kar smo si vzeli za samoumevno je vprašanje kako izračunati $r' = \lfloor \log x \rfloor$. Spet, to je problem ki ga lahko rešimo z tabelo, `logtab`, velikosti $2^{r/2}$. V tem primeru je koda še posebej enostavna, ker je $\lfloor \log x \rfloor$ samo kazalo pomembnega 1 bita v binarni predstavitvi x . To pomeni, da za $x > 2^{r/2}$, lahko premaknemo v desno bite od x za $r/2$ pozicij, preden ga uporabimo za kazalo v `logtab`. Sledeča koda naredi to, z uporabo tabele `logtab` velikosti 2^{16} za izračun $\lfloor \log x \rfloor$ za vse x v obsegu $\{1, \dots, 2^{32} - 1\}$.

FastSqrt

```

int log(int x) {
    if (x >= halfint)
        return 16 + logtab[x>>16];
    return logtab[x];
}

```

Nazadnje, z namenom dopolnitve vključimo sledečo kodo ki inicializira `logtab` in `sqrttab`:

FastSqrt

```

void inittabs() {
    sqrtab = new int[1<<(r/2)];
    logtab = new int[1<<(r/2)];
    for (int d = 0; d < r/2; d++)
        Arrays.fill(logtab, 1<<d, 2<<d, d);
    int s = 1<<(r/4); // sqrt(2^(r/2))
    for (int i = 0; i < 1<<(r/2); i++) {
        if ((s+1)*(s+1) <= i < (r/2)) s++; // sqrt increases
        sqrtab[i] = s;
    }
}

```

Za povzetek, izračuni ki so nastali od `i2b(i)` metode lahko implementiramo v konstantnem času na besednem-RAM z uporabo $O(\sqrt{n})$ doda-

tnega spomina za shranjevanje `sqrttab` in `logtab` arrays. Te tabele lahko obnovimo ko `n` naraste ali se zmanjša za faktor ali dva in strošek te obnovitve je lahko amortiziran čez števila od `add(i, x)` and `remove(i)` operaciji, ki sta povzročili spremembo v `n` enako kot je strošek `resize()` analiziran v `ArrayStack` implementaciji.

2.7 Razprava in vaje

Večina podatkovnih struktur, opisanih v tem poglavju je del folklore. Njihove implementacije so stare tudi več kot 30 let. Na primer, implementacije skladov, vrst in dvojnih vrst so lahko generalizirajo v `ArrayStack`, `ArrayQueue` and `ArrayDeque` opisani v tej knjigi, razloži Knuth [?, Section 2.2.2]

Brodnik *et al.* [?] je prvi opisal `RootishArrayStack` in dokazal \sqrt{n} spodnjo omejenost, kot v 2.6.2. Prikazujejo tudi drugačne strukture, ki uporabljajo bolj sofisticirano izbiro velikosti bloka, zato da se izognejo računanju kvadratnih korenov v `i2b(i)` metodi. Znotraj njihove sheme, blok, ki vsebuje `i` je blok $\lfloor \log(i+1) \rfloor$, ki je indeks vodečega 1 bita v binarni reprezentaciji `i + 1`. Nekatere računalniške arhitekture imajo ukaz, ki izračuna indeks vodečega bita v integer-ju. V Java-i, `Integer` ima razred metodo `numberOfLeadingZeros(i)` s katero se lahko izračuna $\lfloor \log(i+1) \rfloor$.

Struktura sorodna `RootishArrayStack` je dvo-nivojski *tiered-vector of* Goodrich and Kloss [?]. Ta struktura omogoča `get(i, x)` in `set(i, x)` operacije v konstantnem času, operacije `add(i, x)` in `set(i, x)` pa v $O(\sqrt{n})$ času. Ti časi so podobni časom, ki jih zmore bolj previdna implementacija `RootishArrayStack` opisana v 2.11.

Naloga 2.1. V implementaciji `ArrayStack`, po prvem klicu operacije `remove(i)`, interno polje `a`, vsebuje `n + 1` non-`null` vrednost kljub dejstvu, da `ArrayStack` vsebuje samo `n` elementov. Kje se nahaja dodatna non-`null` vrednost? Razmislite kakšne so posledice te non-`null` vrednosti za nadzor pomnilnika v Java Runtime Environment-u.

Naloga 2.2. Metoda `addAll(i, c)` v `List` vstavi vse elemente iz `Collection c` v seznam na pozicijo `i`. (Metoda `add(i, x)` je poseben primer, kjer je `c = {x}`.) Razložite zakaj je za podatkovne strukture, opisane v tem

poglavju, neučinkovito implementirati `addAll(i, c)` z zaporednimi klici `add(i, x)`. Razvijte bolj učinkovito implementacijo.

Naloga 2.3. Razvijte *RandomQueue*. To je implementacija *Queue* vmesnika v kateri operacija `remove()` odstrani naključen element izmed vseh elementov, ki so trenutno v vrsti (Razmislite o *RandomQueue* kot o torbi, v katero lahko dodajamo elemente ali odstranimo naključen element.). Operacije `add(x)` in `remove()` naj se v *RandomQueue* izvajajo v konstantnem času.

Naloga 2.4. Razvijte *Treque* (trojna vrsta). To je implementacija vmesnika *List*, v katerem se operacije `get(i)` and `set(i, x)` izvajajo v konstantnem času, operacije `add(i, x)` in `remove(i)` pa v času

$$O(1 + \min\{i, n - i, |n/2 - i|\}) .$$

Z drugimi besedami, modifikacije so hitre, če so blizu kateremukoli koncu ali če so blizu sredine seznama.

Naloga 2.5. Implementirajte metodo `rotate(a, r)` tako da, "rotira" polje `a`, tako da je `a[i]` premik v `a[(i+r) mod a.length]`, za vsak $i \in \{0, \dots, a.length\}$.

Naloga 2.6. Implementirajte metodo `rotate(r)` tako da "rotira" seznam *List*, tako da element `i` postane element seznama na $(i + r) \bmod n$. Če se izvaja na *ArrayDeque* ali *DualArrayDeque*, potem naj se metoda `rotate(r)` izvaja v času $O(1 + \min\{r, n - r\})$.

Naloga 2.7. Popravite implementacijo *ArrayDeque* tako, da bo se premikanje, ki ga sprožijo operacije `add(i, x)`, `remove(i)`, and `resize()`, izvajalo hitreje kot `System.arraycopy(s, i, d, j, n)` metoda.

Naloga 2.8. Popravite implementacijo *ArrayDeque* tako, da ne uporablja `%` operatorja (na nekaterih sistemih počasna operacija). Namesto tega naj se posluži dejstva, če je `a.length` potenca 2, potem

$$k \% a.length = k \& (a.length - 1) .$$

(Operator `&` se tu smatra kot bitni.)

Naloga 2.9. Razvijte varijanto `ArrayDeque`, ki ne izvaja nobene modularne aritmetike. Namesto tega so vsi podatki v zaporednem bloku, urejeno znotraj polja. Ko podatki preplavijo začetek ali konec tega polja, se sproži prirejena operacija `rebuild()`. Amortizirana cena vseh operacij mora biti enaka kot `ArrayDeque`.

Namig: Ustreznost delovanja je tu povsem odvisna od tega, kako je implementirana operacija `rebuild()`. Želja je, da operacija `rebuild()` postavi podatkovno strukturo v stanje, kjer podatki ne morejo zbežati, proti kateremukoli koncu, dokler se ne izvede vsaj $n/2$ operacij.

Testirajte vašo implementacijo z primerjanjem performans z `ArrayDeque`. Optimizirajte vašo implementacijo (z uporabo `System.arraycopy(a, i, b, i, n)`) in preverite če lahko deluje bolje kot implementacija `ArrayDeque`.

Naloga 2.10. Razvijte verzijo `RootishArrayStack`, ki ima samo $O(\sqrt{n})$ porabljenega prostora in lahko izvaja operacije `add(i, x)`, `remove(i, x)` v $O(1 + \min\{i, n - i\})$ času.

Naloga 2.11. Razvijte verzijo `RootishArrayStack`, ki ima samo $O(\sqrt{n})$ porabljenega prostora in lahko izvaja operacije `add(i, x)`, `remove(i, x)` v $O(1 + \min\{\sqrt{n}, n - i\})$ času. (Namig, glej 3.3.)

Naloga 2.12. Razvijte verzijo `RootishArrayStack`, ki ima samo $O(\sqrt{n})$ porabljenega prostora in lahko izvaja operacije `add(i, x)`, `remove(i, x)` v $O(1 + \min\{i, \sqrt{n}, n - i\})$ času. (Namig, glej 3.3.)

Naloga 2.13. Razvijte `CubishArrayStack`. To je tri nivojska struktura, ki implementira `List` vmesnik, in porabi $O(n^{2/3})$ prostora. V tej strukturi se operacije `get(i)` in `set(i, x)` izvajajo v konstantnem času; medtem ko se operacije `add(i, x)` in `remove(i)` izvajajo $O(n^{1/3})$ amortizirano.

Poglavje 3

Povezani seznam

V tem poglavju nadaljujemo z implementacijo seznama `List`, s to razliko, da bomo uporabli podatkovne strukture, ki delujejo na osnovi kazalcev namesto polj. Strukture v tem poglavju so sestavljene iz vozlišč, ki vsebujejo elemente seznama. Z uporabo referenc (kazalcev) so vozlišča zaporedno povezana med seboj. Najprej bomo pogledali enostransko povezane seznane, s katerimi lahko implementiramo operacije `Skлада` in (FIFO) `Vrste`, ki se izvedejo v konstantnem času. Nato si bomo pogledali še obojestransko povezani seznam, s katerim lahko implementiramo `Deque` operacije tako, da se izvedejo v konstantnem času (`Deque` - vrsta pri kateri lahko dodajamo ter odstranjujemo elemente na začetku ali na koncu).

Povezani seznamami imajo prednosti in slabosti v primerjavi z implementacijo seznama `List` z uporabo polja. Največja slabost je ta, da izgubimo zmožnost, da lahko v konstantnem času dostopamo do kateregakoli elementa z uporabo metod `get(i)` ali `set(i, x)`. Namesto tega, se moramo sprehoditi po celotnem seznamu, element za elementom, dokler ne pridemo do `i`-tega elementa. Največja prednost pa je dinamičnost: z uporabo referenc vsakega vozlišča seznama `u`, lahko izbrišemo `u` ali vstavimo sosednje vozlišče vozlišču `u` v konstantnem času. To je vedno res ne glede na to, kje se nahaja vozlišče `u` v seznamu.

3.1 SLList: Enostransko povezani seznam

Enostransko povezani seznam `SLList` (singly-linked list) je zaporedje vozlišč `Nodes`. Vsako vozlišče `u` hrani vrednost `u.x` ter referenco `u.next` na naslednje vozlišče. Zadnje vozlišče `w` ima `w.next = null`

```

class Node {
    T x;
    Node next;
}
SLList

```

Za boljšo učinkovitost delovanja `SLList` uporablja spremenljivki `head` (glava) in `tail` (rep) za beleženje prvega ter zadnjega vozlišča. Za beleženje dolžine seznama, pa hrani še celoštevilsko spremenljivko `n`:

```

Node head;
Node tail;
int n;
SLList

```


Zaporedje ukazov Sklada in Vrste nad enostransko povezanim seznamom je prikazana na 3.1.

Enostransko povezani seznam lahko učinkovito implementira operaciji Sklada, to sta `push(x)` in `pop()`, s katerima dodajamo ter odstranjujemo elemente iz začetka seznama. Operacija `push(x)` kreira novo vozlišče `u` z vrednostjo `x`, nastavi `u.next` tako, da kaže na stari začetek seznama, novi začetek seznama pa postane `u`. Na koncu je potrebno še povečati vrednost števca vozlišč `n` za 1.

```

T push(T x) {
    Node u = new Node();
    u.x = x;
    u.next = head;
    head = u;
    if (n == 0)
        tail = u;
    n++;
}
SLList

```

Slika 3.1: Zaporedje ukazov Vrste (`add(x)` in `remove()`) ter Sklada (`pop()` in `push(y)`) nad enostransko povezanim seznamom.

```
return x;
}
```

Operacija `pop()` najprej preveri ali je enostransko povezani seznam prazen. Če ni prazen, odstrani začetno vozlišče tako, da nastavi spremenljivko, ki kaže na začetek vozišča na `head = head.next` in zmanjša spremenljivko `n` za 1. Poseben primer je odstranjevanje zadnjega vozlišča, v tem primeru postavimo `tail` na `null`:

```

SLList
T pop() {
    if (n == 0) return null;
    T x = head.x;
    head = head.next;
    if (--n == 0) tail = null;
    return x;
}
```

Časovna zahtevnost operacij `push(x)` in `pop()` je $O(1)$.

3.1.1 Operacije Vrste

Enostransko povezani seznam lahko implementira tudi operaciji FIFO ("prvi noter, prvi ven") vrste, to sta `add(x)` in `remove()`. Operacija brisanja elementa je identična operaciji `pop()`, odstrani se torej začetno vozlišče. Obe operaciji se izvedeta v konstantnem času.

```

SLList
T remove() {
    if (n == 0) return null;
    T x = head.x;
    head = head.next;
    if (--n == 0) tail = null;
    return x;
}

```

Dodajanje pa je izvedeno tako, da se novo vozlišče pripne na konec seznama. V večini primerov to naredimo tako, da postavimo `tail.next = u`, kjer je `u` novo nastalo vozlišče in vsebuje vrednost `x`. Paziti je treba na poseben primer, ki se zgodi, kadar je seznam prazen, `n = 0`. To pomeni, da je `tail = head = null`. V tem primeru `tail` in `head` nastavimo tako, da kažeta na `u`.

```

SLList
boolean add(T x) {
    Node u = new Node();
    u.x = x;
    if (n == 0) {
        head = u;
    } else {
        tail.next = u;
    }
    tail = u;
    n++;
    return true;
}

```

Obe operaciji, `add(x)` in `remove()`, se izvedeta v konstantnem času.

3.1.2 Povzetek

Sledeči izrek povzame zmožnosti enostransko povezanega seznama `SLList`:

Izrek 3.1. *Enostransko povezani seznam `SLList` implementira operacije vmesnika `Skлада in (FIFO) Vrste`. Operacije `push(x)`, `pop()`, `add(x)` in `remove()` se izvedejo v $O(1)$.*

Enostransko povezani seznam `SLList` implementira skoraj vse operacije Degue vrste. Edina manjkajoča operacija je odstranjevanje elementov iz konca enostransko povezanega seznama. Brisanje iz konca enojno povezanega seznama je težavno, saj moramo posodobiti vrednost `tail`, tako da kaže na vozlišče `w`, ki je predhodnik našega vozlišča `tail`. Naše vozlišče `w` izgleda tako `w.next = tail`. Na žalost pa je edina možnost da pridemo do vozlišča `w` ta, da se še enkrat sprehodimo čez celoten seznam, od začetka v vozlišču `head`, za kar pa potrebujemo $n - 2$ korakov.


3.2 `DLList`: Obojestransko povezan seznam

(obojestransko povezan seznam) je zelo podoben `SLList` le, da ima vsako vozlišče `u` v `DLList` referenco na dve vozlišči, `u.next`, ki mu sledi ter vozlišče `u.prev`, ki je pred njim.

```
class Node {  
    T x;  
    Node prev, next;  
}
```

Pri implementaciji `SLList`, smo ugotovili, da imamo kar nekaj posebnih primerov, na katere moramo paziti. Na primer, pri odstranjevanju zadnjega elementa iz `SLList` ali pa dodajanju elementa v prazen `SLList` moramo zagotoviti, da se `head` (glava) in `tail` (rep) pravilno posodobita. V `DLList` se število teh posebnih primerov znatno poveča. Morda najboljši način, da poskrbimo za vse te posebne primere v `DLList` je, da uvedemo `dummy` (navidezno) vozlišče. To je vozlišče brez vsebine, služi

Povezani seznam



Slika 3.2: DLList, ki vsebuje a,b,c,d,e.

pa kot vsebovalnik, čeprav ne vsebuje vozlišč; vsako vozlišče ima `next` in `prev`, kjer `dummy` služi kot vozlišče, ki sledi zadnjemu vozlišču in razpo-reja prvo vozlišče v seznamu. Tako so vozlišča obojestransko povezava v cikel, kot je prikazano v 3.2.

DLList

```
int n;  
Node dummy;  
DLList() {  
    dummy = new Node();  
    dummy.next = dummy;  
    dummy.prev = dummy;  
    n = 0;  
}
```

Iskanje vozlišče z določenim indeksom v DLList je enostavno; lahko bodisi začnemo pri glavi seznama (`dummy.next`) in se pomikamo naprej, ali pa začnemo pri repu seznama (`dummy.prev`) in se pomikamo nazaj. To nam omogoča, da dosežemo i -to vozlišče v času $O(1 + \min\{i, n - i\})$:

DLList

```
Node getNode(int i) {  
    Node p = null;  
    if (i < n / 2) {  
        p = dummy.next;  
        for (int j = 0; j < i; j++)  
            p = p.next;  
    } else {  
        p = dummy;  
        for (int j = n; j > i; j--)  
            p = p.prev;  
    }  
}
```

```

    }
    return p;
}

```

`get(i)` in `set(i,x)` operacije so prav tako enostavne. Najprej moramo najti `i`-to vozlišče, nato pa dobimo ali nastavimo njegovo vrednost `x`:

```

DLList
T get(int i) {
    return getNode(i).x;
}
T set(int i, T x) {
    Node u = getNode(i);
    T y = u.x;
    u.x = x;
    return y;
}

```

Čas izvajanja teh operacij je določen z strani časa, ki potrebujemo, da najdemo `i`-to vozlišče in je zato $O(1 + \min\{i, n - i\})$.

3.2.1 Dodajanje in odstranjevanje


Če imamo referenco na vozlišče `w` v `DLList` in želimo vstaviti vozlišče `u` pred `w`, potem je potrebno le nastaviti `u.next = w`, `u.prev = w.prev` ter `u.prev.next` in `u.next.prev`. (Glej 3.3.) Zahvaljujoč navideznem vozlišču nam ni treba skrbeti, ali vozlišči `w.prev` in `w.next` sploh obstajata.

```

DLList
Node addBefore(Node w, T x) {
    Node u = new Node();
    u.x = x;
    u.prev = w.prev;
    u.next = w;
    u.next.prev = u;
    u.prev.next = u;
    n++;
    return u;
}

```

Povezani seznam



Slika 3.3: Dodajanje vozlišča *u* pred vozlišče *w* v DLList.

Operacija seznama `add(i, x)` je trivialna za implementacijo. Najti moramo *i*-to vozlišče v DLList in nato vstavimo novo vozlišče *u*, ki vsebuje *x*, tik pred njim.

```

DLList
void add(int i, T x) {
    addBefore(getNode(i), x);
}

```

Edini nekonstantni del časa izvajanja časa izvajanja `add(i, x)`, je čas, ki ga potrebujemo, da najdemo *i*-to vozlišče (z `getNode(i)`). Tako se `add(i, x)` izvede v času $O(1 + \min\{i, n - i\})$.

Odstranjevanje vozlišča *w* iz DLList je enostavno. Potrebujemo samo nastaviti kazalec *w.next* in *w.prev* tako, da preskočijo vozlišče *w*. Uporaba navideznega vozlišča odpravi potrebo po upoštevanju posebnih primerov:

```

DLList
void remove(Node w) {
    w.prev.next = w.next;
    w.next.prev = w.prev;
    n--;
}

```

Operacija `remove(i)` je prav tako enostavna. Najdemo vozlišče z indeksom *i* in ga odstranimo:

```

DLList
T remove(int i) {
    Node w = getNode(i);
}

```

```
remove(w);  
return w.x;  
}
```

Edini dragi del te operacije je iskanje i -tega vozlišča z operacijo `getNode(i)`. `remove(i)` se torej izvede v času $O(1 + \min\{i, n - i\})$.

3.2.2 Povzetek

Naslednji izrek povzema uspešnost `DLList`:

Izrek 3.2. *`DLList` implementira vmesnik `List` (seznam). V tej izvedbi, je časovna zahtevnost operacij `get(i)`, `set(i, x)`, `add(i, x)` in `remove(i)` $O(1 + \min\{i, n - i\})$.*

Treba je omeniti, da če odmislimo ceno operacije `getNode(i)`, se vse operacije v `DLList` izvedejo v konstantnem času. Edina draga operacija v `DLList` je torej iskanje ustreznega vozlišča. Ko imamo dostop do ustreznega vozlišča, se dodajanje, odstranjevanje ali dostop do podatkov v tem vozlišču se izvede v konstantnem času.

To je v popolnem nasprotju z implementacijami `seznama` na osnovi polja 2; v teh izvedbi, lahko ustrezen element najdemo v konstantnem času. Vendar pa dodajanje ali odstranjevanje zahteva premikanje elementov v polju, kar pa načeloma ni operacija, ki se bi izvedla v konstantnem času.

Iz tega razloga, so povezani seznam primerni za primere, kjer lahko reference vozlišč pridobimo iz zunanjih virov. Primer za to je `LinkedHashSet` v Java Collection Framework, v kateri je sklop elementov shranjen v obojestransko povezani seznam in vozlišča obojestransko povezanega seznama se hranijo v razpršeni tabeli (obravnavano v 5). Pri odstranjevanju iz `LinkedHashSet` se razpršena tabela uporabi pri iskanju ustreznega vozlišča v konstantnem času in nato se vozlišče izbriše (tudi v konstantnem času).

3.3 SEList: Prostorsko učinkovit povezan seznam

Ena od slabosti povezanih seznamov (poleg časa, ki je potreben za dostop do elementov, ki so globoko v seznamu) je njihova poraba prostora. Vsak člen v `DLList` zahteva dodatni dve referenci do naslednjega in prejšnjega člena v seznamu. Dve polji v `Node` sta namenjeni vzdrževanju seznama, le eno polje pa shrambi podatkov.

`SEList` (Prostorsko-učinkovit seznam) zmanjša porabo prostora v duhu preproste ideje. Namesto, da shrani posamezne elemente v `DLList`, shrani kar tabelo večih elementov. Podrobneje, `SEList` je parameteriziran s pomočjo *bloka velikosti* `b`. Vsak posamezen člen v `SEList` hrani blok, ki vsebuje `b + 1` elementov.

Zaradi kasnejših razlogov bo lažje, če lahko izvedemo `Deque` operacijo na vsakem bloku. Izbrali bomo podatkovno strukturo `BDeque` (omejen `Deque`), izpeljano iz strukture `ArrayDeque` structure described in 2.4. `BDeque` se le malo razlikuje od `ArrayDeque`. Ko se `BDeque` ustvari, je velikost tabele `a` konstantna in sicer `b + 1`. Pomembna lastnost podatkovne strukture `BDeque` je možnost dodajanja in odstranjevanja od spredaj ali zadaj v konstantnem času. To je uporabno, ker se elementi prenašajo iz enega bloka v drugega.

```

SEList
class BDeque extends ArrayDeque<T> {
    BDeque() {
        super(SEList.this.type());
        a = newArray(b+1);
    }
    void resize() { }
}

```

`SEList` postane dvostransko povezan seznam blokov:

```

SEList
class Node {
    BDeque d;
    Node prev, next;
}

```



```
int n;
Node dummy;
```

3.3.1 Prostorske zahteve

SEList ima zelo tesne omejitve glede števila elementov v bloku. Razen zadnjega bloka vsebujejo najmanj $b - 1$ in največ $b + 1$ elementov. To pomeni, če SEList vsebuje n elementov, ima največ

$$n/(b - 1) + 1 = O(n/b)$$

blokov. Pri BDeque vsak blok vsebuje tabelo velikosti $b + 1$, ampak vsi razen zadnjega elementa potrebujejo največ konstantno prostora. Prav tako je konstanten tudi neporabljen prostor bloka. To pomeni, da je poraba prostora podatkovne strukture SEList le $O(b + n/b)$. Z izbiro vrednosti b znotraj kontantnega faktorja \sqrt{n} , lahko prostorsko potrato približamo spodnji meji \sqrt{n} predstavljeno v poglavju 2.6.2.

3.3.2 Iskanje elementov

Izziv pri podatkovni strukturi SEList je iskanje elementa z indeksom i . Pri čemer lokacija elementa predstavlja 2 dela:

1. Člen u , ki vsebuje blok z indeksom i ; in
2. indeks elementa j znotraj bloka.

```
class Location {
    Node u;
    int j;
    Location(Node u, int j) {
        this.u = u;
        this.j = j;
    }
}
```

Pri iskanju bloka, ki vsebuje določen element uporabljamo isti postopek kot pri strukturi `DLList`. Lahko začnemo spredaj in potujemo naprej, ali pa začnemo zadaj in potujemo nazaj, do iskanega člena. Edina razlika je, da pri tej strukturi pri vsakem členu preskočimo celoten blok elementov.

```

SEList
Location getLocation(int i) {
    if (i < n/2) {
        Node u = dummy.next;
        while (i >= u.d.size()) {
            i -= u.d.size();
            u = u.next;
        }
        return new Location(u, i);
    } else {
        Node u = dummy;
        int idx = n;
        while (i < idx) {
            u = u.prev;
            idx -= u.d.size();
        }
        return new Location(u, i-idx);
    }
}

```

Pomembno je, da si zapomnimo, da razen enega bloka, vsak blok vsebuje najmanj $b-1$ elementov, torej smo z vsakim korakom pri iskanju $b-1$ elementov bližje iskanemu elementu. Če iščemo od začetka naprej, lahko dosežemo iskani člen v $O(1 + (n-i)/b)$ korakih. Algoritem je odvisen od indeksa i , torej je čas iskanja z indeksom i enak $O(1 + \min\{i, n-i\}/b)$.

Ko enkrat vemo kako najti element z indeksom i , lahko z `get(i)` in `set(i,x)` operacijami dobimo ali nastavimo element z poljubnim indeksom v določenem bloku:

```

SEList
T get(int i) {
    Location l = getLocation(i);
    return l.u.d.get(l.j);
}

```

```

}
T set(int i, T x) {
    Location l = getLocation(i);
    T y = l.u.d.get(l.j);
    l.u.d.set(l.j, x);
    return y;
}

```

Čas izvajanja teh operacij sta odvisni od časa iskanja elementa, torej imata enako časovno zahtevnost $O(1 + \min\{i, n - i\}/b)$.

3.3.3 Dodajanje elementov

Dodajanje elementov v podatkovno strukturo `SEList` je malo bolj kompleksno. Preden se lotimo splošnih primerov, si pogledjmo najlažjo operacijo, `add(x)`, pri kateri se `x` doda na konec seznama. Če je zadnji blok poln (ali ne obstaja, ker še nimamo blokov), potem najprej naredimo nov blok in dodamo v seznam blokov. Sedaj, ko obstaja blok in ni prazen, dodamo `x` zadnjemu bloku.


```

SEList
boolean add(T x) {
    Node last = dummy.prev;
    if (last == dummy || last.d.size() == b+1) {
        last = addBefore(dummy);
    }
    last.d.add(x);
    n++;
    return true;
}

```

Dodajanje se malo bolj zakomplicira pri dodajanju v notranjost seznama s pomočjo metode `add(i, x)`. Najprej lociramo `i` da dobimo člen `u` čigar blok vsebuje `i`ti element. Problem nastane, ker hočemo vstaviti element `x` v blok ukjer blok `u` že vsebuje `b + 1` elementov, torej je poln in ni prostora za `x`.

Naj `u0, u1, u2, ...` označujejo `u`, `u.next`, `u.next.next`, in tako naprej. Preiščemo `u0, u1, u2, ...` v iskanju člena, ki ima prostor za `x`. Možne so (glej 3.4):



Slika 3.4: 3 različni scenariji, ki se lahko zgodijo pri dodajanju elementa x v SE-List. (SEList ima velikost bloka $b = 3$.)

1. Člen u_r , čigar blok ni poln, najdemo hitro ($v \ r + 1 \leq b$ korakov). V tem primeru izvedemo r zamenjav elementa iz trenutnega v naslednji blok, da prazen prostor v u_r postane prazen prostor v u_0 . Nato vstavimo x v blok u_0 .
2. Prav tako hitro ($v \ r + 1 \leq b$ korakov) pridemo do konca seznama blokov. V tem primeru preprosto dodamo nov prazen blok na konec seznama in nadaljujemo s 1. scenarijem.
3. Po b korakov ne nardemo bloka, ki ni poln. V tem primeru, je u_0, \dots, u_{b-1} zaporedje b blokov, ki vsebujejo vsak po $b + 1$ elementov. Vstavimo nov blok u_b na konec zaporedja in *razširimo* prvotnih $b(b + 1)$ elementov tako, da vsak blok u_0, \dots, u_b vsebuje natanko b elementov. Sedaj blok u_0 vsebuje le b elementov in ima prostor za x , ki ga vstavljamo.

```
SEList
void add(int i, T x) {
    if (i == n) {
```

```


    add(x);
    return;
}
Location l = getLocation(i);
Node u = l.u;
int r = 0;
while (r < b && u != dummy && u.d.size() == b+1) {
    u = u.next;
    r++;
}
if (r == b) {           // b blocks each with b+1 elements
    spread(l.u);
    u = l.u;
}
if (u == dummy) {      // ran off the end - add new node
    u = addBefore(u);
}
while (u != l.u) {     // work backwards, shifting elements
    u.d.add(0, u.prev.d.remove(u.prev.d.size()-1));
    u = u.prev;
}
u.d.add(l.j, x);
n++;
}

```

Čas izvajanja operacije $\text{add}(i, x)$ je različen, glede na to, kateri od treh scenarijev zgoraj se zgodi. Primera 1 in 2 vsebujeta preiskovanje in predstavljane elementov pri največ b b blokkih, torej je časovna zahtevnost $O(b)$. Primer 3 vsebuje $\text{spread}(u)$ metodo, ki premakne $b(b+1)$ elementov, kar vzame $O(b^2)$ časa. Če ignoriramo ceno 3. scenarija (ki ga bomo upoštevali kasneje v amortizaciji), to pomeni, da je celotna časovna zahtevnost lociranja i ja in izvajanja vstavljanja elementa x $O(b + \min\{i, n - i\}/b)$.

3.3.4 Odstranjevanje elementov

Odstranjevanje elementa iz podatkovne strukture `SEList` je podobno dodajanju elementov vanjo. Najprej lociramo vozlišče u , ki vsebuje element z indeksom i . Zdaj moramo biti pripravljeni na primer, ko elementa ne



Slika 3.5: Trije scenariji, ki se zgodijo ob odstranjevanju predmeta x znotraj podatkovne strukture `SEL` ist. (Velikost bloka tega `SEL` ista je $b = 3$.)

moremo zbrisati iz vozlišča u , ne da bi u -jev blok postal manjši od $b - 1$.

Ponovno naj vozlišča u_0, u_1, u_2, \dots označujejo u , $u.next$, $u.next.next$ in tako naprej. Med vozlišči poiščemo tisto, iz katerega si lahko sposodimo element, s katerim bo velikost bloka vozlišča u_0 vsaj $b - 1$. To lahko storimo na 3 načine (3.5):

1. Hitro (v $r + 1 \leq b$ korakih) najdemo vozlišče, čigar blok vsebuje več kot $b - 1$ elementov. V tem primeru izvedemo r menjav elementa iz enega bloka v prejšnji blok, tako da dodaten element v u_r postane dodaten element v u_0 . Nato lahko odstranimo ustrezen element iz bloka vozlišča u_0 .
2. Hitro (v $r + 1 \leq b$ korakih) se sprehajamo s konca seznama blokov. V tem primeru je u_r zadnji blok, zato zanj ni nujno, da vsebuje vsaj $b - 1$ elementov. Nadaljujemo kot zgoraj. Sposodimo si element iz u_r in iz njega naredimo dodaten element v u_0 . Če blok vozlišča u_r zaradi te menjave postane prazen, ga odstranimo.
3. Po b korakih ni več bloka, ki bi vseboval več kot $b - 1$ elementov.

V tem primeru je u_0, \dots, u_{b-1} zaporedje blokov b , kjer vsak izmed njih vsebuje $b - 1$ elementov. Teh $b(b - 1)$ elementov združimo v u_0, \dots, u_{b-2} , tako da vsak izmed novih $b - 1$ blokov vsebuje natančno b elementov, vozlišče u_{b-1} , ki je zdaj prazno, pa zberemo. Blok vozlišča u_0 zdaj vsebuje b elementov, zato lahko iz njega odstranimo ustrezen element.

`codeimportods/SEList.remove(i)`

Operaciji `add(i, x)` in `remove(i)` imata enak čas izvajanja, $O(b + \min\{i, n - i\}/b)$, če ne poštujemo stroška metode `gather(u)`, ki jo uporabimo v 3. načinu odstranjevanja.

3.3.5 Amortizirana analiza širjenja in združevanja

Razmislimo o strošku metod `gather(u)` in `spread(u)`, ki sta lahko izvršeni preko metod `add(i, x)` in `remove(i)`. Metodi sta sledeči:

```
SEList
void spread(Node u) {
    Node w = u;
    for (int j = 0; j < b; j++) {
        w = w.next;
    }
    w = addBefore(w);
    while (w != u) {
        while (w.d.size() < b)
            w.d.add(0, w.prev.d.remove(w.prev.d.size() - 1));
        w = w.prev;
    }
}
```

```
SEList
void gather(Node u) {
    Node w = u;
    for (int j = 0; j < b - 1; j++) {
        while (w.d.size() < b)
            w.d.add(w.next.d.remove(0));
        w = w.next;
    }
```

```

    }
    remove(w);
}

```

Čas izvajanja vsake metode je odvisen od dveh ugnezenih zank. Obe, notranja in zunanja zanka, se izvršita največ $b + 1$ krat. Celoten čas izvajanja vsake metode je tako $O((b + 1)^2) = O(b^2)$. Ne glede na vse, naslednji izrek dokaže, da se metodi izvršita na največ enem izmed mnogih b klicev metod $\text{add}(i, x)$ ali $\text{remove}(i)$.

Lema 3.1. *Če je ustvarjena prazna podatkovna struktura SEList in je izvršena katera koli ponovitev od $m \geq 1$ klicev metod $\text{add}(i, x)$ in $\text{remove}(i)$, potem je celoten čas izvajanja vseh klicov metod $\text{spread}()$ in $\text{gather}()$ enak $O(bm)$.*

Dokaz. Uporabili bomo potencialno metodo amortiziranih analiz. Predpostavimo, da je vozlišče u *ranljivo*, če njegov blok ne vsebuje b elementov (u je ali zadnje vozlišče ali pa vsebuje $b - 1$ ali $b + 1$ elementov). Vozlišče je *robustno*, če njegov blok vsebuje b elementov. *Potencial* podatkovne strukture SEList določimo na podlagi števila ranljivih vozlišč, ki jih vsebuje. Osredotočili se bomo samo na metodo $\text{add}(i, x)$ in njeno relacijo s številom klicev metode $\text{spread}(u)$. Analiza metod $\text{remove}(i)$ in $\text{gather}(u)$ je identična.

Opazimo, da se v primeru, ko se pri metodi $\text{add}(i, x)$ izvrši scenarij 1, spremeni velikost bloka samo enemu vozlišču, vozlišču u_r . Zato se tudi največ eno vozlišče, vozlišče u_r , spremeni iz robustnega v ranljivo, ostala vozlišča pa ohranijo velikost, tako da se število ranljivih vozlišč poveča za 1. Sledi, da se potencial podatkovne strukture SEList poveča za največ 1 v scenarijih 1 in 2.

Če se izvrši scenarij 3, se izvrši, ker so vsa vozlišča u_0, \dots, u_{b-1} ranljiva. Nato se pokliče metoda $\text{spread}(u_0)$, ki b ranljivih vozlišč zamenja z $b + 1$ robustnimi vozlišči. Na koncu v blok vozlišča u_0 dodamo x , ki vozlišče naredi ranljivo. V splošnem se potencial zniža za $b - 1$.

Potencial (ki šteje število ranljivih vozlišč) ni nikoli manjši od 0. Vsakič, ko se izvrši scenarij 1 ali scenarij 2, se potencial zviša za največ 1. Vsakič, ko se zgodi scenarij 3, se potencial zniža za $b - 1$. V vsakem primeru scenarija 3 je vsaj $b - 1$ primerov scenarija 1 ali scenarija 2. Tako je za vsak klic metode $\text{spread}(u)$ vsaj b klicev metode $\text{add}(i, x)$. To potrди dokaz. \square

3.3.6 Povzetek

Sledeči izrek povzema učinkovitost podatkovne strukture `SEList`:

Izrek 3.3. Podatkovna struktura `SEList` implementira `List` vmesnik. Čeprav se ne ozira na stroška klicev metod `spread(u)` in `gather(u)`, `SEList` z `b` velikostjo bloka podpira operacije

- `get(i)` in `set(i, x)` v času $O(1 + \min\{i, n - i\}/b)$ na operacijo; in
- `add(i, x)` in `remove(i)` v času $O(b + \min\{i, n - i\}/b)$ na operacijo.

Če začnemo s praznim `SEList`, bo skupno porabljen čas med vsemi klici metod `spread(u)` in `gather(u)` za vsako ponovitev od m `add(i, x)` in `remove(i)` operacij enak $O(bm)$.

Prostor (merjen v besedah)¹ porabljen za podatkovno strukturo `SEList`, ki hrani `n` elementov je $n + O(b + n/b)$.

`SEList` je kompromis med podatkovnima strukturama `ArrayList` in `DLList`, kjer je njuna relativna mešanica odvisna od bloka velikosti `b`. Pri skrajnosti `b = 2`, vsako vozlišče v `SEList` (in tudi v `DLList`) hrani največ 3 vrednosti. Pri drugi skrajnosti `b > n`, so vsi elementi shranjeni v eni tabeli, tako kot pri `ArrayList`. Med tema skrajnostma je kompromis v času, ki je potreben za dodajanje ali odstranjevanje elementa in časom, ki je potreben za lociranje točno določenega predmeta.

3.4 Razprave in vaje

Tako enosmerno-povezani kot dvosmerno-povezani seznammi so uveljavljene tehnike, uporabljene v programih že več kot 40 let. O njih na primer razpravlja Knuth [?, Sections 2.2.3–2.2.5]. Tudi podatkovna struktura `SEList` je uveljavljena kot dobro poznana vaja podatkovnih struktur. `SEList` včasih imenujemo tudi *Odvit povezan seznam* [?].

Na prostoru v dvosmerno-povezanem seznamu lahko prihranimo z uporabo t.i. XOR-seznamov. V XOR-seznamu vsako vozlišče `u` vsebuje samo en kazalec, imenovan `u.nextprev`, ki vsebuje bitna XOR kazalca

¹Poglavje 1.4 za razlago o merjenju spomina.

`u.prev` in `u.next`. Seznam potrebuje za delovanje dva kazalca, eden kaže na `dummy` vozlišče, drug pa na `dummy.next` (prvo vozlišče, ali `dummy` vozlišče, če je seznam prazen). Ta tehnika izrablja dejstvo, da če imamo dva kazalca na `u` in `u.prev`, lahko izluščimo `u.next` s pomočjo naslednje formule

$$u.next = u.prev \wedge u.nextprev .$$

(Tukaj nam operator \wedge izračuna bitni XOR dveh argumentov.) Ta tehnika programsko kodo zakomplicira in implementacija v vseh programskih jezikih, kot je na primer Java ali Python, ki imajo mehanizme za sproščanje pomnilnika (garbage collector) ni možna. Tukaj podamo dvosmerno povezan seznam, ki za delovanje potrebuje samo en kazalec na vozlišče.

—including Java— Za referenco o podrobnejši razpravi XOR seznamov si poglej članek Sinhe [?].

Naloga 3.1. Zakaj ni možna uporaba praznega vozlišča v `SLList` za izogib posebnih primerov, ki se zgodijo pri operacijah `push(x)`, `pop()`, `add(x)`, and `remove()`?

Naloga 3.2. Napišite `SLList` (enosmerno-povezan seznam) metodo `secondLast()`, ki vrne predzadnji element v `SLList`. Metodo implementirajte brez uporabe članovske spremenljivke `n`, ki skrbi za velikost seznama.

Naloga 3.3. Na enosmerno-povezanem seznamu implementirajte naslednje `List` operacije: `get(i)`, `set(i, x)`, `add(i, x)` in `remove(i)`. Vse metode se naj izvedejo v $O(1 + i)$ časovni zahtevnosti.

Naloga 3.4. Na enosmerno-povezanem seznamu `SLLIST` implementirajte metodo `reverse()`, ki obrne vrstni red elementov v seznamu. Metoda naj teče v $O(n)$ časovni zahtevnosti. Ni dovoljena uporaba rekurzije in implementacija z drugimi časovnimi strukturami. Prav tako ni dovoljeno ustvarjati nova vozlišča.

Naloga 3.5. Napišite metodo za enosmerno `SLList` in dvosmerno `DLList` povezan seznam `checkSize()`. Metoda naj se sprehodi skozi seznam in prešteje število vozlišč. Če se prešteto število vozlišč ne ujema z vrednostjo shranjeno v spremenljivki `n`, naj metoda vrže izjemo. V primeru da se števila ujemata, metoda ne vrača ničesar.

Naloga 3.6. Ponovno napišite kodo za `addBefore(w)` operacijo, ki ustvari novo vozlišče `u` in ga doda v dvosmerno-povezan seznam tik pred vozliščem `w`. Tudi, če se vaša koda ne popolnoma ujema s kodo iz te knjige, je metoda še vseeno lahko pravilna. Najbolje, da metodo stestirate in preverite.

Z naslednjimi vajami bomo izvajali manipulacije na dvosmerno-povezanih seznamih. Vse vaje morate dokončati brez dodeljevanja novih vozlišč ali začasnih seznamov. Vse naloge se lahko rešijo s spreminjanjem vrednosti `prev` in `next` v že obstoječih vozliščih.

Naloga 3.7. Napišite metodo za dvosmerno-povezan seznam `isPalindrome()`, ki vrne `true`, če je seznam *palindrom*, npr., element na poziciji `i` je enak elementu na poziciji `n - i - 1` za vsak $i \in \{0, \dots, n - 1\}$. Metoda se naj izvede v $O(n)$ časovni zahtevnosti.

Naloga 3.8. Napišite novo metodo `rotate(r)`, ki obrne dvosmerno-povezan seznam tako, da element na poziciji `i` postane element $(i + r) \bmod n$. Ta metoda se običajno izvaja v $O(1 + \min\{r, n - r\})$ časovni zahtevnosti in ne spreminja vozlišč v seznamu.

Naloga 3.9. Napišite metodo `truncate(i)`, ki odseka dvojno-povezan seznam na poziciji `i`. Po izvedbi metode naj bo velikost seznama `i`, vsebuje pa naj samo elemente na intervalu $0, \dots, i - 1$. Metoda naj vrne dvojno-povezan seznam `DLList` in vsebuje elemente na intervalu `i, \dots, n - 1`. Metoda naj se izvede v $O(\min\{i, n - i\})$ časovni zahtevnosti.

Naloga 3.10. Napišite metodo dvojno-povezanega seznama `DLList absorb(12)`, ki za vhodni parameter prejme dvojno-povezan seznam `DLList 12`, ter sprazni njegovo vsebino in jo pripne na konec svojega seznama. Napríklad, če `11` vsebuje `a, b, c` in `12` vsebuje `d, e, f`, po klicu `11.absorb(12)` `11` vsebuje `a, b, c, d, e, f`, `12` pa bo prazen.

Naloga 3.11. Napišite metodo `deal()`, ki iz pod. strukture `DLList` odstrani vse elemente z lihimi indeksi in vrne `DLList`, ki vsebuje izbrišane elemente. Napríklad, če `11` vsebuje `a, b, c, d, e, f`, potem bo po klicu `11.deal()` vseboval `a, c, e`, metoda pa bo vrnila seznam, ki vsebuje elemente `b, d, f`.

Naloga 3.12. Napišite metodo `reverse()`, ki obrne vrstni red elementov v pod. strukturi `DLList`.

Naloga 3.13. V tej vaji boste implementirali urejanje pod. strukture `DLList` z zlivanjem, kot je opisano v poglavju 11.1.1. Da bo končna implementacija sposobna urediti katerikoli `DLList` z elementi, ki implementirajo `Comparable`, primerjavo med elementi v vaši implementaciji izvedite z metodo `compareTo(x)`.

1. Napišite metodo pod. strukture `DLList` `takeFirst(12)`, ki odstrani prvo vozlišče iz 12 ter ga doda na konec seznama, nad katerim je bila metoda klicana. Metoda je enakovredna klicu `add(size(), 12.remove(0))`, vendar pri tem ne ustvari novega vozlišča.
2. Napišite statično metodo pod. strukture `DLList` `merge(11, 12)`, ki kot argument dobi dva urejena seznama 11 in 12, ju združi ter vrne nov urejen seznam. Seznama 11 ter 12 se v metodi izpraznita. Na primer, če 11 vsebuje a, c, d in 12 vsebuje b, e, f , metoda vrne nov seznam, ki vsebuje a, b, c, d, e, f .
3. Napišite metodo pod. strukture `DLList` `sort()`, ki uredi elemente v seznamu z uporabo urejanja z zlivanjem. Ta rekurzivni algoritem deluje tako:
 - (a) Če je velikost seznama 0 ali 1, je seznam urejen. V nasprotnem primeru...
 - (b) Z uporabo metode `truncate(size()/2)`, razdeli seznam v dva seznama 11 in 12, ki sta približno enake velikosti.
 - (c) Rekurzivno uredi 11.
 - (d) Rekurzivno uredi 12.
 - (e) Združi 11 in 12 v en urejen seznam.

Naslednje vaje so naprednejše ter zahtevajo jasno razumevanje kaj se dogaja z najmanjšo vrednostjo shranjeno v skladu ali vrsti, ko dodajamo ter odstranjujemo elemente.

Naloga 3.14. Zasnuj ter implementiraj podatkovno strukturo `MinStack`, ki hrani primerljive elemente in podpira skladovne operacije `push(x)`,

`pop()` ter `size()`. Poleg tega podpira tudi operacijo `min()`, ki vrne trenutno najmanjšo vrednost v skladu. Vse operacije naj se izvedejo v konstantnem času.

Naloga 3.15. Zasnuj ter implementiraj podatkovno strukturo `MinQueue`, ki hrani primerljive elemente in podpira operacije vrste: `add(x)`, `remove()` in `size()`. Poleg tega vsebuje tudi operacijo `min()`, ki vrne trenutno najmanjšo vrednost v vrsti. Vse operacije naj se izvedejo v konstantnem amortiziranem času.

Naloga 3.16. Zasnuj ter implementiraj podatkovno strukturo `MinDeque`, ki hrani primerljive elemente in podpira operacije obojestranske vrste: `addFirst(x)`, `addLast(x)`, `removeFirst()`, `removeLast()` in `size()`. Poleg tega vsebuje tudi operacijo `min()`, ki vrne trenutno najmanjšo vrednost v obojestranski vrsti. Vse operacije nase se izvedejo v konstantnem amortiziranem času.

Naslednje vaje preverijo razumevanje implementacije in analize prostorsko učinkovitega povezanega seznama(`SEList`).

Naloga 3.17. Dokaži, da se operacije pod. strukture `SEList` uporabljene kot sklad (`SEList` spreminjata le operaciji $\text{push}(x) \equiv \text{add}(\text{size}(), x)$ in $\text{pop}() \equiv \text{remove}(\text{size}() - 1)$), izvedejo v konstantnem amortiziranem času neodvisno od vrednosti b .

Naloga 3.18. Zasnuj ter implementiraj različico pod. strukture `SEList`, ki izvede vse operacije pod. strukture `DLList` v konstantnem amortiziranem času na vsako operacijo, neodvisno od vrednosti b .

Naloga 3.19. Kako bi uporabil bitno operacijo ekskluzivni ali(XOR) za zamenjavo vrednosti dveh celoštevilskih(`int`) spremenljivk brez, da bi uporabil tretjo spremenljivko?

g

Poglavje 4

Preskočni seznam

V tem poglavju bomo govorili o lepi podatkovni strukturi: preskočnem seznamu, ki ima veliko možnosti uporabe. Z uporabo preskočnega seznama lahko implementiramo `List`, ki ima časovne zahtevnosti operacij `get(i)`, `set(i, x)`, `add(i, x)`, in `remove(i)` $O(\log n)$. Prav tako lahko implementiramo `SSet`, v katerem vse operacije potrebujejo $O(\log n)$ pričakovanega časa.

Učinkovitost preskočnega seznama je povezana z njegovo naključnostjo. Ko je nov element dodan preskočnemu seznamu, ta uporabi metodo metanja kovanca za določitev višine novega elementa. Učinek preskočnega seznama je odvisen od pričakovanih izvajanj in dolžine poti. To pričakovanje pa je povezano z uporabo metode meta kovanca. V implementaciji je metoda meta kovanca simulirana z uporabo generatorja naključnih števil.

4.1 Osnovna struktura

Konceptualno je preskočni seznam zaporedje enojno povezanih seznamov L_0, \dots, L_h . Vsak seznam L_r vsebuje podniz elementov v L_{r-1} . Začnimo z vhodnim seznamom L_0 , ki vsebuje n elementov in naredimo L_1 iz L_0 , L_2 iz L_1 , in tako naprej. Elementi v L_r so pridobljeni z metanjem kovanca za vsak element, x , v L_{r-1} in dodajo x v L_r , če kovanec "pokaže" glavo. To delamo, dokler ne naredimo praznega seznama L_r . Primer preskočnega seznama je prikazan na sliki 4.1.


Za vsak element x , v preskočnem seznamu imenujemo *višina* x največjo

vrednost r , kjer se x pojavi v L_r . Tako imajo na primer elementi, ki se pojavijo samo v L_0 , višino 0. Če pomislimo, ugotovimo, da je višina x ustreza naslednjemu eksperimentu: Mečimo kovanec tako dolgo, dokler ne bo pokazal cifre. Kolikokrat je pokazal glavo? Odgovor, ne presenetljivo, je, da je pričakovana višina vozlišča enaka 1. (Pričakovali smo, da bomo kovanec vrgli dvakrat, da dobimo cifro, vendar nismo šteli zadnjega meta). *Višina preskočnega seznama* je višina njegovega najvišjega vozlišča.

Natančneje, za izdelati pot iskanja za vozlišče u v L_0 , začnemo pri stražarju w v L_h . Nato pregledamo $w.next$. Če $w.next$ vsebuje element, ki se pojavi pred u v L_0 , nastavimo $w = w.next$, sicer se premaknemo navzdol in nadaljujemo iskanje pojavitve w v seznamu L_{h-1} . Postopek ponavljamo dokler na dosežemo predhodnika od u v L_0 .

Lema 4.1. *Pričakovana dolžina poti iskanja za vsako vozlišče u v L_0 je največ $2\log n + O(1) = O(\log n)$.*

88



Slika 4.2: The search path for the node containing 4 in a skiplist.

kazalcev `next`, kjer `u.next[i]` kaže na naslednika `u`-ja v seznamu L_i . Na ta način je podatek `x` v vozlišču referenciran samo enkrat, čeprav se `x` pojavlja v različnih seznamih.

SkiplistSSet

```
class Node<T> {
    T x;
    Node<T>[] next;
    Node(T ix, int h) {
        x = ix;
        next = Array.newInstance(Node.class, h+1);
    }
    int height() {
        return next.length - 1;
    }
}
```

V naslednjih dveh podpoglavjih bomo govorili o dveh različnih uporabah preskočnih seznamov. Pri obeh je L_0 shranjena glavna struktura (seznam elementov ali sortiran niz elementov). Glavna razlika med tema dvema strukturama je v načinu premikanja po poti iskanja; drugače povedano, razlikujeta se v tem, kako se odločajo, ali gre pot iskanja do L_{r-1} ali le do L_r .

4.2 SkipListSSet: Učinkovit SSet

SkipListSSet uporablja preskočni seznam za implementirati SSet vmesnik. Ko ga uporabljamo na ta način, so v seznamu L_0 shranjeni elementi SSet-a v urejenem vrstnem redu. Metoda `find(x)` deluje tako, da sledi poti iskanja za najmanjšo vrednostjo y , kjer je $y \geq x$:

```

SkipListSSet
Node<T> findPredNode(T x) {
    Node<T> u = sentinel;
    int r = h;
    while (r >= 0) {
        while (u.next[r] != null && compare(u.next[r].x, x) < 0)
            u = u.next[r];    // go right in list r
        r--;                  // go down into list r-1
    }
    return u;
}
T find(T x) {
    Node<T> u = findPredNode(x);
    return u.next[0] == null ? null : u.next[0].x;
}

```

Sledenje poti iskanja za y je preprosto: ko se nahajamo v določenem vozlišču u v L_r , pogledamo v desno z $u.next[r].x$. Če je $x > u.next[r].x$, se premaknemo za eno mesto v desno v L_r ; sicer se premaknemo navzdol v L_{r-1} . Vsak korak (desno ali navzdol) v takem iskanju potrebuje konstanten čas; potemtakem, po 4.1, je pričakovani čas izvajanja `find(x)` enak $O(\log n)$.

Preden lahko dodamo element v SkipListSSet, potrebujemo metodo, ki nam bo simulirala met kovanca za določitev višine k novega vozlišča. To naredimo tako, da si izberemo poljubno število z in štejemo število zaporednih enic v dvojiškem zapisu števila z .¹

¹Ta metoda ne ponazarja popolnoma eksperiment metanja kovanca saj bo vrednost k vedno manjša od števila bitov v `int`. Kakorkoli, to bo imelo malenkosten vpliv dokler ne bo število elementov v strukturi veliko večje kot $2^{32} = 4294967296$.

```

int pickHeight() {
    int z = rand.nextInt();
    int k = 0;
    int m = 1;
    while ((z & m) != 0) {
        k++;
        m <= 1;
    }
    return k;
}

```


Pri izvedbi metode `add(x)` v `SkiplistSSet` smo najprej poiskali `x` in ga nato dodali v več seznamov L_0, \dots, L_k , kjer je `k` izbran s pomočjo `pickHeight()` metode. Najlažji način za narediti to je s pomočjo polja, `sklad`, ki hrani sled vozlišč, kjer se je pot iskanja spustila iz seznama L_r v L_{r-1} . Natančneje, `sklad[r]` je vozlišče v L_r kjer se je pot iskanja nadaljevala en nivo nižje, v seznamu L_{r-1} . Vozlišča, ki smo jih prilagodili za vstaviti `x` so točno vozlišča `stack[0], ..., stack[k]`. Koda v nadaljevanju prikazuje implementacijo algoritma za `add(x)`:

```

boolean add(T x) {
    Node<T> u = sentinel;
    int r = h;
    int comp = 0;
    while (r >= 0) {
        while (u.next[r] != null
            && (comp = compare(u.next[r].x, x)) < 0)
            u = u.next[r];
        if (u.next[r] != null && comp == 0) return false;
        stack[r--] = u;           // going down, store u
    }
    Node<T> w = new Node<T>(x, pickHeight());
    while (h < w.height())
        stack[++h] = sentinel;    // height increased
    for (int i = 0; i < w.next.length; i++) {
        w.next[i] = stack[i].next[i];
        stack[i].next[i] = w;
    }
}

```

Preskočni seznam



Slika 4.3: Dodajanje vozlišča 3.5 v preskočni seznam. Vozlišča shranjena v **sklad** so označena.

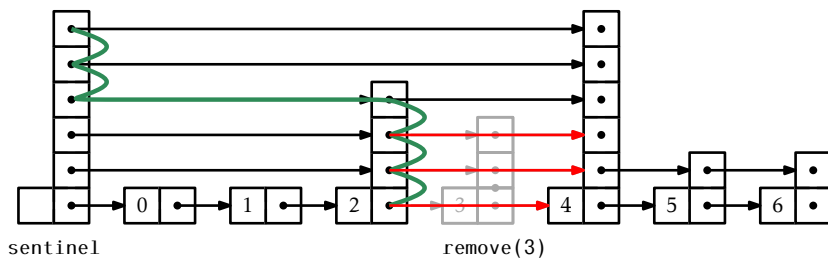
```
n++;
return true;
}
```

Brisanje elementa **x** je podobno vstavljanju, le da pri tej metodi ni potrebe po **skladu** za hranjenje poti iskanja. Brisanje je lahko opravljeno s sledenjem poti iskanja. Ko iščemo **x**, vedno ko se premaknemo korak navzdol iz vozlišča **u**, preverimo, če je **u.next.x = x** in če je, odstranimo **u** iz seznama:

```

SkiplistSSet
boolean remove(T x) {
    boolean removed = false;
    Node<T> u = sentinel;
    int r = h;
    int comp = 0;
    while (r >= 0) {
        while (u.next[r] != null
            && (comp = compare(u.next[r].x, x)) < 0) {
            u = u.next[r];
        }
        if (u.next[r] != null && comp == 0) {
            removed = true;
            u.next[r] = u.next[r].next[r];
            if (u == sentinel && u.next[r] == null)
                h--; // height has gone down
        }
        r--;
    }
}

```



Slika 4.4: Brisanje vozlišča 3 iz preskočnega seznama.

```

    }
    if (removed) n--;
    return removed;
}

```

4.2.1 Povzetek

Naslednji teorem povzema uporabnost preskočnega seznama, ko ga uporabljamo za implementacijo sortiranih nizov:


Izrek 4.1. *SkiplistSSet je uporabljen za izvedbo vmesnika SSet. SkiplistSSet opravi operacije $\text{add}(x)$ (dodaj), $\text{remove}(x)$ (odstrani), and $\text{find}(x)$ (najdi) v pričakovanem času $O(\log n)$ na operacijo.*

4.3 SkiplistList: Učinkovit naključni dostop List

SkiplistList implementira vmesnik List z uporabo preskočnega seznama. V SkiplistList, L_0 vsebuje elemente seznama v istem zaporedju, kot so ti razvrščeni v seznamu. Tako kot v SkiplistSSet, lahko elemente dodajamo, brišemo ali do njih dostopamo v $O(\log n)$ časa.

Da to lahko dosežemo, je potrebno najti iskalno pot do i -tega elementa v L_0 . Najlažji način je opredeliti pojem *dolžine* nivoja v nekem seznamu L_r . Vsak nivo v seznamu L_0 definiramo kot 1. Dolžina nivoja, e , v L_r , $r > 0$, je definirana kot vsota dolžin nivojev, ki so pod e v L_{r-1} . Dolžina e -ja je ekvivalenčna številu nivojev v L_0 , ki so pod e . Poglej 4.5

Preskočni seznam



Slika 4.5: Dolžine nivojev v preskočnem seznamu.

za primer preskočnega seznama z dolžino njegovih nivojev. Ker so nivoji preskočnega seznama shranjeni v polju, lahko na enak način shranjujemo tudi dolžino:

SkiplistList

```
class Node {
    T x;
    Node[] next;
    int[] length;
    Node(T ix, int h) {
        x = ix;
        next = Array.newInstance(Node.class, h+1);
        length = new int[h+1];
    }
    int height() {
        return next.length - 1;
    }
}
```

Uporabna lastnost opredelitve dolžin je, da če smo trenutno v vozlišču, ki se nahaja na poziciji j v L_0 in sledimo nivoju dolžine ℓ , se potem premaknemo v vozlišče, ki se nahaja na mestu $j + \ell$ v seznamu L_0 . Tako lahko, ko sledimo iskalni poti, ohranjamo vrednost pozicije, j , trenutnega vozlišča v L_0 . Ko smo v vozlišču, u , v L_r , gremo desno če j plus dolžina nivoja $u.next[r]$ manj kot i . V nasprotnem primeru, se pomaknemo navzdol v L_{r-1} .

SkiplistList

```
Node findPred(int i) {
```

```

Node u = sentinel;
int r = h;
int j = -1;    // index of the current node in list 0
while (r >= 0) {
    while (u.next[r] != null && j + u.length[r] < i) {
        j += u.length[r];
        u = u.next[r];
    }
    r--;
}
return u;
}

```

SkiplistList

```

T get(int i) {
    return findPred(i).next[0].x;
}
T set(int i, T x) {
    Node u = findPred(i).next[0];
    T y = u.x;
    u.x = x;
    return y;
}


```

Ker je najtežji del operacij `get(i)` in `set(i,x)` iskanje i -tega vozlišča v L_0 , se operacije izvedejo v $O(\log n)$ časa.


Dodajanje elementa v `SkiplistList` na pozicijo i , je enostavno. Za razliko od dodajanja v `SkiplistSSet`, vemo da bo vozlišče dejansko dodano, zato lahko hkrati dodajamo in iščemo lokacijo za novo vozlišče. Najprej izberemo višino, k , novega vozlišča, w , nato sledimo iskalni poti i . Vsakič ko se iskalna pot premakne navzdol od L_r z $r \leq k$, spojimo w v L_r . Dodatno moramo biti pozorni, da se dolžina nivojev pravilno osvežuje. Pogledj 4.6.

Pozorni moramo biti, da vsakič ko se iskalna pot v vozlišču premakne nivo nižje, u , v L_r , se dolžina nivoja `u.next[r]` poveča za ena, ker dodajamo element pod nivo na poziciji i . Spoj vozlišča w med vozlišča, u in z , deluje kot je prikazano v 4.7. Ko sledimo iskalni poti, shranjujemo tudi pozicijo, j , od u v L_0 . Zato, vemo da je dolžina nivoja od u do w enaka

Preskočni seznam



Slika 4.6: Dodajanje v SkipListList.



Slika 4.7: Posodabljanje dolžine nivojev, med spajanjem vozlišča w v preskočni seznam.

$i - j$. Sklepamo lahko da je dolžina nivoja od w do z iz dolžine, ℓ , od nivoja u do z . Potemtakem, lahko spojimo v w in osvežimo dolžine nivojev v konstantnem času.


Postopek izgleda veliko bolj kompleksen kot v resnici je. Koda je pravzaprav zelo enostavna:

```

SkiplistList
void add(int i, T x) {
    Node w = new Node(x, pickHeight());
    if (w.height() > h)
        h = w.height();
    add(i, w);
}
    
```

```

SkiplistList
Node add(int i, Node w) {
    Node u = sentinel;
    
```

Slika 4.8: Branje elementa iz SkipListList.

```

int k = w.height();
int r = h;
int j = -1; // index of u
while (r >= 0) {
    while (u.next[r] != null && j+u.length[r] < i) {
        j += u.length[r];
        u = u.next[r];
    }
    u.length[r]++; // accounts for new node in list 0
    if (r <= k) {
        w.next[r] = u.next[r];
        u.next[r] = w;
        w.length[r] = u.length[r] - (i - j);
        u.length[r] = i - j;
    }
    r--;
}
n++;
return u;
}

```

Do sedaj bi morala biti implementacija operacije `remove(i)` v `SkipListList` jasna. Sledimo iskalni poti vozlišča na poziciji `i`. Vsakič ko se iskalna pot zmanjša za ena od vozlišča, `u`, na nivoju `r` zmanjšamo dolžino nivoja, ki izstopa iz `u`-ja na tistem nivoju. Pregledati moramo tudi, da je `u.next[r]` element ranga `i` in v kolikor drži, ga premaknemo iz seznama na tisti nivo. Primer si lahko ogledate tukaj [4.8](#).

SkiplistList

```

T remove(int i) {
    T x = null;
    Node u = sentinel;
    int r = h;
    int j = -1; // index of node u
    while (r >= 0) {
        while (u.next[r] != null && j+u.length[r] < i) {
            j += u.length[r];
            u = u.next[r];
        }
        u.length[r]--; // for the node we are removing
        if (j + u.length[r] + 1 == i && u.next[r] != null) {
            x = u.next[r].x;
            u.length[r] += u.next[r].length[r];
            u.next[r] = u.next[r].next[r];
            if (u == sentinel && u.next[r] == null)
                h--;
        }
        r--;
    }
    n--;
    return x;
}

```

4.3.1 Povzetek

Naslednji teorem povzema učinkovitost podatkovne strukture `SkiplistList`:

Izrek 4.2. *`SkiplistList` izvede vmesnik `List`. `SkiplistList` podpira operacije `get(i)`, `set(i, x)`, `add(i, x)`, ter `remove(i)` v $O(\log n)$ pričakovanem času na operacijo.*

4.4 Analiza preskočnega seznama

V sledečem delu bomo analizirali pričakovano višino, velikost ter dolžino Iskalne poti v preskočnem seznamu. Za razumevanje potrebujemo osnovno

ozadnje verjetnosti. Nekateri dokazi so osnovani na metu kovanca.

Lema 4.2. *Naj bo T število, kadar se pošten kovanec obrne navzgor, vključno s primerom kadar kovanec pade z glavo navzgor. Takrat $E[T] = 2$.*

Dokaz. Recimo da nehamo metati kovanec prvič kadar pade z glavo navzgor. Definirajmo indikacijsko spremenljivko

$$I_i = \begin{cases} 0 & \text{če je kovanec vržen navzgor } i \text{ kar} \\ 1 & \text{če je kovanec vržen } i \text{ ali več krat} \end{cases}$$

Upoštevajte da $I_i = 1$ če in samo če edini $i - 1$ met kovanca postane rep, torej $E[I_i] = \Pr\{I_i = 1\} = 1/2^{i-1}$. Opazimo da T , vse mete kovanca lahko zapišemo kot $T = \sum_{i=1}^{\infty} I_i$. Sledi,

$$\begin{aligned} E[T] &= E\left[\sum_{i=1}^{\infty} I_i\right] \\ &= \sum_{i=1}^{\infty} E[I_i] \\ &= \sum_{i=1}^{\infty} 1/2^{i-1} \\ &= 1 + 1/2 + 1/4 + 1/8 + \dots \\ &= 2 . \end{aligned} \quad \square$$

Naslednji hipotezi nam pokažeta da ima preskočni seznam linearno velikost:

Lema 4.3. *Pričakovano število vozlišč v preskočnem seznamu vsebuje n elementov, če ne upoštevamo kontrolnih pojavljanj, je $2n$.*

Dokaz. Verjetnost, da je kateri koli element, x , vsebovan v seznamu L_r is $1/2^r$, so the expected number of nodes in L_r je $n/2^r$.² Sledi, da je skupno število pričakovanih vozlišč v seznamu

$$\sum_{r=0}^{\infty} n/2^r = n(1 + 1/2 + 1/4 + 1/8 + \dots) = 2n . \quad \square$$

²Poglej 1.3.4 za obrazložitev kako pridemo do rezultata z uporabo indikatorja spremenljivk in linearnosti pričakovanja.

Lema 4.4. *Pričakovana višina preskočnega seznama, ki vsebuje n elementov je največ $\log n + 2$.*

Dokaz. Za vsak $r \in \{1, 2, 3, \dots, \infty\}$, Definiramo indikator naključnih spremljivk

$$I_r = \begin{cases} 0 & \text{if } L_r \text{ je prazen} \\ 1 & \text{if } L_r \text{ ni prazen} \end{cases}$$

Višina, h , preskočnega seznama je

$$h = \sum_{i=1}^{\infty} I_r .$$

Upoštevajte, da I_r ni nikoli večji kot dolžina, $|L_r|$, od L_r , zato

$$E[I_r] \leq E[|L_r|] = n/2^r .$$

Zato imamo

$$\begin{aligned} E[h] &= E\left[\sum_{r=1}^{\infty} I_r\right] \\ &= \sum_{r=1}^{\infty} E[I_r] \\ &= \sum_{r=1}^{\lfloor \log n \rfloor} E[I_r] + \sum_{r=\lfloor \log n \rfloor+1}^{\infty} E[I_r] \\ &\leq \sum_{r=1}^{\lfloor \log n \rfloor} 1 + \sum_{r=\lfloor \log n \rfloor+1}^{\infty} n/2^r \\ &\leq \log n + \sum_{r=0}^{\infty} 1/2^r \\ &= \log n + 2 . \end{aligned}$$

□

Lema 4.5. *Pričakovano število vozlišč v preskočnem seznamu vsebuje n elementov, z vsemi pojavitvami “opazovalca”, je $2n + O(\log n)$.*

Dokaz. Po 4.3, sledi da je pričakovano število vozlišč, brez “opazovalca” $2n$. Število pojavitev “opaovalca” je enako višini, h , preskočnega seznama, torej 4.4 the expected number of occurrences of the je “opazovalec” največ $\log n + 2 = O(\log n)$. □

Lema 4.6. *Pričakovana dolžina iskalne poti v preskočnem seznamu je največ $2 \log n + O(1)$.*

Dokaz. Najlažje dokažemo hipotezo tako da uporabimo *reverse search path* za vozlišče, x . Ta pot začne pri predhodniku x v L_0 . Kadarkoli, če gredimo lahko pot eno nadstropje višje takrat lahko. V kolikor nemoremo iti eno nadstropje višje, gre levo. Če nekaj trenutkov premišljujemo o tem nas bo prepričalo da je vzvratna iskalna pot za x enaka iskalni poti za x , z razliko da je vzvratna.

Število vozlišč, ki obiščejo vzvratno pot v nekem nadstropju, r , je povezana z naslednjim eksperimentom: Vržimo kovanec. Če pade glava, se premakni navzgor, nato ustavi. V nasprotnem primeru se premakni levo in ponovi eksperiment. Številov metov kovanca, preden pade glava predstavlja število korakov v levo, ki jih vzvratna iskalna pot porabi v nekem nadstropju.

Bodite pozorni da lahko pride do "overcounta" števila korakov na levo, saj se mora eksperiment končati. Končati mora ob prvi glavi ali ko iskalna pot doseže "opazovalca", kateri pride prvi. To ne predstavlja problema saj leži hipoteza na zgornji meji. 4.2 nam prikazuje, da je pričakovano število metov kovanca preden pade prva "glava", 1.

Naj S_r označuje število korakov ki jih porabi iskalna pot naprej na nadstropju r ki gre levo. Pravkar smo trdili da $E[S_r] \leq 1$. Poleg tega, $S_r \leq |L_r|$, ker nemoremo narediti več korakov v L_r kot je dolžina L_r , zato

$$E[S_r] \leq E[|L_r|] = n/2^r .$$

Sedaj lahko dokončamo dokaz 4.4. Naj bo S dolžina iskalne poti nekega vozlišča, u , v preskočnem seznamu in naj bo h višina preskočnega seznama. Sledi

$$\begin{aligned} E[S] &= E \left[h + \sum_{r=0}^{\infty} S_r \right] \\ &= E[h] + \sum_{r=0}^{\infty} E[S_r] \\ &= E[h] + \sum_{r=0}^{\lfloor \log n \rfloor} E[S_r] + \sum_{r=\lfloor \log n \rfloor + 1}^{\infty} E[S_r] \end{aligned}$$

$$\begin{aligned}
 &\leq E[h] + \sum_{r=0}^{\lfloor \log n \rfloor} 1 + \sum_{r=\lfloor \log n \rfloor+1}^{\infty} n/2^r \\
 &\leq E[h] + \sum_{r=0}^{\lfloor \log n \rfloor} 1 + \sum_{r=0}^{\infty} 1/2^r \\
 &\leq E[h] + \sum_{r=0}^{\lfloor \log n \rfloor} 1 + \sum_{r=0}^{\infty} 1/2^r \\
 &\leq E[h] + \log n + 3 \\
 &\leq 2\log n + 5 .
 \end{aligned}
 \quad \square$$

Sledeči teorem povzema rezultat sekcije:

Izrek 4.3. *Preskočni seznam, ki vsebuje n elementov je pričakoval velikost $O(n)$ in pričakovana dolžina iskalne poti nekega elementa je največ: $2\log n + O(1)$.*

4.5 Razprava in vaje

Preskočne sezname je predstavil Pugh [?] ki je tudi predstavil veliko aplikacij in razširitev preskočnih seznamov [?]. Od takrat se jih je veliko preučevalo. Veliko raziskovalcev je naredilo veliko natančnih analiz pričakovane dolžine in variance dolžine iskanja poti za i ti element v preskočnem seznamu [?, ?, ?]. Deterministične različice [?], pristranske različice [?, ?], in samo-prilagodljive različice [?] preskočnih seznamov so se razvile. Implementacije preskočnih seznamov so bile napisane za različne jezike in ogrodja in so uporabljeni v odprtokodnih podatkovnih sistemih [?, ?]. Različica preskočnih seznamov je uporabljena v strukturah upravljanja procesov jedra operacijskega sistema HP-UX [?]. Preskočni sezname so celo del Java 1.6 API [?].

Naloga 4.1. Narišite iskalne poti za 2.5 in 5.5 v preskočnem seznamu v 4.1.

Naloga 4.2. Narišite dodajanje vrednosti 0.5 (z višino 1) in nato 3.5 (z višino 2) v preskočni seznam v 4.1.

Naloga 4.3. Narišite odstranjevanje vrednosti 1 in nato 3 iz preskočnega seznama v 4.1.

Naloga 4.4. Narišite izvedbo `remove(2)` v `SkipListList` v 4.5.

Naloga 4.5. Narišite izvedbo `add(3, x)` v `SkipListList` v 4.5. Predpostavi, da `pickHeight()` izbere višino 4 za novo ustvarjeno vozlišče.

Naloga 4.6. Pokažite da je med izvajanjem `add(x)` ali `remove(x)` operacij, pričakovano število kazalcev v `SkipListSet` ki se spremenijo konstanta.

Naloga 4.7. Predpostavite da, namesto povišanja elementa iz L_{i-1} v L_i na osnovi meta kovanca, element povišamo z neko verjetnostjo p , $0 < p < 1$.

1. Pokažite, da je s to modifikacijo pričakovana dolžina iskalne poti največ $(1/p) \log_{1/p} n + O(1)$.
2. Kakšna je vrednost p ki zmanjša prejšnji izraz?
3. Kakšna je pričakovana višina preskočnega seznama?
4. Kakšno je pričakovano število vozlišč v preskočnem seznamu?

Naloga 4.8. Metoda `find(x)` v `SkipListSet` včasih izvede *odvečne primerjave*; Te se pojavijo kadar je x primerjan z isto vrednostjo več kot enkrat. Pojavijo se lahko za neko vozlišče, u , $u.next[r] = u.next[r - 1]$. Pokažite kako se te odvečne primerjave zgodijo in priredite `find(x)` tako da se jih izognete. Analizirajte pričakovano število primerjav izvedenih z vašo prirejeno `find(x)` metodo.

Naloga 4.9. Zasnujte in implementirajte različico preskočnega seznama, ki implementira `SSet` interface, pa tudi dovoljuje hiter dostop do elementov po rangi. To pomeni, da tudi podpira funkcijo `get(i)`, ki vrača element katerega rang je i v $O(\log n)$ pričakovani časovni zahtevnosti. (Rang elementa x v `SSet` je število elementov v `SSet` ki so manjši od x .)

Naloga 4.10. *prst* v preskočnem seznamu je polje ki shranjuje zaporedje vozlišč v iskalni poti kjer se iskalna pot spušča. (Spremenljivka `stack` v `add(x)` koda na strani 91 je *prst*; osenčena vozlišča v 4.3 kažejo na vsebino enega prsta.) Na prst lahko gledamo kot na nekaj kar kaže pot do vozlišča v najnižjem seznamu, L_0 .

finger search implementira `find(x)` operacijo z uporabo prsta, s sprehajanjem po seznamu navzgor z uporabo prsta dokler ne doseže vozlišča

u tako da je $u.x < x$ in $u.next = \text{null}$ ali $u.next.x > x$ in nato izvajanjem normalnega iskanja x začenši z u . Mogoče je dokazati da je pričakovano število potrebnih korakov za finger search $O(1 + \log r)$, kjer je r število vrednosti v L_0 med x in vrednostjo na katero kaže prst.

Implementirajte podrazred od `Skiplist`, ki se imenuje `SkiplistWithFinger`, ki implementira `find(x)` operacije z uporabo notranjega prsta. Podrazred naj hrani prst, ki je uporabljen tako da je vsaka operacija `find(x)` implementirana kot prstno iskanje (finger search). Med vsako `find(x)` operacijo je prst posodobljen tako da vsaka operacija `find(x)` uporabi, kot začetno točko, prst ki kaže na rezultat prejšnje `find(x)` operacije.

Naloga 4.11. Zapišite metodo `truncate(i)`, ki skrajša `SkiplistList` na poziciji i . Po izvedbi metode, je velikost seznama i in vsebuje samo elemente na indexih $0, \dots, i-1$. Vrnjena vrednost je nek drug `SkiplistList`, ki vsebuje elemente na indexih $i, \dots, n-1$. Metoda mora imeti časovno zahtevnost $O(\log n)$.

Naloga 4.12. Napišite `SkiplistList` metodo, `absorb(l2)`, ki sprejme argument `SkiplistList`, $l2$, ga izprazni in pripne njegovo vsebino, urejeno, prejemniku. Naprimer, če $l1$ vsebuje a, b, c in $l2$ vsebuje d, e, f , potem bo po klicu `l1.absorb(l2)`, $l1$ vseboval a, b, c, d, e, f in $l2$ bo prazen. Metoda naj ima časovno zahtevnost $O(\log n)$.

Naloga 4.13. Z uporabo pristopov prostorsko učinkovitega seznama `SEList`, zasnujte in implementirajte prostorsko učinkovit `SSet`, `SESSet`. Da bi to stroili, shranite urejene podatke v `SEList`, in bloke tega `SEList` v `SSet`. Če prvotna implementacija `SSet` porabi $O(n)$ prostora za shranjevanje n elementov, potem bo `SESSet` imel dovolj prostora za n elementov plus $O(n/b + b)$ odvečnega prostora.

Naloga 4.14. Z uporabo `SSet` kot vašo osnovno strukturo, zasnujte in implementirajte aplikacijo, ki prebere (veliko) besedilno datoteko in dovoljuje interaktivno iskanje, za katerikoli podniz vsebovan v besedilu. Ko uporabnik vnaša svojo iskalno zahtevo naj se kot rezultat prikazuje ujemajoč del besedila (če obstaja).

Namig 1: Vsak podniz je predpona neki priponi, tako da zadošča shraniti vse pripone besedilne datoteke.

Namig 2: Vsaka pripona je lahko predstavljena strnjeno kot samojstojna številka, ki predstavlja kje v besedilu se pripona začne.

Preizkusite svojo aplikacijo na velikih besedilih, kot so na primer knjige dostopne na Project Gutenberg [?]. If done correctly, your applications will be very responsive; there should be no noticeable lag between typing keystrokes and seeing the results.

Naloga 4.15. (Ta vaja naj bo opravljena po branju o binarnih iskalnih drevesih.) in 6.2.) Primerjajte preskočne sezname z binarnimi iskalnimi drevesi po naslednjih kriterijih:

1. Razložite kako odstranjevanje robnih elementov preskočnega seznama vodi k strukturi ki izgleda kot binarno drevo in je enaka binarnemu iskalnemu drevesu.
2. Preskočni sezname in dvojiška iskalna drevesa oboji porabijo približno enako število kazalcev (2 na vozlišče). Preskočni sezname bolje uporabijo te kazalce. Razložite zakaj.

Poglavje 5

Zgoščevalne tabele

Zgoščevalne tabele predstavljajo učinkovito metodo za shranjevanje majhnega števila celih števil n , iz velikega obsega $U = \{0, \dots, 2^w - 1\}$. Izraz *zgoščevalna tabela* sicer označuje širok spekter podatkovnih struktur. Prvi del poglavja se osredotoča na dve najbolj pogosti implementaciji: zgoščevanje z veriženjem in linearno naslavljanje.

Zelo pogosto se uporabljajo za shranjevanje podatkov, katerih tip niso cela števila. V tem primeru je celoštevilska *zgoščevalna koda* povezana z vsako podatkovno enoto in uporabljena v zgoščevalni tabeli. Drugi del predstavi, kako so zgoščevalne kode ustvarjene.


Nekatere uporabljene metode iz tega poglavja potrebujejo naključno izbrana števila v določenem razponu. V primerih kode, so nekatera “naključna” cela števila enolično določena z uporabo naključnih bitov generiranih iz atmosferskega šuma.

5.1 Zgoščevalna tabela z veriženjem

Podatkovna struktura zgoščevalna tabela z veriženjem za shranjevanje tabele t seznamov uporablja zgoščevanje z veriženjem. Za hranjenje skupnega števila podatkov v vseh seznamih se uporablja celo število n . (glej 5.1):

```
ChainedHashTable  
List<T>[] t;  
int n;
```

Zgoščevalne tabele



Slika 5.1: Primer zgoščevalne tabele z veriženjem z $n = 14$ in `t.length` = 16. V tem primeru je `hash(x)` = 6

Zgoščena vrednost podatkovnega elementa `x`, označena z `hash(x)` predstavlja vrednost v razponu $\{0, \dots, \text{t.length} - 1\}$. Vsi podatki z zgoščeno vrednostjo `i` so shranjeni v seznamu na lokaciji `t[i]`. Da se izognemo prevelikim seznamom, ohranjamo invarianto

$$n \leq \text{t.length}$$

tako da je povprečno število elementov shranjenih v posameznem seznamu $n/\text{t.length} \leq 1$.

Pri dodajanju elementa `x`, v zgoščevalno tabelo, najprej preverimo če je potrebno povečati `t.length`. V kolikor je to potrebno ga povečamo. Potem zgostimo `x`, da dobimo število `i`, v razponu $\{0, \dots, \text{t.length} - 1\}$, in pripnemo `x` seznamu `t[i]`:

```

ChainedHashTable
boolean add(T x) {
    if (find(x) != null) return false;
    if (n+1 > t.length) resize();
    t[hash(x)].add(x);
    n++;
    return true;
}
    
```

Povečevanje tabele, v kolikor je le-to potrebno, vključuje podvojitev dolžine tabele `t` in ponovno vstavljanje elementov vanjo. Ta strategija je popolnoma enaka kot pri implementaciji `ArrayStacka` in tudi tu velja enako pravilo: Cena rasti je amortizirano po nekaj sekvencah vstavljanja samo konstantna (glej 2.1 na strani 33).

Poleg rasti je edino potrebno opravilo ob vstavljanju nove vrednosti x v zgoščevalno tabelo z veriženjem dodajanje x -a seznamu $t[hash(x)]$. Za katerokoli od implementacij seznama opisanih v poglavjih 2 in 3, potrebujemo le konstanten čas.

Za odstranitev elementa x iz zgoščevalne tabele se sprehodimo čez seznam $t[hash(x)]$, dokler ne najdemo elementa x , tako da ga lahko odstranimo:

```
ChainedHashTable
T remove(T x) {
    Iterator<T> it = t[hash(x)].iterator();
    while (it.hasNext()) {
        T y = it.next();
        if (y.equals(x)) {
            it.remove();
            n--;
            return y;
        }
    }
    return null;
}
```

Časovna zahtevnost je $O(n_{hash(x)})$, pri čemer n_i označuje dolžino seznama shranjenega v $t[i]$.

Iskanje elementa x v zgoščevalni tabeli poteka podobno. Izvedemo linearno iskanje nad seznamom $t[hash(x)]$:

```
ChainedHashTable
T find(Object x) {
    for (T y : t[hash(x)])
        if (y.equals(x))
            return y;
    return null;
}
```

Podobno tudi tu potrebujemo čas sorazmerno z dolžino seznama $t[hash(x)]$.

Hitrosti zgoščevalnih tabel so odvisne predvsem od izbire zgoščevalne funkcije. Dobra zgoščevalna funkcija razprši elemente enakomerno med $t.length$ seznamov, tako da je pričakovana velikost seznama $t[hash(x)]$

$O(n/t.length) = O(1)$. Po drugi strani pa slaba zgoščevalna funkcija zgošči vse vrednosti (vključno z x) na isto lokacijo v tabeli. V tem primeru bo velikost seznama $t[hash(x)]$ n . V naslednjem poglavju je opisan primer dobre zgoščevalne funkcije.

5.1.1 Zgoščevanje z množenjem

Zgoščevanje z množenjem je učinkovita metoda tvorbe zgoščevalnih vrednosti osnovana na kongruenci (opisana v poglavju 2.3) in celoštevilskemu deljenju. Uporablja operator div , ki obdrži celoštevilski del kvocienta, ostanek pa zanemari. Praktično za vsako število velja $a \geq 0$ in $b \geq 1$, $a \text{ div } b = \lfloor a/b \rfloor$.

Pri zgoščevanju z množenjem uporabljamo tabele velikosti 2^d pri čemer je d neko celo število (imenovano *dimenzija*). Formula za zgoščevanje cellega števila $x \in \{0, \dots, 2^w - 1\}$ je

$$\text{hash}(x) = ((z \cdot x) \bmod 2^w) \text{div } 2^{w-d}.$$

Pri tem je z neko naključno izbrano celo število v $\{1, \dots, 2^w - 1\}$. Zgoščevalna funkcija je lahko realizirana zelo učinkovito, z obzirom na to, da so operacije nad celimi števili že v osnovi izvedene nad 2^w biti, kjer je w število bitov v celem številu. (Glej 5.2.) Poleg tega je celoštevilsko deljenje z 2^{w-d} enako izločanju skrajno desnih $w - d$ bitov v binarni predstavitvi (kar uredimo s premikom za $w - d$ bitov). S tem dosežemo, da ima koda lažjo implementacijo kot matematična formula:

```

ChainedHashTable
int hash(Object x) {
    return (z * x.hashCode()) >>> (w-d);
}

```

Pri naslednjem primeru, čigar dokaz je prikazan kasneje v poglavju, pokažemo, da igra zgoščevalna funkcija z množenjem odlično vlogo pri izmikanju trkov.

Lema 5.1. Naj bosta x in y dve vrednosti izmed $\{0, \dots, 2^w - 1\}$ in $x \neq y$. Potem sledi, da $\Pr\{\text{hash}(x) = \text{hash}(y)\} \leq 2/2^d$.

Sedaj bi želeli dokazati primer 5.1, a za slednje, najprej potrebujemo rezultat iz teorije števil. Pri naslednjem dokazu uporabljamo notacijo $(b_r, \dots, b_0)_2$ pri označevanju $\sum_{i=0}^r b_i 2^i$, kjer je vsak b_i bitna vrednost, ali 0 ali 1. Z drugimi besedami je $(b_r, \dots, b_0)_2$ celo številčna vrednost, čigar dvojiška predstavitev je podana kot b_r, \dots, b_0 . Z uporabo \star označimo neznan bitno vrednost.

Lema 5.3. *Naj bo S zbirka lihih celih števil na intervalu $\{1, \dots, 2^w - 1\}$; prav tako naj bosta q in i dva, katera koli, elementa izmed vseh elementov v S . Potem takem obstaja točno ena vrednost $z \in S$ za katero velja $zq \bmod 2^w = i$.*

Dokaz. Ker je število izbira za z in i enaka, je zadostljivo dokazati, največ ena vrednost $z \in S$ za katero velja $zq \bmod 2^w = i$.

Predpostavimo da sta, za voljo nasprotij, dve vrednosti z and z' , kjer velja $z > z'$. Potem je

$$zq \bmod 2^w = z'q \bmod 2^w = i$$

Kar sledi k

$$(z - z')q \bmod 2^w = 0$$

Slednje pomeni, da je

$$(z - z')q = k2^w \tag{5.1}$$

za neko celo število k . V smislu dvojiških števil, bi slednje pomenilo da imamo

$$(z - z')q = k \cdot \underbrace{(1, 0, \dots, 0)_2}_w ,$$

tako da so w zadnje bitne vrednosti v dvojiški predstavitvi $(z - z')q$ vse ničle (0).

Poleg tega velja tudi da je $k \neq 0$, ker velja da je $q \neq 0$ in $z - z' \neq 0$. Ker je q liho število, nima ničel kot zadnje vrednosti v bitni predstavitvi:

$$q = (\star, \dots, \star, 1)_2 .$$

Ker velja da ima $|z - z'| < 2^w$, $z - z'$ manj, kot w , ničelnih zadnjih vrednosti v bitni predstavitvi slednjega:

$$z - z' = (\star, \dots, \star, \underbrace{1, 0, \dots, 0}_{<w})_2 .$$

□

Uporabnost 5.3 izhaja iz sledeče predpostavke: Če je z izbran enakomerno naključno iz S , potem je zt enakomerno porazdeljen nad S . V sledečem dokazu, si pomagamo z dvojiško predstavitvijo z , katera sestoji iz $w - 1$ naključnih bitov s pripono 1.

Dokaz za 5.1. Začnemo z ugotovitvijo da je $\text{hash}(x) = \text{hash}(y)$ ekvivalenten trditvi “ d najpomembnejših bitov v $zx \bmod 2^w$ in d najpomembnejših bitov $zy \bmod 2^w$ je enakih.” Pri prejšnji trditvi je potrebno poudariti, da je d najpomembnejših bitov v dvojiški predstavitvi $z(x - y) \bmod 2^w$ vseh enakih 1 ali enakih 0. Torej velja,

$$z(x - y) \bmod 2^w = (\underbrace{0, \dots, 0}_d, \underbrace{\star, \dots, \star}_{w-d})_2 \quad (5.2)$$

ko velja $zx \bmod 2^w > zy \bmod 2^w$ ali

$$z(x - y) \bmod 2^w = (\underbrace{1, \dots, 1}_d, \underbrace{\star, \dots, \star}_{w-d})_2 . \quad (5.3)$$

ko velja $zx \bmod 2^w < zy \bmod 2^w$. Potemtakem, ugotavljamo le verjetnost, da $z(x - y) \bmod 2^w$ izgleda kot (5.2) or (5.3).

Naj bo q enolično liho število, za katero velja $(x - y) \bmod 2^w = q2^r$ za neko število $r \geq 0$. Po 5.3, ima dvojiška predstavitev $zq \bmod 2^w$ $w - 1$ naključnih bitov, zaključenih z 1:

$$zq \bmod 2^w = (\underbrace{b_{w-1}, \dots, b_1}_w, 1)_2$$

Iz tega sledi, da ima dvojiška predstavitev $z(x - y) \bmod 2^w = zq2^r \bmod 2^w$ $w - r - 1$ naključnih bitov, zaključenih z 1, zaključenih z r ponovitvami 0:

$$z(x - y) \bmod 2^w = zq2^r \bmod 2^w = (\underbrace{b_{w-r-1}, \dots, b_1}_{w-r-1}, \underbrace{1, 0, 0, \dots, 0}_r)_2$$

S tem zaključimo dokaz. Če je $r > w - d$, potem d najpomembnejših bitov $z(x - y) \bmod 2^w$ vsebuje tako ničle kot enice, tako da je verjetnost da $z(x - y) \bmod 2^w$ izgleda kot (5.2) ali (5.3) nična. Če je $r = w - d$, potem je verjetnost da izgleda kot (5.2) nična, vendar je verjetnost da izgleda kot (5.3) $1/2^{d-1} = 2/2^d$ (ker moramo imeti $b_1, \dots, b_{d-1} = 1, \dots, 1$).

Če velja $r < w - d$, potem moramo imeti $b_{w-r-1}, \dots, b_{w-r-d} = 0, \dots, 0$ ali $b_{w-r-1}, \dots, b_{w-r-d} = 1, \dots, 1$. Verjetnost posamezne od teh možnosti je $1/2^d$ pri čemer so vse vzajemno izključujoče, tako da je verjetnost da se zgodi katerakoli $2/2^d$. S tem zaključimo dokaz. \square

5.1.2 Povzetek

Naslednji izrek povzema uspešnost `ChainedHashTable` podatkovne strukture:

Izrek 5.1. *`ChainedHashTable` implementira vmesnik `USet`. Če ignoriramo ceno klicev metode `grow()`, `ChainedHashTable` podpira operacije `add(x)`, `remove(x)`, `find(x)`, v pričakovanem $O(1)$ času na operacijo.*

Poleg tega, da je začetna `ChainedHashTable` prazna, vsaka sekvenca od m `add(x)` in `remove(x)` operacije rezultira v skupni porabi $O(m)$ časa za vse klice na `grow()`.

5.2 LinearHashTable: Odprto naslavljanje

Podatkovna struktura `ChainedHashTable` uporablja polje seznamov, kjer `i` seznam shrani vse elemente `x` tako da je `hash(x) = i`. Alternativa po imenu *odprto naslavljanje* je namenjena shranjevanju elementov neposredno v polje `t`, z vsako lokacijo polja v `t` pa shrani največ eno vrednost. Tak pristop se uporablja v `LinearHashTable` in je opisan v tem poglavju. Ponekod je ta podatkovna struktura opisana kot *odprto naslavljanje*.

Glavna ideja `LinearHashTable` je da bi mi lahko, idealno, shranili element `x` z zgoščevalno vrednostjo `i = hash(x)` v lokacijo tabele `t[i]`. Če tega ne moremo storiti (ker je nek element že shranjen tam) potem ga skušamo shraniti v lokaciji `t[(i + 1) mod t.length]`; če tudi to ni mogoče, potem poskusimo z `t[(i + 2) mod t.length]`, in tako naprej, dokler ne najdemo mesta za `x`.

V `t` imamo shranjene tri tipe vhodov:

1. podatkovne vrednosti: dejanske vrednosti iz `USet` katere predstavljamo;

2. `null` vrednosti: na lokacijah v tabeli kjer ni in ni bilo nikoli kakršnihkoli podatkov; in
3. `del` vrednosti: na lokacijah tabele kjer so bili podatki nekoč shranjeni ampak so od takrat bili izbrisani.

Poleg števca, `n`, ki skrbi za spremljanje številov elementov v `LinearHashTable`, imamo še števec, `q`, ki skrbi za spremljanje števila elementov Tipov 1 in 3. To pomeni, `q` je enak `n` z dodanimi števili `del` vrednosti v `t`. Za učinkovito delovanje potrebujemo da je `t` precej večji od `q`, tako da je veliko `null` vrednosti v `t`. Operacije na `LinearHashTable` torej ohranjajo invarianto, da je `t.length ≥ 2q`.

Torej, `LinearHashTable` hrani tabelo, `t`, ki hrana podatkovne elemente in cela števila `n` in `q` ki spremljata število dejanski podatkovnih elementov in ne-`null` vrednosti v `t`. Ker vrsta zgoščevalnih funkcij deluje le za tabele katerih velikosti potence števila 2, prav tako hranimo celo število `d` in ohranjamo invarianto da je `t.length = 2d`.

```

LinearHashTable
T[] t;    // the table
int n;    // the size
int d;    // t.length = 2^d
int q;    // number of non-null entries in t

```

Delovanje iskanja `find(x)` je v `LinearHashTable` preprosto. Začnemo z vpisom v tabelo `t[i]` kjer je `i = hash(x)` in iskanih elementov `t[i]`, `t[(i + 1) mod t.length]`, `t[(i + 2) mod t.length]`, in tako naprej dokler ne najdemo indeksa `i'` tako, da je bodisi `t[i'] = x`, ali `t[i'] = null`. V prvem primeru bomo vrnili `t[i']`. V drugem primeru pa lahko ugotovimo, da `x` ni vsebovan v zgoščevalni tabeli in vrnemo `null`.

```

LinearHashTable
T find(T x) {
    int i = hash(x);
    while (t[i] != null) {
        if (t[i] != del && x.equals(t[i])) return t[i];
        i = (i == t.length-1) ? 0 : i + 1; // increment i
    }
}

```

```

    return null;
}

```

Delovanje `add(x)` je tudi dokaj enostavno izvajati. Po preverjanju, da `x` slučajno že ni shranjena v tabeli (uporabimo `find(x)`), iščemo `t[i]`, `t[(i + 1) mod t.length]`, `t[(i + 2) mod t.length]`, in tako naprej, dokler ne najdemo `null` ali `del` in shranimo `x` na lokaciji, če je potrebno povečamo `n` in `q`.

```

LinearHashTable
boolean add(T x) {
    if (find(x) != null) return false;
    if (2*(q+1) > t.length) resize(); // max 50% occupancy
    int i = hash(x);
    while (t[i] != null && t[i] != del)
        i = (i == t.length-1) ? 0 : i + 1; // increment i
    if (t[i] == null) q++;
    n++;
    t[i] = x;
    return true;
}

```

Do sedaj naj bi bilo delovanje izvajanja `remove(x)` očitno. Iščemo `t[i]`, `t[(i + 1) mod t.length]`, `t[(i + 2) mod t.length]`, in tako naprej dokler ne najdemo indeksa `i'` tako, da bo `t[i'] = x` ali `t[i'] = null`. V prvem primeru nastavimo `t[i'] = del` in vrnemo `true`. V drugem primeru ugotovimo, da `x` wni bil shranjen v tabeli (zato ga ne moremo odstraniti) in vrnemo `false`.

```

LinearHashTable
T remove(T x) {
    int i = hash(x);
    while (t[i] != null) {
        T y = t[i];
        if (y != del && x.equals(y)) {
            t[i] = del;
            n--;
            if (8*n < t.length) resize(); // min 12.5% occupancy
            return y;
        }
        i = (i == t.length-1) ? 0 : i + 1;
    }
    return null;
}

```

```

    }
    i = (i == t.length-1) ? 0 : i + 1; // increment i
}
return null;
}

```

Pravilnost metod `find(x)`, `add(x)` in `remove(x)` je lahko preveriti, čeprav temelji na uporabi `del` vrednosti. Opazimo lahko, da nobena od teh operacij nikoli ne postavi ne-`null` vnosa na `null`. Zato ko dosežemo indeks `i'`, kot je recimo `t[i'] = null`, je to dokaz da element `x`, ki ga iščemo, ni shranjen v tabeli; `t[i']` je bil vedno `null`, zato ni razloga da bi prejšnja operacija `add(x)` nadaljevala čez indeks `i'`.

Metodo `resize()` pokliče metoda `add(x)` ko število ne-`null` vnosov preseže `t.length/2` ali pa metoda `remove(x)`, ko je število podatkovnih vnosov manjše od `t.length/8`. Metoda deluje enako kot v drugih podatkovnih strukturah, ki temeljijo na tabelah. Najdemo najmanjše pozitivno število `d`, tako da je $2^d \geq 3n$. Tabelo `t` dodelimo tako da dobimo tabelo velikosti 2^d in nato vse elemente iz stare verzije tabele `t` vstavimo v novo ustvarjeno kopijo tabele `t`. Medtem ponastavimo `q` na vrednost `n`, saj nova tabela `t` ne vsebuje `del` vrednosti.

```

LinearHashTable
void resize() {
    d = 1;
    while ((1<<d) < 3*n) d++;
    T[] told = t;
    t = newArray(1<<d);
    q = n;
    // insert everything from told
    for (int k = 0; k < told.length; k++) {
        if (told[k] != null && told[k] != del) {
            int i = hash(told[k]);
            while (t[i] != null)
                i = (i == t.length-1) ? 0 : i + 1;
            t[i] = told[k];
        }
    }
}
}

```

5.2.1 Analiza odprtega naslavljanja

Vsaka od operacij `add(x)`, `remove(x)` in `find(x)` se konča najkasneje takoj ko odkrije prvi `null` vnos v `t`. Intuicija za to analizo temelji na tem, da je najmanj polovica elementov v tabeli `t` enakih `null`, zato operacija ne bi smela potrebovati veliko časa za zaključitev, saj zelo hitro naleti na `null` vnos. Na to intuicijo se ne smemo preveč trdno zanašati, ker bi nas pripeljala do (napačnega) sklepa da je pričakovano število lokacij v tabeli `t`, ki jo poda ta operacija, največ 2.

Za preostanek tega poglavja bomo domnevali, da so vse zgoščene vrednosti neodvisno in enotno porazdeljene v $\{0, \dots, t.length - 1\}$. To ni realistična domneva, vendar nam bo omogočila analizo linearnega naslavljanja. Kasneje v tem poglavju bomo opisali metodo imenovano tabelarno zgoščevanje, ki ustvari zgoščevalno funkcijo, ki je "dovolj dobra" za linearno naslavljanje. Prav tako bomo predpostavili, da so vsi indeksi v položajih `t` celoštevilsko deljeni z `t.length`, tako da je `t[i]` okrajšava za `t[i mod t.length]`.

Pravimo da se izvršitev dolžine k , ki se začne pri i zgodi, kadar noben od elementov `t[i]`, `t[i + 1]`, ..., `t[i + k - 1]` ni `null` in `t[i - 1] = t[i + k] = null`. Število elementov tabele `t` ki niso `null` je enako q , metoda `add(x)` pa zagotavlja, da vedno velja $q \leq t.length/2$. Obstaja q elementov x_1, \dots, x_q ki so bili vstavljeni v `t` po zadnji rebusid() operaciji. Po naši domnevi ima vsak izmed teh elementov zgoščevalno vrednost `hash(xj)`, ki je enotna in neodvisna od drugih. S tako nastavitvijo lahko dokažemo glavno trditev potrebno za analiziranje linearnega naslavljanja.

Lema 5.4. Določimo vrednost $i \in \{0, \dots, t.length - 1\}$. Potem je možnost, da se izvršitev dolžine k začne pri i , enaka $O(c^k)$ za konstanto $0 < c < 1$.

Dokaz. Če se začetek dolžine k začne pri i , je natanko k elementov x_j , ki so `hash(xj)` $\in \{i, \dots, i + k - 1\}$. Verjetnost za to je točno

$$p_k = \binom{q}{k} \left(\frac{k}{t.length} \right)^k \left(\frac{t.length - k}{t.length} \right)^{q-k},$$

ker za vsako izbiro k elementov, teh k elementov mora zgostiti k eni izmed k lokacij. Preostalih $q - k$ pa mora zgostiti k preostalim `t.length - k`

lokacijam v tabeli.¹

V naslednji izpeljavi bomo pogoljufali in zamenjali $r!$ z $(r/e)^r$. Stirlingova aproksimacija (1.3.2) nam pove da je to le faktor $O(\sqrt{r})$ od pravilnosti. To naredimo zato, da si poenostavimo izpeljavo; 5.4 od bralca zahteva, da natančneje in v celoti ponovi izračun z uporabo Stirlingove aproksimacije.

Vrednost p_k je maksimalna, ko je `t.length` minimum in podatkovna struktura obdrži nespremenjen `t.length` $\geq 2q$, torej

$$\begin{aligned}
 p_k &\leq \binom{q}{k} \left(\frac{k}{2q}\right)^k \left(\frac{2q-k}{2q}\right)^{q-k} \\
 &= \left(\frac{q!}{(q-k)!k!}\right) \left(\frac{k}{2q}\right)^k \left(\frac{2q-k}{2q}\right)^{q-k} \\
 &\approx \left(\frac{q^q}{(q-k)^{q-k}k^k}\right) \left(\frac{k}{2q}\right)^k \left(\frac{2q-k}{2q}\right)^{q-k} \quad [\text{Stirlingova aproksimacija}] \\
 &= \left(\frac{q^k q^{q-k}}{(q-k)^{q-k}k^k}\right) \left(\frac{k}{2q}\right)^k \left(\frac{2q-k}{2q}\right)^{q-k} \\
 &= \left(\frac{qk}{2qk}\right)^k \left(\frac{q(2q-k)}{2q(q-k)}\right)^{q-k} \\
 &= \left(\frac{1}{2}\right)^k \left(\frac{(2q-k)}{2(q-k)}\right)^{q-k} \\
 &= \left(\frac{1}{2}\right)^k \left(1 + \frac{k}{2(q-k)}\right)^{q-k} \\
 &\leq \left(\frac{\sqrt{e}}{2}\right)^k.
 \end{aligned}$$

(V zadnjem koraku uporabimo neenakost $(1 + 1/x)^x \leq e$, ki drži za vse $x > 0$). Ker je $\sqrt{e}/2 < 0.824360636 < 1$, dokaz lahko potrdimo. \square

Uporaba 5.4 za dokaz zgornje meje na času izvajanja `find(x)`, `add(x)` in `remove(x)` je sedaj enostavna. Upoštevajmo najenostavnejši primer, kjer izvršimo `find(x)` za neko vrednost `x`, ki ni bila nikoli shranjena v `LinearHashTable`. V tem primeru `i = hash(x)` dobi naključno vrednost

¹Upoštevajte, da je p_k večje kot verjetnost, da se izvajanje dolžine k začne pri `i`, ker definicija od p_k ne upošteva pogoja `t[i - 1] = t[i + k] = null`.

v $\{0, \dots, \mathbf{t.length} - 1\}$, ki je neodvisna od vsebine \mathbf{t} . Če je \mathbf{i} del izvajanja dolžine k , potem je čas izvajanja operacije $\mathbf{find}(\mathbf{x})$ v najboljšem primeru $O(1 + k)$. Potemtakem, zgornja meja pričakovanega časa izvajanja je

$$O\left(1 + \left(\frac{1}{\mathbf{t.length}}\right) \sum_{i=1}^{\mathbf{t.length}} \sum_{k=0}^{\infty} k \Pr\{\mathbf{i} \text{ je del obhoda dolžine } k\}\right).$$

Upoštevajte, da vsako izvajanje dolžine k prispeva k notranji vsoti k -krat za končni prispevek k^2 , torej lahko navedeno vsoto ponovno napišemo kot

$$\begin{aligned} & O\left(1 + \left(\frac{1}{\mathbf{t.length}}\right) \sum_{i=1}^{\mathbf{t.length}} \sum_{k=0}^{\infty} k^2 \Pr\{\mathbf{i} \text{ začne obhod dolžine } k\}\right) \\ & \leq O\left(1 + \left(\frac{1}{\mathbf{t.length}}\right) \sum_{i=1}^{\mathbf{t.length}} \sum_{k=0}^{\infty} k^2 p_k\right) \\ & = O\left(1 + \sum_{k=0}^{\infty} k^2 p_k\right) \\ & = O\left(1 + \sum_{k=0}^{\infty} k^2 \cdot O(c^k)\right) \\ & = O(1). \end{aligned}$$

Zadnji korak v tej izpeljavi prihaja iz dejstva, da $\sum_{k=0}^{\infty} k^2 \cdot O(c^k)$ eksponentno zmanjšuje vrsto.² Potemtakem lahko sklepamo, da je pričakovan čas izvajanja operacije $\mathbf{find}(\mathbf{x})$ za vrednost \mathbf{x} , ki ni vsebovana v `LinearHashTable` enaka, $O(1)$.

Če zanemarimo ceno operacije `resize()`, potem nam gornja analiza poda vse kar potrebujemo za analiziranje cene ostalih operacij v `LinearHashTable`.

Analiza gornje operacije $\mathbf{find}(\mathbf{x})$ velja pri operaciji `add(x)` kadar, \mathbf{x} ni v tabeli. Za analizo operacije $\mathbf{find}(\mathbf{x})$ kadar, \mathbf{x} je vsebovan v tabeli moramo upoštevati samo to, da je cena enaka operaciji `add(x)` s katero smo dodali \mathbf{x} v tabelo. Za konec, cena operacije `remove(x)` je enaka ceni operacije $\mathbf{find}(\mathbf{x})$.

²V terminologiji več matematičnih učbenikov nam ta vsota poda razmerje: Obstaja pozitivno celo število k_0 , ki velja za vse $k \geq k_0$, $\frac{(k+1)^2 c^{k+1}}{k^2 c^k} < 1$.

V povzetku, če zanemarimo ceno klicev operacije `resize()`, so vse ostale operacije v `LinearHashTable` izvršene v pričakovanem času $O(1)$. Da upoštevamo ceno operacije `resize`, lahko uporabimo enako amortizirano analizo izvedeno za podatkovno strukturo `ArrayStack` v 2.1.

5.2.2 Povzetek

Spodnji izrek je povzetek časovnih zahtevnosti, metod, podatkovne strukture `LinearHashTable`:

Izrek 5.2. *`LinearHashTable` implementira vmesnik `USet`. Če ignoriramo ceno klicev metode `resize()`, je pričakovana časovna zahtevnost metod `add(x)`, `remove(x)`, in `find(x)`, podatkovne strukture `LinearHashTable`, enaka $O(1)$.*

Če začnemo s prazno `LinearHashTable`, velja, da za katerokoli zaporedje m operacij metod `add(x)` in `remove(x)`, porabimo $O(m)$ časa za klice metode `resize()`.

5.2.3 Tabelarno zgoščevanje

Med analizo podatkovne strukture `LinearHashTable`, smo naredili zelo močno predpostavko: Da so za katerokoli množico elementov, $\{x_1, \dots, x_n\}$, zgoščevalne vrednosti $\text{hash}(x_1), \dots, \text{hash}(x_n)$ neodvisno in enakomerno razporejene po množici $\{0, \dots, t.\text{length} - 1\}$. En način, kako to doseči je, da hranimo ogromno polje, `tab`, dolžine 2^w , kjer je vsak zapis naključno w bitno celo število, neodvisno od vseh ostalih zapisov. Na ta način bi lahko implementirali `hash(x)`, tako da bi izbrali d bitno celo število iz tabele `tab[x.hashCode()]`:

```
LinearHashTable
int idealHash(T x) {
    return tab[x.hashCode() >>> w-d];
}
```

Na žalost je hranjenje polja velikosti 2^w neoptimalna rešitev, kar se tiče prostorske porabe. Pristop, ki ga uporablja *tabelarno zgoščevanje* je, da w bitna cela števila obravnava kot cela števila, ki so sestavljena iz w/r celih števil, ki imajo dolžino le r bitov. Tako pri tabelarnem zgoščevanju

potrebujemo samo w/r polj velikosti 2^r . Vsi zapisi v teh poljih so neodvisna w -bitna cela števila. Da pridobimo vrednost $\text{hash}(x)$, razdelimo $x.\text{hashCode}()$ v w/r r -bitnih celih števil ter jih uporabimo kot indekse za polja. Nato vse te vrednosti združimo z bitnim operatorjem izključni ali(XOR), da pridobimo $\text{hash}(x)$. Spodnja programska koda prikazuje kako to deluje za $w = 32$ in $r = 4$:

```

LinearHashTable
int hash(T x) {
    int h = x.hashCode();
    return (tab[0][h&0xff]
            ^ tab[1][(h>>8)&0xff]
            ^ tab[2][(h>>16)&0xff]
            ^ tab[3][(h>>24)&0xff])
        >>> (w-d);
}

```

V temu primeru je `tab` dvodimenzionalno polje s štirimi stolpci in $2^{32/4} = 256$ vrsticami.

Enostavno lahko preverimo, da je, za poljubni x , $\text{hash}(x)$ enakomerno razporejen po intervalu $\{0, \dots, 2^d - 1\}$. Z malo dodatnega dela lahko tudi preverimo, da ima poljubni par vrednosti neodvisne zgoščene vrednosti. To pomeni, da bi se za implementacijo `ChainedHashTable`, namesto zgoščevalne funkcije - metode množenja uporabilo tabelarno zgoščevanje.

Dejstvo, da ima poljubna množica n različnih vrednosti množico n neodvisnih zgoščenih vrednosti ne velja. Ne glede na to, pa velja, da ko uporabljamo tabelarno zgoščevanje, še vedno velja meja 5.2. Reference za to lahko najdete na koncu tega poglavja.

5.3 Zgoščene vrednosti

Zgoščene tabele, ki smo si jih pogledali v prejšnjem podpoglavju se uporabljajo za povezovanje podatkov s celoštevilskimi ključi sestavljenimi iz w bitov. Velikokrat pa uporabljamo ključe, ki niso cela števila. Lahko so nizi znakov, objekti, tabele ali ostale sestavljene strukture. Da lahko uporabimo zgoščevalne funkcije na takih tipih podatkov moramo prej pre-

slikati te podatke v w -bitne zgoščene vrednosti. Preslikave zgoščevalnih funkcij morajo imeti naslednje lastnosti:

1. Če sta x in y enaka, potem morata biti enaka tudi $x.hashCode()$ in $y.hashCode()$.
2. Če x in y nista enaka, potem mora biti verjetnost, da sta $x.hashCode() = y.hashCode()$ majhna (blizu $1/2^w$).

Prva lastnost nam zagotavlja, da če v zgoščeni tabeli hranimo x in kasneje iščemo vrednost y (ki je enaka x), da bomo našli x . Druga lastnost pa nam preprečuje izgubo podatkov pri pretvarjanju objektov v cela števila. Zagotavlja nam, da bodo različni objekti imeli različno zgoščeno vrednost in bodo tako zelo verjetno shranjeni na različnih mestih v naši zgoščeni tabeli.

5.3.1 Zgoščene vrednosti osnovnih podatkovnih tipov

Za majhne osnovne podatkovne tipe kot so `char`, `byte`, `int`, in `float` lahko ponavadi hitro najdemo zgoščeno vrednost. Ti podatkovni tipi imajo vedno binarno predstavitev sestavljeno iz w ali manj bitov. (V Javi je, `byte` 8-bitni podatkovni tip in `float` 32-bitni.) V teh primerih te bite obravnavamo kot cela števila na intervalu $\{0, \dots, 2^w - 1\}$. Če sta dve vrednosti različni potem dobijo različni zgoščeni vrednosti. Če sta vrednosti enaki pa dobita enako zgoščeno vrednost.

Nekateri podatkovni tipi pa so sestavljeni iz več kot w bitov. Ponavadi cw bitov za neko konstantno celo število c . (V Javi sta `long` in `double` primera tipov pri katerih je $c = 2$.) Te podatkovne tipe lahko obravnavamo kot objekte sestavljene iz c delov, kot je opisano v naslednjem podpodglavju.

5.3.2 Zgoščene vrednosti sestavljenih podatkovnih tipov

Za sestavljene objekte si želimo zgraditi zgoščevalno funkcijo, ki bi kombinirala zgoščene vrednosti podatkovnih tipov, ki ta objekt sestavljajo. Vendar pa to ni tako enostavno kot zveni. Kljub temu, da lahko najdemo kar nekaj bližnic s katerimi to lahko naredimo (na primer sestavljanje zgoščenih vrednosti z operacijo XOR) pa to ni rešitev problema,

saj lahko hitro pridemo do primerov kjer take bližnjice odpovedo (glej naloge 5.7–5.9). A vendar obstajajo hitri in robustni načini reševanja tega problema, če si lahko privoščimo računanje z 2^w bitno natančnostjo. Zamislimo si objekt sestavljen iz delov P_0, \dots, P_{r-1} katerih zgoščene vrednosti so x_0, \dots, x_{r-1} . Potem si lahko izberemo neodvisna in naključna w -bitna števila z_0, \dots, z_{r-1} in eno liho in naključno celo število z sestavljeno iz 2^w bitov. Iz tega lahko izračunamo zgoščeno vrednost za naš objekt na naslednji način:

$$h(x_0, \dots, x_{r-1}) = \left(\left(z \sum_{i=0}^{r-1} z_i x_i \right) \bmod 2^{2^w} \right) \text{div } 2^w .$$

Upoštevajte, da ima ta zgoščena vrednost zadnji korak (deljenje z z in deljenje z 2^w), ki uporablja multiplikativno zgoščevalno funkcijo iz 5.1.1, da vzame 2^w -bitni vmesni rezultat in ga pomanjša v w -bitni končni rezultat. Tukaj je primer te metode uporabljene na enostavnemu sestavljenemu podatkovnemu tipu s tremi deli x_0 , x_1 , and x_2 :

```

Point3D
int hashCode() {
    // random numbers from rand.org
    long[] z = {0x2058cc50L, 0xcb19137eL, 0x2cb6b6fdL};
    long zz = 0xbea0107e5067d19dL;

    // convert (unsigned) hashcodes to long
    long h0 = x0.hashCode() & ((1L<<32)-1);
    long h1 = x1.hashCode() & ((1L<<32)-1);
    long h2 = x2.hashCode() & ((1L<<32)-1);

    return (int)((z[0]*h0 + z[1]*h1 + z[2]*h2)*zz)
        >>> 32);
}

```

Naslednji izrek nam pokaže, da je metoda, ob tem da je enostavna za implementacijo, tudi dokazano dobra:

Izrek 5.3. Naj bosta x_0, \dots, x_{r-1} in y_0, \dots, y_{r-1} sekvenci w bitnih integerjev v $\{0, \dots, 2^w - 1\}$ in predvidevamo, da $x_i \neq y_i$ za vsaj en indeks $i \in \{0, \dots, r-1\}$. Potem

$$\Pr\{h(x_0, \dots, x_{r-1}) = h(y_0, \dots, y_{r-1})\} \leq 3/2^w .$$

Dokaz. Najprej bomo ignorirali zadnji multiplikativni zgoščevalni korak in si kasneje pogledali kako ta korak prispeva. Opredeli:

$$h'(\mathbf{x}_0, \dots, \mathbf{x}_{r-1}) = \left(\sum_{j=0}^{r-1} z_j \mathbf{x}_j \right) \bmod 2^{2w} .$$

Predvidevamo, da $h'(\mathbf{x}_0, \dots, \mathbf{x}_{r-1}) = h'(\mathbf{y}_0, \dots, \mathbf{y}_{r-1})$. To lahko zapišemo kot:

$$z_i(\mathbf{x}_i - \mathbf{y}_i) \bmod 2^{2w} = t \quad (5.4)$$

kjer

$$t = \left(\sum_{j=0}^{i-1} z_j(\mathbf{y}_j - \mathbf{x}_j) + \sum_{j=i+1}^{r-1} z_j(\mathbf{y}_j - \mathbf{x}_j) \right) \bmod 2^{2w}$$

Če predvidevamo, da je brez izgube splošnosti $\mathbf{x}_i > \mathbf{y}_i$, potem (5.4) postane

$$z_i(\mathbf{x}_i - \mathbf{y}_i) = t , \quad (5.5)$$

saj je vsak od z_i in $(\mathbf{x}_i - \mathbf{y}_i)$ največ $2^w - 1$, torej je njun produkt največ $2^{2w} - 2^{w+1} + 1 < 2^{2w} - 1$. Po domnevi, $\mathbf{x}_i - \mathbf{y}_i \neq 0$, torej (5.5) ima največ eno rešitev v z_i . Zato, ker sta z_i in t neodvisna (z_0, \dots, z_{r-1} sta medsebojno neodvisna), verjetnost, da izberemo z_i tako da je $h'(\mathbf{x}_0, \dots, \mathbf{x}_{r-1}) = h'(\mathbf{y}_0, \dots, \mathbf{y}_{r-1})$ največ $1/2^w$.

Zadnji korak zgoščevalne funkcije se uporablja za multiplikativno zgoščevanje, da zmanjšamo naše $2w$ -bitne vmesne rezultate $h'(\mathbf{x}_0, \dots, \mathbf{x}_{r-1})$ v w -bitni končni rezultat $h(\mathbf{x}_0, \dots, \mathbf{x}_{r-1})$. Po teoremu 5.3, če $h'(\mathbf{x}_0, \dots, \mathbf{x}_{r-1}) \neq h'(\mathbf{y}_0, \dots, \mathbf{y}_{r-1})$, potem $\Pr\{h(\mathbf{x}_0, \dots, \mathbf{x}_{r-1}) = h(\mathbf{y}_0, \dots, \mathbf{y}_{r-1})\} \leq 2/2^w$.

Če povzamemo,

$$\begin{aligned} & \Pr \left\{ \begin{array}{l} h(\mathbf{x}_0, \dots, \mathbf{x}_{r-1}) \\ = h(\mathbf{y}_0, \dots, \mathbf{y}_{r-1}) \end{array} \right\} \\ &= \Pr \left\{ \begin{array}{l} h'(\mathbf{x}_0, \dots, \mathbf{x}_{r-1}) = h'(\mathbf{y}_0, \dots, \mathbf{y}_{r-1}) \text{ ali} \\ h'(\mathbf{x}_0, \dots, \mathbf{x}_{r-1}) \neq h'(\mathbf{y}_0, \dots, \mathbf{y}_{r-1}) \\ \quad \text{in } zh'(\mathbf{x}_0, \dots, \mathbf{x}_{r-1}) \bmod 2^w = zh'(\mathbf{y}_0, \dots, \mathbf{y}_{r-1}) \bmod 2^w \end{array} \right\} \\ &\leq 1/2^w + 2/2^w = 3/2^w . \end{aligned} \quad \square$$

5.3.3 Zgoščevalne funkcije za polja in nize

Metoda iz prejšnjega dela deluje dobro za objekte, ki imajo stalno število komponent. Vendar ne deluje dobro, ko jo želimo uporabiti za objekte, ki imajo spremenljivo število komponent, saj potrebuje naključno w -bitno celo število za vsako komponento. Lahko bi uporabili psevdonaključno zaporedje za generiranje toliko števil z kolikor jih potrebujemo, toda števila z niso medsebojno neodvisna, zaradi česar bi težko dokazali da psevdonaključna števila ne vplivajo na zgoščevalno funkcijo, ki jo uporabljamo. Vrednosti t in z v dokazu 5.3 nista več neodvisni.

Bolj temeljit pristop je, da uporabimo polinome nad praštevili. To pomeni le, da uporabimo običajne polinomske funkcije, ki dajo ostanek deljenja z nekim praštevilom p . Ta metoda sloni nad sledečim teoremom, ki pravi, da se takšne funkcije obnašajo podobno kot običajne polinomske funkcije:

Izrek 5.4. *Naj bo p praštevilo in $f(z) = x_0z^0 + x_1z^1 + \dots + x_{r-1}z^{r-1}$ netrivialni polinom s koeficienti $x_i \in \{0, \dots, p-1\}$. Takrat ima enačba $f(z) \bmod p = 0$ največ $r-1$ rešitev za $z \in \{0, \dots, p-1\}$.*

Da izkoristimo 5.4, uporabimo zgoščevalno funkcijo nad zaporedjem celih števil x_0, \dots, x_{r-1} kjer je vsak $x_i \in \{0, \dots, p-1\}$ z uporabo naključnega celega števila $z \in \{0, \dots, p-1\}$ in funkcije

$$h(x_0, \dots, x_{r-1}) = (x_0z^0 + \dots + x_{r-1}z^{r-1} + (p-1)z^r) \bmod p.$$

Ste opazili $(p-1)z^r$ na koncu formule? To si lahko predstavljate kot zadnji element, x_r , v zaporedju x_0, \dots, x_r . Ta element se razlikuje od vseh ostalih (ki so v $\{0, \dots, p-2\}$). $p-1$ je kot znak, ki označuje konec zaporedja.

Sledeči teorem, ki upošteva primer, ko sta obe zaporedji enako dolgi, dokazuje, da ta zgoščevalna funkcija daje dober rezultat pri majhni meri naključnosti pri izbiri z :

Izrek 5.5. *Vzemimo $p > 2^w + 1$ da je naravno število, vzemimo x_0, \dots, x_{r-1} in y_0, \dots, y_{r-1} vsako je sekvenca w -bit celih števil v $\{0, \dots, 2^w-1\}$ in predpostavimo $x_i \neq y_i$ za vsaj en indeks $i \in \{0, \dots, r-1\}$. Potem*

$$\Pr\{h(x_0, \dots, x_{r-1}) = h(y_0, \dots, y_{r-1})\} \leq (r-1)/p.$$

Dokaz. Enačba $h(x_0, \dots, x_{r-1}) = h(y_0, \dots, y_{r-1})$ je lahko napisana kot

$$((x_0 - y_0)z^0 + \dots + (x_{r-1} - y_{r-1})z^{r-1}) \bmod p = 0. \quad (5.6)$$

Ker $x_i \neq y_i$, je ta polinom netrivialen. Potemtakem, po 5.4, ima največ $r - 1$ rešitev v \mathbb{Z} . Verjetnost, da izberemo z , ki je ena od teh rešitev, je potemtakem v najboljšem primeru $(r - 1)/p$. \square

Opozorimo, da ima ta zgoščevalna funkcija, prav tako opravka s primeri v katerih imata dve sekvenci različno dolžino, čeprav je ena od sekvenc predpona drugi. To je zaradi tega, ker ta funkcija učinkovito zgoščuje neskončno sekvenco

$$x_0, \dots, x_{r-1}, p - 1, 0, 0, \dots$$

To zagotavlja, da če imamo dve sekvenci dolžine r in r' z $r > r'$, potem se ti dve sekvenci razlikujeta v indeksu $i = r$. V tem primeru (5.6) postane

$$\left(\sum_{i=0}^{i=r'-1} (x_i - y_i)z^i + (x_{r'} - p + 1)z^{r'} + \sum_{i=r'+1}^{i=r-1} x_i z^i + (p - 1)z^r \right) \bmod p = 0,$$

katero, po 5.4, ima največ r rešitev v \mathbb{Z} . Skupaj z 5.5 to zadostuje za dokaz naslednjega bolj splošnega teorema:

Izrek 5.6. *Vzemimo $p > 2^w + 1$ da je naravno število, vzemimo x_0, \dots, x_{r-1} in $y_0, \dots, y_{r'-1}$, da sta unikatne sekvence w -bit celih števil v $\{0, \dots, 2^w - 1\}$. Potem*

$$\Pr\{h(x_0, \dots, x_{r-1}) = h(y_0, \dots, y_{r'-1})\} \leq \max\{r, r'\}/p.$$

Sledeči primer kode prikazuje kako je ta zgoščevalna funkcija uporabljena na objektu, ki vsebuje polje x , ki vsebuje vrednosti:

```

GeomVector
int hashCode() {
    long p = (1L<<32)-5;    // prime: 2^32 - 5
    long z = 0x64b6055aL;    // 32 bits from random.org
    int z2 = 0x5067d19d;     // random odd 32 bit number
    long s = 0;
    long zi = 1;
    for (int i = 0; i < x.length; i++) {

```

```

// reduce to 31 bits
long xi = (x[i].hashCode() * z2) >>> 1;
s = (s + zi * xi) % p;
zi = (zi * z) % p;
}
s = (s + zi * (p-1)) % p;
return (int)s;
}

```

Predstavljena koda žrtvuje nekaj verjetnosti kolizije zaradi implementacijske uporabnosti. Zlasti zaradi tega, ker aplicira multiplikativno razprši-tveno funkcijo iz 5.1.1, z $d = 31$ za zmanjšanje `x[i].hashCode()` v 31-bit vrednost. To je zaradi tega, da seštevanje in množenje, ki sta narajena po operaciji modula naravnega števila $p = 2^{32} - 5$, se lahko izvede z uporabo nepodpisane 63-bit aritmetike. Zaradi tega, je verjetnost dveh različnih sekvenc, od tega ima daljša dolžino r , da imata enako zgoščeno vrednost v najslabšem primeru

$$2/2^{31} + r/(2^{32} - 5)$$

za razliko od $r/(2^{32} - 5)$ specificirano v 5.6.

5.4 Razprave in primeri

Zgoščevalne tabele in zgoščene vrednosti predstavljajo aktivno področje raziskovanja, ki se ga v tem poglavju le grobo dotaknemo. Spletna bibliografija o zgoščevanju [?] vključuje skoraj 2000 vnosov.

Obstaja veliko različnih implementacij zgoščevalnih tabel. Metodo opisano v 5.1 poznamo pod imenom *zgoščevanje z veriženjem* (vsak vnos v tabelo vsebuje verigo ([sezman](#)) elementov). Korenine zgoščevanja z veriženjem segajo vse do internega pisma v podjetju IBM katerega je januarja 1953 napisal H. P. Luhn. To pismo je tudi ena izmed prvih referenc na povezane sezname.

Alternativa zgoščevanju z veriženjem se uporablja pri *odprtem naslavljanju*, kjer so vsi podatki shranjeni neposredno v tabeli. Sem spadajo strukture iz družine `LinearHashTable` 5.2. To idejo je prav tako predlagala neka druga (nepovezana) skupina pri podjetju IBM okoli leta 1950.

Sheme odprtega naslavljanja morajo nasloviti težave *odpravljanja trkov* : primer kadar se dve vrednosti preslikata v enako lokacijo v tabeli. Obstajajo različne tehnike odpravljanja trkov. Te ponujajo različne zmogljivosti in velikokrat uporabljajo bolj napredne zgoščevalne funkcije kot tiste, ki so opisane tukaj.

Obstaja še ena metoda izvedbe zgoščevalnih tabel - tako imenovane *popolne zgoščevalne metode*. To so metode kjer $\text{find}(x)$ operacije vzamejo $O(1)$ časa v najslabšem primeru. Za statične podatke lahko do tega pridemo z iskanjem *popolne zgoščevalne funkcije* za te podatke. Te funkcije preslikajo vse podatke na unikatno mesto v tabeli. Za podatke, ki se skozi čas spreminjajo poznamo dve metodi popolnega zgoščevanja - *FKS dvo-nivojske zgoščevalne tabele* [?, ?] in *cuckoo hashing* [?].

Zgoščevalne funkcije predstavljene v tem poglavju so verjetno ene izmed najbolj praktičnih metod (ki jih poznamo) za shranjevanje vseh vrst podatkov. Ostale dobre metode segajo nazaj do prelomnega dela Carterja in Wegmana, ki sta predstavila idejo *univerzalnega zgoščevanja*

in opisala različne zgoščevalne funkcije za različne scenarije [?]. Tabelarično zgoščevanje, opisano v 5.2.3, poznamo po zaslugi Carterja in Wegmana [?]. Analizo uporabe tabelaričnega zgoščevanja pri linearnem poizvedovanju (in nekaj ostalih metodah) pa sta opisala Pătraşcu in Thorup [?].

Ideja *zgoščevanja z množenjem* je zelo stara in je del zgoščevalne folklore [?, Section 6.4]. Vendar je ideja, da izberemo množitelja z kot naključno *sodo* število in analiza 5.1.1, zastarela po mnenju Dietzfelbingerja *et al.* [?]. Ta različica zgoščevanja z množenjem je ena od najpreprostejših, ampak njena verjetnost kolizije $2/2^d$ je za dva faktorja večja kot pri naključni funkciji $2^w \rightarrow 2^d$. Zgoščevalna metoda *zmnoži-seštej* uporablja funkcijo

$$h(x) = ((zx + b) \bmod 2^{2w}) \text{div } 2^{2w-d}$$

kjer sta z in b naključno izbrana iz $\{0, \dots, 2^{2w}-1\}$. Zmnoži-seštej zgoščevanje ima verjetnost kolizije samo $1/2^d$ [?], ampak zahteva $2w$ -bitne aritmetične operacije.

Obstaja kar nekaj metod za pridobivanje zgoščenih vrednosti iz zaporedja fiksne dolžine, vsebujoč w -bitnih celih števil. Še posebej hitra

metoda [?] je funkcija

$$h(x_0, \dots, x_{r-1}) \\ = \left(\sum_{i=0}^{r/2-1} ((x_{2i} + a_{2i}) \bmod 2^w)((x_{2i+1} + a_{2i+1}) \bmod 2^w) \right) \bmod 2^{2w}$$

kjer je r parno število in a_0, \dots, a_{r-1} naključno izbrani iz $\{0, \dots, 2^w\}$. To ustvari $2w$ -bitno zgoščeno vrednost, katere možnost kolizije je $1/2^w$. To se lahko zmanjša na w -bitno zgoščeno vrednost z uporabo zgoščevanja z množenjem. Ta metoda je hitra, ker zahteva samo $r/2$ $2w$ -bitnih množenj, metoda omenjena v 5.3.2 pa zahteva r množenj. (mod operacije se dogajajo zaporedno z uporabo w in $2w$ -bitne aritmetične operacije za seštevanje in množenje.)

Metoda iz 5.3.3, ki uporablja polinome in polja praštevil za zgoščevanje tabel in nizov spremenljive dolžine je zastarela po mnenju Dietzfelbinerja *et al.* [?]. Zaradi njene uporabe mod operatorja, ki se zanaša na potrošne strojne ukaze je na žalost počasna. Nekatere različice te metode določijo praštevilo p iz obrazca $2^w - 1$. V tem primeru se lahko operator mod zamenja s prištevanjem (+) in logično in(&) operacijo [?, Section 3.6]. Druga možnost je uporaba hitrejša metode za nize fiksne velikosti pri blokih dolžine c za neko konstanto $c > 1$ in potem metode s polji praštevil za zaporedje $\lceil r/c \rceil$ zgoščenih vrednosti.

Naloga 5.1. Nekatere univerze vsakemu študentu določijo študentsko številko, ko se prvič prijavijo za katerikoli predmet. Te številke so zaporedna cela števila, ki so se začela z 0 mnogo let nazaj in so sedaj zapisana že v milijonih. Recimo, da imamo razred stotih novih študentov in bi radi vsakemu študentu dodelili zgoščeno vrednost, ki je odvisna od njihovih študentskih števil. Ali ima več smisla uporabiti prvi dve števki ali zadnji dve števki študentske številke? Pojasni svoj odgovor.

Naloga 5.2. Upoštevajte zgoščevalno funkcijo iz odstavka 5.1.1, in postavite, da je $n = 2^d$ and $d \leq w/2$.

1. Pokažite, da za vsakega izbranega množitelja, z , obstajajo vrednosti n , ki imajo enako zgoščeno vrednost. (Namig: Gre za preprosto rešitev, ki ne zahteva teorije števil).
2. Glede na podanega množitelja, z , opišite tiste vrednosti n , ki imajo enako zgoščeno vrednost. (Hint: Ta primer je zahtevnejši in zahteva poznavanje osnov teorije števil.)

Naloga 5.3. Pokažite, da je meja dovoljene vrednosti $2/2^d$ v trditvi 5.1 najboljša možna meja, če je $x = 2^{w-d-2}$ in $y = 3x$, then $\Pr\{\text{hash}(x) = \text{hash}(y)\} = 2/2^d$. (Namig: Poglejte si binarni prikaz za zx in $z3x$ in upoštevajte dejstvo, da je $z3x = zx + 2zx$.)

Naloga 5.4. Dokažite trditev 5.4 z uporabo Stirlingove aproksimacije iz poglavja 1.3.2.

Naloga 5.5. Upoštevajte spodnjo poenostavljeno verzijo kode za dodajanje elementa x v LinearHashTable (zgoščevalno tabelo z odprtim naslavljanjem), ki element x shrani v prvo polje v tabeli, ki vsebuje vrednost `null`. Opišite zakaj je ta način dodajanja elementov zelo počasen. Pokažite to na primeru zaporednega izvajanja operacij $O(n)$ `add(x)`, `remove(x)`, in `find(x)`, ki za izvedbo porabijo n^2 časa.

```

LinearHashTable
boolean addSlow(T x) {
    if (2*(q+1) > t.length) resize(); // max 50% occupancy
    int i = hash(x);
    while (t[i] != null) {
        if (t[i] != del && x.equals(t[i])) return false;
        i = (i == t.length-1) ? 0 : i + 1; // increment i
    }
    t[i] = x;
    n++; q++;
    return true;
}

```

Naloga 5.6. Zgodnejše verzije metode Java `hashCode()` za razred `String` ni delovala tako, da bi uporabila vse znake v dolgem nizu. Naprimer, za 16 znakov dolg niz se je zgoščena vrednost izračunala glede na osem sodo indeksiranih znakov. Na primeru pojasnite zakaj to ni bila pametna ideja. Primer naj sestoji iz večjega nabora nizov, pri čemer naj imajo vsi enako zgoščeno vrednost.

Naloga 5.7. Predpostavite da imate objekt sestavljen iz dveh w -bitnih števil, x in y . Pokažite zakaj $x \oplus y$ ni dobra zgoščena vrednost za vaš objekt. Pokažite tudi primer večje množice objektov, kjer bi vsi imeli kodo razpršitve 0.

Naloga 5.8. Predpostavite da imate objekt sestavljen iz dveh w -bitnih števil, x in y . Pokažite zakaj $x + y$ ni dobra zgoščena vrednost za vaš objekt. Pokažite tudi primer večje množice objektov, kjer bi vsi imeli enako zgoščeno vrednost.

Naloga 5.9. Predpostavite da imate objekt sestavljen iz dveh w -bitnih števil, x in y . Predpostavite tudi, da je zgoščena vrednost za vaš objekt definirana z deterministično funkcijo $h(x, y)$, ki ustvari eno samo w -bitno število. Dokažite da obstaja večja množica objektov, ki imajo enako zgoščena vrednost.

Naloga 5.10. Naj za neko pozitivno število w velja $p = 2^w - 1$. Razložite zakaj za pozitivno število x velja

$$(x \bmod 2^w) + (x \operatorname{div} 2^w) \equiv x \bmod (2^w - 1) .$$

(Dobimo algoritem za računanje $x \bmod (2^w - 1)$ s pomočjo zaporednega nastavljanja

$$x = x \& ((1 \ll w) - 1) + x \gg w$$

dokler ne velja $x \leq 2^w - 1$.)

Naloga 5.11. Izberite neko pogostokrat uporabljeno implementacijo zgošče-ne tabele kot je recimo JavaCollection Framework HashMap ali HashTable oziroma LinearHashTable iz te knjige in napišite program, ki v to podatkovno strukturo shranjuje števila, x , tako da je časovna zahtevnost funkcije `find(x)` linearna. Se pravi, poiščite množico n števil v kateri je cn elementov, katerih zgoščena vrednost je na isti lokaciji v tabeli. Odvisno od kvalitete implementacije boste to mogoče lahko dosegli že samo z natančnim pregledom kode ali pa boste morali napisati nekaj vrstic kode, ki bo poskušala z vstavljanjem in iskanjem elementov ter merjenjem časa za dodajanje in iskanje posameznih vrednosti. (To se lahko, se tudi že je, uporabi za napad DOS(denial of service) na strežnike [?].)

Poglavje 6

Dvojiška drevesa


To poglavje vpeljuje eno izmed najbolj temeljnih struktur v računalništvu: dvojiška drevesa. Uporaba besede *drevo* prihaja iz dejstva, da je, ko jih rišemo, končna risba podobna drevesom iz gozda. Obstaja več definicij dvojiških dreves. Matematično je *dvojiško drevo* povezan, neusmerjen, končni graf brez ciklov in z vozlišči s stopnjo največ tri.

V računalništvu običajno uporabljamo dvojiška drevesa s *korenskim vozliščem*: Posebno vozlišče r , stopnje največ 2, se imenuje *koren* drevesa. Za vsako vozlišče $u \neq r$, se prvo vozlišče na poti od u do r imenuje *starš* vozlišča u . Ostala sosednja vozlišča vozlišča u imenujemo *otroci* vozlišča u . Večina dvojiških dreves, ki nas zanimajo, so *urejena*, tako da ločimo med *levim* in *desnim otrokom* vozlišča u .


Dvojiška drevesa običajno rišemo obrnjena navzdol, s korenem na vrhu slike in z levim oz. desnim otrokom na levi oz. strani (slika 6.1). Na sliki 6.2 je prikazano dvojiško drevo z devetimi vozlišči.

Ker so dvojiška drevesa tako pomembna, zanje uporabljamo naslednje izrazoslovje: *globina* vozlišča u , je v dvojiškem drevesu dolžina poti od u do korena drevesa. Če je vozlišče w na poti od u do r , potem w imenujemo *prednik* vozlišča u , u pa imenujemo *potomec* vozlišča w . *Poddrevo* vozlišča u je dvojiško drevo, ki ima koren u in vsebuje vse potomce vozlišča u . *Višina* vozlišča u je dolžina najdaljše poti od u do enega izmed njegovih potomcev. *Višina* drevesa je višina njegovega korena. Vozlišče u je *list*, če nima nobenega otroka.

Včasih si predstavljamo, da so drevesa dopolnjena z *navideznimi zunanjimi vozlišči*. Vsako vozlišče, ki nima levega oz. desnega otroka, ima



Slika 6.1: Starš, levi otrok, desni otrok vozlišča u v dvojiškem drevesu (BinaryTree).



Slika 6.2: Dvojiško drevo (a) z devetimi dejanskimi vozlišči in (b) z desetimi navideznimi vozlišči.

zunanje vozlišče na njunih mestih (glej 6.2.b). Z indukcijo lahko enostavno pokažemo, da ima dvojiško drevo z $n \geq 1$ dejanskimi vozlišči $n + 1$ navideznih vozlišč.

6.1 BinaryTree: Osnovno dvojiško drevo

Najenostavnejši način predstavitve vozlišča u v dvojiškem drevesu je neposredna hramba (največ treh) sosedov vozlišča u :

```
BinaryTree
class BTreeNode<Node> extends BTreeNode<Node>> {
    Node left;
    Node right;
    Node parent;
}
```

Če kateri koli od njih ni prisoten, ga nastavimo na `nil`. Vrednosti vseh zunanjih vozlišč in starša korena je vedno `nil`.

Za predstavitev dvojiškega drevesa ni potrebna ločena podatkovna struktura, ampak lahko uporabimo kar referenco na koren dvojiškega drevesa, r :

```
BinaryTree
Node r;
```

Globino vozlišča u lahko izračunamo tako, da preštujemo korake od vozlišča u do korena drevesa:

```
BinaryTree
int depth(Node u) {
    int d = 0;
    while (u != r) {
        u = u.parent;
        d++;
    }
    return d;
}
```

6.1.1 Rekurzivni algoritmi

Z rekurzivnimi algoritmi je delo z drevesi preprosto. Na primer, za izračun velikosti (število vozlišč) dvojiškega drevesa s korenem **u** rekurzivno izračunamo velikosti obeh poddreves vozlišča **u**, ju seštejemo in prištejemo 1:

```

BinaryTree
int size(Node u) {
    if (u == nil) return 0;
    return 1 + size(u.left) + size(u.right);
}

```

Za izračun višine vozlišča **u** rekurzivno izračunamo višini obeh poddreves, izberemo višino višjega in prištejemo 1:

```

BinaryTree
int height(Node u) {
    if (u == nil) return -1;
    return 1 + max(height(u.left), height(u.right));
}

```

6.1.2 Obhod dvojiškega drevesa

Algoritma iz predhodnega razdelka za obisk vozlišč v dvojiškem drevesu uporabljata rekurzijo. Oba obiskujeta vozlišča v vrstnem redu, kot ga prikazuje sledeča koda:

```

BinaryTree
void traverse(Node u) {
    if (u == nil) return;
    traverse(u.left);
    traverse(u.right);
}

```

Z uporabo rekurzije lahko pišemo kratko in enostavno kodo, kar pa je lahko problematično. Največja globina rekurzije je določena z globino vozlišča, to je višina preiskovanega drevesa. Če je ta zelo velika, lahko

rekurzivni klici presežejo dodeljeno velikost sklada, kar povzroči sesutje programa.


Za obhod dvojiškega drevesa brez rekurzije lahko uporabimo algoritem, ki se zanaša na to, da ve, od kod je prišel in kam bo odšel. Glej kodo 6.3. Če pridemo v vozlišče `u` iz `u.parent`, potem obiščemo `u.left`. Če pridemo v `u` iz `u.left`, potem obiščemo `u.right`. Če prispemo v `u` iz `u.right`, potem smo končali z obiskovanjem poddreves vozlišča `u` in se vrnemo v `u.parent`. Naslednja koda prikazuje delovanje, vključno s primeri, ko je kateri koli od `u.left`, `u.right` ali `u.parent nil`:

```
BinaryTree
void traverse2() {
    Node u = r, prev = nil, next;
    while (u != nil) {
        if (prev == u.parent) {
            if (u.left != nil) next = u.left;
            else if (u.right != nil) next = u.right;
            else next = u.parent;
        } else if (prev == u.left) {
            if (u.right != nil) next = u.right;
            else next = u.parent;
        } else {
            next = u.parent;
        }
        prev = u;
        u = next;
    }
}
```

Vse probleme, ki jih rešujemo z rekurzivnimi algoritmi, lahko rešimo z iterativnimi algoritmi. Na primer, za izračun velikosti drevesa hranimo števec `n` in ga povečamo vsakič, ko obiščemo novo vozlišče.

```
BinaryTree
int size2() {
    Node u = r, prev = nil, next;
    int n = 0;
    while (u != nil) {
        if (prev == u.parent) {
            n++;
        }
    }
}
```

Dvojiška drevesa




Slika 6.3: Na levi strani: Trije primeri, ki se pojavijo pri nerekurzivnem obhodu drevesa za vozlišče *u*. Na desni strani: Rezultat obhoda drevesa *r*.

```
    if (u.left != nil) next = u.left;
    else if (u.right != nil) next = u.right;
    else next = u.parent;
  } else if (prev == u.left) {
    if (u.right != nil) next = u.right;
    else next = u.parent;
  } else {
    next = u.parent;
  }
  prev = u;
  u = next;
}
return n;
}
```

V nekaterih izvedbah dvojiških dreves se ne uporablja referenca na starša (*parent*). V takih primerih lahko še vedno uporabimo iterativno metodo, vendar potrebujemo še seznam (*List*) ali sklad (*Stack*), da beležimo pot od trenutnega vozlišča do korena.

Posebna vrsta obhoda, ki ne ustreza nobenemu od zgoraj omenjenih vzorcev, je *iskanje v širino*. Pri iskanju v širino vozlišča obiskujemo po nivojih. Začnemo v korenu in nadaljujemo navzdol, kjer obiščemo vsa vozlišča od levega proti desni (glej sliko 6.4). Enak pristop uporabljamo npr. ljudje pri branju knjige v slovenščini. Obhod v širino je izveden z uporabo vrste *q*, ki na začetku vsebuje le koren *r*. Na vsakem koraku



Slika 6.4: Pri obhodu v širino obiščemo vozlišča dvojiškega drevesa po nivojih, na vsakem nivoju pa z leve proti desni.

vzamemo trenutno vozlišče u iz q , nato ga obdelamo in dodamo $u.left$ in $u.right$ (če niso `nil`) v q :


```

BinaryTree
void bfTraverse() {
    Queue<Node> q = new LinkedList<Node>();
    if (r != nil) q.add(r);
    while (!q.isEmpty()) {
        Node u = q.remove();
        if (u.left != nil) q.add(u.left);
        if (u.right != nil) q.add(u.right);
    }
}

```

6.2 BinarySearchTree: Neuravnoteženo dvojiško iskalno drevo

Dvojiško iskalno drevo (`BinarySearchTree`) je posebna oblika dvojiškega drevesa, pri katerem vsako vozlišče u hrani tudi podatek $u.x$ iz neke urejene množice. Podatki dvojiškega iskalnega drevesa upoštevajo *lastnost dvojiških iskalnih dreves*: Za vozlišče u velja, da je vsaka vrednost, shranjena v poddrevesu $u.left$, manjša od $u.x$ in vsaka vrednost, shranjena v poddrevesu $u.right$, večja od $u.x$. Primer dvojiškega iskalnega drevesa je prikazan na sliki 6.5.



Slika 6.5: Dvojiško iskalno drevo.

6.2.1 Iskanje

Zgoraj omenjena lastnost dvojiškega iskalnega drevesa je zelo uporabna, ker nam omogoča hitro iskanje vrednosti x v dvojiškem iskalnem drevesu. Iskanje vrednosti x začnemo v korenu r . Za vsako pregledano vozlišče u imamo tri primere:

1. Če je $x < u.x$, nadaljujemo z iskanjem v $u.left$;
2. Če je $x > u.x$, nadaljujemo z iskanjem v $u.right$;
3. Če je $x = u.x$, pomeni, da smo našli vozlišče u , ki hrani x .

Iskanje se zaključi na dva načina: Bodisi smo naleteli na primer 3, kjer smo x našli, bodisi je $u = \text{nil}$ (prazen), kar pomeni, da x ni v dvojiškem iskalnem drevesu.

BinarySearchTree

```

T findEQ(T x) {
    Node u = r;
    while (u != nil) {
        int comp = compare(x, u.x);
        if (comp < 0)
            u = u.left;
        else if (comp > 0)
            u = u.right;
    }
}
  
```

```

        else
            return u.x;
    }
    return null;
}

```

Na sliki 6.6 sta prikazana dva primera iskanj v dvojiškem iskalnem drevesu. Drugi primer prikazuje, da tudi v primeru neuspešnega iskanja x vseeno pridobimo nekaj pomembnih informacij. Imenujmo vozlišči z oz. z' zadnji vozlišči, pri katerima se je zgodil primer 1 oz. primer 2. Opazimo, da je $z.x$ najmanjša vrednost v drevesu, ki je še večja od x in $z'.x$ največja vrednost v drevesu, ki je še manjša od x . Tako lahko v `BinarySearchTree` sprogramiramo funkcijo `find(x)`, da vrne najmanjšo vrednost, shranjeno v drevesu, ki je večja ali enaka x :

```


BinarySearchTree
T find(T x) {
    Node w = r, z = nil;
    while (w != nil) {
        int comp = compare(x, w.x);
        if (comp < 0) {
            z = w;
            w = w.left;
        } else if (comp > 0) {
            w = w.right;
        } else {
            return w.x;
        }
    }
    return z == nil ? null : z.x;
}

```

6.2.2 Vstavljanje

Pri vstavljanju nove vrednosti x v dvojiško iskalno drevo najprej poiščemo x v drevesu. Če ga najdemo, potem vstavljanje ni potrebno. V nasprotnem primeru pripnemo x k zadnjemu vozlišču p , ki smo ga

Dvojiška drevesa



Slika 6.6: Primer (a) uspešnega iskanja (za 6) ter (b) neuspešnega iskanja (za 10) v dvojiškem iskalnem drevesu.

obiskali med iskanjem vrednosti x . Ali je novo vozlišče levi ali desni otrok vozlišča p , je odvisno od rezultata primerjave med x ter $p.x$.

```


BinarySearchTree
boolean add(T x) {
    Node p = findLast(x);
    return addChild(p, newNode(x));
}

```

```

BinarySearchTree
Node findLast(T x) {
    Node w = r, prev = nil;
    while (w != nil) {
        prev = w;
        int comp = compare(x, w.x);
        if (comp < 0) {
            w = w.left;
        } else if (comp > 0) {
            w = w.right;
        } else {
            return w;
        }
    }
    return prev;
}

```



Slika 6.7: Vstavljanje vrednosti 8,5 v dvojiško iskalno drevo.

}

```

BinarySearchTree
boolean addChild(Node p, Node u) {
    if (p == nil) {
        r = u;                                // inserting into empty tree
    } else {
        int comp = compare(u.x, p.x);
        if (comp < 0) {
            p.left = u;
        } else if (comp > 0) {
            p.right = u;
        } else {
            return false;    // u.x is already in the tree
        }
        u.parent = p;
    }
    n++;
    return true;
}

```

Primer vstavljanja je prikazan na sliki 6.7. Najbolj časovno zahteven del vstavljanja je iskanje vozlišča p . Čas iskanja je sorazmeren z višino novo vstavljenega vozlišča u . V najslabšem primeru je ta enak višini drevesa.

6.2.3 Brisanje


Brisanje vrednosti, ki jo hrani vozlišče u v strukturi `BinarySearchTree` je malce težje. Če je u list potem preprosto odstranimo u iz seznama otrok njegovega starša. V primeru, da ima u samo enega otroka lahko odstranimo u iz drevesa tako, da $u.parent$ posvoji u -jevega otroka (glej 6.8):

```


BinarySearchTree
void splice(Node u) {
    Node s, p;
    if (u.left != nil) {
        s = u.left;
    } else {
        s = u.right;
    }
    if (u == r) {
        r = s;
        p = nil;
    } else {
        p = u.parent;
        if (p.left == u) {
            p.left = s;
        } else {
            p.right = s;
        }
    }
    if (s != nil) {
        s.parent = p;
    }
    n--;
}

```

Brisanje pa se zakomplicira, ko ima u dva otroka. V tem primeru je najlažje poiskati neko vozlišče w , ki ima manj kot dva otroka, ter da $w.x$ lahko zamenja $u.x$. Za ohranjanje lastnosti dvojiškega iskalnega drevesa mora biti vrednost $w.x$ blizu vrednosti $u.x$. Na primer: če bi izbrali w tako, da je $w.x$ najmanjša vrednost, ki je večja od $u.x$, bi delovalo. Iskanje primerne vrednosti w je preprosto: to je najmanjša vrednost, ki se nahaja v poddrevesu $u.right$. To vozlišče lahko brez skrbi odstranimo, ker nima



Slika 6.8: Brisanje lista (6) ali vozlišča z enim otrokom (9) je preprosto.



Slika 6.9: Brisanje neke vrednosti (11) iz nekega vozlišča **u**, ki ima dva otroka, počnemo z zamenjavo **u**-jeve vrednosti z najmanjšo vrednostjo v **u**-jevem desnem poddrevesu.

levega otroka (glej 6.9).

```

BinarySearchTree
void remove(Node u) {
    if (u.left == nil || u.right == nil) {
        splice(u);
    } else {
        Node w = u.right;
        while (w.left != nil)
            w = w.left;
        u.x = w.x;
        splice(w);
    }
}

```

6.2.4 Povzetek

Vsaka izmed funkcij `find(x)`, `add(x)` ter `remove(x)` v strukturi `BinarySearchTree` vključuje sledenje neki poti od korena pa do nekega vozlišča v drevesu. Brez dodatnega znanja o obliki drevesa je težko karkoli povedati o dolžini te poti, razen tega, da je pot manjša kot n - število vseh vozlišč v drevesu. Sledeči izrek povzame zmožnosti podatkovne strukture `BinarySearchTree`:

Izrek 6.1. *`BinarySearchTree` implementira `SSet` vmesnik ter podpira funkcije `add(x)`, `remove(x)` ter `find(x)` v $O(n)$ časa na operacijo.*

6.1 se slabo primerja z 4.1, ki prikazuje, da struktura `SkipListSSet` lahko implementira `SSet` vmesnik z pričakovanim časom $O(\log n)$ na operacijo. Problem strukture `BinarySearchTree` tiči v tem, da lahko postane neuravnoteženo. Namesto da drevo izgleda kot na 6.5, lahko izgleda kot dolga veriga z n vozlišči, ki imajo po točno enega otroka, razen zadnjega, ki nima nobenega.

Obstaja več načinov, kako se izogniti strukturi `BinarySearchTree`, ki je neuravnotežena. Vsi načini vodijo v podatkovne strukture, ki imajo operacije s časom $O(\log n)$. V 7 pokažemo, kako lahko dosežemo operacije z pričakovanim časom $O(\log n)$ s pomočjo naključnosti. V 8 pokažemo, kako dosežemo operacije z amortiziranim časom $O(\log n)$ s pomočjo delnih obnovitvenih operacij. V 9 pokažemo, kako dosežemo operacije z najslabšim časom $O(\log n)$ s pomočjo simulacije dreves, ki niso dvojiška: eno v katerem imajo vozlišča lahko do štiri otroke.

6.3 `BinaryTree`: Razprava in vaje

Dvojiška drevesa se že tisočletja uporabljajo za predstavitev razmerij med elementi. Med drugim se uporabljajo tudi za prikaz družinskih dreves (rodovnika). Vzemimo primer, koren drevesa je oseba A. Levi in desni otrok osebe A sta njena starša in sta vozlišči drevesa; zgodba se naprej ponavlja za vsako vozlišče rekurzivno v globino. V zadnjih stoletjih se uporabljajo tudi v biologiji, natančneje za prikaz vrst v drevesni strukturi, kjer listi drevesa predstavljajo obstoječe vrste, vozlišča znotraj drevesa pa

dogodke v razvoju, kjer se iz ene razvijeta dve novi vrsti (*angl: speciation event*).

V petdesetih letih 19. st. so raziskovalci odkrili dvojiška iskalna drevesa. Več o dvojiških iskalnih drevesih lahko preberete v nadaljevanju.

Ko se srečamo z implementacijo dvojiških dreves, zlasti če le-te gradimo z ničle, se moramo dogovoriti za nekaj pravil. Eno izmed pravil je vprašanje: naj vozlišča drevesa vsebujejo kazalce na svoje starše ali ne? Če večina operacij na drevesu poteka od korena do listov, potem kazalcev ne potrebujemo. Po drugi strani pa to pomeni, da moramo t.i. sprehode po drevesu implementirati rekurzivno ali pa z uporabo posebnih skladov. Pomanjkanje kazalcev se pozna tudi v nekaterih drugih metodah, kot sta npr. vstavljanje in brisanje elementov iz dvojiškega drevesa, kjer se brez kazalcev njuna implementacija močno zaplete.

Drugo pravilo govori o tem kako v vozlišču hraniti kazalce na starša ter levega in desnega otroka. Ena možnost je, da so kazalci shranjeni kot spremenljivke. Druga možnost je, da jih hranimo v tabeli `p`, ki je dolžine 3 tako, da je vrednost `u.p[0]` levi otrok vozlišča `u`, vrednost `u.p[1]` je desni otrok vozlišča `u`, vrednost `u.p[2]` pa je starš vozlišča `u`. Z uporabo tabele kazalcev tudi omogočimo poenostavitev nekaterih zaporedij `if` stavkov v algebrائية izraze.

Takšno poenostavitev lahko opazimo ob sprehodu po drevesu. Ko naletimo na vozlišče `u` iz tabele `u.p[i]`, je naslednje vozlišče v sprehodu `u.p[(i + 1) mod 3]`. Podoben primer nastopi, ko v drevesu nimamo levo-desne simetrije. Npr. sorojenec (tj. brat) vozlišča `u.p[i]` je `u.p[(i + 1) mod 2]`. Takšen trik deluje, če je vozlišče `u.p[i]` levi otrok ($i = 0$) ali desni otrok ($i = 1$) vozlišča `u`. S tem nam ni več potrebno pisati *leve* in *desne* kode (tj. dve različni kodi za urejanje leve in desne strani drevesa), temveč lahko vse združimo v en sam košček kode. Kot primer si lahko ogledate metodi `rotateLeft(u)` in `rotateRight(u)` na strani 160.

Naloga 6.1. Dokažite, da ima dvojiško drevo s številom vozlišč $n \geq 1$ $n - 1$ povezav.

Naloga 6.2. Dokažite, da ima dvojiško drevo s številom notranjih vozlišč $n \geq 1$ $n + 1$ zunanjih vozlišč (listov).

Naloga 6.3. Privzemimo, da imamo dvojiško drevo T z vsaj enim listom. Dokažite bodisi, da: a) ima koren drevesa največ enega otroka bodisi b), da ima drevo T več kot en list.

Naloga 6.4. Implementirajte nerekurzivno metodo $size2(u)$, ki izračunava velikost poddrevesa vozlišča u .


Naloga 6.5. Napišite nerekurzivno metodo $height2(u)$, ki izračunava višino vozlišča u v dvojiškem drevesu.

Naloga 6.6. Dvojiško drevo je uravnoreženo, če za vsako vozlišče u velja, da se višina njegovih poddreves z vozliščem $u.left$ in $u.right$ razlikuje za največ ena. Napišite rekurzivno metodo $isBalanced()$ katera testira, če je drevo uravnoreženo. Metoda mora imeti časovno zahtevnost $O(n)$. (Priporočeno je, da kodo testirate na nekaj velikih drevesih z različnimi oblikami. Metodo s časovno zahtevnostjo veliko večjo od $O(n)$ je dosti lažje napisati.)

Premi pregled (pre-order) po dvojiškem drevesu je sprehod, ki obišče vsako vozlišče u pred svojimi otroci. Vmesni pregled (in-order) pogleda najprej levega otroka potem koren in nato še desnega otroka. Dobljeni vrstni red je sortiran. Obratni pregled (post-order) obišče koren u šele po tem, ko obišče vsa vozlišča v svojih poddrevesih. Glej sliko 6.10.

Naloga 6.7. Ustvarite podrazred `BinaryTree`, čigar vozlišča imajo polja za shranjevanje števil premega, obratnega in vmesnega pregleda. Napišite rekurzivne metode $preOrderNumber()$, $inOrderNumber()$ in $postOrderNumber()$, ki ta števila pravilno dodelijo. Vse te metode morajo imeti časovno zahtevnost $O(n)$.

Naloga 6.8. Napišite nerekurzivno metode $nextPreOrder(u)$, $nextInOrder(u)$ in $nextPostOrder(u)$, ki vračajo vozlišče katero sledi u v premem, vmesnem in obratnem pregledu. Te metode bi morale vzeti amortiziran konstanten čas. Če začnemo pri katerem koli izbranem vozlišču, ter večkrat



Slika 6.10: Pre-order, post-order, and in-order numberings of a binary tree.

kličemo eno izmed teh funkcij dokler u ni enak *null*, bi časovna zahtevnost morala biti $O(n)$.

Naloga 6.9. Recimo, da imamo dvojiško drevo s pre-, in- in post-order številkami dodeljenimi vozliščem. Pokažite, kako se lahko te številke uporabijo za odgovor na vsako izmed naslednjih vprašanj, v konstantnem času.

1. Ob danem vozlišču u , določite velikost poddrevesa, ki ima koren v u .
2. Ob danem vozlišču u , določite globino v u .
3. Ob danih dveh vozliščih u in w , določite ali je u prednik w .

Naloga 6.10. Recimo, da imamo seznam vozlišč, ki so premo in vmesno oštevilčena. Dokažite, da obstaja največ eno premo/vmesno oštevilčeno drevo in pokažite, kako ga sestavimo.

Naloga 6.11. Pokažite, da je lahko oblika kateregakoli dvojiškega drevesa z n vozlišči predstavljena z največ $2(n - 1)$ biti. (Namig: poskusite zabeležiti, kaj se zgodi ob sprehodu, nato podatke uporabite za ponovno postavitve drevesa.)

Naloga 6.12. Narišite, kaj se zgodi, ko dodamo vrednosti 3.5 in nato 4.5 dvojiškemu iskalnemu drevesu v 6.5.

Naloga 6.13. Narišite, kaj se zgodi, ko odstranimo vrednosti 3 in nato 5 iz dvojiškega iskalnega drevesa v 6.5.

Naloga 6.14. Izvedite `BinarySearchTree` metodo, `getLE(x)`, ki vrne seznam vseh členov, ki so manjši ali enaki x . Čas izvajanja vaše metode, bi moral biti $O(n' + h)$, kjer je n' število členov, ki so manjši ali enaki x in h je višina drevesa.

Naloga 6.15. Opišite, kako dodamo elemente $\{1, \dots, n\}$ prvotno praznemu `BinarySearchTree` tako, da ima končno drevo višino $n - 1$. Na koliko načinov je to mogoče narediti?

Naloga 6.16. Če imamo neko `BinarySearchTree` in izvedemo operaciji `add(x)`, ki ji sledi `remove(x)` (z enako vrednostjo x), ali se nujno povrnemo v prvotno drevo?

Naloga 6.17. Ali lahko `remove(x)` operacija poveča višino kateregakoli vozlišča v `BinarySearchTree`? In če da, za koliko?

Naloga 6.18. Ali lahko `add(x)` operacija poveča višino kateregakoli vozlišča v `BinarySearchTree`? Ali lahko poveča višino drevesa? Če da, za koliko?

Naloga 6.19. Oblikujte in izvedite različico `BinarySearchTree`, v kateri vsako vozlišče u , vzdržuje vrednosti `u.size` (velikost poddrevesa, ki ima koren v vozlišču u), `u.depth` (globino od u), in `u.height` (višino poddrevesa, s korenem v u).

Te vrednosti vzdržujemo tudi ob klicu `add(x)` in `remove(x)` operacij, ampak to ne sme povečati ceno operacij za več kakor neko konstanto vrednost.

Poglavje 7

Naključna iskalna dvojiška drevesa

V tem poglavju bomo predstavili dvojiško iskalno strukturo, ki uporablja naključje, da doseže pričakovani čas $O(\log n)$ za vse operacije.

7.1 Naključna iskalna dvojiška drevesa

Premislimo o dveh dvojiških iskalnih drevesih, ki sta prikazani na 7.1, od katerih ima vsak $n = 15$ vozlišč. Tista na levi strani je seznam ta druga pa je popolnoma uravnoreženo dvojiško iskalno drevo. Tista na levi strani ima višino $n - 1 = 14$ in tista na desni ima višino tri.

Predstavljajte si, kako bi lahko bili zgrajeni ti dve drevesi. Tista na levi se zgodi, če začnemo s praznim `BinarySearchTree` in dodamo zaporedje

$$\langle 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14 \rangle .$$

Nobeno drugo dodatno zaporedje ne bo ustvarilo to drevo (kot lahko dokažete z indukcijo po n). Po drugi strani, pa je drevo na desni lahko ustvarjeno z zaporedjem


$$\langle 7, 3, 11, 1, 5, 9, 13, 0, 2, 4, 6, 8, 10, 12, 14 \rangle .$$

Ostala zaporedja tudi delujejo dobro, vključno z

$$\langle 7, 3, 1, 5, 0, 2, 4, 6, 11, 9, 13, 8, 10, 12, 14 \rangle ,$$

in

$$\langle 7, 3, 1, 11, 5, 0, 2, 4, 6, 9, 13, 8, 10, 12, 14 \rangle .$$



Slika 7.1: Dve dvojiški iskalni drevesi vsebujeta cela števila $0, \dots, 14$.


Dejstvo je, da obstaja 21,964,800 dodatnih zaporedij, ki lahko ustvarijo drevo na desni strani in samo eno zaporedje, ki lahko ustvari drevo na levi strani.

Zgornji primer daje nekaj nezanesljivih dokazov, saj če izberemo naključno permutacijo od $0, \dots, 14$, in jo dodamo v dvojiško iskalno drevo, potem je bolj verjetno, da bi dobili zelo uravnoteženo drevo (na desni strani 7.1) tako lahko dobimo zelo neuravnoteženo drevo (na levi strani 7.1).

Formaliziramo to notacijo s preučevanjem naključnih dvojiških iskalnih dreves. *Naključno dvojiško iskalno drevo* velikosti n dobimo na naslednji način: Vzamemo naključno permutacijo, x_0, \dots, x_{n-1} , celih števil $0, \dots, n-1$ in dodajamo njene elemente, enega za drugim v BinarySearch-Tree. Z *naključnimi permutacijami* mislimo, da vsaka izmed $n!$ permutacij (urejena) od $0, \dots, n-1$ enako verjetna, tako da je verjetnost pridobitve posebne permutacije $1/n!$.

Upoštevajmo, da lahko vrednosti $0, \dots, n-1$ nadomestimo s poljubnimi urejenim izborom n elementov brez spreminjanja nobene od lastnosti naključnega dvojiškega iskalnega drevesa. Element $x \in \{0, \dots, n-1\}$ preprosto stoji za elementom ranga x v urejenem izboru velikosti n .

Preden bomo lahko predstavili naš glavni rezultat o naključnih dvojiških iskalnih drevesih, si moramo vzeti nekaj časa za kratek odmik, da lahko razpravljamo o tipu števila, ki se pojavlja pogosteje pri preučevanju na-



Slika 7.2: k -tiško harmonično število $H_k = \sum_{i=1}^k 1/i$ je zgoraj omejeno in spodaj omejeno z dvema integraloma. Vrednost teh integralov je podana s območjem, ki je zasenčeno, medtem, ko je vrednost H_k podana z območjem, kjer so pravokotniki.

ključnih struktur. Za nenegativno celo število, k , k -tiško *harmonično število*, označeno H_k , je definirano kot

$$H_k = 1 + 1/2 + 1/3 + \dots + 1/k .$$

Harmonično število H_k nima preproste zaprte oblike, vendar je zelo tesno povezano z naravnim logaritmom od k . Zlasti,

$$\ln k < H_k \leq \ln k + 1 .$$

Bralci, ki so študirali računanje lahko opazijo, da je tako, ker integral $\int_1^k (1/x) dx = \ln k$. Imejmo v mislih, da integral je lahko interpretiran kot območje med krivuljo in x -os, vrednost H_k je lahko nižje omejena z integralom $\int_1^k (1/x) dx$ in višje omejena z $1 + \int_1^k (1/x) dx$. (Glej 7.2 za grafično razlago.)

Lema 7.1. V naključnem dvojiškem iskalnem drevesu velikosti n , držijo naslednje izjave:

1. Za vsak $x \in \{0, \dots, n-1\}$, pričakovana dolžina iskane poti za x je $H_{x+1} + H_{n-x} - O(1)$.¹
2. Za vsak $x \in (-1, n) \setminus \{0, \dots, n-1\}$, pričakovana dolžina iskane poti za x je $H_{\lceil x \rceil} + H_{n-\lceil x \rceil}$.

¹Izraz $x+1$ in $n-x$ si je mogoče razlagati, kot število elementov v drevesu, ki je manjše ali enako x in število elementov v drevesu, ki je večje ali enako x .

Dokazali bomo 7.1 v naslednjem poglavju. Za zdaj, upoštevajmo kaj nam povedo oba dela 7.1. Prvi del nam pove, da če iščemo element v drevesu velikosti n , potem je predvidena dolžina iskane poti največ $2\ln n + O(1)$. Drugi del nam pove, enako stvar pri iskanju za vrednosot, ki ni shranjena v drevesu. Če primerjamo oba dela Leme, vidimo, da je nekoliko hitrejša iskanje, če iščemo nekaj, kar je v drevesu v primerjavi z nečem, kar ni.

7.1.1 Dokaz 7.1


Ključna ugotovitev pri dokazovanju 7.1 je naslednja: Iskana pot za vrednost x v odprtem intervalu $(-1, n)$ v naključnem dvojiškem iskalnem drevesu, T , vsebuje vozlišče s ključem $i < x$ če, in samo če je naključna permutacija uporabljena za ustvarjanje T , i preden se pojavi katerakoli od $\{i+1, i+2, \dots, \lfloor x \rfloor\}$.

Da bi to videli, se nanašamo 7.3 in lahko opazimo, da do nekaterih vrednosti v $\{i, i+1, \dots, \lfloor x \rfloor\}$ je dodana iskana pot za vsako vrednost v odprtem intervalu $(i-1, \lfloor x \rfloor + 1)$ ter te sta enake. (Zapomnimo si to, za dve vrednosti, ki imata različne iskane poti, tu mora biti nek element v drevesu, ki je različen od obeh.) Naj bo j prvi element v $\{i, i+1, \dots, \lfloor x \rfloor\}$, ki nastopa v naključni permutaciji. Opazimo, da j je zdaj in bo vedno v iskani poti za x . Če $j \neq i$ potem vozlišče u_j , ki vsebuje j je ustvarjeno pred vozliščem u_i , ki vsebuje i . Kasneje, ko je i dodan, bo bil dodan v korenu poddrevesa pri $u_j.\text{left}$, saj $i < j$. Po drugi strani iskana pot za x , ne bo nikoli obiskala poddrevo, ker bi se nadaljevala k $u_j.\text{right}$ po obisku u_j .

Podobno za $i > x$, i se pojavi v iskalni poti za x če, in samo če i se pojavi pred katerikoli od $\{\lceil x \rceil, \lceil x \rceil + 1, \dots, i-1\}$ v naključni permutaciji, ki uporablja za ustvarjanje T .

Opazimo, da če začnemo z naključno permutacijo od $\{0, \dots, n\}$, potem pod-zaporedje vsebuje samo $\{i, i+1, \dots, \lfloor x \rfloor\}$ in $\{\lceil x \rceil, \lceil x \rceil + 1, \dots, i-1\}$ so tudi naključne permutacije njihovih pripadajočih elementov. Vsak element, potem v podmnožici $\{i, i+1, \dots, \lfloor x \rfloor\}$ in $\{\lceil x \rceil, \lceil x \rceil + 1, \dots, i-1\}$ je verjetno, da nastopi pred katerikoli drugim v svoji podmnožici v naključni permutaciji uporabljeni za ustvarjanje T . Torej imamo

$$\Pr\{i \text{ is on the search path for } x\} = \begin{cases} 1/(\lfloor x \rfloor - i + 1) & \text{if } i < x \\ 1/(i - \lceil x \rceil + 1) & \text{if } i > x \end{cases}.$$



Slika 7.3: Vrednost $i < x$ je na iskalni poti za x če, in samo če i je prvi element med $\{i, i + 1, \dots, [x]\}$ dodan drevesu.

S tem opazovanjem, dokaz za 7.1 vključuje nekaj preprostih izračunov z harmonskimi števili:


Dokaz 7.1. Naj I_i bo pokazatelj naključne spremenljivke, ki je enaka ena, kadar se i pojavi na iskalni poti za x in nič sicer. Potem je dolžina iskalne poti podana z

$$\sum_{i \in \{0, \dots, n-1\} \setminus \{x\}} I_i$$

tako da, če $x \in \{0, \dots, n-1\}$, je pričakovana dolžina iskalne poti podana z (glej 7.4.a)

$$\begin{aligned} E \left[\sum_{i=0}^{x-1} I_i + \sum_{i=x+1}^{n-1} I_i \right] &= \sum_{i=0}^{x-1} E[I_i] + \sum_{i=x+1}^{n-1} E[I_i] \\ &= \sum_{i=0}^{x-1} 1/([x] - i + 1) + \sum_{i=x+1}^{n-1} 1/(i - [x] + 1) \\ &= \sum_{i=0}^{x-1} 1/(x - i + 1) + \sum_{i=x+1}^{n-1} 1/(i - x + 1) \end{aligned}$$

Naključna iskalna dvojiška drevesa



Slika 7.4: Verjetnost, da je element na iskalni poti za x kadar (a) x je celo število in (b) kadar x ni celo število.

$$\begin{aligned}
 &= \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{x+1} \\
 &\quad + \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{n-x} \\
 &= H_{x+1} + H_{n-x} - 2 .
 \end{aligned}$$

Ustreden izračun za iskalno vrednost $x \in (-1, n) \setminus \{0, \dots, n-1\}$ so skoraj enake (glej 7.4.b). □

7.1.2 Povzetek

Spodnji teorem povzame učinkovitost naključnega dvojiškega iskalnega drevesa:

Izrek 7.1. *Naključno dvojiško iskalno drevo lahko ustvarimo v $O(n \log n)$ času. V naključnem dvojiškem iskalnem drevesu, $\text{find}(x)$ operacija potrebuje $O(\log n)$ predvidenega časa.*

Ponovno moramo poudariti, da pričakovanja v 7.1 je v zvezi z naključno permutacijo uporabljena za ustvarjanje naključnega dvojiškega iskalnega drevesa. Predvsem, pa ni odvisno od naključne izbire x ; , saj je pravilna za vsako x vrednost x .

7.2 Treap: Naključno generirano dvojiško iskalno drevo

Problem naključnih dvojiških iskalnih dreves je seveda, da niso dinamična. Ta drevesa ne podpirajo `add(x)` ali `remove(x)` operacij, ki so potrebne za implementacijo SSet vmesnika. V tem poglavju bomo opisali podatkovno strukturo, imenovano Treap, ki uporablja 7.1 za implementacijo SSet vmesnika.²

Vozlišče v Treap je kot vozlišče v `BinarySearchTree` s tem, da ima podatkovno vrednost, `x`, toda vsebuje tudi edinstveno številčno *prioriteto*, `p`, ki je dodeljena naključno:

```
class Node<T> extends BSTNode<Node<T>,T> {  
    int p;  
}
```

Poleg tega, da je dvojiško iskalno drevo, vozlišča v Treap prav tako ubogajo *lastnostim kopice*:

- (Lastnosti kopice) Pri vsakem vozlišču `u`, razen pri korenu, `u.parent.p < u.p`.


Z drugimi besedami, vsako vozlišče ima prioriteto manjšo od svojih dveh otrok. Primer je prikazan na 7.5.

Pogoji kopice in dvojiškega iskalnega drevesa skupaj zagotavljajo, da enkrat ko so ključ (`x`) in prioriteta (`p`) definirane za vsako vozlišče, je oblika drevesa Treap popolnoma določena. Lastnost kopice nam pove, da vozlišče z najmanjšo prioriteto mora biti koren, `r`, drevesa Treap. Lastnost dvojiškega iskalnega drevesa nam pove, da vsa vozlišča s ključem manjšim od `r.x` so shranjene v poddrevesu, ki je zasidran na `r.left` in vsa vozlišča s ključem večjim od `r.x` so shranjene v poddrevesu, ki je zasidran na `r.right`.

Pomembna točka o vrednosti prioritete v drevesu Treap je, da so edinstveni id dodeljeni naključno. Zaradi tega obstajajo dva enakovredna načina razmišljanja o drevesu Treap. Kot je definirano zgoraj, drevo Treap

²Ime Treap izhaja iz dejstva, da je podatkovna struktura, hkrati dvojiško iskalno drevo (tree) (6.2) in kopice(heap) (??).

Naključna iskalna dvojiška drevesa



Slika 7.5: Primer drevesa Treap, ki vsebuje cela števila $0, \dots, 9$. Vsako vozlišče, u , je prikazano kot škatla, ki vsebuje $u.x, u.p$.

uboga lastnostim kopice in dvojiškega iskalnega drevesa. Alternativno lahko razmišljamo o drevesu Treap kot o `BinarySearchTree` katerega vozlišča so bila dodana v naraščajočem vrstnem redu prioritete. Na primer drevo Treap na 7.5 ga lahko dobimo z dodajanjem zaporedja (x, p) vrednosti

$\langle (3, 1), (1, 6), (0, 9), (5, 11), (4, 14), (9, 17), (7, 22), (6, 42), (8, 49), (2, 99) \rangle$

v `BinarySearchTree`.


Ker so prioritete izbrane naključno, je to enako, če vzamemo naključno permutacijo ključev—v tem primeru permutacija je

$\langle 3, 1, 0, 5, 9, 4, 7, 6, 8, 2 \rangle$

—in jo dodamo v `BinarySearchTree`. To pa pomeni, da je oblika treap drevesa identična obliki naključnega dvojiškega iskalnega drevesa. Še posebej, če želimo zamenjati vsak ključ x z njegovim rangom³, potem se aplicira 7.1. Preračunavanju lemref rbs glede na drevesa Treap, imamo:

Lema 7.2. *V drevesu Treap, ki shranjuje niz S z n ključi, naslednje izjave držijo:*

³Rang elementa x v nizu S elementov je število elementov v S , ki so manjši kot x .



Slika 7.6: Leva in desna rotacija v dvojiškem iskalnem drevesu.

1. Za vsak $x \in S$, pričakovana dolžina iskanja poti za x je $H_{r(x)+1} + H_{n-r(x)} - O(1)$.
2. Za vsak $x \notin S$, pričakovana dolžina iskanja poti za x je $H_{r(x)} + H_{n-r(x)}$.

Tukaj, $r(x)$ označuje rang x v nizu $S \cup \{x\}$.

Ponovno poudarimo, da se pričakovanje pri 7.2 prevzemajo preko naključne izbire prioriteta za vsako vozlišče. To ne potrebuje nobene predpostavke o naključju ključev.

7.2 nam pove, da lahko Treap drevesom učinkovito implementiramo $\text{find}(x)$ operacijo. Vendar, resnična korist Treap dreves je, da lahko podpre operacije $\text{add}(x)$ in $\text{delete}(x)$. Za narediti to, mora izvajati rotacije, tako da ohrani lastnosti kopice. Nanaša se na figrefrotations. Rotacija v dvojiških iskalnih drevesih je lokalna sprememba, ki vzame starša u vozlišča w in naredi, da je w starš od u , medtem ko ohranjuje lastnosti dvojiškega iskalnega drevesa. Rotacije pridejo v dveh okusih: emph levo ali emph desno glede na to, ali je w desni ali levi otrok od u .

Koda, ki implementira to mora ravnati z tema dvema možnostma in mora biti pozorna na mejne primere (ko je u koren), tako da je dejanska koda malo daljša kot 7.6 bi vodila bralca, da verjame:

```

BinarySearchTree
void rotateLeft(Node u) {
    Node w = u.right;
    w.parent = u.parent;

```

```

    if (w.parent != nil) {
        if (w.parent.left == u) {
            w.parent.left = w;
        } else {
            w.parent.right = w;
        }
    }
    u.right = w.left;
    if (u.right != nil) {
        u.right.parent = u;
    }
    u.parent = w;
    w.left = u;
    if (u == r) { r = w; r.parent = nil; }
}

void rotateRight(Node u) {
    Node w = u.left;
    w.parent = u.parent;
    if (w.parent != nil) {
        if (w.parent.left == u) {
            w.parent.left = w;
        } else {
            w.parent.right = w;
        }
    }
    u.left = w.right;
    if (u.left != nil) {
        u.left.parent = u;
    }
    u.parent = w;
    w.right = u;
    if (u == r) { r = w; r.parent = nil; }
}

```

V zvezi s podatkovno strukturo Treap je najpomembnejša lastnost rotacije, da se globina od w zmanjša za ena, medtem ko se globina u poveča za ena.

Z uporabo rotacij, lahko implementiramo operacijo $\text{add}(x)$, kakor sledi: ustvarimo novo vozlišče, u , dodelimo $u.x = x$, in izberemo naključno vrednost za $u.p$. Nato dodamo u z uporabo običajnega $\text{add}(x)$ algoritma za

BinarySearchTree , tako da je u zdaj list Treap drevesa. Na tej točki, naše Treap drevo izpolnjuje lastnosti dvojiškega iskalnega drevesa, vendar pa ni nujno, da izpolnjuje lastnosti kopice. Zlasti se lahko zgodi, da $u.parent.p > u.p$. Če se to zgodi, moramo izvesti rotacijo na vozlišču $w = u.parent$, tako da u postane starš w . Če u še naprej krši lastnosti kopice, bomo morali ponoviti to, zmanjšuje globino u -ja za ena vsakič, dokler u ne postane koren ali $u.parent.p < u.p$.

```


Treap
boolean add(T x) {
    Node<T> u = newNode();
    u.x = x;
    u.p = rand.nextInt();
    if (super.add(u)) {
        bubbleUp(u);
        return true;
    }
    return false;
}

void bubbleUp(Node<T> u) {
    while (u.parent != nil && u.parent.p > u.p) {
        if (u.parent.right == u) {
            rotateLeft(u.parent);
        } else {
            rotateRight(u.parent);
        }
    }
    if (u.parent == nil) {
        r = u;
    }
}

```

Primer $add(x)$ operacije je prikazana na 7.7.

Čas izvajanja operacije $add(x)$ je podan s časom, ki je potreben, za slediti iskalni poti do x plus število vrtljajev, ki so bili opravljeni za premik novo dodanega vozlišča, u , do njegove prave lokacije v drevesu Treap. Z 7.2 je pričakovano trajanje iskalne poti maksimalno $2 \ln n + O(1)$. Poleg tega, vsaka rotacija zmanjša globino u . To se ustavi, če u postane koren, tako da pričakovano število rotacij ne sme preseči predvidene dolžine is-



Slika 7.7: Dodajamo vrednost 1.5 v Treap drevo iz 7.5.

kalne poti. Zato je pričakovani čas izvajanja operacije `add(x)` v drevesu Treap, $O(\log n)$. (7.5 sprašuje po dokazu, da je pričakovano število opravljenih rotacij v času dodajanja samo $O(1)$.)

Operacija `remove(x)` v drevesu Treap je nasprotna operaciji `add(x)`. Iščemo vozlišče, `u`, ki vsebuje `x`, nato izvedemo rotacije za premakniti `u` navzdol, dokler ne postane list in potem spojimo `u` iz Treap drevesa. Opazite, da za premikanje `u` navzdol, lahko opravljamo bodisi levo bodisi desno rotacijo na `u`, ki bo nadomestila `u` z `u.right` ali `u.left`. Izbira je opravljena s prvim od naslednjih, ki velja:

1. Če `u.left` in `u.right` sta `null`, potem `u` je list in rotacija ni bila izvedena.
2. Če `u.left` (ali `u.right`) je `null`, potem izvedi desno (oz. levo) rotacijo na `u`.
3. Če `u.left.p < u.right.p` (ali `u.left.p > u.right.p`), potem izvedi desno rotacijo (oz. levo rotacijo) na `u`.

Ta tri pravila zagotavljajo, da drevo Treap ne postane nepovezano in da se lastnosti kopice obnovijo, ko je `u` odstranjen.

Treap

```
boolean remove(T x) {
    Node<T> u = findLast(x);
    if (u != nil && compare(u.x, x) == 0) {
        trickleDown(u);
        splice(u);
        return true;
    }
    return false;
}

void trickleDown(Node<T> u) {
    while (u.left != nil || u.right != nil) {
        if (u.left == nil) {
            rotateLeft(u);
        } else if (u.right == nil) {
            rotateRight(u);
        } else if (u.left.p < u.right.p) {
            rotateRight(u);
        }
    }
}
```

```

    } else {
        rotateLeft(u);
    }
    if (r == u) {
        r = u.parent;
    }
}
}

```

Primer operacije `remove(x)` je prikazan na 7.8.

Trik za analizirati čas izvajanja operacije `remove(x)` je opaziti, da operacija obrne operacijo `add(x)`. Še posebej, če bi ponovno vstavili `x` z uporabo iste prioritete `u.p`, potem bi operacija `add(x)` naredila popolnoma enako število rotacij in bi obnovila drevo Treap kot je bilo pred potekom operacije `remove(x)`. (Branje iz dna do vrha, 7.8 prikazuje dodajanje vrednosti 9 v drevo Treap.) To pomeni, da je pričakovan čas izvajanja `remove(x)` na drevesu Treap z velikostjo `n` je sorazmeren s pričakovanim časom izvajanja operacije `add(x)` na drevesu Treap, ki je velikosti `n - 1`. Zaključujemo tako, da je pričakovani čas izvajanja `remove(x)` $O(\log n)$.

7.2.1 Povzetek

Naslednji izrek povzema zmogljivosti podatkovne strukture Treap:


Izrek 7.2. *Treap implementira vmesnik SSet. Treap podpira operacije `add(x)`, `remove(x)` in `find(x)` v pričakovanem času $O(\log n)$ za vsako operacijo.*

To je vredno primerjave podatkovne strukture Treap s podatkovno strukturo `SkipListSSet`. Obe implementirata operacije `SSet` v predvidenem času $O(\log n)$ za vsako operacijo. V obeh podatkovnih strukturah, `add(x)` in `remove(x)` vključujeta iskanje in nato konstantno število sprememb kazalca (glej 7.5 spodaj). Tako je za obe strukturi, pričakovana dolžina iskalne poti je kritična vrednost pri ocenjevanju njihove uspešnosti. V `SkipListSSet`, pričakovana dolžina iskalne poti je

$$2 \log n + O(1) ,$$

V Treap, pričakovana dolžina iskalne poti je

$$2 \ln n + O(1) \approx 1.386 \log n + O(1) .$$



Slika 7.8: Brišemo vrednost 9 iz drevesa Treap na 7.5.

Tako je iskanje poti v Treap precej krajše in to se prevede v občutno hitrejšo operacijo nad Treap drevesih kot nad SkipList. 4.7 v 4 prikazuje, kako se lahko pričakovana dolžina iskalne poti v SkipList zmanjša na

$$e \ln n + O(1) \approx 1.884 \log n + O(1)$$

z uporabo pristranskega meta kovanca. Tudi s to optimizacijo, pričakovana trajanje iskanja poti v SkipListSSet je občutno daljše kot v Treap.

7.3 Razprava in vaje

Naključna iskalna drevesa so obsežno raziskana. Devroye [?] dokazuje lemo 7.1 in še mnoge druge. Enega izmed ostalih dokazov je izpeljal Reed [?], ki je pokazal, da je pričakovana višina naključnega dvojiškega iskalnega drevesa

$$\alpha \ln n - \beta \ln \ln n + O(1)$$

kjer je $\alpha \approx 4.31107$ unikatna rešitev na intervalu $[2, \infty)$ enačb $\alpha \ln((2e/\alpha)) = 1$ in $\beta = \frac{3}{2 \ln(\alpha/2)}$. Poleg tega je varianca višine konstanta.

Ime Treap je skovanka Seidela in Aragona [?], ki je razpravljal o Treap in nekaterih njihovih izpeljankah. Njihovo osnovno zgradbo pa je že mnogo prej preučeval Vuillemin [?], ki jih je poimenoval Kartezijska drevesa.

Ena izmed možnih prostorskih optimizacij Treap je odstranitev neposrednega shranjevanja prioritete p v vsakem vozlišču. Namesto tega izračunamo prioriteto vozlišča u z zgoščevanjem naslova le-tega v pomnilniku (v 32-bitni Javi je to ekvivalent zgoščevanju `u.hashCode()`). Čeprav veliko zgoščevalnih funkcij deluje dovolj dobro v praksi, je za pomembne dele dokaza 7.1 pomembno, da je funkcija dobro porazdeljena in ima *minimalno-usmerjeno neodvisnost*: Za vsako različno vrednost x_1, \dots, x_k mora biti vsaka izmed vrednosti zgoščevanja $h(x_1), \dots, h(x_k)$ različna z visoko verjetnostjo in za vsak $i \in \{1, \dots, k\}$,

$$\Pr\{h(x_i) = \min\{h(x_1), \dots, h(x_k)\}\} \leq c/k$$

za neko konstanto c . Ena izmed takih zgoščevalnih funkcij, ki je lahka za implementacijo in dokaj hitra je *tabelarno zgoščevanje* (5.2.3).

Druga različica Treap, ki ne shranjuje prioritete v vsakem vozlišču je naključno dvojiško iskalno drevo V tej različici vsako vozlišče u hrani velikost $u.size$ poddrevesa s korenom v u . Algoritma $add(x)$ in $remove(x)$ delujeta poljubno. Algoritem za dodajanje x k poddrevesu s korenom v vozlišču u naredi sledeče:

1. Z verjetnostjo $1/(size(u) + 1)$, je vrednost x dodana kot list in s pomočjo rotacij premaknjena na koren poddrevesa.
2. V nasprotnem primeru (z verjetnostjo $1 - 1/(size(u) + 1)$), je vrednost x rekurzivno dodana enemu izmed dveh poddreves s korenom v $u.left$ oziroma $u.right$.

Prvi primer se uporablja pri operaciji $add(x)$ v podatkovni strukturi Treap, kjer vozlišče z vrednostjo x pridobi poljubno prednost, ki je manjša kot katera koli izmed $size(u)$ prednosti v poddrevesu u . Ta opcija se pojavlja s to verjetnostjo.

Odstranjevanje vrednosti x z naključnega dvojiškega iskalnega drevesa je podobno odstranjevanja s podatkovne strukture Treap. Poiščemo vozlišče u , ki vsebuje x in opravimo rotacije, ki povečuje globino le-tega, dokler ne postane list, nakar ga odstranimo. Izbira med levo in desno rotacijo je poljubna.

1. Z verjetnostjo $u.left.size/(u.size - 1)$ opravimo desno rotacijo vozlišča u , kjer postavimo $u.left$ kot koren poddrevesa, ki je bil prej vkorenjen v u .
2. Z verjetnostjo $u.right.size/(u.size - 1)$ opravimo desno rotacijo vozlišča u , kjer postavimo $u.right$ kot koren poddrevesa, ki je bil prej vkorenjen v u .

Enostavno lahko potrdimo, da je verjetnost, da bo Treap opravil levo ali desno rotacijo vozlišča u enaka.

Naključna dvojiška iskalna drevesa imajo v primerjavi s Treap to slabost, da pri dodajanju in odstranjevanju elementov opravljajo veliko naključnih odločitev in morajo ohranjati velikost poddreves. Ena izmed prednosti naključnega dvojiškega iskalnega drevesa je ta, da velikost poddrevesa služi tudi drugemu uporabnemu namenu in sicer pridobivanju

dostopa po razredih z časovno zahtevnostjo $O(\log n)$. (glej 7.10). V primerjavi poljubne prednosti shranjene v vozliščih podatkovne strukture treap nimajo nobene druge uporabne vrednosti kot skrbenju, da je treap uravnotežen.

Naloga 7.1. Prikažite dodajanje 4.5 (s prednostjo 7) in potem s 7.5 (s prioriteto 20) k Treap iz 7.5.

Naloga 7.2. Prikažite odstranjevanje 5 in 7 s Treap iz 7.5.

Naloga 7.3. Dokaži trditev, da je 21,964,800 sekvenc, ki ustvarjajo drevo na desni strani 7.1. (Namig: Podaj rekurzivno enačbo za število sekvenc, ki ustvarjajo celotno dvojiško drevo višine h in razreši to enačbo za $h = 3$.)

Naloga 7.4. Razvij in implementiraj metodo `permute(a)`, ki prejme kot vhod polje `a`, ki vsebuje `n` različnih vrednosti in naključno permutira `a`. Metoda naj teče v času $O(n)$. Dokaži, da je vsaka od $n!$ možnih permutacij `a` enako verjetna.

Naloga 7.5. Uporabi oba dela 7.2 za dokaz, da je pričakovano število rotacij, opravljenih pri operaciji `add(x)` (in pravtako tudi pri operaciji `remove(x)`) enako $O(1)$.

Naloga 7.6. Spremeni implementacijo Treap podano tukaj, tako, da ne hrani prednosti neposredno. Namesto tega naj jih simulira z zgoščevanjem `hashCode()` vsakega vozlišča.

Naloga 7.7. Recimo, da dvojiško iskalno drevo hrani v vsakem vozlišču `u` višino `u.height` poddreves vkorenjenih v `u` in velikost `u.size` poddrevesa vkorenjenega v `u`.

1. Pokaži, kako se; če izvedemo levo ali desno rotacijo v `u`; tidve količini posodabljata v konstantnem času, za vsa vozlišča na katere vpliva rotacija.
2. Razloži zakaj ni isti izid možen, če želimo v vsakem vozlišču `u` hraniti tudi globino `u.depth`.

Naloga 7.8. Razvij in implementiraj algoritem, ki zgradi Treap z urejenega polja `a`, ki vsebuje `n` elementov. Ta metoda naj teče v časovni zahtevnosti $O(n)$ v najslabšem primeru. Treap, ki ga zgradi, naj bo identičen

tistemu, ki se zgradi z dodajanjem posameznik elementov z uporabo metode `add(x)`.

Naloga 7.9. V tej vaji raziščemo, kako lahko učinkovito iščemo v Treap, če je kazalec preblizu vozlišča, katerega iščemo.

1. Razvij in implementiraj različico Treap, ki v vsakem vozlišču hrani največjo in najmanjšo vrednost v svojem poddrevesu.
2. Z uporabo tega dodatnega podatka, dodaj metodo `fingerFind(x, u)`, ki izvrši operacijo `find(x)` s pomočjo kazalca nad vozliščem `u`, za katerega upamo, da ni daleč od vozlišča, ki vsebuje `x`). Ta operacija naj začne v `u` in se sprehaja navzgor, dokler ne doseže vozlišča `w`, kjer velja $w.min \leq x \leq w.max$. Od tam naprej naj opravi običajno iskanje vrednosti `x`, začenši v `w`. (Pokažemo lahko, da `fingerFind(x, u)` deluje v času $O(1 + \log r)$, kjer je r število elementov v podatkovni strukturi treap, čigar vrednost je med `x` in `u.x`.)
3. Razširi svojo implementacijo v različico podatkovne strukture treap, ki začne vse operacije `find(x)` v vozlišču, ki je bilo zadnje poiskano z operacijo `find(x)`.

Naloga 7.10. Razvij in implementiraj različico podatkovne strukture Treap, ki vsebuje operacijo `get(i)`, ki vrne ključ ranga `i` s Treap. (Namig: Vsako vozlišče `u` naj hrani velikost poddrevesa vkorenjenega v `u`.)

Naloga 7.11. Implementiraj izvedenko vmesnika `List` imenovanega `TreapList` kot podatkovno strukturo treap. Vsako vozlišče naj hrani seznam, ki je enak vmesnemu prehodu po podatkovni strukturi. Vse operacije v `List`; `get(i)`, `set(i, x)`, `add(i, x)` in `remove(i)`; naj tečejo v času $O(\log n)$.

Naloga 7.12. Razvij in implementiraj različico podatkovne strukture Treap, ki podpira operacijo `split(x)`. Ta operacija odstrani vse vrednosti s Treap, ki so večje od `x` in vrne nov Treap, ki vsebuje vse odstranjene vrednosti. Primer: koda `t2 = t.split(x)` odstrani s `t` vse vrednosti večje od `x` in vrne nov Treap `t2`, ki vsebuje te vrednosti. Operacija `split(x)` naj teče v času $O(\log n)$.

Pozor: Da bi ta različica pravilno delovala in omogočala dolovanje metode `size()` v realnem času, je potrebno implementirati spremembe iz 7.10.

Naloga 7.13. Razvij in implementiraj različico podatkovne strukture Treap, ki podpira `absorb(t2)` operacijo, katera deluje nasprotno `split(x)` operacije. Ta odstrani vse vrednosti s Treap `t2` in jih doda k prejemniku. Ta operacija predvideva, da je najmanjša vrednost v `t2` večja od največje vrednosti v prejemniku. Operacija `absorb(t2)` naj teče v času $O(\log n)$.

Naloga 7.14. Implementiraj Martinezovo naključno dvojiško iskalno drevo, ki je bilo opisano v tej sekciji. Primerjaj učinkovitost dvoje implementacije z Treap implementacijo.

Poglavje 8

Drevesa “grešnega kozla”

V tem poglavju bomo preučili podatkovno strukturo dvojiškega iskalnega drevesa, `ScapegoatTree`. Struktura temelji na znanem dejstvu, da, ko gre nekaj narobe, ljudje najprej nekoga okrivijo (*grešni kozel*). Ko najdemo grešnega kozla, lahko ves problem prepustimo njemu.

`ScapegoatTree` ohranja ravnotežje z *operacijami delne rekonstrukcije*. Med delno rekonstrukcijo se celotno poddrevo razstavi in zgradi nazaj v popolnoma uravnoreženo poddrevo. Obstaja mnogo načinov, kako spremeniti drevo s korenem v vozlišču `u` v popolnoma uravnoreženo drevo. Eden od najpreprostejših je, da se sprehodimo čez poddrevo `u` in zberemo vsa vozlišča v tabelo `a`, nato pa iz te tabele rekurzivno zgradimo uravnoreženo poddrevo. Če je `m = a.length/2`, potem je element novi `a[m]` koren poddrevesa, elementi `a[0], ..., a[m-1]` se shranijo rekurzivno v levo poddrevo in `a[m+1], ..., a[a.length-1]` se shranijo rekurzivno v desno poddrevo.

```

ScapegoatTree
void rebuild(Node<T> u) {
    int ns = size(u);
    Node<T> p = u.parent;
    Node<T>[] a = Array.newInstance(Node.class, ns);
    packIntoArray(u, a, 0);
    if (p == nil) {
        r = buildBalanced(a, 0, ns);
        r.parent = nil;
    } else if (p.right == u) {
        p.right = buildBalanced(a, 0, ns);
    }
}
```

```

    p.right.parent = p;
} else {
    p.left = buildBalanced(a, 0, ns);
    p.left.parent = p;
}
}
int packIntoArray(Node<T> u, Node<T>[] a, int i) {
    if (u == nil) {
        return i;
    }
    i = packIntoArray(u.left, a, i);
    a[i++] = u;
    return packIntoArray(u.right, a, i);
}
Node<T> buildBalanced(Node<T>[] a, int i, int ns) {
    if (ns == 0)
        return nil;
    int m = ns / 2;
    a[i + m].left = buildBalanced(a, i, m);
    if (a[i + m].left != nil)
        a[i + m].left.parent = a[i + m];
    a[i + m].right = buildBalanced(a, i + m + 1, ns - m - 1);
    if (a[i + m].right != nil)
        a[i + m].right.parent = a[i + m];
    return a[i + m];
}

```

En klic `rebuild(u)` traja $O(\text{size}(u))$. Popravljeno poddrevo je minimalne velikosti; ni možno izgraditi nižjega drevesa s $\text{size}(u)$ vozlišči.


8.1 ScapegoatTree: Dvojiško iskalno drevo z delno rekonstrukcijo

`ScapegoatTree` je `BinarySearchTree`, ki poleg števca (`n`) vozlišč v drevesu hrani še števec (`q`), ki drži zgornjo mejo dovoljenega števila vozlišč.

```

int q;
ScapegoatTree

```



Slika 8.1: ScapegoatTree z 10 vozlišči in višino 5.

$$q/2 \leq n \leq q .$$

Poleg tega ima ScapegoatTree logaritmčno višino; njegova višina nikoli ne prekorači

$$\log_{3/2} q \leq \log_{3/2} 2n < \log_{3/2} n + 2 . \quad (8.1)$$

Tudi s to omejitvijo lahko ScapegoatTree izgleda presenetljivo neuravnoteženo. Drevo na sliki 8.1 ima $q = n = 10$ in višino $5 < \log_{3/2} 10 \approx 5.679$.

Implementacija `find(x)` je v ScapegoatTree narejena s standardnim algoritmom za iskanje v BinarySearchTree (glej 6.2). Njena časovna zahtevnost je sorazmerna z višino drevesa, ki je po (8.1) enaka $O(\log n)$.

Ko implementiramo operacijo `add(x)`, najprej povečamo n in q in potem uporabimo običajni algoritem za dodajanje x v dvojiško iskalno drevo; poiščemo x in nato dodamo nov list u z $u.x = x$. Tu se nam lahko posreči in globina u ne preseže $\log_{3/2} q$. V tem primeru smo zadovoljni z rezultatom in ne naredimo nič drugega.

Žal se včasih zgodi, da $\text{depth}(u) > \log_{3/2} q$. V tem primeru moramo višino zmanjšati. To pa ni velik zalogaj, saj imamo le eno vozlišče, u , katerega globina presega $\log_{3/2} q$. Da popravimo u , se sprehodimo nazaj proti korenu in iščemo *grešnega kozla*, w . Ta grešni kozel, w , je zelo neu-

ravnoteženo vozlišče z lastnostjo

$$\frac{\text{size}(\mathbf{w.child})}{\text{size}(\mathbf{w})} > \frac{2}{3}, \quad (8.2)$$

kjer $\mathbf{w.child}$ predstavlja otroka \mathbf{w} na poti od korena do \mathbf{u} . Kmalu bomo dokazali, da grešni kozel obstaja, za zdaj pa to predpostavimo. Ko smo našli grešnega kozla \mathbf{w} , popolnoma uničimo poddrevo s korenem v \mathbf{w} in ga ponovno izgradimo kot popolnoma uravnoteženo dvojiško iskalno drevo. Iz (8.2) vemo, da že pred vstavljanjem \mathbf{u} , poddrevo \mathbf{w} ni bilo polno dvojiško drevo. Zato se ob ponovni izgradnji poddrevesa \mathbf{w} njegova višina zniža za vsaj 1, tako da je višina celotnega drevesa spet kvečjemu $\log_{3/2} q$.

ScapegoatTree


```

boolean add(T x) {
    // first do basic insertion keeping track of depth
    Node<T> u = newNode(x);
    int d = addWithDepth(u);
    if (d > log32(q)) {
        // depth exceeded, find scapegoat
        Node<T> w = u.parent;
        while (3*size(w) <= 2*size(w.parent))
            w = w.parent;
        rebuild(w.parent);
    }
    return d >= 0;
}

```

Če ne upoštevamo cene iskanja grešnega kozla \mathbf{w} in ponovne izgradnje poddrevesa s korenem v \mathbf{w} , je čas za izvedbo $\text{add}(\mathbf{x})$ odvisen od začetnega iskanja, ki traja $O(\log q) = O(\log n)$. Ceno iskanja grešnega kozla in rekonstrukcije bomo izračunali z amortizacijsko analizo v naslednji sekciji.

Implementacija $\text{remove}(\mathbf{x})$ v ScapegoatTree je zelo preprosta. Poiščemo element \mathbf{x} in ga odstranimo z običajnim algoritmom za odstranjevanje vozlišča iz BinarySearchTree. (To nikoli ne poveča višine drevesa.) V naslednjem koraku znižamo \mathbf{n} , \mathbf{q} pa pustimo nespremenjen. Na koncu preverimo, če je $q > 2n$ in, če je, *ponovno zgradimo celotno drevo* v popolnoma uravnoteženo dvojiško iskalno drevo in nastavimo $q = n$.



Slika 8.2: Vstavljanje 3.5 v ScapegoatTree poveča njegovo višino v 6, kar krši (8.1), saj je $6 > \log_{3/2} 11 \approx 5.914$. Grešni kozel je drevo z elementom 5.

ScapegoatTree

```
boolean remove(T x) {
    if (super.remove(x)) {
        if (2*n < q) {
            rebuild(r);
            q = n;
        }
        return true;
    }
    return false;
}
```

Če zanemarimo ceno rekonstrukcije, je čas izvajanja `remove(x)` spet sorazmeren z višino drevesa, torej je enak $O(\log n)$.

8.1.1 Analiza pravilnosti in časovne kompleksnosti

V tej sekciji bomo analizirali pravilnost in amortiziran čas izvajanja operacij na ScapegoatTree. Najprej dokažimo pravilnost tako, da pokažemo, da ko operacija `add(x)` naredi vozlišče, ki krši pogoj (8.1), vedno lahko najdemo grešnega kozla:

Lema 8.1. Naj bo u vozlišče višine $h > \log_{3/2} q$ v *ScapegoatTree*. Potem obstaja vozlišče w na poti od u do korena, za katerega drži

$$\frac{\text{size}(w)}{\text{size}(\text{parent}(w))} > 2/3 .$$

Dokaz. Uporabili bomo dokaz s protislovjem. Predpostavimo, da lema ne drži in je

$$\frac{\text{size}(w)}{\text{size}(\text{parent}(w))} \leq 2/3 .$$

za vsa vozlišča w na poti od u do korena. Označimo pot od korena do u kot $r = u_0, \dots, u_h = u$. Potem drži $\text{size}(u_0) = n$, $\text{size}(u_1) \leq \frac{2}{3}n$, $\text{size}(u_2) \leq \frac{4}{9}n$ in bolj v splošnem,

$$\text{size}(u_i) \leq \left(\frac{2}{3}\right)^i n .$$

A to nas pripelje to protislovja, saj je $\text{size}(u) \geq 1$, torej drži

$$1 \leq \text{size}(u) \leq \left(\frac{2}{3}\right)^h n < \left(\frac{2}{3}\right)^{\log_{3/2} q} n \leq \left(\frac{2}{3}\right)^{\log_{3/2} n} n = \left(\frac{1}{n}\right)n = 1 . \quad \square$$

Sedaj analiziramo še dele algoritma, ki jih prej nismo upoštevali. Ostala sta dva dela: cena klicev $\text{size}(u)$, ko iščemo grešne kozle in cena $\text{rebuild}(w)$, ko najdemo grešnega kozla w . Cena klicev $\text{size}(u)$ je povezana s ceno klicev $\text{rebuild}(w)$ na sledeč način:

Lema 8.2. Med klicem $\text{add}(x)$ v *ScapegoatTree* je cena iskanja grešnega kozla w in rekonstrukcije poddrevesa s korenem w enaka $O(\text{size}(w))$.

Dokaz. Cena rekonstrukcije vozlišča w , ko ga najdemo, je $O(\text{size}(w))$. Ko iščemo grešnega kozla, kličemo $\text{size}(u)$ na zaporedju vozlišč u_0, \dots, u_k , dokler ne najdemo grešnega kozla $u_k = w$. A ker je u_k prvo vozlišče v tem zaporedju, ki je grešni kozel, vemo, da

$$\text{size}(u_i) < \frac{2}{3} \text{size}(u_{i+1})$$

za vse $i \in \{0, \dots, k-2\}$. Torej je cena vseh klicev $\text{size}(\mathbf{u})$ enaka

$$\begin{aligned}
 O\left(\sum_{i=0}^k \text{size}(\mathbf{u}_{k-i})\right) &= O\left(\text{size}(\mathbf{u}_k) + \sum_{i=0}^{k-1} \text{size}(\mathbf{u}_{k-i-1})\right) \\
 &= O\left(\text{size}(\mathbf{u}_k) + \sum_{i=0}^{k-1} \left(\frac{2}{3}\right)^i \text{size}(\mathbf{u}_k)\right) \\
 &= O\left(\text{size}(\mathbf{u}_k) \left(1 + \sum_{i=0}^{k-1} \left(\frac{2}{3}\right)^i\right)\right) \\
 &= O(\text{size}(\mathbf{u}_k)) = O(\text{size}(\mathbf{w})) ,
 \end{aligned}$$

kjer zadnja vrstica sledi iz dejstva, da je vsota geometrično padajoča vrsta. \square

Ostane nam le še, da dokažemo zgornjo mejo cene vseh klicov $\text{rebuild}(\mathbf{u})$ med zaporedjem m operacij:

Lema 8.3. Če začnemo s praznim *ScapegoatTree*, vsako zaporedje m operacij $\text{add}(\mathbf{x})$ in $\text{remove}(\mathbf{x})$ zahteva kvečjemu $O(m \log m)$ časa za $\text{rebuild}(\mathbf{u})$ operacije.

Dokaz. Da to dokažemo, bomo uporabili *creditno shemo*. Predstavljajmo si, da ima vozlišče neko količino kreditov. Z vsakim kreditom lahko za rekonstrukcijo plačamo neko konstantno število, c , enot časa. Ta shema nam skupaj da $O(m \log m)$ kreditov in vsak klic $\text{rebuild}(\mathbf{u})$ plačamo s krediti, ki jih ima \mathbf{u} . Med vstavljanjem ali izbrisom damo en kredit vsakemu vozlišču na poti do vstavljenega ali izbrisanega vozlišča \mathbf{u} . Na ta način podelimo največ $\log_{3/2} q \leq \log_{3/2} m$ kreditov na operacijo. Za vsako operacijo izbriša damo še en dodaten kredit "na stran." Skupaj torej podelimo kvečjemu $O(m \log m)$ kreditov. Dokazati moramo le še, da jih imamo dovolj, da plačamo vse klice $\text{rebuild}(\mathbf{u})$.

Če kličemo $\text{rebuild}(\mathbf{u})$ med vstavljanjem, je to zato, ker je \mathbf{u} grešni kozel. Zamislimo si, da drži

$$\frac{\text{size}(\mathbf{u.left})}{\text{size}(\mathbf{u})} > \frac{2}{3} .$$

Če uporabimo dejstvo, da

$$\text{size}(\mathbf{u}) = 1 + \text{size}(\mathbf{u.left}) + \text{size}(\mathbf{u.right})$$

pridemo do sklepa

$$\frac{1}{2}\text{size}(\text{u.left}) > \text{size}(\text{u.right})$$

in torej

$$\text{size}(\text{u.left}) - \text{size}(\text{u.right}) > \frac{1}{2}\text{size}(\text{u.left}) > \frac{1}{3}\text{size}(\text{u}) .$$

Zadnjič, ko je bilo neko poddrevo, ki vsebuje u , ponovno zgrajeno (če se to nikoli ni zgodilo, pa takrat, ko je bil u vstavljen), je držalo

$$\text{size}(\text{u.left}) - \text{size}(\text{u.right}) \leq 1 .$$

Zato je število $\text{add}(x)$ in $\text{remove}(x)$ operacij, ki so vplivale na u.left ali u.right od takrat enako ali večje

$$\frac{1}{3}\text{size}(\text{u}) - 1 .$$

Zato je v u vsaj toliko kreditov in z njimi lahko plačamo ceno $O(\text{size}(u))$, ki jo zahteva $\text{rebuild}(u)$.

Če kličemo $\text{rebuild}(u)$ med izbrisom, je to zato, ker $q > 2n$. V tem primeru smo med izbrisi že dali $q - n > n$ kreditov "na stran" in z njimi lahko plačamo $O(n)$ ceno, potrebno za rekonstrukcijo korena. S tem je dokaz zaključen. \square

8.1.2 Povzetek

Sledeči izrek povzame učinkovitost podatkovne strukture Scapegoat-Tree:

Izrek 8.1. *ScapegoatTree implementira vmesnik SSet. Če zanemarimo ceno $\text{rebuild}(u)$ operacij, ScapegoatTree podpira operacije $\text{add}(x)$, $\text{remove}(x)$ in $\text{find}(x)$ v času $O(\log n)$ na operacijo.*

Poleg tega, če začnemo s praznim ScapegoatTree, poljubno zaporedje m $\text{add}(x)$ in $\text{remove}(x)$ operacij zahteva kvečjemu $O(m \log m)$ časa za klice $\text{rebuild}(u)$.

Poglavje 9


Rdeče-Črna Drevesa

V tem poglavju so predstavljena rdeče-črna drevesa. Le ta so zasnovana kot uravnotežena iskalna dvojiška drevesa z logaritemsko višino. So ena najbolj razširjenih podatkovnih struktur in se pojavljajo kot primarne iskalne strukture v mnogih knjižnicah, kot je Java Collections Framework, številnih implementacijah C++ Standard Template Library ter tudi znotraj jedra operacijskega sistema Linux. Nekaj glavnih razlogov zakaj so rdeče-črna drevesa tako priljubljena:

1. Največja možna višina rdeče-črnega drevesa z n vozlišči je enaka $2\log n$.
2. Časovna zahtevnost operacij `add(x)` in `remove(x)` je enaka $O(\log n)$ v *najslabšem primeru*.
3. Amortizirano število rotacij, ki nastopijo med izvajanjem operacij `add(x)` ali `remove(x)` je konstantno.

Že prvi dve lastnosti postavljajo rdeče-črna drevesa pred preskočne sezname, naključna iskalna binarna drevesa in samouravnotežena binarna drevesa. Preskočni sezname in naključna iskalna binarna drevesa se zanašajo na naključje, njihova pričakovana časovna zahtevnost je $O(\log n)$. Samouravnotežena binarna drevesa imajo zagotovljeno omejitev višine, vendar se `add(x)` in `remove(x)` izvršita v $O(\log n)$ amortiziranem času. Tretja lastnost je le pika na i. Pove nam, da je čas potreben za vstavev ali izločitev elementa x manjši od časa, ki ga porabimo za iskanje elementa

Rdeče-Črna Drevesa



Slika 9.1: 2-4 drevo višine 3.

x.¹

Vendar pa imajo dobre lastnosti rdeče-črnih dreves določeno ceno: kompleksnost implementacije. Ohranjati mejo višine $2 \log n$ ni preprosto. Zahteva pazljivo in podrobno analizo številnih primerov. Zagotoviti moramo, da implementacija naredi natančno določeno stvar za določen primer. Že samo ena napačna rotacija ali zamenjava barve povzroči napako, ki jo je težko najti in razumeti.

Preden se bomo lotili implementacije rdeče-črnih dreves, bomo spoznali ozadje sorodne podatkovne strukture: 2-4 drevesa. S tem bomo pridobili informacije na podlagi česa so bila rdeče-črna drevesa ustvarjena in kako jih je možno tako učinkovito ohranjati.

9.1 2-4 Trees

2-4 Drevo je korensko drevo, ki ima naslednje lastnosti:

Lastnost 9.1 (height). Vsi listi imajo enako globino.

Lastnost 9.2 (degree). Vsako notranje vozlišče ima 2, 3 ali 4 otroke.

Primer 2-4 drevesa je prikazan v 9.1. Lastnost 2-4 dreves je logaritemska višina v številu listov:

Lema 9.1. *Najvišja višina 2-4 drevesa z n listi je $\log n$.*

¹Naključna iskalna binarna drevesa in samouravnotežena binarna drevesa imajo enako lastnost. Glej vaje 4.6 in 7.5.

Dokaz. Omejenost vsakega notranjega vozlišča na najmanj 2 otroka dokazuje, da imamo v primeru višine h v 2-4 drevesu vsaj 2^h listov. Z drugimi besedami,

$$n \geq 2^h .$$

Če obe strani logaritmiramo dobimo neenačbo $h \leq \log n$. □

9.1.1 Dodajanje lista

Dodajanje lista v 2-4 drevo je preprosto (glej 9.2). Če želimo dodati list u kot otroka nekemu vozlišču w na predzadnjem nivoju, potem preprosto postavimo u za otroka vozlišča w . V tem primeru vsekakor ohranja višino, ampak lahko krši pravilo; če bi imel w štiri otroke pred dodajanjem u , potem ima w sedaj pet otrok. V tem primeru moramo *razdeliti* w v dve vozlišči, w in w' , ki imata sedaj 2 in 3 otroke. A ker w' sedaj nima staršev, w rekurzivno nastavimo kot otroka starša w . V tem primeru ima lahko starš vozlišča w' preveč otrok, zato ga moramo razdeliti. Ta postopek se nadaljuje, dokler ne pridemo do vozlišča, ki ima manj kot štiri otroke ali dokler ne razdelimo korena r , v dva vozlišča r in r' . V slednjem primeru naredimo nov koren ki ima otroka r in r' . To hkrati povečuje globino vseh listov in tako ohranja višino the height property.


Ker višina 2-4 drevesa ni nikoli več kot $\log n$, se proces dodajanja listov konča po največ $\log n$ korakih.

9.1.2 Odstranjevanje lista


Odstranjevanje lista 2-4 drevesa je lahko rahlo bolj komplicirano kot dodajanje (Glej 9.3). Da ločimo list u od njegovega starša w , ga samo odstranimo. Če ima w samo dva lista in mu mi enega izmed njih odstranimo, moramo drevo ustrezno popraviti, saj krši pravilo.

Da popravimo napako, poiščemo brata w ki je w' . Vozlišče w' definitivno obstaja, ker ima starš w vsaj dva otroke. Če ima w' tri ali štiri otroke, potem vzamemo enega izmed otrok in ga dodamo w . Sedaj ima w dva otroke in w' ima dva ali tri, nato končamo s popravljanjem.

Če ima w' samo dva otroke, potem ju *združimo* v skupno vozlišče, ki ima tri otroke. Potem moramo rekurzivno izbrisati w' . dokler ne dosežemo vozlišča u ali njegovega brata, ki ima več kot dva otroke ali ne dosežemo



Slika 9.2: Dodajanje lista v 2-4 drevo. Ta proces se konča po enem razdeljevanju, ker ima $w.parent$ stopnjo manj kot 4 pred dodajanjem.



Slika 9.3: Odstranjevanje lista z 2-4 drevesa. Ta proces sega vse do korena, saj ima vsak prednik in bratje vozlišča u samo dva otroke.

korena. Če je koren levi z enim samim otrokom, nato pobrišemo koren in otroka dodamo v koren. Tudi to istočasno zmanjšuje višino vsakega lista in tako ohranimo višino drevesa.

Ker višina 2-4 drevesa ni nikoli več kot $\log n$, se proces odstranjevanja listov konča po največ $\log n$ korakih.

9.2 RedBlackTree: Simulirano 2-4 drevo

Rdeče-črno drevo je binarno iskalno drevo, katerega vsako vozlišče, u , je *rdeče* ali *črno*. Rdeče predstavlja vrednost 0, črno pa vrednost 1.

```

class Node<T> extends RedBlackTree.BSTNode<Node<T>, T> {
    byte colour;
}


```

Pred in po spreminjanju rdeče-črnega drevesa, morata veljati naslednji dve lastnosti. Vsaka lastnost je definirana v obeh izrazih, v rdeči in črni barvi in številskih vrednostih 0 in 1.

Lastnost 9.3 (višina-črnih). Enako število črnih vozlišč v poti od korena do katerega koli lista. (Vsota barv na poti od korena do poljubnega lista je enaka.)

Lastnost 9.4 (list-ni-rdeč). Dve rdeči vozlišči nista med seboj nikoli sosednji. (Velja za vsako vozlišče u , razen korena, $u.barva + u.stars.barva \geq 1$.)

Opazili smo, da lahko vedno pobarvamo koren, r , rdeče-črnega drevesa črno, ne da bi kršili katero od lastnosti, zato bomo predvidevali, da je koren črne barve in algoritmi za posodabljanje rdeče-črnih dreves bodo to upoštevali. Druga stvar, ki poenostavlja rdeče-črna drevesa je, da so zunanja vozlišča (predstavljena z `nil`) črna vozlišča. Na ta način ima vsako vozlišče, u , rdeče-črnega drevesa natanko dva otroka, vsak z opredeljeno barvo. Primer rdeče-črnega drevesa je predstavljen v sliki 9.4.



Slika 9.5: Vsako rdeče-črno drevo ima ustrezno 2-4 drevo.

pot od korena do kateregakoli *notranjega* vozlišča v T je največ

$$2\log(n+1) - 2 \leq 2\log n ,$$


za vsak $n \geq 1$. S tem dokažemo najpomembnejšo lastnost rdeče-črnih dreves:

Lema 9.2. *Višina rdeče-črnega drevesa z n vozlišči je največ $2\log n$.*

Sedaj, ko smo videli relacijo med 2-4 drevesi in rdeče-črnimi drevesi, ni tako težko za verjeti, da lahko učinkovito ohranjamo rdeče-črno drevo med dodajanjem in brisanjem elementov.

Videli smo že, da dodajanje elementa v `BinarySearchTree` izvedemo z dodajanjem novega lista. Torej, za implementacijo `add(x)` v rdeče-črno drevo moramo imeti metodo za simulacijo razdelitve vozlišča s petimi otroki v 2-4 drevesu. Vozlišče v 2-4 drevesu s petimi otroki je predstavljeno s črnim vozliščem, ki ima dva rdeča otroka, eden od teh ima tudi rdečega otroka. Lahko “razdelimo” to vozlišče s tem, da ga pobarvamo v rdeče in pobarvamo njegova dva otroka v črno. Primer prikazuje 9.6.

Podobno, implementacija `remove(x)` zahteva metodo za združevanje dveh vozlišč in izposajo sorodnikovega otroka. Združitev dveh vozlišč



Slika 9.6: Simuliranje operacije deljenja 2-4 drevesa med dodajanjem v rdeče-črno drevo. (To simulira dodajanje v 2-4 drevo prikazano na 9.2.)

je inverz deljenja vozlišč (prikazano na 9.6) in vključuje barvanje dveh (črnih) sorodnikov v rdeče in barvanje njegovega (rdečega) starša v črno. Izposoja od sorodnika je najbolj zakompliciran postopek in vključuje obe rotacije in barvanje vozlišč.

Vsekakor, med vsem tem moramo še vedno ohranjati lastnost list-ni-rdeč in lastnost višina-črnih. Medtem ko ni več presenetljivo, da lahko naredimo direktno simulacijo 2-4 drevesa z rdeče-črnim drevesom, je vseeno veliko primerov, na katere moramo paziti. V določenem trenutku postane lažje, če ne upoštevamo 2-4 drevesa in samo ohranjamo lastnosti rdeče-črnega drevesa.

9.2.2 Levo-poravnana rdece-crna drevesa


Definicija rdeče-črnega drevesa ne obstaja. Namesto tega imamo družino struktur, ki znajo ohranjati lastnosti višina-črnih in list-ni-rdeč med uporabo operacij `add(x)` in `remove(x)`. Različne strukture to delajo na različne načine. V našem primeru implementiramo podatkovno strukturo, ki ji rečemo `RedBlackTree`. Ta struktura implementira posebno obliko rdeče-črnega drevesa, ki zadovoljuje dodatno lastnost:

Lastnost 9.5 (levo-poravnano). Na kateremkoli vozlišču `u`, če je `u.left` črno, potem je `u.right` črno.

Opomnimo, da rdeče-črno drevo prikazano na 9.4 ne zadošča lastnosti levo-poravnano. Krši jo starš rdečega vozlišča na najbolj desni poti od korena proti listu.

Razlog za ohranjanje lastnosti levo-poravnano je, da zmanjšuje število soočenih primerov pri posodabljanju drevesa med operacijama `add(x)` in `remove(x)`. V smislu 2-4 dreves, to pomeni, da ima vsako 2-4 drevo edinstveno zastopanje: Vozlišče stopnje dva postane črno vozlišče z dvema črnima otrokoma. Vozlišče stopnje tri postane črno vozlišče, katerega levi otrok je rdeč in desni otrok je črn. Vozlišče stopnje štiri postane črno vozlišče z dvema rdečima otrokoma.

Preden podrobno opišemo implementacijo operacij `add(x)` in `remove(x)`, predstavimo nekaj osnovnih podoperacij, uporabljenih v metodah prikazanih v 9.7. Prvi dve podoperaciji stao za manipulacijo barv med ohranjanjem lastnosti višina-črnih. Operacija `pushBlack(u)` vzame za vhod črno



Slika 9.7: Rotacije, potegi in potiski

vozlišče u , katero ima dva rdeča otroka in pobarva u rdeče in njegova dva otroka črno. Operacija `pullBlack(x)` obrne to opisano operacijo:

```

RedBlackTree
void pushBlack(Node<T> u) {
    u.colour--;
    u.left.colour++;
    u.right.colour++;
}
void pullBlack(Node<T> u) {
    u.colour++;
    u.left.colour--;
    u.right.colour--;
}

```

Metoda `flipLeft(u)` zamenja barve vozlišča u in $u.right$ ter izvede levo rotacijo nad vozliščem u . Ta metoda obrne barve teh dveh vozlišč tako kot tudi njuno relacijo starš-otrok:

```

RedBlackTree
void flipLeft(Node<T> u) {
    swapColors(u, u.right);
    rotateLeft(u);
}

```

Operacija `flipLeft(u)` je posebej uporabna pri povrnitvi lastnosti levo-poravnano na vozlišču u , katero krši to lastnost (ker je $u.left$ črno in

`u.right` rdeče). V tem posebnem primeru, smo lahko prepričani, da ta operacija ohranja obe lastnosti višina-črnih in list-ni-rdeč. Relacija `flipRight(u)` je simetrična s `flipLeft(u)`, ko so vloge levega in desnega obrnjene.

```

                                RedBlackTree
void flipRight(Node<T> u) {
    swapColors(u, u.left);
    rotateRight(u);
}

```

9.2.3 Dodajanje

Za implementacijo `add(x)` v `RedBlackTree`, izvedemo standardno `BinarySearchTree` vstavljanje za dodajanje novega lista, `u`, z `u.x = x` in nastavimo `u.colour = red`. Opomnimo, da to ne spremeni črne višine katerekoli vozlišču, torej ne krši lastnosti višina-črnih. To pa lahko krši lastnost levo-poravnano (če je `u` desni otrok svojega starša) in lahko krši lastnost list-ni-rdeč (če je `u`jev starš `red`). Za povrnitev teh lastnosti, moramo klicati metodo `addFixup(u)`.


```

                                RedBlackTree
boolean add(T x) {
    Node<T> u = newNode(x);
    u.colour = red;
    boolean added = add(u);
    if (added)
        addFixup(u);
    return added;
}

```

Ilustrirano na 9.8, metoda `addFixup(u)` vzame na vhod vozlišče `u`, katerega barva je rdeča in katero bi lahko kršilo lastnost list-ni-rdeč in/ali lastnost levo-poravnano. Slednja razprava je verjetno nemogoča za sledenje brez sklicevanja na 9.8 ali ponovnega ustvarjanja na kosu papirja. Preden bralec nadaljuje, bi moral preučiti to sliko.

Če je `u` koren drevesa, potem lahko pobarvamo `u` črno za povrnitev obeh lastnosti. Če je tudi `u`jev sorodnik rdeč, potem mora biti `u`jev starš črn, torej obe lastnosti levo-poravnano in list-ni-rdeč že držita.



Slika 9.8: Prikaz enega koraka pri popravljanju Lastnost 2 po vstavljanju.

Sicer, najprej preverimo, če je u jev starš, w , kršil lastnost levo-poravnano in, če je da, potem izvedemo operacijo `flipLeft(w)` in nastavimo $u = w$. Tako pristanemo v lepo definiranem stanju: u je levi otrok starša, w , torej w sedaj zadošča lastnosti levo-poravnano. Vse kar nam ostane je, da zagotovimo lastnost list-ni-rdeč na u . Moramo samo še skrbeti za primer, v katerem je w rdeč, sicer že zadošča lastnosti list-ni-rdeč.

Če sta u in w rdeča, še nismo končali. Lastnost list-ni-rdeč (katero krši u in ne w) implicira, da u jev stari starš g obstaja in je črn. Če je g jev desni otrok rdeč, potem lastnost levo-poravnano zagotavlja, da oba g jev otrok je rdeč in klic na `pushBlack(g)` naredita g rdečega in w črnega. To povrne lastnost list-ni-rdeč na u , ampak lahko povzroči, da jo krši na vozlišču g tako, da celoten proces začne z $u = g$.

Če je g jev otrok črn, potem klic na `flipRight(g)` postane w črni starš od g in naredi w ju dva rdeča otroka, u in g . To zagotovi, da u zadošča lastnosti list-ni-rdeč in g zadošča lastnosti levo-poravnano. Sedaj lahko zaključimo.

```

                                RedBlackTree
void addFixup(Node<T> u) {
    while (u.colour == red) {
        if (u == r) { // u is the root - done
            u.colour = black;
            return;
        }
        Node<T> w = u.parent;
        if (w.left.colour == black) { // ensure left-leaning
            flipLeft(w);
            u = w;
            w = u.parent;
        }
        if (w.colour == black)
            return; // no red-red edge = done
        Node<T> g = w.parent; // grandparent of u
        if (g.right.colour == black) {
            flipRight(g);
            return;
        } else {
            pushBlack(g);
            u = g;
        }
    }
}

```



```

    }
  }
}

```

Metoda `insertFixup(u)` ima konstantni čas za iteracijo in vsaka iteracija, ali konča ali premakne `u` bližje korenu. Zato, metoda `insertFixup(u)` konča po $O(\log n)$ iteracijah in po $O(\log n)$ času.

9.2.4 Odstranitev

Operacija `remove(x)` v `RedBlackTree` je najbolj zahtevna za implementacijo in to velja za vse različice rdeče-črnega drevesa. Tako kot operacija `remove(x)` v `BinarySearchTree`, ta operacija išče vozlišče `w` z enim otrokom, `u`, in spoji `w` iz drevesa tako, da `w.parent` posvoji `u`.

Težava lahko nastane takrat, ko je `w` črn, saj s tem kršimo lastnost višina-črnih v `w.parent`. Temu se lahko začasno izognemo z dodajanjem `w.colour` do `u.colour`. To predstavlja dve težavi: (1) če se `u` in `w` obe začneta s črno, potem `u.colour + w.colour = 2` (dvojna-črna), ki pa ni veljavna. Če je bil `w` rdeč, se ga nadomesti s črnim vozliščem `u`, kateri lahko krši lastnost levo-poravnano pri `u.parent`. Obe težavi lahko rešimo tako, da pokličemo metodo `removeFixup(u)`.

Metoda `removeFixup(u)` prejme kot vhodni parameter vozlišče `u`, ki je črne (1) ali dvojno-črne barve (2). Če je `u` dvojno-črn, potem `removeFixup(u)` opravi vrsto vrtenj in prebarvanj tako, da dvojno-črno vozlišče premika navzgor po drevesu, dokler ni odpravljen. Skozi ta postopek se vozlišče `u` spreminja, dokler ne pride do konca, `u` pa pripada korenu poddrevesa, ki se je spremenil. Koren tega drevesa je lahko sedaj druge barve. Če je prešel iz rdeče na črno barvo, metoda `removeFixup(u)` na koncu preverja, če `u`jev starš krši lastnost levo-poravnano in če jo, to popravi.

```

RedBlackTree
void removeFixup(Node<T> u) {
    while (u.colour > black) {
        if (u == r) {
            u.colour = black;
        } else if (u.parent.left.colour == red) {
            u = removeFixupCase1(u);

```

```

    } else if (u == u.parent.left) {
        u = removeFixupCase2(u);
    } else {
        u = removeFixupCase3(u);
    }
}
if (u != r) { // restore left-leaning property if needed
    Node<T> w = u.parent;
    if (w.right.colour == red && w.left.colour == black) {
        flipLeft(w);
    }
}
}
}

```

Metoda `removeFixup(u)` je predstavljena na 9.9. Naslednjemu besedilu bo težko, če ne kar nemogoče slediti, brez sklicevanja na 9.9. Vsaka ponovitev zanke v postopku `removeFixup(u)` dvojno-črnega vozlišča `u`, temelji na enem od štirih primerov:

Primer 0: `u` je koren. To je najpreprostejši primer. Prebarvali smo `u` v črno (s tem ne kršimo nobene lastnosti rdeče-črnega drevesa).


Primer 1: `u`jev sorodnik, `v`, je rdeč. V tem primeru, je `u`jev sorodnik levi otrok njegovega starša, `w` (z lastnostjo levo-poravnano). Opravimo desno rotacijo na `w` in nadaljujemo z naslednjo ponovitvijo. Upoštevamo, da ta ukrep povzroči, da `w`jev starš krši lastnost levo-poravnano in globina `u` naraste. To pomeni tudi, da bo naslednja ponovitev v Primer 3, z `w` obarvanim rdeče. Pri preučevanju Primer 3 spodaj, bomo videli, da se postopek ustavi med naslednjo ponovitvijo.

```

RedBlackTree
Node<T> removeFixupCase1(Node<T> u) {
    flipRight(u.parent);
    return u;
}

```

Primer 2: `u`jev sorodnik, `v`, je črn, `u` je levi otrok njegovega starša, `w`. V tem primeru pokličemo funkcijo `pullBlack(w)`, ki obarva `u` črno, `v` rdeče in spremeni barvo `w` v črno ali dvojno-črno. V tem primeru `w` ne izpolnjuje lastnost levo-poravnano, zato to uredimo tako, da pokličemo `flipLeft(w)`.



Slika 9.9: Iteracija v procesu odpravljanje dvojno-črnega vozlišča po odstranitvi.

V tem trenutku je w rdeč, v pa je koren poddrevesa, v katerem smo začeli. Preveriti moramo še, če w ne povzroča kršitve lastnosti list-ni-rdeč. To naredimo tako, da preverimo w jevega desnega otroka q . Če je q črn, potem w izpolnjuje lastnost list-ni-rdeč in nadaljujemo z naslednjo ponovitvijo z $u = v$.

Sicer (q je rdeč) sta obe lastnosti, list-ni-rdeč – rdeče pravilo in levo-poravnano, kršeni pri q in w . Levo-poravnano popravimo s klicem `rotateLeft(w)`, sedaj nam ostane le še lastnost list-ni-rdeč, ki jo še vedno kršimo. V tem trenutku je q levi sin od v , w je levi sin od q , q in w sta rdeča, v je črn ali dvojno-črn. `flipRight(v)` popravi drevo tako, da je q sedaj starš tako od v kot od w . Takoj zatem pokličemo `pushBlack(q)`, tako dobimo sledečo situacijo: v in w postaneta črna, q pa dobi originalno barvo od w .

Tako smo se znebili dvojno-črnega vozlišča ter ponovno vzpostavili lastnosti list-ni-rdeč in višina-črnih. Ostane nam samo še ena težava: če ima v desnega sina, ki je rdeč, kršimo lastnost levo-poravnano. To še preverimo ter pokličemo `flipLeft(v)`, ki nam to težavo odpravi, če je potrebno.

```

                                RedBlackTree
Node<T> removeFixupCase2(Node<T> u) {
    Node<T> w = u.parent;
    Node<T> v = w.right;
    pullBlack(w); // w.left
    flipLeft(w); // w is now red
    Node<T> q = w.right;
    if (q.colour == red) { // q-w is red-red
        rotateLeft(w);
        flipRight(v);
        pushBlack(q);
        if (v.right.colour == red)
            flipLeft(v);
        return q;
    } else {
        return v;
    }
}

```

Primer 3: u jev sorodnik je črn in u je desni otrok w . Primer je simetričen

Primeru 2 in ga rešujemo precej podobno. Razlikuje se v tem, da je lastnost levo-poravnano asimetrična, in zato ga obravnavamo drugače.

Kot pri prejšnjem, začnemo s klicem `pullBack(w)`, kar naredi `v` rdeče vozlišče in `u` črno. S klicem `flipRight(w)` postane `v` koren našega poddrevesa. Tako je `w` rdeč, zato sedaj ločimo dva primera glede na `q`, ki je levi sorodnik `w`.

Če je `q` rdeč, nam da isto situacijo kot pri Primer 2, vendar z olajševalno okoliščino, namreč, `v` nam ne more pokvariti lastnosti levo-poravnano.

Bolj zapleteno pa je v primeru, ko je `q` črne barve. Tu moramo preveriti barvo levega otroka vozlišča `v`. Če je ta rdeč, potem ima `v` dva rdeča sinova, zato pokličemo `pushBlack(v)`. Sedaj je `w` črn, `v` je prejšnje barve `w` in smo končali z urejanjem.

Če je `v`jev levi otrok črn, kršimo lastnost levo-poravnano. Vzpostavimo jo nazaj s klicem `flipLeft(v)`. Nato vrnemo vozlišče `v`, zato da se naslednja iteracija `removeFixup(u)` nadaljuje z `u = v`.

```
RedBlackTree
Node<T> removeFixupCase3(Node<T> u) {
    Node<T> w = u.parent;
    Node<T> v = w.left;
    pullBlack(w);
    flipRight(w); // w is now red
    Node<T> q = w.left;
    if (q.colour == red) { // q-w is red-red
        rotateRight(w);
        flipLeft(v);
        pushBlack(q);
        return q;
    } else {
        if (v.left.colour == red) {
            pushBlack(v); // both v's children are red
            return v;
        } else { // ensure left-leaning
            flipLeft(v);
            return w;
        }
    }
}
```

Vsaka iteracija `removeFixup(u)` se izvrši v konstantnem času. Primer 2 in 3 lahko proceduro končata, ali pa premakneta `u` bližje korenu drevesa. Primer 0 (kjer je `u` koren) se vedno konča, Primer 1 pelje v Primer 3, ki se prav tako konča. Ker vemo, da je višina drevesa največ $2\log n$, zaključimo, da imamo največ $O(\log n)$ iteracij procedure `removeFixup(u)`, torej se `removeFixup(u)` izvrši v $O(\log n)$ času.

9.3 Povzetek

Naslednji izrek povzema učinkovitost podatkovne strukture `RedBlackTree`:

Izrek 9.1. *RedBlackTree uporablja vmestnik `SSet` in omogoča, da se operacije `add(x)`, `remove(x)` in `find(x)` izvedejo v najslabšem času $O(\log n)$ na operacijo.*

Kar ni vključeno v zgornji teoriji, ima dodatni bonus:

Izrek 9.2. *Med vsemi klici metod `addFixup(u)` in `removeFixup(u)` se vsako zaporedje operacij doda `j(x)` in odstrani `(x)` izvede v času $O(m)$, na začetku ko je `RedBlackTree` prazen.*

Naredili smo samo skico dokaza za 9.2. S primerjanjem metod `addFixup(u)` in `removeFixup(u)`, z algoritmi za dodajanje ali odstranjevanje listov v 2-4 drevesu se lahko prepričamo, da se ta lastnost deduje z 2-4 drevesa. Običajno, če lahko dokažemo, da je skupni čas porabljen za delitev, združevanje in zadolževanje v 2-4 drevesu $O(m)$, potem ta dokaz namiguje na 9.2.

Dokaz tega izreka za 2-4 drevo uporablja potencial odplačne analize.² Definiraj potencial za notranje vozlišče `u` v 2-4 drevesu kot

$$\Phi(u) = \begin{cases} 1 & \text{če ima } u \text{ 2 otroka} \\ 0 & \text{če ima } u \text{ 3 otroke} \\ 3 & \text{če ima } u \text{ 4 otroke} \end{cases}$$

in potencial za 2-4 drevo kot vsoto potencialov za njegova vozlišča. Delitev se pojavi, ko se vozlišča s štirimi otroci razdelijo na dve vozlišči z

²Oglej si 2.2 in 3.1 dokaze za potencialno metodo v ostalih aplikacijah.

dvema in tremi otroci. To pomeni, da se skupni potencial zmanjša za $3 - 1 - 0 = 2$. Ko pride do združevanja, se dve vozlišči z dvema otroki zamenjata z vozliščem, ki ima tri otroke. Rezultat tega je zmanjšanje potenciala za $2 - 0 = 2$. Torej se za vsako delitev ali združitev potencial zmanjša za dva.

Nato bodite pozorni, da če zanemarimo delitev in združevanje vozlišč, temu sledi konstantno število vozlišč katerih število otrok je bilo s tem ali odstranitvijo lista spremenjeno. Ob dodajanju vozlišča se nekemu vozlišču število otrok poveča za ena, s tem pa povečamo potencial za največ tri. Med odstranitvijo lista, se vozlišču zmanjša število otrok za ena, potencial pa se mu poveča največ za ena. Ob tem sta lahko v odstranjevanje vključeni dve vozlišči s čimer se njun potencial poveča za največ ena.

Kot povzetek torej sledi, da lahko vsaka združitev ali delitev povzroči zmanjšanje potenciala za vsaj dva. V primeru, da ne upoštevamo združitev ter delitev pri dodajanju oziroma odstranjevanju, pa lahko povzroči povečanje potenciala za največ tri. Potencial je vedno ne-negativno število. Zatorej je število združitev ter delitev, povzročenih s strani m dodajanj oziroma odstranjevanj, na prvotno praznem drevesu največ $3m/2$. 9.2 izhaja iz te analize in povezav med 2-4 drevesi in rdeče-črnimi drevesi.

9.4 Razprava in naloge

Rdeče-črna drevesa sta prvič predstavila Guibas in Sedgewick [?]. Kljub njihovi visoki zapletenosti izvedbe so najdeni v nekaterih najbolj pogosto uporabljenih knjižnicah in aplikacijah. Večina algoritmov in učbenikov o podatkovnih strukturah razpravlja o nekaj različicah rdeče-črnih dreves.

Andersson [?] je predstavil levo-visečo različico uravnananega drevesa, ki je podobna rdeče-črnim drevesom, vendar z omejitvijo, da ima vsako vozlišče lahko največ enega rdečega otroka. Zaradi omenjene omejitve je izvedba 2-3 dreves veliko pogostejša od 2-4 dreves. Ta so veliko preprostejša kot podatkovna struktura RedBlackTree predstavljenih v tem poglavju.

Sedgewick [?] opisuje dve verziji levo-visečih rdeče-črnih dreves. Te uporabljajo rekurzijo, skupaj s simulacijo delitvijske od zgoraj navzdol in

združevanje v 2-4 drevesih. Kombinacija obeh tehnik nam omogoča zelo kratek in eleganten zapis kode.

Povezana, a starejša, podatkovna struktura je *AVL tree* [?]. AVL drevesa so *height-balanced*: V vsakem vozlišču u se višina levega poddrevesa $u.left$ ter desnega poddrevesa $u.right$ razlikuje za največ ena. Iz tega sledi: če je $F(h)$ najmanjše število listov drevesa višine h , potem se $F(h)$ uvršča v okvir Fibonaccijevega zaporedja

$$F(h) = F(h-1) + F(h-2)$$

z osnovnima primeroma $F(0) = 1$ in $F(1) = 1$. $F(h)$ je tako približno $\varphi^h/\sqrt{5}$, kjer je $\varphi = (1 + \sqrt{5})/2 \approx 1.61803399$ is the *golden ratio*. (Bolj natančno $|\varphi^h/\sqrt{5} - F(h)| \leq 1/2$.) S pomočjo utemeljitve v 9.1, to pomeni

$$h \leq \log_{\varphi} n \approx 1.440420088 \log n ,$$

torej imajo AVL drevesa manjšo višino kot rdeče-črna drevesa. Višina je lahko vzdrževana med izvajanjem $add(x)$ in $remove(x)$ operacij z prehodom navzgor do korena drevesa, med katerim se izvede uravnoteženje vsakega vozlišča u , katerega višina levega in desnega poddrevesa se razlikuje za dva. Glej 9.10.

Uporaba Anderssonove in Sadgewickove različice rdeče-črnih dreves in uporaba AVL dreves je enostavnejša kot uporaba strukture `RedBlackTree`. Žal pa ne more nobena od njih zagotavljati, da bi bil amortizacijski čas $O(1)$, za vsako posodobitev uravnovešen. Zlasti zato, ker te strukture nemoremo primerjati z 9.2.


Naloga 9.1. Nariši 2-4 drevo, ki ustreza `RedBlackTree` iz 9.11.

Naloga 9.2. Nariši dodajanje elementov 13, 3.5 in 3.3 na `RedBlackTree` iz 9.11.


Naloga 9.3. Nariši odstranjevanje elementov 11, 9, ter 5 na `RedBlackTree` iz 9.11.

Naloga 9.4. Pokaži, da za poljubno velike vrednosti n , obstaja rdeče-črno drevo z n vozlišči, ki imajo višino $2 \log n - O(1)$.

Naloga 9.5. Preuči operaciji `pushBlack(u)` and `pullBlack(u)`. Kaj naredijo ti dve operaciji na 2-4 drevesu, ki temelji na simulaciji z rdeče-črnim drevesom.



Slika 9.10: Uravnoteženje v AVL drevesih. Največ dve rotaciji sta potrebni, da vozlišče s poddrevesoma višine h in $h+2$ spremenimo v vozlišče s poddrevesoma višine $h+1$.



Slika 9.11: A red-black tree on which to practice.

Naloga 9.6. Pokaži, da za poljubno velike vrednosti n , obstaja zaporedje ukazov $\text{dodaj}(x)$ in $\text{odstrani}(x)$, ki vodi do rdeče-črnega drevesa z n vozlišči, ki imajo višino $2 \log n - O(1)$.

Naloga 9.7. Zakaj metoda $\text{odstrani}(x)$ v `RedBlackTree` izvede operacijo $u.\text{parent} = w.\text{parent}$? Naj nebi bilo to storjeno že z klicem metode $\text{splice}(w)$?

Naloga 9.8. Predvidevaj, da ima 2-4 drevo T , n_ℓ listov in n_i notranjih vozlišč.

1. Kakšna je najmanjša vrednost n_i , kot funkcija n_ℓ ?
2. Kakšna je največja vrednost n_i , kot funkcija n_ℓ ?
3. Če je T' rdeče-črno drevo, ki predstavlja T , koliko ima potem T' rdečih vozlišč?

Naloga 9.9. Predpostavimo, da imamo binarno iskalno drevo z n vozlišči in višini največ $2 \log n - 2$. je možno, da vedno pobarvamo vozlišča tako, da drevo zadošča pogoju črne višine in pogoju da rob ni rdeč? Če da, ali potem zadošča tudi lastnostim levo-visečih dreves?

Naloga 9.10. Predpostavimo, da imamo dva rdeče-črna drevesa T_1 in T_2 , ki imata enako višino črnih vozlišč h in, da je največji ključ v T_1 manjši od najmanjšega ključa v T_2 . Prikaži kako se združita drevesi T_1 in T_2 v eno rdeče-črno drevo v času $O(h)$.

Naloga 9.11. Nadgradi rešitev iz 9.10, da bo veljala tudi za drevesi T_1 in T_2 , ki imata različni višini črnih vozlišč, $h_1 \neq h_2$. Čas izvajanja naj bo $O(\max\{h_1, h_2\})$.

Naloga 9.12. Dokaži, da mora AVL drevo pri izvajanju $\text{add}(x)$ metode, izvesti največ eno operacijo uravnoteženja (vključuje največ dve rotaciji; glej 9.10). Podaj primer AVL drevesa in klica metode $\text{remove}(x)$ na tem drevesu, ki zahteva $\log n$ operacij uravnoteženja.

Naloga 9.13. Napiši razred `AVLTree`, ki uporablja AVL drevo kot je opisano zgoraj. Primerjaj hitrost izvajanja s hitrostjo `RedBlackTree`. Katera izvedba ima hitrejšo operacijo $\text{find}(x)$?

Naloga 9.14. Oblikuj in izvedi vrsto poskusov, da primerjamo relativno uspešnost metod `find(x)`, `add(x)`, in `remove(x)` for the SSet implementations `SkiplistSSet`, `ScapegoatTree`, `Treap`, and `RedBlackTree`. Bodite prepričani, da vključite več testnih primerov, vključno s primeri, ko so podatki naključno razporejeni, že razporejeni, jih odstranite, ko so urejeni in tako naprej.

Poglavje 10

Kopice

V tem poglavju si bomo pogledali 2 implementacije zelo uporabne podatkovne strukture `Pol` je s prednostjo. Obe od teh dveh struktur sta posebne oblike Dvojiškega drevesa imenovani *Kopica*, kar pomeni "neorganizirana kopica". To je v nasprotju z dvojiškimi iskalnimi drevesi pri katerih pomislimo na zelo urejeno kopico.


Prva izvedba kopic uporablja polje, da simuliramo popolno dvojiško drevo. Ta zelo hitra implementacija je osnova za enega izmed najhitrejših znanih sortirnih algoritmov, in sicer kopično urejanje (glej 11.1.3). Druga implementacija je bazirana na bolj fleksibilnih dvojiških drevesih, ki podpirajo `meld(h)` operacijo, ki omogoča vrsti s prednostjo, da absorbira elemente druge vrste s prednostjo `h`.

10.1 BinaryHeap: implicitno dvojiško drevo

Naša prva implementacija `Queue` (s prednostjo) temelji na tehniki, ki je stara preko 400 let. *Eytzingerjeva metoda* nam omogoča, da predstavimo popolno dvojiško drevo kot polje, v katerem imamo vozlišča postavljena v vrsto iz leve proti desni (glej 6.1.2). Na ta način je koren drevesa shranjen na poziciji 0, njegov levi otrok je shranjen na poziciji 0, njegov desni otrok na poziciji 1, levi otrok na 2, levi otrok otroka na poziciji 3 in tako naprej. Glej 10.1.

Če uporabimo Eytzingerjevo metodo na dovolj velikih drevesih se začnejo pojavljati vzorci. Levi otrok vozlišča pri indexu `i` je na indexu

Kopice



Slika 10.1: Eytzingerjeva metoda predstavlja popolno dvojiško drevo kot polje.

$\text{left}(i) = 2i+1$ in desni otrok vozlišča pri indexu i je na indexu $\text{right}(i) = 2i + 2$. Starš vozlišča pri indexu i pa je na $\text{parent}(i) = (i - 1)/2$.

BinaryHeap

```

int left(int i) {
    return 2*i + 1;
}
int right(int i) {
    return 2*i + 2;
}
int parent(int i) {
    return (i-1)/2;
}
  
```

BinaryHeap uporablja to tehniko, da implicitno predstavi popolno dvojiško drevo v katerem so elementi *kopično urejeni*: Vrednost shranjena na katerem koli indexu i ni manjša kot vrednost shranjena na katerem koli indexu $\text{parent}(i)$, razen izjeme vrednosti korena $i = 0$. To nam omogoča, da je najmanjša vrednost Queue s prednostjo tako shranjena na poziciji 0 (koren).

V BinaryHeap, je n elementov shranjenih v tabeli a :

BinaryHeap

```

T[] a;
int n;
  
```

Implementacija operacije `add(x)` je preprosta. Kot vse strukture bazirane na polju najprej pogledamo, če je `a` poln (preverimo `a.length = n`) in če je, povečamo `a`. Nato `x` zapišemo na mesto `a[n]` in povečamo `n`. Na tej točki je potrebno storiti samo še to, da zagotovimo lastnost kopice. To storimo tako, da zamenjujemo `x` z njegovim staršem, dokler ni `x` manjši od svojega starša. Glej 10.2.

BinaryHeap

```
boolean add(T x) {
    if (n + 1 > a.length) resize();
    a[n++] = x;
    bubbleUp(n-1);
    return true;
}
void bubbleUp(int i) {
    int p = parent(i);
    while (i > 0 && compare(a[i], a[p]) < 0) {
        swap(i, p);
        i = p;
        p = parent(i);
    }
}
```





Implementacija `remove()` operacije, katera odstrani najmanjšo vrednost v kopici, je nekoliko težja. Vemo, kje je najmanjši element (v korenu), vendar ga moramo po odstranitvi nadomestiti in zagotoviti, da ohranjamo lastnosti kopice.

Najlažji način, da to naredimo je, da koren nadomestimo z vrednostjo `a[n - 1]`, zberemo vrednost in zmanjšamo `n`. Na žalost novi koren najverjetneje ni najmanjši element, zato ga moramo prestaviti po kopici navzdol. To naredimo tako, da rekurzivno primerjamo element z njegovimi otroki. V primeru, da je element v kopici najmanjši smo končali, v nasprotnem primeru ga zamenjamo z najmanjšim izmed otrok in nadaljujemo ta postopek rekurzivno.

BinaryHeap

```
T remove() {
    T x = a[0];
    a[0] = a[--n];
```

Kopice



Slika 10.2: Dodajanje elementa 6 v BinaryHeap.


```

    trickleDown(0);
    if (3*n < a.length) resize();
    return x;
}
void trickleDown(int i) {
    do {
        int j = -1;
        int r = right(i);
        if (r < n && compare(a[r], a[i]) < 0) {
            int l = left(i);
            if (compare(a[l], a[r]) < 0) {
                j = l;
            } else {
                j = r;
            }
        } else {
            int l = left(i);
            if (l < n && compare(a[l], a[i]) < 0) {
                j = l;
            }
        }
        if (j >= 0) swap(i, j);
        i = j;
    } while (i >= 0);
}

```

Kot ostale implementirane strukture polja, bomo mi ignorirali porabljen čas v celicah za funkcijo `resize()`, ker se to lahko obračunava na amortizacijskem argumentu iz Lemma 2.1. Pretečeni čas za `add(x)` in `remove()` je odvisen od višine (implicitnega) dvojiškega drevesa. Na srečo je to *polno* Dvojiško drevo; vsak nivo, razen zadnjega ima največje možno število vozlišč. Tako, je višina drevesa enaka h in ima najmanj 2^h vozlišč. Začnimo na ta način


$$n \geq 2^h .$$

Če logaritmiramo, dobimo na obeh straneh enačbe

$$h \leq \log n .$$

Tako obe, `add(x)` in `remove()` operaciji tečeta v $O(\log n)$ času.

Kopice



Slika 10.3: Odstranjevanje najmanjšega elementa, 4, iz BinaryHeap.

10.1.1 Povzetek

Naslednji teorem povzame uspešnost BinaryHeap.

Izrek 10.1. *BinaryHeap implementira Queue (s prednostjo). Če ignoriramo ceno `resize()` za povečanje polja, BinaryHeap izvede operaciji `add(x)` in `remove()` v času $O(\log n)$ na operacijo.*

Poleg tega, začenši s prazno BinaryHeap, katero koli zaporedje m operacij `add(x)` in `remove()` potrebuje skupno $O(m)$ časa za vse klice funkcije `resize()`.

10.2 MeldableHeap: Naključna zlivalna kopica

V poglavju bomo opisali MeldableHeap, implementacijo prioritete vrste Queue, shranjeno v kopičasto urejenem dvojiškem drevesu. Za razliko od BinaryHeap, pri katerem dvojiško drevo definira število elementov, dvojiško drevo MeldableHeap nima omejitev glede oblike.

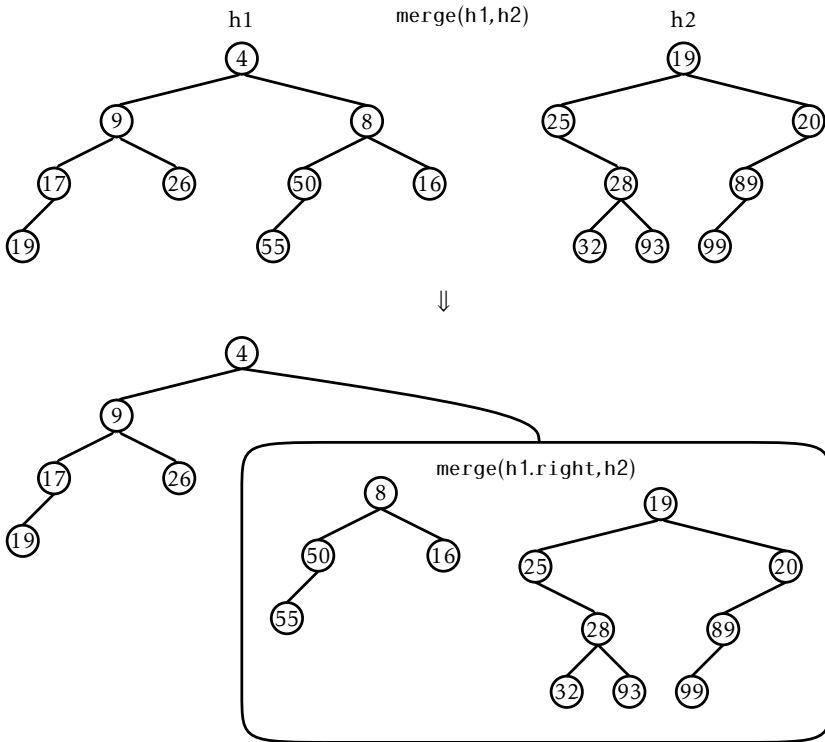
Operaciji `add(x)` in `remove()` v MeldableHeap sta implementirani z uporabo operacije `merge(h1, h2)`. Operacija `merge(h1, h2)` zlije skupaj kopicih `h1` in `h2` tako, da združi vozlišči kopice `h1` in `h2` in vrne korensko vozlišče nove kopice, ki vsebuje vse elemente poddreves vozlišč `h1` in `h2`.

Operacijo `merge(h1, h2)` lahko implementiramo rekurzivno. Glej 10.4. Če je vozlišče `h1` oz. `h2 nil`, zlivamo s prazno množico in vrnemo vozlišče `h1` ali `h2`, ki ni `nil`. V nasprotnem primeru zamenjamo vlogi `h1` in `h2` glede na velikost vrednosti vozlišča tako, da večje od obeh vozlišč postane koren nove kopice. V primeru, da je v korenu vrednost `h1.x`, potem lahko `h2` lahko rekurzivno zlijemo z `h1.left` ali `h1.right`, odvisno od naključne vrednosti meta kovanca.

```

                                MeldableHeap
Node<T> merge(Node<T> h1, Node<T> h2) {
    if (h1 == nil) return h2;
    if (h2 == nil) return h1;
    if (compare(h2.x, h1.x) < 0) return merge(h2, h1);
    // now we know h1.x <= h2.x
    if (rand.nextBoolean()) {
        h1.left = merge(h1.left, h2);
        h1.left.parent = h1;
    }
}
```

Kopice



Slika 10.4: Zlivanje $h1$ in $h2$ opravimo z združitvijo $h2$ in $h1.\text{left}$ oz. $h1.\text{right}$.

```

} else {
    h1.right = merge(h1.right, h2);
    h1.right.parent = h1;
}
return h1;
}

```

V naslednjem delu poglavja pokažemo, da ima operacija $\text{merge}(h1, h2)$ pričakovano časovno zahtevnost $O(\log n)$, kjer je n končno število elementov v $h1$ in $h2$.

S pomočjo operacije $\text{merge}(h1, h2)$ je vstavljanje $\text{add}(x)$ enostavno. Ustvarimo novo vozlišče u z vrednostjo x in zlijemo vozlišče s korenom kopice:

```

boolean add(T x) {
    Node<T> u = newNode();
    u.x = x;
    r = merge(u, r);
    r.parent = nil;
    n++;
    return true;
}

```

Operacija ima pričakovano časovno zahtevnost $O(\log(n+1)) = O(\log n)$.

Podobno je z operacijo `remove()`. Odstranjujemo korensko vozlišče, ki ga zamenja rezultat zlivanja njegovih otrok:

```

T remove() {
    T x = r.x;
    r = merge(r.left, r.right);
    if (r != nil) r.parent = nil;
    n--;
    return x;
}

```

Tudi `remove()` ima pričakovano časovno zahtevnost $O(\log n)$.

MeldableHeap lahko implementira tudi mnogo ostalih operacij s časovno zahtevnostjo $O(\log n)$, npr.:

- `remove(u)`: iz kopice odstranimo vozlišče `u` (in pripadajoč ključ `u.x`).
- `absorb(h)`: vse elemente MeldableHeap `h` dodamo kopici, kjer v postopku praznimo `h`.

Vsaka operacija lahko vsebuje konstantno število `merge(h1, h2)` operacij s časovno zahtevnostjo $O(\log n)$.

10.2.1 Analiza `merge(h1, h2)`

Analiza operacije `merge(h1, h2)` je osnovana na analizi naključnega sprehoda v dvojiškem drevesu. V dvojiškem drevesu se *naključni sprehod* začne v korenu drevesa. V vsakem koraku naključnega sprehoda vržemo

kovanec, ki določa smer sprehoda (levi ali desni otrok trenutnega vozlišča). Ko trenutno vozlišče postane **n** se sprehod konča.

Sledeča lema je zanimiva, ker ni odvisna od oblike dvojiškega drevesa:

Lema 10.1. *Pričakovana dolžina naključnega sprehoda v dvojiškem drevesu z n vozlišči je največ $\log(n + 1)$.*

Dokaz. Trditev lahko dokažemo z indukcijo. Za osnovo izberimo $n = 0$ in dolžino sprehoda $0 = \log(n + 1)$. Trditev drži za vsa pozitivna števila $n' < n$.

Dolžino korenskega levega poddrevesa označimo z n_1 , da bo $n_2 = n - n_1 - 1$ velikost korenskega desnega poddrevesa. Sprehod se začne v korenu, zavzame en korak in nato nadaljuje v poddrevesu velikosti n_1 ali n_2 . Po naši induktivni predpostavki je pričakovana dolžina sprehoda naključnega sprehoda

$$E[W] = 1 + \frac{1}{2} \log(n_1 + 1) + \frac{1}{2} \log(n_2 + 1) ,$$

saj je vsako od n_1 ali n_2 manjše od n . Ker je log funkcija konkavne oblike $E[W]$ doseže maksimum, ko je $n_1 = n_2 = (n-1)/2$. Potemtakem je pričakovano število korakov

$$\begin{aligned} E[W] &= 1 + \frac{1}{2} \log(n_1 + 1) + \frac{1}{2} \log(n_2 + 1) \\ &\leq 1 + \log((n-1)/2 + 1) \\ &= 1 + \log((n+1)/2) \\ &= \log(n+1) . \end{aligned} \quad \square$$

Za bralce s pomanjkljivim poznavanjem informacijske teorije lahko dokaz za 10.1 izrazimo s pomočjo entropije.

Informacijski teoretični dokaz za 10.1. Naj d_i označuje globino i -tega zunanjšega vozlišča. Spomnimo se, da ima dvojiško drevo z n vozlišči $n+1$ zunanjih vozlišč. Verjetnost, da bo naključni sprehod dosegel i -to zunanje vozlišče je natančno $p_i = 1/2^{d_i}$. Tako je pričakovana dolžina naključnega sprehoda

$$H = \sum_{i=0}^n p_i d_i = \sum_{i=0}^n p_i \log(2^{d_i}) = \sum_{i=0}^n p_i \log(1/p_i)$$

Desna stran enačbe je prepoznavna kot entropija verjetnostne distribucije na $n + 1$ elementih, katera nikoli ne preseže $\log(n + 1)$, kar dokazuje lemo. \square

S tem tudi enostavno dokažemo, da je čas izvajanja operacije `merge(h1, h2)` $O(\log n)$.

Lema 10.2. Če sta `h1` in `h2` korena dveh kopic z vozliščema n_1 in n_2 je pričakovan čas izvajanja operacije `merge(h1, h2)` največ $O(\log n)$, kjer je $n = n_1 + n_2$.

Dokaz. Vsak korak algoritma za zlivanje zavzame en korak v naključnem prehodu, bodisi v kopici s korenem `h1` bodisi v kopici s korenem `h2`. Algoritem se zaključi ko katerikoli izmed dveh naključnih sprehodov doseže konec drevesa. Pričakovano število korakov zlivalnega algoritma je največ

$$\log(n_1 + 1) + \log(n_2 + 1) \leq 2 \log n . \quad \square$$

10.2.2 Povzetek

Sledeči teorem povzame zmogljivost `MeldableHeap`:

Izrek 10.2. `MeldableHeap` implementira (prioritetni) `Queue` vmesnik. `MeldableHeap` podpira operaciji `add(x)` in `remove()`. $O(\log n)$ je pričakovan čas izvajanja posamezne operacije.

10.3 Diskusije in vaje

Izgleda, da je implicitno predstavitev polnega dvojiškega drevesa s tabelo ali seznamom prvič predlagal Eytzinger [?]. Implicitno predstavitev je v svojih knjigah uporabil na primeru družinskih drevesih plemiških družin. Podatkovno strukturo `BinaryHeap` opisano v tej knjigi je prvič predstavil Williams [?].

Naključno podatkovno strukturo `MeldableHeap` sta prvič predlagala Gambin in Malinowski [?]. Obstajajo tudi druge implementacije zlivalnih kopic vključno z levo poravnane kopice [?, ?, Section 5.3.2], binomske kopice [?], Fibonaccijeve kopice [?], parne kopice [?], in samoprilagoditvene kopice [?], Čeprav niso tako enostavne kot je struktura `MeldableHeap`.

Nekaj zgoraj navedenih struktur podpira tudi operacijo $\text{decreaseKey}(u, v)$ v kateri se vrednost vozlišča u zniža na vrednost vozlišča v (ob predpogoju $v \leq u.x$). V večini strukturah lahko operacijo $\text{decreaseKey}(u, v)$ izvajamo s časovno zahtevnostjo $O(\log n)$ z odstranjanjem vozlišča u in dodajanjem vozlišča t . Nekatere strukture lahko implementirajo operacijo bolj učinkovito. V Fibonaccijevih kopicah ima amortizirano časovno zahtevnost $O(1)$ in amortizirano $O(\log \log n)$ v posebni različici parnih kopic [?]. Omenjena učinkovitejša različica operacije $\text{decreaseKey}(u, v)$ se uporablja pri pohitritvi grafov, vključno z algoritmom Dijkstre za iskanje najkrajše poti [?].

Naloga 10.1. Narišite dodajanje elementov vrednosti 7 in vrednosti 3 na BinaryHeap prikazano na koncu slike 10.2.

Naloga 10.2. Narišite odstranjevanje naslednjih dveh elementov (6 in 8) na BinaryHeap prikazano na koncu slike 10.3.

Naloga 10.3. Implementirajte metodo $\text{remove}(i)$, ki odstrani shranjene vrednosti v $a[i]$ v BinaryHeap. Metoda mora teči v časovni zahtevnosti $O(\log n)$. Razložite, zakaj se ta metoda verjetno ne bo uporabljala.

Naloga 10.4. A d -ary drevo je posplošitev dvojiškega drevesa, v katerem ima vsako notranje vozlišče d otrok. Uporabite Eytzingerjevo metodo, ki je lahko predstavljena kot popolno d -tiško drevo z uporabo tabele. Ugotovite enačbe, v katerih je podan indeks i , določite indeks staršev od i in vsakega d otroka od indeksa i' .

Naloga 10.5. Uporabite kar ste spoznali v 10.4, oblikujte in implementirajte *DaryHeap*, d -aryeva posplošitev BinaryHeap. Analizirajte čas poteka za operacije na DaryHeap in testirajte vaše delovanje DaryHeap katera se izvaja na BinaryHeap katere implementacija je podana.

Naloga 10.6. Narišite dodajanje elementov vrednosti 17 in 82 v MeldableHeap `h1` prikazan na sliki 10.4. Uporabite kovanec za simulacijo naključnega bita, če je potrebno.

Naloga 10.7. Narišite odstranjevanje naslednjih dveh elementov (4 in 8) iz MeldableHeap `h1` prikazano v 10.4. Uporabite kovanec za simulacijo naključnega bita, če je potrebno.

Naloga 10.8. Implementirajte metodo `remove(u)`, ki odstrani vozlišče `u` iz `MeldableHeap`. Metoda mora teči v časovni zahtevnosti $O(\log n)$.

Naloga 10.9. Pokažite, kako poiskati drugo najmanjšo vrednost v `BinaryHeap` ali v `MeldableHeap` v konstantnem času.

Naloga 10.10. Poiščite k -to najmanjšo vrednost v `BinaryHeap` ali v `MeldableHeap` v časovni zahtevnosti $O(k \log k)$. (Namig: Mogoče pomaga uporaba drugačne kopice.)

Naloga 10.11. Predpostavimo da imamo podanih k razporejenih seznamov, dolžine n . Z uporabo kopice, pokažite kako združiti urejene seznime v času $O(n \log k)$. (Namig: Pomaga, če začnete s primerom $k = 2$.)

Poglavje 11

Algoritmi za urejanje

V tem poglavju se bomo pogovarjali o algoritmih, ki uredijo zbirko n elementov. To se lahko sliši kot čudna tema v knjigi podatkovnih struktur, ampak za to obstaja nekaj dobrih razlogov. Najočitnejši je ta, da sta dva od urejevalnih algoritmov (hitro urejanje in urejanje s kopico) tesno povezana s podatkovnima strukturama, ki smo ju že obdelali (naključno dvojiško drevo in kopice).

V prvem delu tega poglavja bo govora o algoritmih, ki uporabljajo zgolj primerjanje in sicer tri take algoritme s časovno zahtevnostjo $O(n \log n)$. Kot se izkaže, so vsi trije algoritmi asimptotično optimalni. Se pravi vsak algoritem, ki uporablja zgolj primerjanje izvede približno $n \log n$ primerjav v najslabšem kot tudi v povprečnem primeru.

Preden nadaljujemo velja izpostaviti, da lahko uporabimo katerikoli implementacijo urejene množice ali prioritete vrste, ki smo jih predstavili v prejšnjih poglavjih, da dobimo algoritem za urejanje s časovno zahtevnostjo $O(n \log n)$. Naprimer, lahko uredimo n elemente tako, da izvedemo najprej n `add(x)` operacij, nato pa n `remove()` operacij na dvojiški ali zdržljivi kopici. Alternativno lahko uporabimo tudi n `add(x)` operacij na katerikoli dvojiškim iskalnim drevesom, kjer nato izvedemo vmesno prečkanje (6.8), da dobimo elemente v urejenem vrstnem redu. Vendar si v obeh primerih naredimo veliko preglavic, da zgradimo strukturo, ki je nikoli ne uporabljamo v celoti. Urejanje je tako pomembna težava, da je vredno razviti direktne metode, ki so kot se le da hitre, preproste in prostorsko učinkovite.

Drugi del tega poglavja kaže, da ne obstaja časovnih zagotovil, če upo-

rabimo katerekoli druge operacije razen primerjave. Je pa res, da lahko s tabelnim indeksiranjem uredimo množico n števil v območju $\{0, \dots, n^c - 1\}$ s časovno zahtevnostjo $O(cn)$.

11.1 Urejanje s primerjanjem

V tem delu bomo predstavili tri algoritme za urejanje: urejanje z zlivanjem, hitro urejanje in urejanje s kopico. Vsak izmed teh treh algoritmov sprejme kot prvi argument tabelo a , ki jo uredi v naraščajočem vrstnem redu v (pričakovanem) času $O(n \log n)$. Vsi ti algoritmi delujejo *na osnovi primerjav*. Njihov drugi argument c je *Comparator* ki implementira metodo $\text{compare}(a, b)$. Ti algoritmi za urejanje nimajo privzetega tipa podatkov, ker izvajajo zgolj operacijo $\text{compare}(a, b)$. Spomnimo se poglavja 1.2.4, kjer smo se naučili, da $\text{compare}(a, b)$ vrača negativno vrednost če je $a < b$, pozitivno, če je vrednost $a > b$ in nič, če je $a = b$.

11.1.1 Urejanje z zlivanjem (merge-sort)

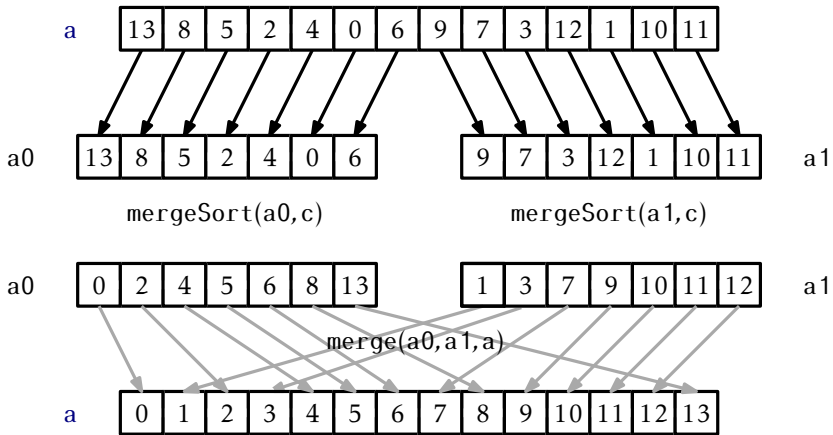
Algoritem *urejanja z zlivanjem* je klasičen primer rekurzivnega algoritma deli in vladaj. Če je dolžina od a največ 1, potem je a že urejen in zato ne naredimo ničesar. V nasprotnem primeru pa a razdelimo na dva dela, $a_0 = a[0], \dots, a[n/2 - 1]$ in $a_1 = a[n/2], \dots, a[n - 1]$. Nato rekurzivno uredimo a_0 in a_1 ter ju nato združimo s čimer dobimo popolno urejeno tabelo a .

Algorithms

```
<T> void mergeSort(T[] a, Comparator<T> c) {
    if (a.length <= 1) return;
    T[] a0 = Arrays.copyOfRange(a, 0, a.length/2);
    T[] a1 = Arrays.copyOfRange(a, a.length/2, a.length);
    mergeSort(a0, c);
    mergeSort(a1, c);
    merge(a0, a1, a, c);
}
```

Primer 11.1.

V primerjavi z urejanjem je zlivanje urejenih tabel a_0 in a_1 dokaj enostavno. Elemente dodajamo enega za drugim. Če je a_0 ali a_1 prazna,



Slika 11.1: Izvedba mergeSort(**a**,**c**)

potem dodajamo naslednje elementi iz druge (ne prazne) tabele. Sicer vzamemo manjšega od naslednjih elementov iz obeh tabel in ga dodamo v **a**:

```


Algorithms
<T> void merge(T[] a0, T[] a1, T[] a, Comparator<T> c) {
    int i0 = 0, i1 = 0;
    for (int i = 0; i < a.length; i++) {
        if (i0 == a0.length)
            a[i] = a1[i1++];
        else if (i1 == a1.length)
            a[i] = a0[i0++];
        else if (compare(a0[i0], a1[i1]) < 0)
            a[i] = a0[i0++];
        else
            a[i] = a1[i1++];
    }
}

```

Opazimo, da algoritem merge(**a0**,**a1**,**a**,**c**) v najslabšem primeru izvede $n - 1$ primerjav, preden izprazni **a0** ali **a1**.

Da bi lažje razumeli čas izvajanja urejanja z zlivanjem, si ga je najboljše predstavljati kot njegovo rekurzivno drevo. Zaenkrat predpostavimo, da

Algoritmi za urejanje



Slika 11.2: The merge-sort recursion tree.

je n potenca števila dve, tako da je $n = 2^{\log n}$, $\log n$ pa je celo število. Glej sliko 11.2. Urejanje z zlivanjem spremeni problem urejanja n elementov v dva problema urejanja $n/2$ elementov. Ta dva podproblema potem spremeni vsakega v dva nova podproblema, torej skupno v štiri probleme velikosti $n/4$. Te štiri nato razdelimo v osem podproblemov velikosti $n/8$ in tako dalje. Na koncu tega procesa $n/2$ podproblemov, vsakega velikosti dve, razdelimo v n problemov velikosti ena. Za vsak podproblem velikosti $n/2^i$ je čas zlivanja in kopiranja podatkov razreda $O(n/2^i)$. Ker imamo 2^i podproblemov velikosti $n/2^i$, je skupen čas reševanja problemov velikosti 2^i , če ne štejemo rekurzivnih klicev:

$$2^i \times O(n/2^i) = O(n) \text{ .}$$

Iz tega sledi, da je skupen čas, ki ga porabi urejanje z zlivanjem:

$$\sum_{i=0}^{\log n} O(n) = O(n \log n) \text{ .}$$

Dokaz za naslednji izrek je osnovan na prejšnji analizi, vendar pa moramo biti pazljivi zaradi primera, kadar n ni potenca števila 2.

Izrek 11.1. *Metoda mergeSort(a,c) teče v času $O(n \log n)$ in izvede največ $n \log n$ primerjav.*

Dokaz. Dokažemo z indukcijo po n . Osnovni primer, kadar je $n = 1$, je trivialen; če algoritem v obdelavo dobi tabelo dolžine 0 ali 1, to tabelo enostavno vrne, brez da bi izvedel kakršne koli primerjave.

Zlivanje dveh urejenih seznamov skupne dolžine n zahteva največ $n - 1$ primerjav. Naj $C(n)$ označuje največje možno število primerjav, ki jih izvede `mergeSort(a, c)` na tabeli a dolžine n . Če je n sodo število, potem za podproblema uporabimo induksijsko hipotezo in s tem dobimo:

$$\begin{aligned}
 C(n) &\leq n - 1 + 2C(n/2) \\
 &\leq n - 1 + 2((n/2)\log(n/2)) \\
 &= n - 1 + n\log(n/2) \\
 &= n - 1 + n\log n - n \\
 &< n\log n .
 \end{aligned}$$

Če je n liho število pa je dokaz nekoliko bolj zapleten. V tem primeru uporabimo dve neenačbi, ki jih lahko enostavno dokažemo:

$$\log(x + 1) \leq \log(x) + 1 , \quad (11.1)$$

za vse $x \geq 1$ in:

$$\log(x + 1/2) + \log(x - 1/2) \leq 2\log(x) , \quad (11.2)$$

za vse $x \geq 1/2$. Neenačbo (11.1) izpeljemo iz dejstva, da je $\log(x) + 1 = \log(2x)$, (11.2) pa izpeljemo iz dejstva, da je \log konkavna funkcija. Ko vemo vse to, za lihi n velja:

$$\begin{aligned}
 C(n) &\leq n - 1 + C(\lceil n/2 \rceil) + C(\lfloor n/2 \rfloor) \\
 &\leq n - 1 + \lceil n/2 \rceil \log \lceil n/2 \rceil + \lfloor n/2 \rfloor \log \lfloor n/2 \rfloor \\
 &= n - 1 + (n/2 + 1/2) \log(n/2 + 1/2) + (n/2 - 1/2) \log(n/2 - 1/2) \\
 &\leq n - 1 + n \log(n/2) + (1/2)(\log(n/2 + 1/2) - \log(n/2 - 1/2)) \\
 &\leq n - 1 + n \log(n/2) + 1/2 \\
 &< n + n \log(n/2) \\
 &= n + n(\log n - 1) \\
 &= n \log n .
 \end{aligned}$$

□

11.1.2 Hitro urejanje (quicksort)

Hitro urejanje ali *quicksort* algoritem je še en klasični algoritem deli in vladaj . V nasprotju z algoritmom zlivanja (mergesort), ki združuje rešitvi dveh podproblemov, algoritem hitrega urejanja počne vse svoje delo vnaprej.


Algoritem lahko preprosto opišemo tako: Izberemo naključni delilni element, ki ga imenujemo *pivot*, x , ki ga dobimo iz a ; Razdelek a je sestavljena iz sklopa elementov manjših od x , sklopa elementov enakih kot x in niz elementov večjih od x ; na koncu rekurzivno razvrstimo prvi in tretji sklop števil v tem razdelku. Primer je prikazan na sliki 11.3.

```

Algorithms
<T> void quickSort(T[] a, Comparator<T> c) {
    quickSort(a, 0, a.length, c);
}
<T> void quickSort(T[] a, int i, int n, Comparator<T> c) {
    if (n <= 1) return;
    T x = a[i + rand.nextInt(n)];
    int p = i-1, j = i, q = i+n;
    // a[i..p]<x, a[p+1..q-1]==x, a[q..i+n-1]>x
    while (j < q) {
        int comp = compare(a[j], x);
        if (comp < 0) {           // move to beginning of array
            swap(a, j++, ++p);
        } else if (comp > 0) {
            swap(a, j, --q);     // move to end of array
        } else {
            j++;                 // keep in the middle
        }
    }
    // a[i..p]<x, a[p+1..q-1]=x, a[q..i+n-1]>x
    quickSort(a, i, p-i+1, c);
    quickSort(a, q, n-(q-i), c);
}

```

Vse to je narejeno na mestu, tako da namesto ustvarjanja kopij urejenih podseznamov, `quickSort(a,i,n,c)` metoda razvršča samo podseznam



Slika 11.3: Primer izvajanja `quickSort(a, 0, 14, c)`

$a[i], \dots, a[i + n - 1]$. Prvotno kličemo to metodo kot `quickSort(a, 0, a.length, c)`.

V središču algoritma quicksort je algoritem delitve na mestu. Ta algoritem, brez uporabe dodatnega prostora, zamenja elemente v a in izračuna indekse p in q tako da:

$$a[i] \begin{cases} < x & \text{če } 0 \leq i \leq p \\ = x & \text{če } p < i < q \\ > x & \text{če } q \leq i \leq n - 1 \end{cases}$$

Ta delitev, ki se opravi z `while` zanko v sami kodi, deluje s ponavljajočim povečanjem p -ja in zmanjševanjem q -ja ob ohranjanju prvega in zadnjega od teh pogojev (p in q). Ob vsakem koraku element na položaju j premaknemo na prvo mesto, ali pa na zadnje mesto. V prvih dveh primerih, je j povečan, v zadnjem primeru pa ne, ker nov element na položaju j še ni bil obdelan.

Quicksort algoritem je zelo tesno povezan z naključnim dvojiškim iskalnim drevesom, opisanem v poglavju 7.1. Pravzaprav, če poženemo quicksort algoritem nad n različnimi elementi, potem je quicksort-ovo rekurzivno drevo enako naključnemu iskalnemu drevesu. Da bi to videli, se moramo spomniti, kako gradimo naključno dvojiška iskalna drevesa. Najprej naključno izberemo element x in ga postavimo za koren drevesa.

Nato vsak naslednji element primerjamo z x -om. Manjše elemente postavljamo v levo poddrevo, večje pa v desno poddrevo.

S tem algoritmom izberemo naključni element x in takoj za tem primerjamo vse elemente s tem x -om. Najmanjše elemente postavimo na začetek polja, večje pa postavimo na konec. Quicksort algoritem nato rekurzivno uredi začetek in konec polja, medtem ko naključno dvojiško iskalno drevo rekurzivno vstavi manjše elemente v levo poddrevo korena in večje elemente v desno poddrevo korena.

Zgornje ujemanje med naključnim dvojiškim iskalnim drevesom in algoritmom hitrega urejanja lahko uporabimo za lemo 7.1

Lema 11.1. *Ko kličemo algoritem quicksort za urejanje polja, ki vsebuje cela števila $0, \dots, n-1$, je pričakovano število primerjav elementa s pivot-om $H_{i+1} + H_{n-i}$.*


Malo seštevanja harmoničnih števil nam da naslednji izrek o času delovanja, katerega porabi algoritem:

Izrek 11.2. *Ko quicksort algoritem uporabimo za urejanje polja z n različnimi elementi, pričakujemo največje število opravljenih primerjav $2n \ln n + O(n)$.*

Dokaz. Naj bo T število primerjav opravljenih z algoritmom quicksort, ko razvršča n različnih elementov. Z uporabo Leme 11.1, imamo:

$$\begin{aligned} E[T] &= \sum_{i=0}^{n-1} (H_{i+1} + H_{n-i}) \\ &= 2 \sum_{i=1}^n H_i \\ &\leq 2 \sum_{i=1}^n H_n \\ &\leq 2n \ln n + 2n = 2n \ln n + O(n) \quad \square \end{aligned}$$

Izrek 11.3 opisuje primer, kjer so razvrščeni elementi vsi različni. Ko vhodni seznam a , vsebuje podvojene elemente, pričakovani čas delovanja za hitro urejanje ni nič slabši, in je lahko celo boljši. Vedno ko je podvojeni



Slika 11.4: Primer izvedbe `heapSort(a, c)`.

element x izbran kot pivot a , vse pojavitve x -a združimo in jih kasneje ne vključimo v enega od dveh podproblemov.

Izrek 11.3. Časovna zahtevnost metode `Quicksort(a, c)` je $O(n \log n)$, pričakovano število primerjav, ki jih opravi, je večinoma $2n \ln n + O(n)$.

11.1.3 Urejanje s kopico (heap-sort)

Algoritem *Heap-sort* je še eden izmed algoritmov urejanja na mestu. Heap-sort uporablja dvojiško kopico, ki smo jo obravnavali v poglavju 10.1. Spomnimo se, da podatkovna struktura `BinaryHeap`¹ predstavlja kopico, ki je realizirana z enim seznamom. Urejanje s kopico pretvori vhodni seznam a v kopico in nato ponavljajoče izloča minimalno vrednost.

Bolj natančno povedano, kopica hrani n elementov v seznamu a na lokacijah $a[0], \dots, a[n-1]$ z najmanjšo vrednostjo v korenu oz. $a[0]$. Po transformaciji v `BinaryHeap` urejanje s kopico ponavljajoče izmenjuje $a[0]$ in $a[n-1]$, ter kliče `trickleDown(0)`, tako da so $a[0], \dots, a[n-2]$ ponovno v kopičasti ureditvi. Ko se ta proces konča (ker je $n = 0$), so elementi a shranjeni v padajočem zaporedju. Sedaj a obrnemo, da dobimo rezultat.

¹ Na sliki 11.4 je primer izvajanja `heapSort(a, c)`.

¹ Algoritem bi lahko prav tako redefiniral `compare(x, y)`, tako da algoritem že na začetku vstavi elemente v naraščajočem vrstnem redu.

```

BinaryHeap
<T> void sort(T[] a, Comparator<T> c) {
    BinaryHeap<T> h = new BinaryHeap<T>(a, c);
    while (h.n > 1) {
        h.swap(--h.n, 0);
        h.trickleDown(0);
    }
    Collections.reverse(Arrays.asList(a));
}

```

Ključna podrutina v heap-sort je konstruktor za pretvorbo urejenega seznama a v kopico. To bi z lahkoto storili v času $O(n \log n)$ s ponavljajočim klicem metode `add(x)` dvojiške kopice, a znamo to operacijo izvesti hitreje z uporabo bottom-up algoritma. Spomnimo se, da so v dvojiški kopici otroci $a[i]$ shranjeni na položajih $a[2i + 1]$ in $a[2i + 2]$. To namiguje, da elementi $a[\lfloor n/2 \rfloor], \dots, a[n - 1]$ nimajo otrok. Z drugimi besedami je vsak element $a[\lfloor n/2 \rfloor], \dots, a[n - 1]$ podkopica velikosti 1. Sedaj ko delamo od zadaj naprej, lahko kličemo metodo `trickleDown(i)` za vsak $i \in \{\lfloor n/2 \rfloor - 1, \dots, 0\}$. To deluje, ker je do trenutka ko kličemo `trickleDown(i)` vsak od otrok $a[i]$ koren podkopice. S tem ko kličemo `trickleDown(i)`, nastavimo $a[i]$ kot koren svoje podkopice.

```

BinaryHeap
BinaryHeap(T[] a, Comparator<T> c) {
    this.c = c;
    this.a = a;
    n = a.length;
    for (int i = n/2-1; i >= 0; i--) {
        trickleDown(i);
    }
}

```

Zanimivost te bottom-up strategije je, da je bolj učinkovita kot klicanje metode `add(x)` n -krat. Opazimo, da za $n/2$ elementov sploh ne delamo, za $n/4$ elementov kličemo `trickleDown(i)` nad podkopico, katere koren je $a[i]$ in je njena višina enaka 1. Za $n/8$ elementov kličemo metodo `trickleDown(i)` nad podkopico katere višina je enaka 2 in tako dalje. Ker je delo, ki ga izvaja `trickleDown(i)` sorazmerno višini podkopice $a[i]$, je

celotnega dela največ

$$\sum_{i=1}^{\log n} O((i-1)n/2^i) \leq \sum_{i=1}^{\infty} O(in/2^i) = O(n) \sum_{i=1}^{\infty} i/2^i = O(2n) = O(n) .$$

Predzadnja enakost sledi, ker je seštevek $\sum_{i=1}^{\infty} i/2^i$ po definiciji enak pričakovanemu številu glav ob metu kovanc ob uporabi leme 4.2.

Naslednji izrek opisuje zmogljivost metode `heapSort(a, c)`.

Izrek 11.4. *Metoda `heapSort(a, c)` se izvede v času $O(n \log n)$ in izvede največ $2n \log n + O(n)$ primerjav.*

Dokaz. Algoritem deluje v treh korakih: (1) Pretvorba **a** v kopico, (2) ponavljajoče izločanje najmanjšega elementa iz **a** in (3) obrne elemente v **a**. Ravno smo zatrili da korak 1 potrebuje $O(n)$ časa za izvedbo in $O(n)$ primerjav. Korak 3 potrebuje $O(n)$ časa za izvedbo in nič primerjav. Korak 2 izvede **n** klicev metode `trickleDown(0)`. *i*-ti klic se izvaja na kopici velikosti **n** – *i* in izvede največ $2 \log(n - i)$ primerjav. Če seštejemo preko **i** dobimo

$$\sum_{i=0}^{n-i} 2 \log(n - i) \leq \sum_{i=0}^{n-i} 2 \log n = 2n \log n$$

S tem ko dodamo število izvedenih primerjav v vsakem od treh korakov dokončamo dokaz. □


11.1.4 Spodnja meja algoritmov za urejanje, temelječih na primerjavah

Sedaj smo videli tri primerjalne algoritme za urejanje, ki imajo časovno zahtevnost $O(n \log n)$. Čas je da se vprašamo, če obstaja hitrejši algoritem. Kratek odgovor, je ne. Če je edina dovoljena operacija primerjava dveh elementov **a**, potem ni algoritma, ki se lahko izogne približno $n \log n$ primerjavam. To ni težko dokazati in izhaja iz

$$\log(n!) = \log n + \log(n-1) + \dots + \log(1) = n \log n - O(n) .$$

(Dokaz te formule je 11.11.)

Najprej bomo pozornost namenili determinističnim algoritmom, kot sta razvrščanje z zlivanjem in urejanje s kopico. Predstavljajte si, da tak algoritem uporabimo za urejanje **n** različnih elementov.



Slika 11.5: Primerjalno drevo za urejanje polja $a[0], a[1], a[2]$ dolžine $n = 3$.


Pri dokazovanju spodnje meje je ključno opažanje, da je za deterministične algoritme z enako vrednostjo n , prva primerjava vedno enaka. Na primer pri `heapSort(a, c)`, ko je n liho, je prvi klic `trickleDown(i)` s vrednostjo $i = n/2 - 1$, in prva primerjava med elementoma $a[n/2 - 1]$ in $a[n - 1]$.

Ker se elementi ne ponavljajo, ima prva primerjava samo dva možna izida. Druga primerjava pa je lahko odvisna od prve. Tretja je pa lahko odvisna od prve in druge in tako naprej. Na ta način, si lahko kateri koli deterministični primerjalni algoritem za urejanje predstavljamo kot *comparison tree* s korenem. Vsako notranje vozlišče u , tega drevesa, je označeno s parom indeksov $u.i$ in $u.j$. Če je $a[u.i] < a[u.j]$, algoritem nadaljuje pot po levem pod drevesu, drugače pa po desnem pod drevesu. Vsak list w , je označen s permutacijo $w.p[0], \dots, w.p[n - 1]$ pri $0, \dots, n - 1$. To permutacijo potrebujemo za urejanje polja a , če primerjalno drevo obiše ta list. To je,

$$a[w.p[0]] < a[w.p[1]] < \dots < a[w.p[n - 1]] .$$

Primer primerjalnega drevesa za polje dolžine $n = 3$, je prikazano na sliki 11.5.

Primerjalno drevo za algoritem za urejanje, nam pove vse o njem. Pove nam natančno zaporedje primerjav, ki jih bo algoritem izvedel na nekem polju a , ki ima n različnih elementov, in nam pove, kako bo algoritem spremenil vrstni red polja a , da ga bo uredil. Posledično, mora primerjalno drevo vsebovati vsaj $n!$ listov. Če nima, pomeni da obstajata 2 različni permutaciji, ki vodita do istega lista, zato, algoritem ne uredi pravilno vsaj ene od permutacij.



Slika 11.6: Primerjalno drevo, ki ne uredi pravilno vseh možnih vhodnih podatkov.

Na primer, primerjalno drevo prikazano na 11.6 ima samo $4 < 3! = 6$ listov. Če pregledamo drevo, opazimo, da za polji z elementi 3, 1, 2 in 3, 2, 1 oba vodita do istega lista. Za polje 3, 1, 2 dobimo pravi izhod $a[1] = 1, a[2] = 2, a[0] = 3$. Ampak če imamo na vhodu 3, 2, 1, nas napačno vodi do $a[1] = 2, a[2] = 1, a[0] = 3$. To vodi do osnovne spodnje meje za urejevalne algoritme, ki temeljijo na primerjavah.

Izrek 11.5. *Za kateri koli deterministični algoritem za urejanje \mathcal{A} , ki temelji na primerjavah, in za katero koli celo število $n \geq 1$, obstaja tako vhodno polje \mathbf{a} dolžine n , da se izvede vsaj $\log(n!) = n \log n - O(n)$ primerjav, ko urejamo \mathbf{a} .*

Dokaz. Primerjalno drevo definirano kot \mathcal{A} , mora imeti vsaj $n!$ listov. Preprosto dokaz z indukcijo nam pokaže, da ima vsako dvojiško drevo s k listi, višino vsaj $\log k$. Posledično mora imeti primerjalno drevo \mathcal{A} list \mathbf{w} , ki ima globino vsaj $\log(n!)$ in obstaja tako vhodno polje \mathbf{a} , da vodi do tega lista. Polje \mathbf{a} je tako, da \mathcal{A} izvede vsaj $\log(n!)$ primerjav. \square

Izrek 11.5 govori o determinističnih algoritmihih, kot sta razvrščanje z zlivanjem in urejanje s kopico. Kaj pa če imamo naključen algoritem kot je hitro urejanje? Ali bi lahko naključen algoritem bil boljši od spodnje meje $\log(n!)$ primerjav? Odgovor, je ponovno, ne. To lahko dokažemo, če na to, kaj je naključen algoritem, pomislimo malo drugače.

Predvidevali bomo, da je naše odločitveno drevo “očiščeno”: Vsako vozlišče, ki ga ne moremo obiskati z nekim vhodnim poljem \mathbf{a} , odrežemo. To pomeni, da bo imelo drevo natanko $n!$ listov. Ima vsaj $n!$ listov, ker drugače ne bi uredilo polje pravilno. Ima največ $n!$ listov, ker za vsako od $n!$ permutacij n elementov, obstaja natanko en koren, ki vodi do tega lista.

Na algoritem za urejanje \mathcal{R} , ki ima naključnost, lahko gledamo kot deterministični algoritem, ki sprejme 2 vhoda: Polje \mathbf{a} , ki ga bomo uredili, in dolgo zaporedje $b = b_1, b_2, b_3, \dots, b_m$ naključnih realnih števil v obsegu $[0, 1]$. Naključna števila potrebujemo za naključnost v algoritmu. Ko želi met kovanca ali naključno odločitev, uporabi eno od vrednosti iz b . Na primer, če želimo izračunati indeks prvega pivota pri hitrem urejanju, lahko algoritem uporabi formulo $\lfloor nb_1 \rfloor$.

Če za b uporabimo neko določeno zaporedje \hat{b} , potem \mathcal{R} postane deterministični algoritem za urejanje, $\mathcal{R}(\hat{b})$, ki ima primerjalno drevo $\mathcal{T}(\hat{b})$. Če za \mathbf{a} izberemo naključno permutacijo iz $\{1, \dots, n\}$, potem je to ekvivalentno izbiri naključnega lista \mathbf{w} , od $n!$ listov od $\mathcal{T}(\hat{b})$.

Naloga 11.13 zahteva dokaz, da če izberemo naključen list iz dvojiškega drevesa, ki ima k listov, potem je pričakovana globina tega lista vsaj $\log k$. Zaradi tega je pričakovana vrednost primerjav (determinističnega) algoritma $\mathcal{R}(\hat{b})$, ki sprejme za vhod naključno permutacijo iz $\{1, \dots, n\}$, vsaj $\log(n!)$. To velja za vsako izbiro \hat{b} , zato to velja tudi za \mathcal{R} . To zaključimo o spodnji meji za naključni algoritem.

Izrek 11.6. *Za vsako celo število $n \geq 1$ in kateri koli (deterministični ali naključni) primerjalni algoritem za urejanje \mathcal{A} , je pričakovana vrednost primerjav, ki jih stori algoritem pri naključni permutaciji $\{1, \dots, n\}$, vsaj $\log(n!) = n \log n - O(n)$.*

11.2 Urejanje s štetjem in korensko urejanje

V tem delu preučujemo dva urejevalna algoritma, ki nista bazirana na primerjanju. Algoritma sta specializirana za ločevanje manjših celih števil, ter se izogneta spodnji meji izreka 11.5 z uporabo elementov v \mathbf{a} kot indeksov v polju. Razmislite o izrazu

$$c[\mathbf{a}[\mathbf{i}]] = 1 \text{ .}$$

Ta izraz se izvrši v konstantnem času, ampak ima $\mathbf{c.length}$ možnih različnih rezultatov, odvisno od vrednosti $\mathbf{a}[\mathbf{i}]$. To pomeni da izvršitev algoritma ki poda tako izjavo ni mogoče modelirati kot dvojiško drevo. To je glavni razlog da so algoritmi v tem delu zmožni urejati hitreje kot algoritmi bazirani na primerjavah.

11.2.1 Urejanje s štetjem (counting sort)

Recimo da imamo polje **a** sestavljeno iz **n** celih števil, vse v obsegu $0, \dots, k-1$. Algoritm *urejanje s štetjem* urejanja **a** z uporabo pomožnega polja števecov **c**. Ven dobimo urejeno verzijo polja **a** kot pomožno polje **b**.

Ideja pri urejanju s štetjem je preprosta: Za vsak $i \in \{0, \dots, k-1\}$, prešteje število pojavitev **i** v **a** in to shrani v **c[i]**. Po urejanju dobimo **c[0]** ponovitev števila 0, sledi **c[1]** pojavitev števila 1, sledi še **c[2]** pojavitev števila 2, ..., sledi **c[k-1]** pojavitev števila **k-1**. Koda, ki to izvrši, je zelo elegantna, njeno delovanje je ilustrirano na sliki 11.7:

```


Algorithms



```

int[] countingSort(int[] a, int k) {
 int c[] = new int[k];
 for (int i = 0; i < a.length; i++)
 c[a[i]]++;
 for (int i = 1; i < k; i++)
 c[i] += c[i-1];
 int b[] = new int[a.length];
 for (int i = a.length-1; i >= 0; i--)
 b[--c[a[i]]] = a[i];
 return b;
}

```



```

Prva **for** zanka v tej kodi nastavi vsak števec **c[i]** tako, da šteje število ponovitev **i** v **a**. Z uporabo vrednosti **a** kot indeks se ti števcji lahko vsi izračunajo v času $O(n)$ z eno samo **for** zanko. Na tej točki bi lahko uporabili **c** da direktno zapolnimo izhodni polje **b**. Vendar pa to ne bi delovalo če bi imeli elementi polja **a** povezane podatke. Zato porabimo nekaj več napora da prekopiramo elemente polja **a** v **b**.

Naslednja **for** zanka, ki potrebuje $O(k)$ časa, izračuna tekoče vsote števecov tako da **c[i]** postane število elementov v **a**, ki so manjši ali enaki **i**. Za vsak $i \in \{0, \dots, k-1\}$, bo izhodno polje **b** imelo

$$b[c[i-1]] = b[c[i-1] + 1] = \dots = b[c[i] - 1] = i.$$

Na koncu algoritem pregleda **a** vzvratno tako, da postavi svoje elemente v pravem vrstnem redu v izhodno polje **b**. Ko pregleduje, postavi element **a[i] = j** na pozicijo **b[c[j]-1]** in vrednost **c[j]** se zmanjša.



Slika 11.7: Operacija urejanja s štetjem na polju velikosti $n = 20$, ki shrani $0, \dots, k-1 = 9$ števil.

Izrek 11.7. Metoda `countingSort(a,k)` lahko uredi polje `a`, ki vsebuje `n` števil v množici $\{0, \dots, k-1\}$ v času $O(n+k)$.

Urejanje s štejetjem ima prijetno lastnost in sicer da je *stabilen*, ohrani relativni vrstni red enakih elementov. Če imata dva elementa `a[i]` in `a[j]` isto vrednost, in $i < j$, potem se bo `a[i]` pojavil pred `a[j]` v `b`. To bo uporabno v naslednjem poglavju.

11.2.2 Korensko urejanje (radix sort)

Urejanje s štejetjem je zelo učinkovita metoda za urejanje polja števil, ko je dolžina polja `n` ni veliko manjša kot maksimalna vrednost $k-1$, ki se pojavi v polju. Algoritem *korensko urejanje*, ki ga sedaj opisujemo uporablja več prehodov algoritma urejanja s štejetjem, kar dopušča večji razpon maksimalnih vrednosti.

Korensko urejanje ureja `w`-bitna števila z uporabo `w/d` prehodov urejanja s štejetjem, da ta števila uredi po `d` bitih naenkrat.² Natančneje, korensko urejanje najprej uredi števila po najmanj pomembnih `d` bitih nato po naslednjih `d` pomembnejših bitih in tako naprej, v zadnjem prehodu so števila urejena po najpomembnejših `d` bitih.

Algorithms

```
int[] radixSort(int[] a) {
    int[] b = null;
    for (int p = 0; p < w/d; p++) {
        int c[] = new int[1<<d];
        // the next three for loops implement counting-sort
        b = new int[a.length];
        for (int i = 0; i < a.length; i++)
            c[(a[i] >> d*p)&((1<<d)-1)]++;
        for (int i = 1; i < 1<<d; i++)
            c[i] += c[i-1];
        for (int i = a.length-1; i >= 0; i--)
            b[--c[(a[i] >> d*p)&((1<<d)-1)]] = a[i];
        a = b;
    }
    return b;
}
```

²Privzamemo da `d` deli `w`, v nasprotnem primeru lahko `w` povečamo na $d\lceil w/d \rceil$.

}

(V tej kodi, izraz $(a[i] \gg d * p) \& ((1 \ll d) - 1)$ izloči število katerega dvojiška predstavitev je dana z biti $(p+1)d-1, \dots, pd$ od $a[i]$.) Primer korakov tega algoritma je prikazan na skiki 11.8.


Ta izjemen algoritem ureja pravilno, ker je urejanje s štetjem stabilen algoritem za urejanje. Če sta $x < y$ dva elementa polja a in če ima najpomembnejši bit pri katerem se x razlikuje od y index r , potem bo x postavljen pred y med prehodom $\lfloor r/d \rfloor$ in vsi naslednji prehodi ne bodo spremenili relativnega vrstnega reda x in y .

Korensko urejene opravi w/d prehodov urejanja s štetjem. Vsak prehod porabi $O(n+2^d)$ časa. Torej, zahtevnost korenskega urejanja je izražena v naslednjem izreku.

Izrek 11.8. Za katerokoli število $d > 0$, $\text{radixSort}(a, k)$ metoda lahko uredi polje a , ki vsebuje n w -bitnih števil v času $O((w/d)(n + 2^d))$.

Če namesto elementov polja v razponu $\{0, \dots, n^c - 1\}$ vzamemo $d = \lceil \log n \rceil$ dobimo naslednjo različico izreka 11.8.

Posledica 11.1. Metoda $\text{radixSort}(a, k)$ lahko uredi polje a , ki vsebuje n številskih vrednosti v razponu $\{0, \dots, n^c - 1\}$ v času $O(cn)$.



Slika 11.8: Uporaba korenskega urejanja za urejanje $w = 8$ -bitnega števila z uporabo štirih prehodov z uporabo urejanja s štetjem na $d = 2$ -bitnih številih

11.3 Diskusija in naloge

Sortiranje je osnovni algoritemski problem v računalništvu in ima dolgo zgodovino. Knuth [?] pripisuje alogritem sortiranja z zlivanjem von Neumann(1945). Hitro urejanje je predstavil Hoare [?]. Originalno urejanje s kopico je last Williams [?], različico predstavljeno tu (v kateri se kopica gradi iz spodaj nazvgor v $O(n)$ času) pa je zasnoval Floyd [?]. Spodnje meje za urejanja, temelječa na primerjavah, se zdijo zastarele. Naslednja tabela povzame časovne zahtevnosti tovrstnih algoritmov:

| | primerjave | na mestu |
|----------------------|-------------------------------------|----------|
| Urejanje z zlivanjem | $n \log n$ najslabši primer | Ne |
| Hitro urejanje | $1.38n \log n + O(n)$ pričakovano | Da |
| Urejanje s kopico | $2n \log n + O(n)$ najslabši primer | Da |

Vsi algoritmi urejanje s primerjanjem imajo svoje prednosti in slabosti. Urejanje z zlivanjem naredi najmanj primerjav in se ne zanaša na naključnost. Na žalost, uporablja pomožno tabelo med fazo zlivanja. Dodeljevanje pomnilnika tej tabeli je lahko drago in potencialno usodno za algoritem, če je količina pomnilnika omejena. Hitro urejanje ureja elemente *na mestu* in je blizu na drugem mestu v številu primerjav, ampak vsebuje naključnost, zato čas izvajanja ni vedno zagotovljen. Urejanje s kopico naredi največ primerjav, ampak deluje na mestu in je deterministično.

Obstaja primer, v katerem je urejanje s kopico očiten zmagovalec; to se zgodi pri urejanju povezanega seznama. V tem primeru, ne potrebujemo pomožne tabele; dva urejena povezana seznama, se zelo lahko zlijeta v en urejen povezan seznam z uporabo manipulacije kazalcev (glej 11.2).

Algoritma urejanje s štetjem in korensko urejanje, opisana tu, temeljita na Sewardovem principu [?, Section 2.4.6]. Ampak različice korenskega urejanja so v uporabi že od dvajsetih let 20. stoletja za razvrščanje luknjanih kartic z uporabo strojev. Te stroji lahko razvrstijo kup kartic v dva kupa, glede na obstoj (ali neobstoj) luknjice na specifični lokaciji na kartici. Ponovitev tega procesa, za drugo luknjico, nam da implementacijo korenskega urejanja.

Na koncu, opazimo, da urejanje s štetjem in korenskega urejanja lahko uporabimo, tudi za urejanje drugih števil poleg pozitivnih celih števil.

Enostavne spremembe urejanja s štetjem lahko uredijo cela števila v poljubnem intervalu $\{a, \dots, b\}$, v $O(n + b - a)$ času. Podobno, korensko urejanje, lahko ureja cela števila na enakem intervalu v $O(n(\log_n(b - a)))$ času. Na koncu, lahko oba algoritma uporabimo za urejanje števil s plavajočo vejico v zapisu IEEE 754 plavajoče vejice. To lahko naredimo zato, ker je zapis IEEE zasnovan tako, da dovoljuje primerjavo dveh števil s plavajočo vejico glede na njuni vrednosti, kot če bi bili celi števili v predznačeni dvojiški predstavitvi [?].

Naloga 11.1. Ilustrirajte izvedbo urejanje z zlivanjem in urejanja s kopico nad vhodno tabelo s števili 1, 7, 4, 6, 2, 8, 3, 5. Naredite vzorčno ilustracijo ene možnosti izvedbe hitrega urejanja nad isto tabelo.

Naloga 11.2. Implementirajte verzijo algoritma urejanja z zlivanjem, ki uredi dvojno povezan seznam brez uporabe pomožne tabele. (Glej nalogo 3.13.)

Naloga 11.3. Nekatere implementacije `quickSort(a, i, n, c)` vedno uporabljajo `a[i]` kot pivot. Podajte primer vhodne tabele dolžine `n` nad katero bi taka implementacija izvedla $\binom{n}{2}$ primerjav.

Naloga 11.4. Nekatere implementacije `quickSort(a, i, n, c)` vedno uporabljajo `a[i + n/2]` kot pivot. Podajte primer vhodne tabele dolžine `n` nad katero bi taka implementacija izvedla $\binom{n}{2}$ primerjav.

Naloga 11.5. Pokažite, da za katerokoli implementacijo `quickSort(a, i, n, c)`, ki izbere pivot deterministično, ne da pogleda katerokoli vrednost v `a[i], \dots, a[i + n - 1]` obstaja vhodna tabela dolžine `n`, ki povzroči, da ta izvede $\binom{n}{2}$ primerjav.

Naloga 11.6. Načrtujte `Comparator, c`, ki lahko podate kot argument funkciji `quickSort(a, i, n, c)`, in bi povzročil $\binom{n}{2}$ primerjav. (Namig: Vašemu `Comparator`-ju ni potrebno gledati vrednosti, ki se primerjajo.)

Naloga 11.7. Natančneje od dokaza 11.3 analizirajte pričakovano število primerjav, ki jih naredi Quicksort. Dokazite, da je pričakovano število primerjav $2nH_n - n + H_n$.

Naloga 11.8. Opišite vhodno tabelo, ki povzroči, da urejanje s kopico, naredi največ $2n \log n - O(n)$ primerjav. Utemeljite vaš odgovor.

Naloga 11.9. Implementacija sortiranja s kopico, ki je opisana tukaj, uredi elemente v obrnjenem vrstnem redu in nato obrne tabelo. Ta zadnji korak, lahko izpustimo, če definiramo nov `Comparator`, ki negira rezultat prvotnega `Comparator` ja `c`. Razložite zakaj to ne bi bila dobra optimizacija. (Namig: Pomislite koliko negacij bi bilo potrebno v razmerju s potrebnim časom za obrat tabele.)

Naloga 11.10. Najdite nek drug par premutacij 1, 2, 3, ki niso pravilno urejene z drevesom primerjav v 11.6.

Naloga 11.11. Dokažite, da $\log n! = n \log n - O(n)$.

Naloga 11.12. Dokažite, da je dvojiško drevo s k listi visoko vsaj $\log k$.

Naloga 11.13. Dokažite, da je pri izbiri naključnega lista v dvojiškem drevesu s k listi pričakovana višina lista najmanj $\log k$.

Naloga 11.14. Implementacija `radixSort(a, k)` podana tukaj, deluje ko vhodna tabela, `a` vsebuje samo pozitivna cela števila. Razširite to implementacijo, tako da ta deluje tako nad pozitivnimi kot tudi nad negativnimi celimi števili.

Poglavje 12


Grafi

V tem poglavju bomo preučili dva načina predstavitve grafov in temeljne algoritme, ki uporabljajo omenjeni predstavitvi.

Matematično je (*usmerjen*) *graf* par $G = (V, E)$, kjer je V množica *vozlišč* in E množica urejenih parov vozlišč imenovanih *povezave*. Povezava (i, j) je *usmerjena* od i do j ; i se imenuje *izvor* povezave, j pa *ponor*. Pot v G je zaporedje vozlišč v_0, \dots, v_k tako, da so za vsak $i \in \{1, \dots, k\}$ vse povezave (v_{i-1}, v_i) prisotne v E . Pot v_0, \dots, v_k je *cikel*, če je tudi pot (v_k, v_0) prisotna v E . Pot (ali cikel) je *enostaven*, če so tudi njegova vozlišča unikatna. Če je pot iz neke točke v_i do neke točke v_j , potem pravimo, da je v_j *dosegljiva* iz v_i . Primer grafa je prikazan na sliki 12.1.

Zaradi svoje zmogljivosti pri izdelavi modela raznih pojavov, imajo grafi ogromno število aplikacij. Obstajajo številni primeri. Računalniška omrežja lahko modeliramo v nek graf, kjer vozlišča (točke) predstavljajo računalnike in povezave predstavljajo (direktno) komunikacijsko pot med dvema računalnikoma. Tudi ceste v nekem mestu lahko predstavimo kot neki graf, kjer vozlišča predstavljajo križišča ter povezave predstavljajo ulice.

Primeri, ki so malo manj očitni, se pojavijo ko spoznamo, da grafe lahko modeliramo v pare kjer nimamo nobenih skupnih odnosov med sabo. Na primer v univerzi imamo lahko *konfliktni graf* urnika kjer vozlišča predstavljajo predavanja na univerzi in povezava (i, j) obstaja samo v primeru, če je prisoten vsaj en študent, ki hodi na predmet i in na predmet j . Tako ena povezava prikaže, da izpit za predmet i ne more na noben način biti načrtovan ob istem času tudi za predmet j .



Slika 12.1: Graf z dvanajstimi vozlišči. Vozlišča so narisana kot oštevilčeni krogi ter povezave so narisane kot usmerjene krivulje od izvora do ponora.

V tem poglavju nam n predstavlja število vozlišč v množici G in m število povezav v množici G . To pomeni, da $n = |V|$ in $m = |E|$. Poleg vsega tega pa predpostavimo, da je $V = \{0, \dots, n-1\}$. Katerekoli druge podatke, ki bi jih radi povezali z elementi množice V , lahko torej hranimo v tabeli dolžine n .

Tipične operacije nad grafi so:

- `addEdge(i, j)`: Doda povezavo (i, j) v E .
- `removeEdge(i, j)`: Zbriše povezavo (i, j) iz E .
- `hasEdge(i, j)`: Poišče povezavo $(i, j) \in E$
- `outEdges(i)`: Vrne `List` (seznam) celih števil j od $(i, j) \in E$
- `inEdges(i)`: Vrne `List` (seznam) celih števil j od $(j, i) \in E$

Vedeti je treba, da takšne operacije ni težko implementirati na učinkovit način. Na primer, prve tri operacije so lahko uporabljene direktno z uporabo `USet`, na tak način, da se lahko izvajajo v konstantnem pričakovanem času z uporabo razpršenih tabel (predstavljene v poglavju 5). Zadnji dve operaciji pa so lahko implementirane v konstantnem času s shranjevanjem, tako da za vsako vozlišče shranimo še seznam sosednjih vozlišč.

Različne aplikacije nad grafi imajo različne minimalne zahteve po hitrosti izvajanja operacij in potrebnega prostora. Idealno bi bilo, če bi uporabili najenostavnejšo izvedbo grafov, ki bi zadovoljila vse vrste aplikacij. V nadaljevanju si bomo pogledali dve najpogostejši izvedbi grafov.

12.1 AdjacencyMatrix: Predstavitev grafov z uporabo matrik

Matrika sosednosti je način za predstavitev n vozlišč grafa $G = (V, E)$ z matriko $n \times n$, a , kjer so notranji elementi tipa "boolean".

AdjacencyMatrix

```
int n;  
boolean[][] a;  
AdjacencyMatrix(int n0) {  
    n = n0;  
    a = new boolean[n][n];  
}
```

Vnos elementa matrike $a[i][j]$ je definiran kot

$$a[i][j] = \begin{cases} \text{true} & \text{if } (i, j) \in E \\ \text{false} & \text{otherwise} \end{cases}$$


Matrika sosednosti za graf iz slike 12.1, je prikazana na sliki 12.2.

Tu je prikazana operacija `addEdge(i, j)`, `removeEdge(i, j)` in `hasEdge(i, j)`, ki vrne vrednost elementa $a[i][j]$ matrike:

AdjacencyMatrix

```
void addEdge(int i, int j) {  
    a[i][j] = true;  
}  
void removeEdge(int i, int j) {  
    a[i][j] = false;  
}  
boolean hasEdge(int i, int j) {  
    return a[i][j];  
}
```

Grafi



| | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 |
|----|---|---|---|---|---|---|---|---|---|---|----|----|
| 0 | 0 | 1 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 1 | 1 | 0 | 1 | 0 | 0 | 1 | 1 | 0 | 0 | 0 | 0 | 0 |
| 2 | 1 | 0 | 0 | 1 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 0 |
| 3 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 |
| 4 | 1 | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 1 | 0 | 0 | 0 |
| 5 | 0 | 1 | 1 | 0 | 1 | 0 | 1 | 0 | 0 | 1 | 0 | 0 |
| 6 | 0 | 0 | 1 | 0 | 0 | 1 | 0 | 1 | 0 | 0 | 1 | 0 |
| 7 | 0 | 0 | 0 | 1 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 1 |
| 8 | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 1 | 0 | 0 |
| 9 | 0 | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 1 | 0 | 1 | 0 |
| 10 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 1 | 0 | 1 |
| 11 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 1 | 0 |

Slika 12.2: Graf in njegova matrika sosednosti.

Vse zgornje operacije trajajo $O(1)$ časa.

Izvajanje matrike sosednosti je slabše za operaciji `outEdges(i)` in `inEdges(i)`. Da bi jo lahko implementirali, je potrebno preveriti vseh n vnosov v ustrezni vrstici oz. stolpcu iz a , in zbrati vse indekse j , kjer je $a[i][j]$ oziroma $a[j][i]$ resnična.

```
AdjacencyMatrix
List<Integer> outEdges(int i) {
    List<Integer> edges = new ArrayList<Integer>();
    for (int j = 0; j < n; j++)
        if (a[i][j]) edges.add(j);
    return edges;
}
List<Integer> inEdges(int i) {
    List<Integer> edges = new ArrayList<Integer>();
    for (int j = 0; j < n; j++)
        if (a[j][i]) edges.add(j);
    return edges;
}
```

Časovna zahtevnost teh operacij je $O(n)$.

Druga slaba lastnost sosednostnih matrik je, da so velike. V matriki je shranjeno $n \times n$ boolean vrednosti, kar pomeni, da potrebujemo vsaj n^2 bitov prostora v pomnilniku. Implementacija tu uporablja dejansko eno matriko z vrednostmi tipa boolean, tako da dejansko zavzame n^2 bajtov pomnilnika. Bolj previdna izvedba shrani w vrednosti boolean v vsako pomnilniško besedo in tako zmanjša porabo na $O(n^2/w)$ besed pomnilnika.

Izrek 12.1. Podatkovna struktura *AdjacencyMatrix*, implementira vmesnik za grafe (v angleščini: *Graph interface*). *AdjacencyMatrix* podpira naslednje operacije

- `addEdge(i, j)`, `removeEdge(i, j)`, in `hasEdge(i, j)` v konstantnem času na operacijo; in
- `inEdges(i)`, in `outEdges(i)` v času $O(n)$ na operacijo.

AdjacencyMatrix zasede $O(n^2)$ prostora.

Kljub visoki zahtevi po prostoru in neučinkovitega delovanja operacij `inEdges(i)` in `outEdges(i)`, je `AdjacencyMatrix` lahko še vedno uporabna za nekatere aplikacije. Še posebej, ko je graf G gost (*dense*), kar pomeni, da ima približno n^2 povezav, potem mora zavzeti n^2 prostora kar je še vedno sprejemljivo.

Podatkovna struktura `AdjacencyMatrix` se pogosto uporablja, saj se operacije nad matriko a lahko uporabljajo za definiranje lastnosti grafa G . To je argument, ki se predela na tečaju za algoritme, ampak oglejmo si vsaj eno lastnost: če obravnavamo vhod kot neko celo število a (1 za `true` in 0 za `false`) in pomnožimo matriko a samo s seboj z uporabo operacije množenja matrik, potem kot rezultat dobimo matriko a^2 . Po definiciji je za množenje matrik

$$a^2[i][j] = \sum_{k=0}^{n-1} a[i][k] \cdot a[k][j] .$$


Interpretacija zgornje vsote glede na graf G bi bila naslednja: formula prešteje vsa vozlišča k , za katere G vsebuje obe povezavi (i, k) in (k, j) . Prešteje vse poti iz i do j (skozi vmesno vozlišče k) katerih dolžina je 2. Omenjena značilnost je temelj algoritma za izračun najkrajših poti med vsemi vozlišči v G , ki namesto $O(n)$ potrebuje le $O(\log n)$ matričnih množenj.

12.2 AdjacencyLists: Predstavitev grafov s seznamom sosednosti

Seznam sosednosti - ponazoritev grafov vzame pristop bolj usmerjen v vozlišča. Obstaja veliko možnih izvedb seznamov sosednosti. V tem poglavju predstavljamo preprosto izvedbo. Na koncu razdelka razpravljamo o različnih možnostih. V seznamu sosednosti je graf $G = (V, E)$ predstavljen kot polje, `adj`, seznamov. Seznam `adj[i]` vsebuje vse sosedne vozlišča i . To je vsak j , kjer velja $(i, j) \in E$.

AdjacencyLists

```
int n;
List<Integer>[] adj;
```



Slika 12.3: A graph and its adjacency lists

```
AdjacencyLists(int n0) {
    n = n0;
    adj = (List<Integer>[])new List[n];
    for (int i = 0; i < n; i++)
        adj[i] = new ArrayStack<Integer>();
}
```

(Primer je pokazan na 12.3.) V tej specifični implementaciji, predstavimo vsak seznam `adj` kot `ArrayStack`, ker želimo doseči konstanten čas dostopov do pozicij. Mogoče so tudi drugačne opcije. Ena opcija je izvedba `adj` kot `DLList`.

Operacija `addEdge(i, j)` doda vrednost `j` na seznam `adj[i]`:

```
void addEdge(int i, int j) {
    adj[i].add(j);
}
```

To se izvede v konstantem času.

Operacija `removeEdge(i, j)` pregleda seznam `adj[i]` dokler ne najde `j` in ga odstrani iz seznama:

```

AdjacencyLists
void removeEdge(int i, int j) {
    Iterator<Integer> it = adj[i].iterator();
    while (it.hasNext()) {
        if (it.next() == j) {
            it.remove();
            return;
        }
    }
}

```

To se izvede v $O(\deg(i))$ času, kjer $\deg(i)$ (*stopnja vozlišča i*) prešteje število robov v E , ki imajo i za njihov izvor.

Operacija `hasEdge(i, j)` je podobna; pregleda seznam `adj[i]` dokler ne najde `j` (in vrne `true`), ali doseže konec seznama (in vrne `false`):

```

AdjacencyLists
boolean hasEdge(int i, int j) {
    return adj[i].contains(j);
}

```

To se izvede v $O(\deg(i))$ času.

Operacija `outEdges(i)` je zelo preprosta;

```

AdjacencyLists
List<Integer> outEdges(int i) {
    return adj[i];
}

```

To se očitno izvede v konstantem času.

Operacija `inEdges(i)` naredi več dela. Operacija pregleda vsa vozlišča `j`, in če povezava `(i, j)` obstaja, doda `j` na izhodni seznam.


```

AdjacencyLists
List<Integer> inEdges(int i) {
    List<Integer> edges = new ArrayStack<Integer>();
    for (int j = 0; j < n; j++)
        if (adj[j].contains(i)) edges.add(j);
    return edges;
}

```

Operacija je zelo počasna. Pregleda seznam sosednosti vsakega vozlišča in se izvede v času $O(n + m)$.

Naslednji izrek povzema delovanje zgornje podatkovne strukture:

Izrek 12.2. Podatkovna struktura *AdjacencyLists* implementira vmesnik *Graph*. *AdjacencyLists* podpira operacije

- `addEdge(i, j)` v konstantem času na operacijo;
- `removeEdge(i, j)` in `hasEdge(i, j)` v $O(\deg(i))$ času na operacijo;
- `outEdges(i)` v konstantem času na operacijo; in
- `inEdges(i)` v $O(n + m)$ času na operacijo.

AdjacencyLists porabi $O(n + m)$ prostora.

Obstaja veliko možnosti kako lahko implementiramo graf kot seznam sosednosti. Ena izmed vprašanj ki se nam porajajo so:

- Kakšno zbirko podatkov uporabiti za shranjevanje vsakega elementa v `adj`? Lahko bi uporabili polje, povezan seznam, ali celo zgoščevalne tabele.
- Lahko bi uporabili drug seznam sosednosti, `inadj`, ki hrani za vsak `i`, seznam vozlišč `j`, tako da $(j, i) \in E$. To lahko močno zmanjša trajanje operacije `inEdges(i)`, ampak rahlo poveča trajanje dodajanja in brisanja povezav.
- Lahko bi vpis za povezavo (i, j) v `adj[i]` bil povezan z referenco na ustrezeni vpis v `inadj[j]`
- Lahko bi bile povezave prvorazredni objekti z njihovimi asociativnimi podatki. Tako bi `adj` vseboval seznam povezav namesto seznama vozlišč (integers).

Pri večini zgornjih vprašanj pride do kompromisa med zahtevnostjo (in prostorom) izvedbe in zmogljivostjo operacij.

12.3 Preiskovanje grafov

V tem poglavju predstavljamo dva algoritma za raziskovanje grafa, z začetkom v eni od njegovih točk, *i*, in zaključkom v vseh točkah ki so dosegljive iz *i*. Oba algoritma sta najbolj primerna za grafe predstavljene s seznamom sosednosti. Zato, ko bomo analizirali te algoritme, bomo predpostavili, da je osnova predstavitev s seznamom sosednosti `AdjacencyLists`.

12.3.1 Iskanje v širino

Algoritem iskanje v širino *breadTH-first-search* začne pri točki *i* in obišče najprej sosedo od *i*, nato sosedo sosedov od *i*, nato sosedo sosedov sosedov od *i* in tako naprej.

Algoritem je posplošitev algoritma za obhod v širino dvojiških dreves (naloge 6.1.2), in je zelo podoben; uporablja vrsto, *q*, ki sprva vsebuje le *i*. Nato zaporedoma izloči po en element iz *q* in v *q* doda njegove sosedo pod pogojem, da predhodno tam še niso bili. Edina pomembna razlika med algoritmoma za iskanje v širino za grafe in za drevesa je ta, da mora algoritem za grafe zagotavljati, da ne doda iste točke v *q* več kot enkrat. To naredi s pomožnim boolean poljem, *seen*, ki beleži katere točke so že bile odkrite.

Algorithms

```
void bfs(Graph g, int r) {
    boolean[] seen = new boolean[g.nVertices()];
    Queue<Integer> q = new SLList<Integer>();
    q.add(r);
    seen[r] = true;
    while (!q.isEmpty()) {
        int i = q.remove();
        for (Integer j : g.outEdges(i)) {
            if (!seen[j]) {
                q.add(j);
                seen[j] = true;
            }
        }
    }
}
```


da bo obstajala direktna pot iz r do j . Še več, vozlišča z razdaljo 0 od r (r sam) bodo vstopila v q pred vozlišči z razdaljo 1, ki bodo vstopila v q pred vozlišči z razdaljo 2 in tako naprej. Torej metoda $\text{bfs}(g, r)$ obišče vozlišča v naraščajočem vrstnem redu razdalje od r in vozlišča, ki jih ne dosežemo iz r niso nikoli obiskana.

Precej uporabna aplikacija breadth-first-search algoritma je torej, v iskanju najkrajše poti. Da bi izračunali najkrajšo pot od r do vseh ostalih vozlišč, uporabimo različne verzije $\text{bfs}(g, r)$ ki uporabljajo pomožni seznam, p , dolžine n . Ko je novo vozlišče j dodano v q , nastavimo $p[j] = i$. Na ta način, $p[j]$ postane predzadnje vozlišče z najkrajšo razdaljo od r do j . S ponavljanjem tega postopka, če vzamemo $p[p[j]]$, $p[p[p[j]]]$, in tako naprej, lahko rekonstruiramo (v obratnem vrstnem redu) najkrajšo pot od r do j .

12.3.2 Iskanje v globino

The *depth-first-search* algoritem je podoben običajnemu algoritmu za sprehod po dvojiških drevesih; najprej razišče celotno poddrevo, potem pa se vrne na trenutno vozlišče in nato razišče še drugo poddrevo. Še en način, kako si lahko predstavljamo depth-first-search algoritem je breadth-first search algoritem, z razliko, da depth-first-search uporablja sklad namesto vrste.

Med izvedbo depth-first-search algoritma, vsakemu vozlišču, i , določimo barvo, $c[i]$: *bela* če vozlišča še nismo srečali, *siva* če smo trenutno na tem vozlišču, in *crna*, če smo končali s tem vozliščem. Depth-first-search algoritem si najlažje predstavljamo kot rekurzivni algoritem. Začnemo tako, da obiščemo r . Ob obisku vozlišča i , ga najprej označimo s *sivo* barvo. Nato, pogledamo i -jev seznam sosedov in rekurzivno obiščemo vsa bela vozlišča, ki jih najdemo v tem seznamu. Na koncu, ko smo končali s procesiranjem i -ja, ga pobarvamo v *crna* in vrnemo.

Algorithms

```
void dfs(Graph g, int r) {
    byte[] c = new byte[g.nVertices()];
    dfs(g, r, c);
}
void dfs(Graph g, int i, byte[] c) {
```



```

    int i = s.pop();
    if (c[i] == white) {
        c[i] = grey;
        for (int j : g.outEdges(i))
            s.push(j);
    }
}
}

```

V zgornji kodi, ko je naslednje vozlišče i procesirano, se i obarva v **sivo** in zamenja v skladu, z njegovimi sosednjimi vozlišči. V naslednji iteraciji bo eno izmed teh vozlišč obiskano.


Kot pričakovano, sta časovni zahtevnosti za $\text{dfs}(g, r)$ in $\text{dfs2}(g, r)$ enaki kot tista od $\text{bfs}(g, r)$:

Izrek 12.4. *Ko je Graf g podan kot vhod, ki je implementiran kot podatkovna struktura *AdjacencyLists*, potem oba algoritma $\text{dfs}(g, r)$ in $\text{dfs2}(g, r)$ potrebujeta $O(n + m)$ časa.*

Kot pri algoritmu za iskanje v širino, imamo ustrezno drevo, ki je povezano z vsako izvedbo iskanja v globino. Ko se vozlišče $i \neq r$ obarva z **bele** na **sivo**, to se zgodi, ker je bil $\text{dfs}(g, i, c)$ rekurzivno klican med procesiranjem nekega vozlišča i' . (V primeru $\text{dfs2}(g, r)$ algoritma, je i eden od vozlišč ki zamenja i' v skladu.) Če gledamo na i' kot starša od i , potem ohranimo drevo s korenem pri r . Na sliki 12.5, je to drevo pot od vozlišča 0 do vozlišča 11.

Pomembna lastnost iskanja v globino je sledeča: Predpostavimo da ko je vozlišče i obarvano **sivo**, obstaja pot od i do nekega drugega vozlišča j ki uporablja le bela vozlišča. Potem bo j prvo obarvan v **sivo** nato pa v **crno**, preden bo i obarvan v **crno**. (To je lahko dokazano s protislovjem, tako da upoštevamo katerokoli pot P od i do j .)

Ena vloga te lastnosti je prepoznavanje ciklov. Glejte 12.6. Preučimo nek cikel C , ki je dosegljiv iz r . Naj bo i prvo vozlišče od C , ki bo obarvano **sivo** in naj bo vozlišče j predhodnik od i v ciklu C . Potem, preko zgoraj omenjene lastnosti bo j obarvan **sivo** in algoritem bo obravnaval povezavo (j, i) medtem, ko je vozlišče i še vedno **sivo**. Zato lahko algoritem sklepa, da obstaja pot P od i do j pri iskanju v globino, zato obstaja tudi povezava (j, i) , kar pomeni da je P prav tako cikel.



Slika 12.6: Iskanje v globino lahko uporabimo za odkrivanje ciklov v G . Vozlišče j je obarvano **sivo** dokler je i obarvan **sivo**. To pomeni, da obstaja pot P od i do j v drevesu pri iskanju v globino. Povezava (j, i) pomeni da je P tudi cikel.

12.4 Diskusija in vaje

Časovna zahtevnost iskanja v globino in iskanja v širino so nekoliko precejšene preko izreka 12.3 in 12.4. Definiraj n_r kot število vozlišč, i od G , za katerega obstaja pot od r do i . Definiraj m_r kot število povezav, ki imajo ta vozlišča za svoj izvor. Potem bo v sledečem izreku časovna zahtevnost iskanja v globino in iskanja v širino algoritmov, bolj točno navedena. (Ta bolj točen izrek je uporaben v nekaterih vlogah algoritmov, podčranih v vajah.)


Izrek 12.5. *Ko je Graf G podan kot vhod, ki je implementiran kot podatkovna struktura *AdjacencyLists*, potem se vsak algoritem $\text{bfs}(g, r)$, $\text{dfs}(g, r)$ in $\text{dfs2}(g, r)$ izvaja $O(n_r + m_r)$ časa.*

Izgleda, da sta iskanje v širino neodvisno odkrila Moore [?] in Lee [?] v kontekstu raziskovanja labirintov in preusmerjanja tokokroga.

Predstavitev grafov kot seznam sosedov sta demonstrirala Hopcroft in Tarjan [?] kot alternativo (bolj pogostim) predstavitev z matrikami sosednosti. Ta predstavitev, kot tudi iskanje v globino igrata veliko vlogo v znameniti Hopcroft-Tarjan ravninskem testnem algoritmu ki lahko določi v $O(n)$ času, če se lahko graf nariše v ravnini in v takem načinu, da noben par vozlišč ne preseka drug drugega. [?].

V naslednji vajah, imamo neusmerjen graf v enem ki za vsaki i in j , povezavo (i, j) je predstavljen, če in samo če je povezava (j, i) prisotna.

Naloga 12.1. Narišite seznam sosednosti ter matriko sosednosti za graf na sliki 12.7.



Slika 12.7: Primer grafa.

Naloga 12.2. Matrika neodvisnosti za graf, G , je $n \times m$ matrika, A , kjer velja

$$A_{i,j} = \begin{cases} -1 & \text{če je točka } i \text{ vir množice } j \\ +1 & \text{če je točka } i \text{ tarča množice } j \\ 0 & \text{sicer.} \end{cases}$$

1. Narišite incidenčno matriko za graf na sliki 12.7.
2. Zasnujte, analizirajte ter implementirajte incidenčno matriko za podan graf. Analizirajte porabo prostora ter ceno za `addEdge(i, j)`, `removeEdge(i, j)`, `hasEdge(i, j)`, `inEdges(i)` in `outEdges(i)`.

Naloga 12.3. Prikažite izvedbo algoritmov `bfs(G, 0)` in `dfs(G, 0)` na grafu, G , na sliki 12.7.

Naloga 12.4. Naj bo G neusmerjen graf. G je *povezan* graf, če za vsak par vozlišč i in j v G velja, da obstaja pot iz vozlišča i v vozlišče j (dokler je G neusmerjen, obstaja tudi pot iz j v i). Dokažite, da pri povezanem grafu G velja časovna zahtevnost $O(n + m)$.

Naloga 12.5. Naj bo G neusmerjen graf. *Označevanje povezanih komponent* v grafu G razdeli vozlišča od G v maksimalne množice, kjer vsaka ustvari povezan podgraf. Pokaži kako izračunati označevanje povezanih komponent grafa G v času $O(n + m)$.

Naloga 12.6. Naj bo graf G neusmerjen graf. *Vpeto drevo* grafa G je skupek dreves, kjer povezave ter vozlišča posameznih dreves, pripadajo grafu G . Izračunajte vpeto drevo grafa G pri časovni zahtevnosti $O(n+m)$.

Naloga 12.7. Rekli smo, da je graf G *kreepko povezan*, če za vsak par vozlišč i in j v G , obstaja pot iz vozlišča i v vozlišče j . Dokažite, da je pri krepko povezanem grafu G časovna zahtevnost $O(n+m)$.

Naloga 12.8. Podan je graf $G = (V, E)$ ter nekaj točk, kjer je $r \in V$. Izračunajte dolžino najkrajše poti iz točke r v i za vsako točko, kjer je $i \in V$.

Naloga 12.9. Podajte primer, kjer metoda $\text{dfs}(g, r)$ obišče vozlišča grafa v nasprotnem vrstnem redu, kot metoda $\text{dfs2}(g, r)$. Napišite novo verzijo metode $\text{dfs2}(g, r)$, ki obišče vozlišča danega grafa v enakem vrstnem redu kot metoda $\text{dfs}(g, r)$. (Namig: Sledite izvršitvi vsakega algoritma na grafu kjer je r izvor več kot 1 množice.)

Naloga 12.10. *Univerzalni ponor* v grafu G je točka, ki je ponor $n-1$ povezav in ni izvor nobene množice.¹ Zasnujte in implementirajte algoritem, ki preveri, če ima graf G , predstavljen kot `AdjacencyMatrix`, univerzalni ponor. Časovna zahtevnost vašega algoritma bi morala biti $O(n)$.

¹Univerzalni ponor, v , včasih imenujemo tudi *slavno* vozlišče. Vsi zbrani v nekem prostoru prepoznajo v , vozlišče v pa nobenega v tem prostoru.

Poglavje 13

Podatkovne strukture za cela števila


V tem poglavju se bomo vrnili k problemu implementiranja SSet-a. Razlika v implementaciji je ta, da zdaj privzamemo, da so elementi shranjeni v SSet-u, w -bitna cela števila. To pomeni da hočemo implementirati metode $\text{add}(x)$, $\text{remove}(x)$ in $\text{find}(x)$, kjer velja da $x \in \{0, \dots, 2^w - 1\}$. Če malo pomislimo obstaja veliko aplikacij, kjer imamo podatke, oziroma vsaj ključne za sortiranje podatkov, ki so cela števila.

Govorili bomo o treh podatkovnih strukturah, vsaka izmed njih bo temeljila na idejah že prej omenjenih podatkovnih strukturah. Prva struktura, `BinaryTrie`, lahko izvrši vse tri SSet operacije v času $O(w)$. To sicer ni tako zelo impresivno, saj ima vsaka podmnožica $\{0, \dots, 2^w - 1\}$ velikost $n \leq 2^w$, tako da je $\log n \leq w$. Vse ostale SSet implementacije, s katerimi imamo opravka v tej knjigi lahko izvedejo vse operacije v $O(\log n)$ času, torej so vse vsaj toliko hitre kot `BinaryTrie`.

Druga struktura, `XFastTrie`, pohitri iskanje v `BinaryTrie` z uporabo razpršenja. S to pohitritvijo se $\text{find}(x)$ operacija izvede v $O(\log w)$ času, vendar pa $\text{add}(x)$ in $\text{remove}(x)$ operaciji v `XFastTrie` še vedno potrebujeta $O(w)$ časa. Prostor, ki ga `XFastTrie` potrebuje pa je $O(n \cdot w)$.

Tretja podatkovna struktura, `YFastTrie`, uporablja `XFastTrie` za shranjevanje le vzorca enega oz. okoli enega, od vsakih w elementov in preostale elemente shranjuje v standardno SSet strukturo. Ta trik zmanjša čas izvajanja operacij $\text{add}(x)$ in $\text{remove}(x)$ na $O(\log w)$ in zmanjša prostorsko zahtevnost na $O(n)$.

Implementacije uporabljene kot primeri v tem poglavju lahko shranjujejo katerikoli tip podatkov, dokler je lahko ta podatek nekako pred-




Slika 13.1: Cela števila shranjena v binary trie so zakodirana kot poti od korena do lista.

stavljen tudi kot celo število. V primerih programske kode, predstavlja spremenljivka `ix` vedno, vrednost celega števila, ki pripada `x`. Metoda `in.intValue(x)` pa pretvori `x` v njegovo pripadajoče celo število. V besedilu bomo enostavno uporabljali `x` kot celo število.

13.1 BinaryTrie: digitalno iskalno drevo

BinaryTrie zakodira niz `w`-bitnih celih števil v binarno drevo. Vsi listi v drevesu imajo globino `w` in vsako celo število je prikazano kot pot od korena do lista. Pot za celo število `x` na nivoju `i` nadaljuje pot proti levemu poddrevesu, če je `i`-ti najpomembnejši bit (most significant bit) `x` enak 0 oz. nadaljuje pot proti desnemu poddrevesu, če je ta bit enak 1. 13.1 prikazuje primer, ko je `w = 4`, in trie shranjuje cela števila 3(0011), 9(1001), 12(1100), in 13(1101).

Ker iskalna pot za vrednost `x` odvisi od bitov `x`-a, nam bo koristilo, če otroka vozlišča poimenujemo `u`, `u.child[0]` (*left*) in `u.child[1]` (*right*). Tile kazalci na otroke bodo pravzaprav služili dvema namenoma. Ker listi v binary trie nimajo nobenega otroka, so kazalci uporabljeni za povezavo listov v dvojno povezan seznam. Za list v binary trie je `u.child[0]` (*prev*) je vozlišče, ki je pred `u`-jem v seznamu in `u.child[1]` (*next*) je vozlišče, ki



Slika 13.2: BinaryTrie z `jump` kazalci, prikazanimi kot prekinjene ukrivljene povezave.


sledi `u`-ju v seznamu. Posebno vozlišče `dummy`, je uporabljeno pred prvim vozliščem in za zadnjim vozliščem v seznamu. (glej 3.2).

Vsako vozlišče, `u`, vsebuje tudi dodatni kazalec `u.jump`. Če je `u` brez svojega levega otroka, potem `u.jump` kaže na najmanjši list v `u`-jevem poddrevesu. Če pa je `u` brez svojega desnega otroka potem `u.jump` kaže na največji list v `u`-jevem poddrevesu. Primer BinaryTrie, ki prikazuje `jump` kazalce in dvojno povezan seznam na nivoju listov, je prikazan na 13.2.

`find(x)` operacija je v BinaryTrie precej enostavna. Najprej sledimo iskalni poti za `x` v trie. Če dosežemo list, potem smo našli `x`. Če pa nalletimo na vozlišče iz katerega potem ne moremo napredovati (ker `u`-ju manjka otrok), potem sledimo `u.jump` kazalcu, ki nam kaže ali na najmanjši list, ki je še večji od `x` ali na največji list, ki je še manjši od `x`. Kateri od teh dveh primerov se zgodi odvisi od tega ali `u`-ju manjka njegov levi ali desni otrok. V prvem primeru (`u`-ju manjka njegov levi otrok), smo že prišli do vozlišča do katerega hočemo. V kasnejšem primeru (`u`-ju manjka njegov desni otrok), pa lahko uporabimo povezan seznam, da pridemo do vozlišča do katerega hočemo. Vsak od teh primerov je prikazan na 13.3.

BinaryTrie

```
T find(T x) {
    int i, c = 0, ix = it.intValue(x);
    Node u = r;
```



Slika 13.3: Poti po katerih gre find(5) in find(8).


```

for (i = 0; i < w; i++) {
    c = (ix >>> w-i-1) & 1;
    if (u.child[c] == null) break;
    u = u.child[c];
}
if (i == w) return u.x; // found it
u = (c == 0) ? u.jump : u.jump.child[next];
return u == dummy ? null : u.x;
}
    
```

Čas izvajanja metode `find(x)` je določena z časom, ki ga struktura potrebuje, da pride po poti iz korena do lista. Torej je časovna kompleksnost $O(w)$.

Tudi `add(x)` operacija je v `BinaryTrie` precej enostavna, vendar ima še vedno veliko za narediti:

1. Sledi iskalni poti za `x` dokler ne doseže vozlišča `u`, kjer ne more več nadeljevati.
2. Ustvari ostanek iskalne poti od `u` do lista, ki vsebuje `x`.
3. Vozlišče `u'`, ki vsebuje `x`, se doda povezanemu seznamu listov (metoda ima dostop do prednika, `pred`, `u'`-ja v povezanem seznamu `jump` kazalca zadnjega vozlišča `u`, na katerega smo naleteli v koraku 1.)



Slika 13.4: Dodajanje vrednosti 2 in 15 v BinaryTrie na 13.2.

4. Sledi nazaj po iskalni poti za x in sproti popravlja `jump` kazalce na vozliščih, kjer bi zdaj moral `jump` kazalec kazati na x .

Dodajanje v strukturo je prikazano na 13.4.

```

BinaryTrie
boolean add(T x) {
    int i, c = 0, ix = it.intValue(x);
    Node u = r;
    // 1 - search for ix until falling out of the trie
    for (i = 0; i < w; i++) {
        c = (ix >>> w-i-1) & 1;
        if (u.child[c] == null) break;
        u = u.child[c];
    }
    if (i == w) return false; // already contains x - abort
    Node pred = (c == right) ? u.jump : u.jump.child[0];
    u.jump = null; // u will have two children shortly
    // 2 - add path to ix
    for (; i < w; i++) {
        c = (ix >>> w-i-1) & 1;
        u.child[c] = newNode();
        u.child[c].parent = u;
        u = u.child[c];
    }
}

```

```

    }
    u.x = x;
    // 3 - add u to linked list
    u.child[prev] = pred;
    u.child[next] = pred.child[next];
    u.child[prev].child[next] = u;
    u.child[next].child[prev] = u;
    // 4 - walk back up, updating jump pointers
    Node v = u.parent;
    while (v != null) {
        if ((v.child[left] == null
            && (v.jump == null || it.intValue(v.jump.x) > ix))
            || (v.child[right] == null
            && (v.jump == null || it.intValue(v.jump.x) < ix)))
            v.jump = u;
        v = v.parent;
    }
    n++;
    return true;
}


```

Ta metoda naredi en sprehod navzdol po iskalni poti x -a in en sprehod nazaj navzgor. Vsak korak od teh sprehodov potrebuje konstantno časa, torej je časovna zahtevnost $\text{add}(x)$ enaka $O(w)$.

$\text{remove}(x)$ operacija razveljavi, kar naredi $\text{add}(x)$ operacija. Prav tako kot $\text{add}(x)$, ima tudi $\text{remove}(x)$ veliko za postoriti:

1. Najprej sledi iskalni poti za x dokler ne doseže lista u , ki vsebuje x .
2. Izbriše u iz dvojno povezanega seznama.
3. Izbriše u in se sprehodi nazaj navzgor po iskalni poti za x ter sproti briše vozlišča dokler ne doseže vozlišča v , ki ima otroka, ki ni del iskalne poti za x .
4. Sprehodi se še navzgor od v -ja do korena in spreminja jump kazalce, ki kažejo na u .

Odstranjevanje je prikazano na 13.5.



Slika 13.5: Odstranjevanje vrednosti 9 iz BinaryTrie na 13.2.

BinaryTrie

```

boolean remove(T x) {
    // 1 - find leaf, u, containing x
    int i = 0, c, ix = it.intValue(x);
    Node u = r;
    for (i = 0; i < w; i++) {
        c = (ix >>> w-i-1) & 1;
        if (u.child[c] == null) return false;
        u = u.child[c];
    }
    // 2 - remove u from linked list
    u.child[prev].child[next] = u.child[next];
    u.child[next].child[prev] = u.child[prev];
    Node v = u;
    // 3 - delete nodes on path to u
    for (i = w-1; i >= 0; i--) {
        c = (ix >>> w-i-1) & 1;
        v = v.parent;
        v.child[c] = null;
        if (v.child[1-c] != null) break;
    }
    // 4 - update jump pointers
    v.jump = u;
    for (; i >= 0; i--) {
        c = (ix >>> w-i-1) & 1;
    }
}

```

```

    if (v.jump == u)
        v.jump = u.child[1-c];
    v = v.parent;
}
n--;
return true;
}

```


Izrek 13.1. *BinaryTrie implementira SSet vmesnik za w -bitna cela števila. BinaryTrie podpira operacije $\text{add}(x)$, $\text{remove}(x)$ in $\text{find}(x)$ v časovni kompleksnosti $O(w)$ na operacijo. Prostor, ki ga BinaryTrie uporablja za shranjevanje n vrednosti je $O(n \cdot w)$.*

13.2 XFastTrie: Iskanje v dvojnem logaritmičnem času

Hitrost izvajanja BinaryTrie strukture ni ravno impresivna. Število elementov n shranjenih v podatkovni strukturi je najmanj 2^w torej $\log n \leq w$. Z drugimi besedami, vse primerjalne SSet strukture opisane v drugih poglavjih te knjige so vsaj tako učinkovite kot BinaryTrie in niso omejene samo na shranjevanje celih števil.

V slednjem besedilu je opisana XFastTrie, ki je v osnovi BinaryTrie z $w + 1$ razpršilnimi tabelami—ena za vsak nivo trie. Te razpršilne tabele se uporabljajo za pohitritev $\text{find}(x)$ operacije na $O(\log w)$ čas. $\text{find}(x)$ operacija v BinaryTrie je skoraj končana, ko dosežemo vozlišče u kjer gre iskalna pot proti x $u.\text{right}$ (oziroma $u.\text{left}$), ampak u nima desnega (oziroma levega) otroka. Na tej točki iskanje uporablja $u.\text{jump}$ za skok do lista v , ki se nahaja v BinaryTrie in vrne ali v ali pa svojega naslednika v povezanem seznamu listov. XFastTrie pohitri proces iskanja z uporabo binarnega iskanja na nivojih trie za lociranje vozlišča u .

Za uporabo binarnega iskanja moramo izvedeti ali je vozlišče u , ki ga iščemo, nad določenim nivojem i ali pod nivojem i . Ta informacija je podana prvimi i biti binarnega zapisa x ; ti biti določajo iskalno pot, ki jo naredi x od korena do nivoja i . Na primer sklicujoč na 13.6; na sliki je zadnje vozlišče u na iskalni poti za število 14 (katerega binarni zapis je 1110) označeno z 11★★ na nivoju 2, ker na nivoju tri ni nobenega vozlišča označenega z 111★. Tako lahko označimo vsako vozlišče na nivoju i z i -



Slika 13.6: Ker na sliki ni vozlišča označenega z 111★ se iskalna pot za 14 (1110) konča pri vozlišču 11★★.

bitnim celim številom. Tako bi bilo vozlišče u , ki ga iščemo, na nivoju ali nižje od nivoja i , če in samo če obstaja vozlišče na nivoju i čigar oznaka se sovpada z prvimi i biti binarnega zapisa x .

Pri XFastTrie za vsak $i \in \{0, \dots, w\}$ shranjujemo vsa vozlišča na nivoju i v USet $t[i]$, ki je implementiran kot razpršilna tabela (5). Uporaba USet nam omogoča preverjanje v konstantnem času, če obstaja vozlišče na nivoju i , ki se sovpada s prvimi i biti x . V bistvu lahko to vozlišče najdemo z uporabo $t[i].find(x \gg (w - i))$

Razpršilne tabele $t[0], \dots, t[w]$ nam omogočajo binarno iskanje za iskanje u . Vemo, da se u nahaja na nekem nivoju i z $0 \leq i < w + 1$. Tako torej inicializiramo $l = 0$ in $h = w + 1$ in ponavljajoče gledamo v razpršilno tabelo $t[i]$ kjer $i = \lfloor (l + h) / 2 \rfloor$. Če $t[i]$ vsebuje vozlišče katerega oznaka se sovpada z i prvimi biti x določimo $l = i$ (u je na nivoju ali nižje od nivoja i); v nasprotnem primeru določimo $h = i$ (u je nižje od nivoja i). Ta proces se konča ko $h - l \leq 1$, ko lahko sklepamo, da je u na nivoju l . Potem zaključimo $find(x)$ operacijo z uporabo $u.jump$ in dvojno povezanega seznama listov.

```

XFastTrie
T find(T x) {
    int l = 0, h = w+1, ix = it.intValue(x);
    Node v, u = r, q = newNode();

```

```

while (h-1 > 1) {
    int i = (l+h)/2;
    q.prefix = ix >>> w-i;
    if ((v = t[i].find(q)) == null) {
        h = i;
    } else {
        u = v;
        l = i;
    }
}
if (l == w) return u.x;
Node pred = (((ix >>> w-l-1) & 1) == 1)
    ? u.jump : u.jump.child[0];
return (pred.child[next] == dummy)
    ? null : pred.child[next].x;
}

```

Vsaka iteracija `while` zanke v zgornji metodi zmanjša $h-1$ za približno faktor ali dva, tako da ta zanka najde u po $O(\log w)$ iteracijah. Vsaka iteracija opravi konstantno količino dela in eno $\text{find}(x)$ operacijo v USet , ki porabi konstanten čas. Preostanek dela zavzame samo konstanten čas. Tako $\text{find}(x)$ metoda v XFastTrie potrebuje samo $O(\log w)$ časa.

Metodi $\text{add}(x)$ in $\text{remove}(x)$ za XFastTrie sta skoraj identični enakim metodam v BinaryTrie . Edina razlika je upravljanje z razpršilnimi tabelami $t[0], \dots, t[w]$. Ob izvajanju operacije $\text{add}(x)$, ko je ustvarjeno novo vozlišče na nivoju i , je potem to vozlišče dodano v $t[i]$. Ob izvajanju $\text{remove}(x)$ operacije, ko je vozlišče odstranjeno z nivoja i , je potem to vozlišče odstranjeno iz $t[i]$. Ker vstavljanje in brisanje iz razpršilne tabele traja konstanten čas, to ne poveča časa izvajanja $\text{add}(x)$ in $\text{remove}(x)$ za več kot konstanten faktor. Koda za $\text{add}(x)$ in $\text{remove}(x)$ je izpuščena, ker je skoraj identična (dolgi) kodi, ki se nahaja v implementaciji operacij za BinaryTrie .

Sledeči teorem povzame delovanje XFastTrie :

Izrek 13.2. *XFastTrie implementira SSet vmesnik za w -bitna cela števila. XFastTrie podpira operacije*

- $\text{add}(x)$ in $\text{remove}(x)$ v času $O(w)$ na operacijo in

- $\text{find}(x)$ v času $O(\log w)$ na operacijo

Prostorska zahtevnost XFastTrie , ki shrani n vrednosti je $O(n \cdot w)$.

13.3 YFastTrie: Dvokratni-Logaritmični Čas SSet


XFastTrie je velika, celo eksponentna, izboljšava BinaryTrie v kategoriji poizvedbenega časa, vendar operaciji $\text{add}(x)$ in $\text{remove}(x)$ še nista veliko hitrejši. Poleg tega je poraba prostora $O(n \cdot w)$ večja kot pri drugih SSet implementacijah, predstavljenih v tej knjigi, ki uporabljajo $O(n)$ prostora. Možno je, da sta ta dva problema med sabo povezana; če n $\text{add}(x)$ operacij gradi strukturo velikosti $n \cdot w$, potem operacija $\text{add}(x)$ potrebuje vsaj w časa (in prostora) na operacijo.

YFastTrie , o katerem bomo govorili naprej, izboljša hkrati porabo prostora in hitrosti XFastTrie . YFastTrie uporablja XFastTrie , xft , a le shrani $O(n/w)$ vrednosti v xft . Na ta način xft v celoti uporabi samo $O(n)$ prostora. Poleg tega je samo ena od vseh w operacij $\text{add}(x)$ ali $\text{remove}(x)$ v YFastTrie enaka operaciji $\text{add}(x)$ ali $\text{remove}(x)$ v xft . Na tak način je povprečna zahtevnost nastalih klicev na xft operacije $\text{add}(x)$ in $\text{remove}(x)$ konstantna.

Tako se lahko vprašamo: če xft shrani samo n/w elementov, kam gre preostalih $n(1 - 1/w)$ elementov? Ti elementi se shranijo v *pomožnih strukturah*, v tem primeru je to podaljšana verzija treaps (7.2). Obstaja približno n/w takšnih pomožnih struktur – tako v povprečju vsaka shrani $O(w)$ primerov. Treaps so podprte z operacijami v logaritmičnem času SSet, tako pa bodo operacije treaps delale s časom $O(\log w)$, kot je to potrebno.

Če govorimo bolj konkretno, YFastTrie vsebuje XFastTrie , xft , ki vsebuje naključne primere podatkov, kjer se vsak element pojavi v primerih neodvisno z verjetnostjo $1/w$. Zaradi prikladnosti je vrednost $2^w - 1$ vedno vsebovana v xft . Naj $x_0 < x_1 < \dots < x_{k-1}$ označuje elemente, ki so vsebovani v xft . Povezan z vsakim elementom x_i je treap t_i , ki shrani vse vrednosti v dosegu $x_{i-1} + 1, \dots, x_i$. To je ilustrirano na 13.7.

$\text{find}(x)$ operacija v YFastTrieX je dokaj enostavna. V xft iščemo x in najdemo nekaj vrednosti x_i povezanih z treap t_i . Potem uporabimo



Slika 13.7: A YFastTrie containing the values 0, 1, 3, 4, 6, 8, 9, 10, 11, and 13.

metodo treap `find(x)` na `ti` za odgovor na poizvedbo. Ta metoda se lahko v celoti zapiše v eni vrstici:

```

YFastTrie
T find(T x) {
    return xft.find(new Pair<T>(it.intValue(x))).t.find(x);
}

```

Prva `find(x)` operacija (na `xft`) vzame $O(\log w)$ časa. Druga `find(x)` operacija (nad treap) vzame $O(\log r)$ časa, kjer je r velikost treap. Kasneje v tem razdelku, bomo pokazali, da je pričakovana velikost treap $O(w)$ torej ta operacija vzame $O(\log w)$ časa.¹

Dodajanje elementa v YFastTrie je tudi dokaj preprosto—večino časa. `Add(x)` metoda pokliče `xft.find(x)` ta alocira treap, `t`, v katerega bo `x` lahko vstavljen. Ta potem pokliče `t.add(x)` za dodajanje `x` k `t`. Pri tej točki, meče nepristranski kovanec katerih glave pridejo z verjetnostjo $1/w$ in tudi repi z verjetnostjo $1 - 1/w$. Če na kovanču dobimo glave, potem bo `x` dodan k `xft`.

¹To je aplikacija *Jensenove neenakosti*: If $E[r] = w$, then $E[\log r] \leq \log w$.

Tukaj stvari postanejo malce bolj zapletene. Ko je x dodan k xft , mora biti treap t razdeljeno na dva treaps, $t1$ in t' . Treaps $t1$ vsebuje vse vrednosti manjše ali enake od x ; t' je prvotno treap, t , z vsemi odstranjenimi elementi $t1$. Ko je to narejeno, dodamo par $(x, t1)$ k xft . 13.8 prikazuje primer.

```

YFastTrie
boolean add(T x) {
    int ix = it.intValue(x);
    STreap<T> t = xft.find(new Pair<T>(ix)).t;
    if (t.add(x)) {
        n++;
        if (rand.nextInt(w) == 0) {
            STreap<T> t1 = t.split(x);
            xft.add(new Pair<T>(ix, t1));
        }
        return true;
    }
    return false;
}

```

Dodajanje x k t vzame $O(\log w)$ časa. 7.12 prikazuje, da je razdelitev t v $t1$ in t' lahko narejena v $O(\log w)$ pričakovanem času. Dodajanje para $(x, t1)$ k xft vzame $O(w)$ časa, ampak se zgodi samo z verjetnostjo $1/w$. Zato je, pričakovan čas poteka $\text{add}(x)$ operacije


$$O(\log w) + \frac{1}{w} O(w) = O(\log w) .$$

$\text{Remove}(x)$ metoda razveljavi delo, ki se izvede z $\text{add}(x)$. xft uporabimo, da najdemo list u , in xft , ki vsebuje odgovor za $xft.\text{find}(x)$. Iz u , dobimo treap, t , ki vsebuje x in ta x odstrani iz t . Če je bil x shranjen v xft (in x ni enak $2^w - 1$) potem odstranimo x iz xft in dodamo elemente iz x -tega treap v treap, $t2$, ki je shranjen v u -tem nasledniku v povezanem seznamu. To je prikazano v 13.9.

```

YFastTrie
boolean remove(T x) {
    int ix = it.intValue(x);
    Node<T> u = xft.findNode(ix);
}

```

Slika 13.10: Število elementov v poddrevesu t , ki vsebujejo x je določeno z metanjem dveh kovancev.

$n_x = j + k$, torej velja

$$E[n_x] = E[j + k] = E[j] + E[k] \leq 2w - 1 . \quad \square$$

13.1 Je zadnji del v dokazu teorema, ki povzema učinkovitost `YFastTrie`:

Izrek 13.3. *`YFastTrie` implementira `SSet` vmestnik za w -bitna cela števila. `YFastTrie` podpira operacije `add(x)`, `remove(x)`, in `find(x)` v pričakovanem času $O(\log w)$ na operacijo. Prostor, ki ga `YFastTrie` porabi za hrambo n vrednosti je $O(n + w)$.*

Dodaten člen w pri prostorski zahtevnosti prihaja iz dejstva, da `xft` vedno hrani vrednost $2^w - 1$. Implementacija je lahko drugačna (v zakup moramo vzeti dodajanje kode) in ni potrebno hraniti te vrednosti. V tem primeru prostorska zahtevnost teorema postane $O(n)$.

13.4 Razprava in vaje

Prvo podatkovno strukturo, ki zagotavlja časovno zahtevnost $O(\log w)$ za operacije `add(x)`, `remove(x)`, in `find(x)` je predlagal van Emde Boas in je od takrat poznana kot *van Emde Boas* (or *razslojeno drevo* [?]. Prvotna van Emde Boas struktura je imela velikost 2^w in je bila zato nepraktična za večja cela števila.

Podatkovni strukturi `XFastTrie` in `YFastTrie` je odkril Willard [?]. Struktura `XFastTrie` je močno povezana z drevesom van Emde Boas; na primer, razpršene tabele v `XFastTrie` nadomestijo matrike v drevesu van Emde Boas. To pomeni, da drevo van Emde Boas hrani matriko dolžine 2^i namesto razpršene tabele `t[i]`.

Druga struktura za hranitev celih števil so Fredman in Willardova fuzijska drevesa [?]. Ta struktura lahko hrani n w -bitnih števil v prostoru $O(n)$ tako, da se operacija `find(x)` izvede v času $O((\log n)/(\log w))$. S kombinacijo fuzijskih dreves, ko je $\log w > \sqrt{\log n}$ in `YFastTrie`, ko je $\log w \leq \sqrt{\log n}$, pridobimo prostorno podatkovno strukturo $O(n)$, ki lahko implementira operacijo `find(x)` v času $O(\sqrt{\log n})$. Nedavni rezultati spodnje meje Pătraşcu in Thorup [?] kažejo na to, da so ti rezultati bolj ali manj optimalni, vsaj kar se tiče struktur, ki porabijo le $O(n)$ prostora.

Naloga 13.1. Sestavi in implementiraj poenostavljeno različico `BinaryTrie`, ki nima kazalcev povezanega seznama ali skakalnih kazalcev, operacija `find(x)` pa teče v $O(w)$ času.

Naloga 13.2. Sestavi in izpelji poenostavljeno implementacijo `XFastTrie`, ki ne uporablja dvojiškega drevesa. Namesto tega naj vaša implementacija vse hrani v dvojno povezanem seznamu in v $w + 1$ razpršenih tabelah.

Naloga 13.3. `BinaryTrie` si lahko predstavljamo kot strukturo, ki hrani bitne nize dolžine w na tak način, da je vsak bitni niz predstavljen kot pot, od korena do lista. Uporabite to idejo pri izvedbi `SSet`, ki hrani nize spremenljive dolžine in implementira `add(s)`, `remove(s)`, in `find(s)` v času sorazmernem dolžini s .

Namig: Vsako vozlišče v vaši podatkovni strukturi naj hrani razpršeno tabelo, ki je indeksirana z vrednostjo znaka.

Naloga 13.4. Za število $x \in \{0, \dots, 2^w - 1\}$, kjer $d(x)$ pomeni razliko med x in vrednostjo, ki jo vrne `find(x)` [če `find(x)` vrne `null`, potem določi $d(x)$ kot 2^w]. Na primer, če `find(23)` vrne 43, potem $d(23) = 20$.

1. Sestavi in implementiraj spremenjeno različico operacije `find(x)` v `XFastTrie`, ki se izvaja v času $O(1 + \log d(x))$. Nasvet: Razpršena tabela $t[w]$ vsebuje vse vrednosti, x , kot so $d(x) = 0$, torej bi bilo tu najboljše začeti.
2. Sestavi in implementiraj spremenjeno različico operacije `find(x)` v `XFastTrie`, ki se izvaja v času $O(1 + \log \log d(x))$.


Poglavje 14

Iskanje v zunanjem pomnilniku

Skozi knjigo smo uporabljali *w*-bitni besedni-RAM model računanja, katerega smo opredelili v 1.4. Implicitna predpostavka tega modela je, da ima naš računalnik dovolj velik bralno-pisalni pomnilnik za shranjevanje vseh podatkov v podatkovni strukturi. V nekaterih primerih ta predpostavka ni veljavna. Obstajajo zbirke podatkov, ki so tako velike, da noben računalnik nima dovolj glavnega pomnilnika za njihovo shranjevanje. V takih primerih se mora aplikacija zateči k shranjevanju podatkov na pomožni, zunanji pomnilniški medij, kot je trdi disk, SSD disk ali celo omrežni datotečni strežnik (ki ima lastno zunanje shranjevanje).

Dostopanje do elementa v zunanjem pomnilniku je zelo počasno. Trdi disk v računalniku, na katerem je bila spisana ta knjiga, ima povprečen čas dostopa 19 ms, SSD disk pa ima povprečen čas dostopa 0,3 ms. Za primerjavo, bralno-pisalni pomnilnik v računalniku ima povprečen čas dostopa manj kot 0,000113 ms. Dostop do RAM-a je več kot 2.500-krat hitrejši kot dostop do SSD diska, ter več kot 160.000-krat hitrejši kot dostop do trdega diska.

Te hitrosti so dokaj tipične; dostopanje do naključnega bajta v RAM-u je tisočkrat hitrejše kot dostopanje do naključnega bajta na trdem disku ali SSD disku. Čas dostopa pa vseeno ne pove vsega. Ko dostopamo do bajta na trdem disku ali SSD disku je prebran celoten *blok* diska. Vsak izmed diskov na računalniku ima velikost bloka 4 096; vsakič, ko preberemo en bajt, nam disk vrne blok, ki vsebuje 4 096 bajtov. Če našo podatkovno strukturo skrbno organiziramo, to pomeni, da z vsakim dostopom do diska dobimo 4 096 bajtov, ki so nam v pomoč pri dokončanju



Slika 14.1: V modelu zunanjega pomnilnika, dostop do posameznega elementa x v zunanjem pomnilniku, zahteva branje celotnega bloka, ki vsebuje x , v glavni pomnilnik.

operacije.

To je ideja računanja z *modelom zunanjega pomnilnika*, shematsko prikazanega v 14.1. Pri tem modelu ima računalnik dostop do velikega zunanjega pomnilnika, kjer so vsi podatki. Ta pomnilnik je razdeljen na spominske *bloke*, kjer vsak vsebuje B besed. Računalnik ima tudi omejen notranji pomnilnik na katerem lahko opravlja izračune. Čas za prenos bloka med notranjim in zunanjim pomnilnikom je konstanten. Izračuni izvedeni v notranjem pomnilniku so *zanemarljivi*; ne vzamejo nič časa. Da so izračuni na notranjem pomnilniku *zanemarljivi*, se morda sliši malo nenavadno, vendar le preprosto poudarja dejstvo, da je zunanji pomnilnik toliko počasnejši od RAM-a.

V popolnem modelu zunanjega pomnilnika je velikost notranjega pomnilnika tudi parameter. Vendar pa za podatkovne strukture opisane v tem poglavju zadošča, da imamo notranji pomnilnik velikosti $O(B + \log_B n)$. To pomeni, da mora biti pomnilnik sposoben shraniti konstantno število blokov in rekurziven sklad višine $O(\log_B n)$. V večini primerov, izraz $O(B)$ prevladuje pri zahtevah po pomnilniku. Na primer, tudi pri relativno majhni vrednosti $B = 32$, $B \geq \log_B n$ za vse $n \leq 2^{160}$. V desetiškem

zapisu, $B \geq \log_B n$ za vse

$$n \leq 1\,461\,501\,637\,330\,902\,918\,203\,684\,832\,716\,283\,019\,655\,932\,542\,976 \ .$$

14.1 Bločna shramba

Pojem zunanjega pomnilnika vključuje veliko število različnih naprav, od katerih ima vsaka svojo velikost bloka in je dostopna s svojo zbirko sistemskih klicev. Da poenostavimo razlago tega poglavja in se osredotočimo na skupne ideje, povzamemo zunanje pomnilniške naprave z objektom bločna shramba. Bločna shramba hrani zbirko spominskih blokov, kjer ima vsak velikost B . Vsak blok je enolično določen s celoštevilskim indeksom. Bločna shramba podpira sledeče operacije:

1. `readBlock(i)`: Vrne vsebino bloka z indeksom i .
2. `writeBlock(i,b)`: Zapiše vsebino bloka b v blok z indeksom i .
3. `placeBlock(b)`: Vrne nov indeks in shrani vsebino bloka b na ta indeks.
4. `freeBlock(i)`: Sprosti blok z indeksom i . To nakazuje, da vsebina tega bloka ni več v uporabi in, da se zunanji pomnilnik, ki je bil dodeljen temu bloku, lahko ponovno uporabi.

Bločno shrambo si najlažje predstavljamo tako, da si ga zamislimo kot shranjevanje datoteke na disk, kateri je razdeljen na bloke, kjer vsak vsebuje B bajtov. Na ta način `readBlock(i)` in `writeBlock(i,b)` preprosto bereta in zapisujeta bajte $iB, \dots, (i+1)B-1$ te datoteke. Poleg tega bi preprosta bločna shramba lahko vodila *prosti seznam* blokov, ki so na voljo za uporabo. Bloki, sproščeni s `freeBlock(i)`, so dodani prostemu seznamu. Na ta način lahko `placeBlock(b)` uporabi blok iz prostega seznama ali, če nobeden ni na voljo, doda nov blok na konec datoteke.

14.2 B-drevesa

V tem poglavju bomo razpravljali o posplošitvah dvojiških dreves, imenovanih B -drevesa, ki so učinkovita predvsem v zunanjem pomnilniškem

modelu. Alternativno se na B -drevesa lahko gleda kot na posplošitev 2-4 dreves, opisana v poglavju 9.1. (2-4 drevo je posebni primer B -drevesa, ki ga dobimo z določitvijo $B = 2$.)

Za katerokoli število $B \geq 2$ je B -drevo, drevo, pri katerem imajo vsi listi enako globino in vsako notranjo vozlišče (z izjemo korena), u , ima najmanj B otrok in največ $2B$ otrok. Otroci vozlišča u so shranjeni v polju $u.children$. Zahtevano število otrok ne velja pri korenu, ki pa ima lahko število otrok med 2 in $2B$.

Če je višina B -drevesa h , iz tega sledi, da število listov v B -drevesu ℓ , izpolnjuje naslednji neenakosti:

$$2B^{h-1} \leq \ell \leq 2(2B)^{h-1} .$$

Vzamemo logaritem iz prve neenakosti in preuredimo. Dobimo:

$$\begin{aligned} h &\leq \frac{\log \ell - 1}{\log B} + 1 \\ &\leq \frac{\log \ell}{\log B} + 1 \\ &= \log_B \ell + 1 . \end{aligned}$$


Višina B -drevesa je sorazmerna logaritmu števila listov z osnovo B .

Vsako vozlišče, u , v B -drevesu shranjuje polje ključev $u.keys[0], \dots, u.keys[2B-1]$. Če je u notranje vozlišče z k otroci, potem je število ključev, ki so shranjeni v u natanko $k-1$ in ti so shranjeni v $u.keys[0], \dots, u.keys[k-2]$. Ostalih $2B - k + 1$ mest v polju $u.keys$ je nastavljeno na `null`. Če je u notranje vozlišče in ni koren, potem u vsebuje med $B - 1$ in $2B - 1$ ključev. Ključi v B -drevesu so razvrščeni podobno kot ključi v dvojiškem iskalnem drevesu. Za vsako vozlišče u , ki shranjuje $k - 1$ ključev velja:

$$u.keys[0] < u.keys[1] < \dots < u.keys[k-2] .$$

Če je u notranje vozlišče, potem za vsak $i \in \{0, \dots, k-2\}$ velja, da $u.keys[i]$ je večji od vseh ključev shranjenih v poddrevesu zakoreninjenega na $u.children[i]$ vendar manjši od vseh ključev shranjenih v poddrevesu, ki je zakoreninjen na $u.children[i+1]$.

$$u.children[i] < u.keys[i] < u.children[i+1] .$$



Slika 14.2: B -drevo, $B = 2$.

Primer B -drevesa z $B = 2$ je prikazan na sliki 14.2.

Upoštevajte, da so podatki shranjeni v vozliščih B -drevesa velikosti $O(B)$. Zato je v nastavitvah zunanega pomnilnika vrednost B za B -drevo določena tako, da celotno vozlišče lahko ustreza enemu zunanje pomnilniškemu bloku. V tem primeru je čas izvajanja operacij na B -drevesu v zunanjem spominskem modelu sorazmerno številu vozlišč, ki jih obiščemo (branje ali pisanje) med operacijo.

Poglejmo si primer. Če ključe predstavljajo 4 bajtna števila in indeksi vozlišč so prav tako veliki 4 bajte, potem nastavev $B = 256$ pomeni, da vsako vozlišče hrani

$$(4 + 4) \times 2B = 8 \times 512 = 4096$$


bajtov podatkov. To bi bila odlična vrednost B za trdi disk ali pogon SSD (predstavljen v uvodu tega poglavja), kateri ima velikost bloka 4096 bajtov.

BTree razred, ki implementira B -drevo, vsebuje `BlockStore`, `bs`, ki vsebuje BTree vozlišča in prav tako indeks, `ri`, korena. Kot ponavadi, število `n` predstavlja količino podatkov v podatkovni strukturi:

```

BTree
int n;
BlockStore<Node> bs;
int ri;

```



Slika 14.3: Uspešno iskanje (vrednosti 4) in neuspešno iskanje (za vrednost 16.5) v *B*-drevesu. Obarvana vozlišča predstavljajo, kje se je vrednost med iskanjem *z*ja spremenila.


14.2.1 Iskanje

Implementacija operacije `find(x)`, ilustrirana v 14.3, je posplošitev operacije `find(x)` v dvojiškem iskalnem drevesu. Iskanje *x*-a se začne v korenu. Z uporabo ključev, shranjenih v vozlišču, *u*, določimo v katerem otroku od *u* bomo nadaljevali iskanje.

Bolj natančno, v vozlišču *u* iskanje preveri če je *x* shranjen v *u.keys*. Če je, je bil *x* najden in iskanje je zaključeno. V nasprotnem primeru, najdemo najmanjše število *i*, da je *u.keys[i] > x* in nadaljujemo iskanje v poddrevesu zakoreninjenem na *u.children[i]*. Če noben ključ v *u.keys* ni večji od *x*, potem iskanje nadaljujemo v najbolj desnem otroku od *u*. Tako kot pri dvojiškem iskalnem drevesu, si algoritem zapolni nedavno viden ključ, *z*, ki je večji od *x*. V primeru, ko *x* ni najden, se *z* vrne kot najmanjša vrednost, ki je večja ali enaka *x*.

```

BTTree
T find(T x) {
    T z = null;
    int ui = ri;
    while (ui >= 0) {
        Node u = bs.readBlock(ui);
        int i = findIt(u.keys, x);
        if (i < 0) return u.keys[-(i+1)]; // found it
        if (u.keys[i] != null)
            z = u.keys[i];
        ui = u.children[i];
    }
}
    
```



Slika 14.4: Izvajanje metode `findIt(a, 27)`.

```

    return z;
}

```

Osrednjega pomena za metodo `find(x)` je metoda `findIt(a, x)`, ki išče v `null`-napolnjeno urejeno polje, `a`, vrednost `x`. Ta metoda, predstavljena v 14.4, deluje za vsako polje, `a`, kjer je `a[0], ..., a[k-1]` urejeno zaporedje ključev in so `a[k], ..., a[a.length-1]` vsi postavljeni na `null`. Če je `x` v polju na mestu `i`, potem metoda `findIt(a, x)` vrne `-i-1`. V nasprotnem primeru vrne najmanjši indeks, `i`, za katerega velja, da `a[i] > x` ali `a[i] = null`.

```

BTTree
int findIt(T[] a, T x) {
    int lo = 0, hi = a.length;
    while (hi != lo) {
        int m = (hi+lo)/2;
        int cmp = a[m] == null ? -1 : compare(x, a[m]);
        if (cmp < 0)
            hi = m;           // look in first half
        else if (cmp > 0)
            lo = m+1;         // look in second half
        else
            return -m-1;      // found it
    }
    return lo;
}

```

Metoda `findIt(a, x)` uporabi dvojiško iskanje, ki razpolovi iskanje pri

vsakem koraku. Za delovanje porabi $O(\log(a.\text{length}))$ časa. V našem primeru, $a.\text{length} = 2B$, zato $\text{findIt}(a, x)$ porabi $O(\log B)$ časa.

Čas delovanja obeh operacij B -drevesa $\text{find}(x)$ lahko analiziramo v običajnem besednem-RAM modelu (kjer štejemo vsak ukaz) in v zunanjem pomnilniškem modelu (kjer štejemo samo število obiskanih vozlišč). Ker vsak list v B -drevesu shranjuje vsaj en ključ in je višina B -drevesa z ℓ listi $O(\log_B \ell)$, je višina od B -drevesa, ki shranjuje n ključev $O(\log_B n)$. Zato je v zunanjem pomnilniškem modelu čas, ki ga porabi operacija $\text{find}(x)$ $O(\log_B n)$. Da določimo čas delovanja v RAM modelu, moramo računati čas klicanja operacije $\text{findIt}(a, x)$ za vsako vozlišče, ki ga obiščemo. Čas delovanja operacije $\text{find}(x)$ v modelu besedni RAM je


$$O(\log_B n) \times O(\log B) = O(\log n) .$$

14.2.2 Dodajanje

Ena glavnih razlik med podatkovnima strukturama B -dreves in dvojiških iskalnih dreves (6.2) je, da vozlišča B -dreves ne hranijo kazalcev na njihove starše. Vzrok tega bomo razložili malce kasneje. Ker kazalci na starše ne obstajajo, pomeni, da je operaciji $\text{add}(x)$ in $\text{remove}(x)$ v B -drevesih najlažje implementirani s pomočjo rekurzije.

Kot za vsa uravnotežena iskalna drevesa je tudi tu potrebno uravnoteženje drevesa, če se pri izvajanju operacije $\text{add}(x)$ drevo izrodi. Pri B -drevesih za to skrbi *razdeljevanje* vozlišč. Za nadaljevanje glejte 14.5. Čeprav razdeljevanje deluje na dveh plasteh drevesa, je najbolj razumljivo, kot operacija, ki vzame vozlišče u , ki vsebuje $2B$ ključev in ima $2B + 1$ otrok. Ustvari novo vozlišče w , ki podeduje $u.\text{children}[B], \dots, u.\text{children}[2B]$. Novo vozlišče w prav tako vzame največje ključe $B, u.\text{keys}[B], \dots, u.\text{keys}[2B - 1]$ od vozlišča u . Na tej točki ima u B otrok in B ključev. Dodaten ključ, $u.\text{keys}[B - 1]$, se posreduje staršem vozlišča u , posreduje pa se tudi vozlišče w .

Opazimo, da operacija razdeljevanja spreminja tri vozlišča: u , starše vozlišča u in novo vozlišče w . Sedaj smo prišli do odgovora, zakaj vozlišča B -dreves ne ohranjajo kazalcev na starše. Če bi jih, bi morali vsem $B + 1$ otrokom, ki so podedovani vozlišču w popraviti kazalce na njihove starše. Število dostopov do zunanjega pomnilnika bi se povečalo s 3 na $B + 4$




Slika 14.5: Razdeljvanje vozlišča u v B -drevesu ($B = 3$). Opazimo, da se ključ $u.keys[2] = m$ posreduje iz u njegovim staršem.

dostope. To bi poslabšalo učinkovitost B -drevesa pri večjih številih B .

Metoda $add(x)$ v B -drevesih je prikazana v 14.6. V višji plasti metoda poišče list, u , v katerega bo dodala vrednost x . Če dodajanje pozroči, da u postane prepoln (ker že vsebuje $B - 1$ ključev), se u razdeli. Lahko se zgodi, da postanejo tudi starši prepolni. V tem primeru se razdelijo tudi starši. To lahko spet povzroči deljenje prastaršev vozlišča u in tako naprej. To se vzpenja po drevesu toliko časa, dokler ne doseže vozlišča, ki ni prepoln ali dokler se koren drevesa ne razdeli. V prvem primeru se postopek ustavi. V drugem primeru, se ustvari novo vozlišče, katerega otroci postanejo pridobljena vozlišča pri razdelitvi prvotnega korena.

Povzetek metode $add(x)$ je, da se sprehaja od korena do iskanega(x) lista, doda x v ta list, se začne pomikati nazaj proti korenu, razdeli vsa prepolna vozlišča na katere naleti na poti navzgor. S tem preletom v mi-



Slika 14.6: Operacija $\text{add}(x)$ v B-drevesu. Dodajanje vrednosti 21, dva vozlišča se razdelita

sljih, se lahko sedaj spustimo v detajle, kako naj bo ta rekurzivna metoda implementirana.

Večino dela `add(x)` je narejenega z metodo `addRecursive(x,ui)`, katera doda vrednost `x` v poddrevo, katerega koren `u`, ima identifikator `ui`. Če je `u` list, se `x` enostavno vsavi v `u.keys`, sicer se doda rekurzivno v poddrevo ustreznega sina `u'` od `u`. Rezultat tega rekurzivnega klica je ponavadi `null`, ampak lahko je tudi referenca na novo kreirano vozlišče `w`, kateri je nastal zaradi razdelitve `u'`. V tem primeru `u` podeduje `w` in vzame njegovo prvo vrednost, ter dokonča razdelitev na `u'`.

Ko je bila vrednost `x` dodana (ali v `u` ali v naslednike `u`), metoda `addRecursive(x,ui)` preveri, če `u` hrani preveč (več kot $2B - 1$) ključev. V primeru ko jih hrani preveč, se mora `u` razdeliti z klicom metode `u.split()`. Rezultat klica `u.split()` je novo vozlišče, ki je uporabljeno kot rezultat metode `addRecursive(x,ui)`.

```
BTTree
Node addRecursive(T x, int ui) {
    Node u = bs.readBlock(ui);
    int i = findIt(u.keys, x);
    if (i < 0) throw new DuplicateValueException();
    if (u.children[i] < 0) { // leaf node, just add it
        u.add(x, -1);
        bs.writeBlock(u.id, u);
    } else {
        Node w = addRecursive(x, u.children[i]);
        if (w != null) { // child was split, w is new child
            x = w.remove(0);
            bs.writeBlock(w.id, w);
            u.add(x, w.id);
            bs.writeBlock(u.id, u);
        }
    }
    return u.isFull() ? u.split() : null;
}
```

Metoda `addRecursive(x,ui)` je pomožna metoda metode `add(x)`, katera kliče `addRecursive(x,ri)`, da vstavi `x` v koren `B`-drevesa. Če `addRecursive(x,ri)` povzroči, da se koren razdeli, se ustvari nov koren in si za svoje otroke

vzame otroke starega korena in otroke novega vozlišča, pridobljenega pri razdelitvi starega korena.

```

BTTree
boolean add(T x) {
    Node w;
    try {
        w = addRecursive(x, ri);
    } catch (DuplicateValueException e) {
        return false;
    }
    if (w != null) {    // root was split, make new root
        Node newroot = new Node();
        x = w.remove(0);
        bs.writeBlock(w.id, w);
        newroot.children[0] = ri;
        newroot.keys[0] = x;
        newroot.children[1] = w.id;
        ri = newroot.id;
        bs.writeBlock(ri, newroot);
    }
    n++;
    return true;
}

```

Metodo `add(x)` in pomožno metodo `addRecursive(x,ui)` lahko analiziramo v dveh fazah:

faza ugrezanja: Med fazo ugrezanja rekurzije, preden je `x` dodan, imamo dostop do zaporedja vozlišč B -dreves in nad vsakim vozliščem kličemo metodo `findIt(a,x)`. Kot pri metodi `find(x)` to potrebuje $O(\log_B n)$ časa v zunanjem spominskem modelu in $O(\log n)$ časa v modelu RAM.

faza vzpenjanja: Med fazo vzpenjanja rekurzije, po tem ko je `x` dodan, lahko to izvede največ $O(\log_B n)$ delitev. Vsaka razdelitev vsebuje tri vozlišča, tako, da ta faza porabi $O(\log_B n)$ časa v zunanjem spominskem modelu. Vendar vsaka razdelitev zahteva premikanje B ključev in otrok iz enega vozlišča na drugega, tako da porabi $O(B \log n)$ časa v modelu RAM.

Spomnimo, da je lahko vrednost B precej velika, veliko večja kot $\log n$. Zato je v modelu RAM, dodajanje vrednosti v B -drevo lahko veliko počasije kot dodajanje v uravnovešeno binarno iskalno drevo. Kasneje v 14.2.4, bomo pokazali, da situacija ni tako zelo slaba; amortizacijska številka operacij razdelitve med izvajanjem operacije $\text{add}(x)$ je konstantna. To kaže na to, da (amortiziran) izvajalni čas operacije $\text{add}(x)$ v modelu RAM $O(B + \log n)$.

14.2.3 Odstranjevanje


Operacija $\text{remove}(x)$ v BTree je prav tako najlažje implementirana kot rekurzivna metoda. Čeprav rekurziven način implementacije metode $\text{remove}(x)$ razširi kompleksnost čez več metod, je celoten proces, kot je prikazan v 14.7, dokaj preprost. S prestavljanjem ključev okrog problem skrbimo na odstranitev vrednosti, x' , iz določenega lista, u . Odstranitev x' lahko pusti u z manj kot $B - 1$ ključi; takšen dogodek se imenuje *spodnja prekoračitev*.

V primeru spodnje prekoračitve, si u sposodi ključe od ali je združen z enim od svojih sorodnikov. Če pride do združitve u s sorodnikom, bo sedaj u -jev starš imel enega otroka in enega ključa manj, kar lahko povzroči spodnjo prekoračitev u -jevega starša; to je ponovno popravljeno z izposojami ali združitvijo, vendar združitve lahko povzroči spodnjo prekoračitev u -jevega starega starša. Ta proces se ponavlja vse nazaj do korena, dokler ne pride več do prekoračitve ali se korenova zadnja otroka združita v enega samega. Če se zgodi slednje, je koren odstranjen in njegov preostali otrok postane nov koren.


Sledi podroben ogled načina implementacije posameznega koraka. Prva naloga metode $\text{remove}(x)$ je poiskati element x , ki ga želimo odstraniti. Če se x nahaja v listu, sledi odstranitev x iz tega lista. V nasprotnem primeru, če je x najden v $u.\text{keys}[i]$ za neko notranje vozlišče u , algoritem odstrani najmanjšo vrednost, x' , v poddrevesu s korenem, ki se nahaja na $u.\text{children}[i + 1]$. Vrednost x' je najmanjša vrednost shranjena v BTree, ki je večja od x . Vrednost x' -a nato zamenja vrednost x v $u.\text{keys}[i]$. Ta proces je prikazan v 14.8.

Metoda $\text{removeRecursive}(x, u)$ je rekurzivna implementacija predhodnega algoritma:

Iskanje v zunanjem pomnilniku



Slika 14.7: Odstranitev vrednosti 4 iz B-drevesa povzroči eno združitve in eno izposajo.



Slika 14.8: Operacija $\text{remove}(x)$ v B-drevesu. Da odstranimo vrednost $x = 10$, jo zamenjamo z $x' = 11$ in odstranimo 11 iz lista, ki jo vsebuje.

```

BTree
boolean removeRecursive(T x, int ui) {
    if (ui < 0) return false; // didn't find it
    Node u = bs.readBlock(ui);
    int i = findIt(u.keys, x);
    if (i < 0) { // found it
        i = -(i+1);
        if (u.isLeaf()) {
            u.remove(i);
        } else {
            u.keys[i] = removeSmallest(u.children[i+1]);
            checkUnderflow(u, i+1);
        }
        return true;
    } else if (removeRecursive(x, u.children[i])) {
        checkUnderflow(u, i);
        return true;
    }
    return false;
}

T removeSmallest(int ui) {

```

```

Node u = bs.readBlock(ui);
if (u.isLeaf())
    return u.remove(0);
T y = removeSmallest(u.children[0]);
checkUnderflow(u, 0);
return y;
}

```

Po rekurzivnem odstranjevanju vrednosti x iz i -tega otroka u -ja mora `removeRecursive(x, ui)` zagotoviti, da ima ta otrok še vedno vsaj $B - 1$ ključev. V predhodni kodi je to zagotovljeno z metodo `checkUnderflow(x, i)`, ki preveri podkoračitev v i -temu otroku u -ja in jo po potrebi popravi. Naj bo w i -ti otrok u -ja. Če ima w samo $B - 2$ ključev, ga je treba popraviti, za kar pa potrebujemo w -jevega brata, ki je lahko u -jev otrok z indeksom $i + 1$ ali z indeksom $i - 1$. Ponavadi izberemo tistega z indeksom $i - 1$, ki je w -jev brat neposredno na njegovi levi. Recimo mu v . Edini primer v katerem to ne deluje je kadar je $i = 0$. V tem primeru uporabimo brata, ki je neposredno na w -jevi desni.


```

                                     BTree
void checkUnderflow(Node u, int i) {
    if (u.children[i] < 0) return;
    if (i == 0)
        checkUnderflowZero(u, i); // use u's right sibling
    else
        checkUnderflowNonZero(u, i);
}

```

Sedaj se osredotočimo na primer, ko je $i \neq 0$, tako da bo kakršnakoli podkoračitev pri i -temu otroku vozlišča u popravljena s pomočjo njegovega otroka z indeksom $(i - 1)$. Primer, ko je $i = 0$ je podoben. Podrobnosti so v izvorni kodi. Da popravimo podkoračitev v vozlišču w , moramo temu vozlišču najti več ključev (in po možnosti tudi otrok). To lahko storimo na dva načina:

Izposojanje: Če ima w brata v z več kot $B - 1$ ključi, si lahko w od v -ja izposodi nekaj ključev (in po možnosti tudi otrok). Natančneje, če




Slika 14.9: Če ima v več kot $B - 1$ ključev, jih lahko posodi w -ju.

ima v $\text{size}(v)$ ključev, imata v in w skupaj

$$B - 2 + \text{size}(w) \geq 2B - 2$$

ključev. Torej lahko v -jeve ključve prestavimo w -ju tako, da imata v in w vsaj $B - 1$ ključev. Ta proces je prikazan v 14.9.

Združevanje: Če ima v samo $B - 1$ ključev, moramo narediti nekaj bolj zahtevnega, saj v ne more posoditi nobenega ključa w -ju. Zato vozlišči w in v združimo, kot je prikazano v 14.10. Združevanje je nasprotna operacija razdelitve. Dve vozlišči, ki imata skupaj $2B - 3$ ključev in ju združi v eno samo vozlišče v $2B - 2$ ključi. Dodaten ključ dobimo zato, ker ima po združevanju v -ja in w -ja njun starš u enega otroka manj in mora zato oddati en ključ.



Slika 14.10: Merging two siblings v and w in a B-tree ($B = 3$).

```

void checkUnderflowNonZero(Node u, int i) {
    Node w = bs.readBlock(u.children[i]); // w is child of u
    if (w.size() < B-1) { // underflow at w
        Node v = bs.readBlock(u.children[i-1]); // v left of w
        if (v.size() > B) { // w can borrow from v
            shiftLR(u, i-1, v, w);
        } else { // v will absorb w
            merge(u, i-1, v, w);
        }
    }
}

void checkUnderflowZero(Node u, int i) {
    Node w = bs.readBlock(u.children[i]); // w is child of u
    if (w.size() < B-1) { // underflow at w
        Node v = bs.readBlock(u.children[i+1]); // v right of w
        if (v.size() > B) { // w can borrow from v
            shiftRL(u, i, v, w);
        } else { // w will absorb v
            merge(u, i, w, v);
            u.children[i] = w.id;
        }
    }
}

```

Da povzamemo, metoda `remove(x)` v B -drevesu gre od korenkega vozlišča do lista, odstrani ključ x' iz lista u in nato izvede nič ali več operacij združevanja med u -jem in njegovimi predniki in največ eno operacijo izposojanja. Ker pri vsaki operaciji združevanja in izposojanja spreminjamo največ tri vozlišča, in ker se izvede samo $O(\log_B n)$ takih operacij, to v modelu zunanega pomnilnika porabi $O(\log_B n)$ časa. Kakorkoli že, vsaka operacija združevanja in izposojanja potrebuje $O(B)$ časa v besednem-RAM modelu, zato lahko (za zdaj) za časovno zahtevnost operacije `remove(x)` trdimo, da spada v razred $O(B \log_B n)$.

14.2.4 Amortizirana analiza B -Dreves

Do sedaj smo pokazali, da je

1. v modelu zunanega pomnilnika časovna zahtevnost operacij `find(x)`,

$\text{add}(x)$, in $\text{remove}(x)$ v B -drevesu $O(\log_B n)$, in da je

2. v besednem-RAM modelu časovna zahtevnost operacije $\text{find}(x)$ $O(\log n)$, časovna zahtevnost operacij $\text{add}(x)$ in $\text{remove}(x)$ pa $O(B \log n)$.

Naslednja trditev pokaže, da smo precenili število operacij združevanja in razdelitev v B -drevesih.

Lema 14.1. *Če imamo prazno B -drevo in izvedemo m $\text{add}(x)$ in $\text{remove}(x)$ operacij, se izvede največ $3m/2$ razdelitev, združevanj in izposojanj.*

Dokaz. Dokaz za to je že bil nakazan v 9.3 za poseben primer, ko je $B = 2$. Trditev lahko dokažemo z

1. vsaka razdelitev, združevanje ali izposoja se plača z dvema kovancema (plača se vsakič ko se izvede ena izmed teh operacij); in
2. največ trije kovanci so na razpolago med katerokoli $\text{add}(x)$ ali $\text{remove}(x)$ operacijo.

Ker je na razpolago največ m kovancev in vsaka razdelitev, združevanje in izposoja stane dva kovanca, sledi, da se izvede največ $3m/2$ razdelitev, združevanj in izposoj. Kovanci so prikazani z simbolom ¢ v Slikah 14.5, 14.9, in 14.10.

Da lahko vodimo evidenco o kovancih, dokaz uporablja naslednjo *invarianco kovancev*:

Vsako nekorensko vozlišče z $B - 1$ ključi shrani tri kovance. Vozlišču, ki ima najmanj B in največ $2B - 2$ ključev ni potrebno hraniti kovancev. Sedaj moramo samo še pokazati, da lahko ohranjamo invarianco kovancev in se hkrati držimo trditev 1 in 2 (zgoraj) pri vsaki $\text{add}(x)$ in $\text{remove}(x)$ operaciji.

Dodajanja: Metoda $\text{add}(x)$ ne uporabi nobenih združevanj ali izposojanj, zato lahko pri klicih te metode upoštevamo samo operacije razdelitve.

Vsaka operacija razdelitve ima za vzrok dodajanje ključa vozlišču u , ki že ima $2B - 1$ ključev. Ko pride do tega, se u razdeli na dve vozlišči - vozlišče u' z $B - 1$ ključi in vozlišče u'' z B ključi. Pred to operacijo je imelo vozlišče u $2B - 1$ ključev in zato tri kovance. Dva kovanca porabimo

za operacijo razdelitve in preostali kovanec prenesemo na u' (ki ima $B - 1$ ključev) da ohranimo invarianto kovancev. Tako lahko plačamo za razdelitev in hkrati ohranjamo invarianto kovancev med vsakio operacijo razdelitve.

Edina druga sprememba v vozliščih pri operaciji $\text{add}(x)$ se zgodi šele po vseh opravljenih razdelitvah, če sploh do njih pride. Ta sprememba vključuje dodajanje novega ključa vozlišču u' . Če je imelo pred tem vozlišče u' $2B - 2$ otrok, jih ima sedaj $2B - 1$ in zato prejme tri kovance. Ti kovanci so edini, ki jih dodeli metoda $\text{add}(x)$.

Odstranjevanje: Med operacijo $\text{remove}(x)$ pride do nič ali več operacij združevanja, katerim lahko sledi ena operacija izposoje. Do združevanja pride ko sta vozliča v in w (vsako z po $B - 1$ ključi pred klicem metode $\text{remove}(x)$) združeni v eno vozlišče z $2B - 2$ ključi. Vsako takšno združevanje sprosti dva kovanca, s katerima lahko plačamo združevanje.

Po vseh opravljenih operacijah združevanja lahko pride do največ ene operacije izposoje (po tej operaciji ne pride več do združevanj ali izposojanj). Do te operacije izposoje pride samo v primeru, da iz lista v , ki ima $B - 1$ ključev, odstranimo ključ. Vozlišče v ima tako en kovanec, ki se porabi za to operacijo izposoje. Ker pa en kovanec ni dovolj, moramo ustvariti še enega.

Ustvarili smo en kovanec in moramo sedaj pokazati, da lahko ohranjamo invarianto kovancev. V najslabšem primeru ima v -jev brat w natanko B ključev pred izposojjo, tako da imata oba (v in w) po izposoji $B - 1$ ključev. To pomeni da bi morala vsak imeti po en kovanec po končani operaciji. V tem primeru tako ustvarimo dodatna dva kovanca za vozlišči v in w . Ker se operacija izposoje zgodi največ enkrat na klic metode $\text{remove}(x)$ to pomeni, da ustvarimo skupaj največ tri kovance, kar ne krši pravil.

Če v metodi $\text{remove}(x)$ ne pride do operacije izposoje je to zato, ker se konča z odstranjevanjem ključa iz vozlišča, ki je imelo pred operacijo B ali več ključev. V najslabšem primeru je imelo to vozlišče natanko B ključev, zato jih ima po operaciji $B - 1$ in potrebuje en kovanec, ki ga ustvarimo.

V vsakem primeru - če se odstranjevanje konča z operacijo izposoje ali ne - je potrebno ustvariti največ tri kovance pri klicu metode $\text{remove}(x)$, da se ohranja invarianta kovancev. Dokaz je s tem zaključen. \square

Namen dokaza 14.1 je pokazati, da je pri besednem-RAM modelu časovna zahtevnost operacij razdelitev, združevanje in povezovanje pri m $\text{add}(x)$ in $\text{remove}(x)$ operacijah le $O(Bm)$. To pomeni, da je amortizirana časovna zahtevnost na operacijo samo $O(B)$, torej je amortizirana časovna zahtevnost metod $\text{add}(x)$ in $\text{remove}(x)$ v besednem-RAM modelu $O(B + \log n)$. To je povzeto v naslednjih trditvah:

Izrek 14.1 (*B-Drevesa v zunanjem pomnilniku*). Razred *BTree* implementira vmesnik *SSet*. V modelu zunanjega pomnilnika podpira razred *BTree* operacije $\text{add}(x)$, $\text{remove}(x)$ in $\text{find}(x)$, katerih časovna zahtevnost je $O(\log_B n)$.

Izrek 14.2 (*Besedni RAM B-Drevesa*). Razred *BTree* implementira vmesnik *SSet*. V besednem-RAM modelu podpira razred *BTree* operacije $\text{add}(x)$, $\text{remove}(x)$ in $\text{find}(x)$, katerih časovna zahtevnost je $O(\log n)$, pri čemer zanemarimo ceno razdelitev, združevanj in izposojanj. Če začnemo z praznim *BTree* in opravimo m $\text{add}(x)$ in $\text{remove}(x)$ operacij je časovna zahtevnost razdelitev, združevanj in izposojanj $O(Bm)$.

14.3 Razprave in vaje

Model računanja v zunanjem pomnilniku sta predstavila Aggarwall in Vitter [?]. Včasih se imenuje tudi *V/I model* (ang. *I/O model*) ali pa *diskovno dostopni model* (ang. *DAM*).

B-drevesa so pri iskanju v zunanjem pomnilniku to, kar so dvojiška iskalna drevesa pri iskanju v notranjem pomnilniku. *B*-drevesa sta uvedla Bayer in McCreight [?] leta 1970 in manj kot deset let kasneje jih naslov članka v ACM computing surveys obravnava kot vseprisotne [?]. Tako kot binarnih iskalnih dreves, obstaja veliko različic *B*-dreves, vključno B^+ -drevesa, B^* -drevesa, in štetje *B*-dreves. *B*-drevesa so resnično vseprisotna in so primarna podatkovna struktura v mnogih datotečnih sistemih, vključno z Apple-ov HFS+, Microsoftov NTFS, in Linuxov Ext4; vsak večji sistem podatkovnih baz; in shrambah *key-value*, ki se uporablja v računalništvu v oblaku. Nedavna raziskava Graefe-a [?] zagotavlja pregled 200+ strani, mnogih sodobnih aplikacij, variant in optimizacij *B*-dreves.

B-drevesa implementirajo vmesnik *SSet*. Kadar je potreben le vme-

snik USet, se lahko uporablja hashing zunanjega pomnilnika. Obstajajo programi za hashing zunanjega pomnilnika; za primer glej, Jensen in Pagh [?]. V teh primerih implementirajo USet operacije v pričakovanem času $O(1)$ v modelu zunanjega pomnilnika. Vendar pa zaradi različnih razlogov veliko vlog še vedno uporabljajo B -drevesa, čeprav so zahtevali le operacije USet.

Eden od razlogov, da so B -drevesa tako priljubljena izbira je, da so pogosto uspešnejši od njihove $O(\log_B n)$ predlagane meje časa delovanja. Razlog za to je, ker je vrednost B v nastavitvah zunanjega pomnilnika običajno precej velik - na stotine ali celo tisoče. To pomeni, da je 99% ali celo 99.9% podatkov B -drevesa shranjenih v listih. V sistemu baze podatkov z velikim pomnilnikom, je mogoče shraniti vsa notranja vozlišča B -drevesa v RAM, saj predstavljajo le 1% ali 0.1 celotnega nabora podatkov. Ko se to zgodi, to pomeni, da je iskanje v B -drevesu vključuje zelo hitro iskanje v RAM-u, preko notranjih vozlišč, ki mu sledi enojni dostop do zunanjega pomnilnika za nalaganje listov..

Naloga 14.1. Pokaži kaj se zgodi z ključema 1.5 ter nato z 7.5, ko ju vstavimo v B -drevo, 14.2.

Naloga 14.2. Pokaži kaj se zgodi z ključema 3 in 4, ko ju odstranimo iz B -drevesa v 14.2.

Naloga 14.3. Kakšno je največje število notranjih vozlišč v B -drevesu, ki hrani n ključev (kot funkcija n in B)?

Naloga 14.4. V uvodu trdimo, da B -drevesa potrebujejo notranji pomnilnik velikosti $O(B + \log_B n)$. Vendar implementacija podana tukaj ima večjo pomnilniško zahtevnost.

1. Pokaži, da implementacija za `add(x)` in `remove(x)` metodi podani v tem poglavju uporabljata notranji pomnilnik preporcionalen $B \log_B n$
2. Opiši kako bi lahko te metode preoblikovali, tako da bi zmanjšali njihovo pomnilniško zahtevnost na $O(B + \log_B n)$.

Naloga 14.5. Nariši kredite uporabljene v dokazu 14.1 na drevesih v Figures 14.6 in 14.7. Potrdi, da (z tremi dodatnimi krediti) si je mogoče privoščiti rezcepitev, združitve in sposojanja ter hkrati obdržati kreditno invarianto.

Naloga 14.6. Naredi spremenjeno verzijo B -drevesa, katera ima lahko od B do $3B$ naslednjikov (in zato od $B-1$ do $3B-1$ ključev). Dokaži, da ta nova verzija B -drevesa izvaja samo $O(m/B)$ razcepitve, združitve, in izposojanja v času zaporedja m operacij. (Nasvet: Da bo to delovalo, boste morali biti bolj agresivni z združevanjem, občasno združiti dve vozlišči preden bo to nujno potrebno.)

Naloga 14.7. V tej vaji boste zasnovali spremenjeno metodo za delitev in združevanje v B -drevesih, ki asimptotično zmanjša število delitev, izposojanj in združevanj z upoštevanjem treh vozlišč naenkrat.

1. Naj bo u prepolno vozlišče in naj bo v brat takoj desno od u . Obstajata dva načina, da popravimo prekoračitev pri u :
 - (a) u lahko preseli nekaj svojih ključev na v ; ali
 - (b) u se lahko razdeli in ključi u in v se lahko enakomerno razdelijo med u , v in novo nastalo vozlišče w .


Pokažite, da se to vedno lahko naredi na način, da imajo po operaciji vsa udeležena vozlišča (največ 3) vsaj $B + \alpha B$ ključev in kvečemu $2B - \alpha B$ ključev, za neko konstantno $\alpha > 0$.

2. Naj bo u vozlišče s premalo ključi in naj bosta v ter w brata vozlišča u . Obstajata dva načina kako popraviti praveliko praznost pri u :
 - (a) ključi se lahko enakomerno razdelijo med u , v in w ; ali
 - (b) u , v , w združimo v dve vozlišči ter razdelimo ključe vozlišč u , v , in w med novonastali vozlišči

Pokažite, da se, da to vedno narediti na način, tako, da imajo po operaciji vsa udeležena vozlišča (največ 3) vsaj $B + \alpha B$ ključev in kvečjemu $2B - \alpha B$ ključev, za neko konstanto $\alpha > 0$.

3. Pokažite, da je s temi spremembami, število združevanj, izposojanj in delitev, ki se zgodijo nad m operacijami enako $O(m/B)$.

Naloga 14.8. B^+ -drevo, ilustrirano na 14.11 hrani vsak ključ v listih, vsak list pa je shranjen kot dvojno povezani seznam. Kot ponavadi, vsak list hrani med $B - 1$ in $2B - 1$ ključi. Nad listi je običajno B -drevo, ki hrani največjo vrednost vsakega lista razen zadnjega.



Slika 14.11: B^+ -drevo je B -drevo na vrhu dvojno povezanega seznama blokov.

1. Opišite hitre implementacije metod `add(x)`, `remove(x)` in `find(x)` v B^+ -drevesu.
2. Razložite kako učinkovito implementirati metodo `findRange(x, y)`, ki vrne vse vrednosti večje od x in manjše ali enake y v B^+ -drevesu.
3. Implementirajte razred, `BPlusTree`, ki implementira `find(x)`, `add(x)`, `remove(x)`, in `findRange(x, y)`.
4. B^+ -drevo podvoji nekatere ključne, saj so shranjeni hkrati v B -drevesu ter v listu. Razložite zakaj se to podvajanje ne pozna toliko na velikih vrednostih od B .

Literatura

- [1] Free eBooks by Project Gutenberg. URL: <http://www.gutenberg.org/> [cited 2011-10-12].
- [2] IEEE Standard for Floating-Point Arithmetic. Technical report, Microprocessor Standards Committee of the IEEE Computer Society, 3 Park Avenue, New York, NY 10016-5997, USA, August 2008. doi:10.1109/IEEESTD.2008.4610935.
- [3] G. Adelson-Velskii and E. Landis. An algorithm for the organization of information. *Soviet Mathematics Doklady*, 3(1259-1262):4, 1962.
- [4] A. Aggarwal and J. S. Vitter. The input/output complexity of sorting and related problems. *Communications of the ACM*, 31(9):1116–1127, 1988.
- [5] A. Andersson. Balanced search trees made simple. In F. K. H. A. Dehne, J.-R. Sack, N. Santoro, and S. Whitesides, editors, *Algorithms and Data Structures, Third Workshop, WADS '93, Montréal, Canada, August 11–13, 1993, Proceedings*, volume 709 of *Lecture Notes in Computer Science*, pages 60–71. Springer, 1993.
- [6] A. Bagchi, A. L. Buchsbaum, and M. T. Goodrich. Biased skip lists. In P. Bose and P. Morin, editors, *Algorithms and Computation, 13th International Symposium, ISAAC 2002 Vancouver, BC, Canada, November 21–23, 2002, Proceedings*, volume 2518 of *Lecture Notes in Computer Science*, pages 1–13. Springer, 2002.
- [7] R. Bayer and E. M. McCreight. Organization and maintenance of large ordered indexes. In *SIGFIDET Workshop*, pages 107–141. ACM, 1970.

- [8] Bibliography on hashing. URL: <http://liinwww.ira.uka.de/bibliography/Theory/hash.html> [cited 2011-07-20].
- [9] J. Black, S. Halevi, H. Krawczyk, T. Krovetz, and P. Rogaway. UMAC: Fast and secure message authentication. In M. J. Wiener, editor, *Advances in Cryptology - CRYPTO '99, 19th Annual International Cryptology Conference, Santa Barbara, California, USA, August 15–19, 1999, Proceedings*, volume 1666 of *Lecture Notes in Computer Science*, pages 79–79. Springer, 1999.
- [10] P. Bose, K. Douïeb, and S. Langerman. Dynamic optimality for skip lists and b-trees. In S.-H. Teng, editor, *Proceedings of the Nineteenth Annual ACM-SIAM Symposium on Discrete Algorithms, SODA 2008, San Francisco, California, USA, January 20–22, 2008*, pages 1106–1114. SIAM, 2008.
- [11] A. Brodnik, S. Carlsson, E. D. Demaine, J. I. Munro, and R. Sedgewick. Resizable arrays in optimal time and space. In Dehne et al. [?], pages 37–48.
- [12] J. Carter and M. Wegman. Universal classes of hash functions. *Journal of computer and system sciences*, 18(2):143–154, 1979.
- [13] D. Comer. The ubiquitous B-tree. *ACM Computing Surveys*, 11(2):121–137, 1979.
- [14] C. Crane. Linear lists and priority queues as balanced binary trees. Technical Report STAN-CS-72-259, Computer Science Department, Stanford University, 1972.
- [15] S. Crosby and D. Wallach. Denial of service via algorithmic complexity attacks. In *Proceedings of the 12th USENIX Security Symposium*, pages 29–44, 2003.
- [16] F. K. H. A. Dehne, A. Gupta, J.-R. Sack, and R. Tamassia, editors. *Algorithms and Data Structures, 6th International Workshop, WADS '99, Vancouver, British Columbia, Canada, August 11–14, 1999, Proceedings*, volume 1663 of *Lecture Notes in Computer Science*. Springer, 1999.

- [17] L. Devroye. Applications of the theory of records in the study of random trees. *Acta Informatica*, 26(1):123–130, 1988.
- [18] M. Dietzfelbinger. Universal hashing and k -wise independent random variables via integer arithmetic without primes. In C. Puech and R. Reischuk, editors, *STACS 96, 13th Annual Symposium on Theoretical Aspects of Computer Science, Grenoble, France, February 22–24, 1996, Proceedings*, volume 1046 of *Lecture Notes in Computer Science*, pages 567–580. Springer, 1996.
- [19] M. Dietzfelbinger, J. Gil, Y. Matias, and N. Pippenger. Polynomial hash functions are reliable. In W. Kuich, editor, *Automata, Languages and Programming, 19th International Colloquium, ICALP92, Vienna, Austria, July 13–17, 1992, Proceedings*, volume 623 of *Lecture Notes in Computer Science*, pages 235–246. Springer, 1992.
- [20] M. Dietzfelbinger, T. Hagerup, J. Katajainen, and M. Penttonen. A reliable randomized algorithm for the closest-pair problem. *Journal of Algorithms*, 25(1):19–51, 1997.
- [21] M. Dietzfelbinger, A. R. Karlin, K. Mehlhorn, F. M. auf der Heide, H. Rohnert, and R. E. Tarjan. Dynamic perfect hashing: Upper and lower bounds. *SIAM J. Comput.*, 23(4):738–761, 1994.
- [22] A. Elmasry. Pairing heaps with $O(\log \log n)$ decrease cost. In *Proceedings of the twentieth Annual ACM-SIAM Symposium on Discrete Algorithms*, pages 471–476. Society for Industrial and Applied Mathematics, 2009.
- [23] F. Ergun, S. C. Sahinalp, J. Sharp, and R. Sinha. Biased dictionaries with fast insert/deletes. In *Proceedings of the thirty-third annual ACM symposium on Theory of computing*, pages 483–491, New York, NY, USA, 2001. ACM.
- [24] M. Eytzinger. *Thesaurus principum hac aetate in Europa viventium (Cologne)*. 1590. In commentaries, ‘Eytzinger’ may appear in variant forms, including: Aitsingeri, Aitsingero, Aitsingerum, Eyzingern.
- [25] R. W. Floyd. Algorithm 245: Treesort 3. *Communications of the ACM*, 7(12):701, 1964.

- [26] M. Fredman, R. Sedgwick, D. Sleator, and R. Tarjan. The pairing heap: A new form of self-adjusting heap. *Algorithmica*, 1(1):111–129, 1986.
- [27] M. Fredman and R. Tarjan. Fibonacci heaps and their uses in improved network optimization algorithms. *Journal of the ACM*, 34(3):596–615, 1987.
- [28] M. L. Fredman, J. Komlós, and E. Szemerédi. Storing a sparse table with 0 (1) worst case access time. *Journal of the ACM*, 31(3):538–544, 1984.
- [29] M. L. Fredman and D. E. Willard. Surpassing the information theoretic bound with fusion trees. *Journal of computer and system sciences*, 47(3):424–436, 1993.
- [30] A. Gambin and A. Malinowski. Randomized meldable priority queues. In *SOFSEM'98: Theory and Practice of Informatics*, pages 344–349. Springer, 1998.
- [31] M. T. Goodrich and J. G. Kloss. Tiered vectors: Efficient dynamic arrays for rank-based sequences. In Dehne et al. [?], pages 205–216.
- [32] G. Graefe. Modern b-tree techniques. *Foundations and Trends in Databases*, 3(4):203–402, 2010.
- [33] R. L. Graham, D. E. Knuth, and O. Patashnik. *Concrete Mathematics*. Addison-Wesley, 2nd edition, 1994.
- [34] L. Guibas and R. Sedgwick. A dichromatic framework for balanced trees. In *19th Annual Symposium on Foundations of Computer Science, Ann Arbor, Michigan, 16–18 October 1978, Proceedings*, pages 8–21. IEEE Computer Society, 1978.
- [35] C. A. R. Hoare. Algorithm 64: Quicksort. *Communications of the ACM*, 4(7):321, 1961.
- [36] J. E. Hopcroft and R. E. Tarjan. Algorithm 447: Efficient algorithms for graph manipulation. *Communications of the ACM*, 16(6):372–378, 1973.

- [37] J. E. Hopcroft and R. E. Tarjan. Efficient planarity testing. *Journal of the ACM*, 21(4):549–568, 1974.
- [38] HP-UX process management white paper, version 1.3, 1997. URL: http://h21007.www2.hp.com/portal/download/files/prot/files/STK/pdfs/proc_mgt.pdf [cited 2011-07-20].
- [39] M. S. Jensen and R. Pagh. Optimality in external memory hashing. *Algorithmica*, 52(3):403–411, 2008.
- [40] P. Kirschenhofer, C. Martinez, and H. Prodinger. Analysis of an optimized search algorithm for skip lists. *Theoretical Computer Science*, 144:199–220, 1995.
- [41] P. Kirschenhofer and H. Prodinger. The path length of random skip lists. *Acta Informatica*, 31:775–792, 1994.
- [42] D. Knuth. *Fundamental Algorithms*, volume 1 of *The Art of Computer Programming*. Addison-Wesley, third edition, 1997.
- [43] D. Knuth. *Seminumerical Algorithms*, volume 2 of *The Art of Computer Programming*. Addison-Wesley, third edition, 1997.
- [44] D. Knuth. *Sorting and Searching*, volume 3 of *The Art of Computer Programming*. Addison-Wesley, second edition, 1997.
- [45] C. Y. Lee. An algorithm for path connection and its applications. *IRE Transaction on Electronic Computers*, EC-10(3):346–365, 1961.
- [46] E. Lehman, F. T. Leighton, and A. R. Meyer. *Mathematics for Computer Science*. 2011. URL: <http://courses.csail.mit.edu/6.042/spring12/mcs.pdf> [cited 2012-09-06].
- [47] J. I. Munro, T. Papadakis, and R. Sedgewick. Deterministic skip lists. In *Proceedings of the third annual ACM-SIAM symposium on Discrete algorithms (SODA’92)*, pages 367–375, Philadelphia, PA, USA, 1992. Society for Industrial and Applied Mathematics.
- [48] Oracle. *The Collections Framework*. URL: <http://download.oracle.com/javase/1.5.0/docs/guide/collections/> [cited 2011-07-19].

- [49] Oracle. *Java Platform Standard Ed. 6*. URL: <http://download.oracle.com/javase/6/docs/api/> [cited 2011-07-19].
- [50] Oracle. *The Java Tutorials*. URL: <http://download.oracle.com/javase/tutorial/> [cited 2011-07-19].
- [51] R. Pagh and F. Rodler. Cuckoo hashing. *Journal of Algorithms*, 51(2):122–144, 2004.
- [52] T. Papadakis, J. I. Munro, and P. V. Poblete. Average search and update costs in skip lists. *BIT*, 32:316–332, 1992.
- [53] M. Pătraşcu and M. Thorup. Randomization does not help searching predecessors. In N. Bansal, K. Pruhs, and C. Stein, editors, *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms, SODA 2007, New Orleans, Louisiana, USA, January 7–9, 2007*, pages 555–564. SIAM, 2007.
- [54] M. Pătraşcu and M. Thorup. The power of simple tabulation hashing. *Journal of the ACM*, 59(3):14, 2012.
- [55] W. Pugh. A skip list cookbook. Technical report, Institute for Advanced Computer Studies, Department of Computer Science, University of Maryland, College Park, 1989. URL: <ftp://ftp.cs.umd.edu/pub/skiplist/cookbook.pdf> [cited 2011-07-20].
- [56] W. Pugh. Skip lists: A probabilistic alternative to balanced trees. *Communications of the ACM*, 33(6):668–676, 1990.
- [57] Redis. URL: <http://redis.io/> [cited 2011-07-20].
- [58] B. Reed. The height of a random binary search tree. *Journal of the ACM*, 50(3):306–332, 2003.
- [59] S. M. Ross. *Probability Models for Computer Science*. Academic Press, Inc., Orlando, FL, USA, 2001.
- [60] R. Sedgewick. Left-leaning red-black trees, September 2008. URL: <http://www.cs.princeton.edu/~rs/talks/LLRB/LLRB.pdf> [cited 2011-07-21].

- [61] R. Seidel and C. Aragon. Randomized search trees. *Algorithmica*, 16(4):464–497, 1996.
- [62] H. H. Seward. Information sorting in the application of electronic digital computers to business operations. Master’s thesis, Massachusetts Institute of Technology, Digital Computer Laboratory, 1954.
- [63] Z. Shao, J. H. Reppy, and A. W. Appel. Unrolling lists. In *Proceedings of the 1994 ACM conference LISP and Functional Programming (LFP’94)*, pages 185–195, New York, 1994. ACM.
- [64] P. Sinha. A memory-efficient doubly linked list. *Linux Journal*, 129, 2005. URL: <http://www.linuxjournal.com/article/6828> [cited 2013-06-05].
- [65] SkipDB. URL: <http://dekorte.com/projects/opensource/SkipDB/> [cited 2011-07-20].
- [66] D. Sleator and R. Tarjan. Self-adjusting binary trees. In *Proceedings of the 15th Annual ACM Symposium on Theory of Computing*, 25–27 April, 1983, Boston, Massachusetts, USA, pages 235–245. ACM, ACM, 1983.
- [67] S. P. Thompson. *Calculus Made Easy*. MacMillan, Toronto, 1914. Project Gutenberg EBook 33283. URL: <http://www.gutenberg.org/ebooks/33283> [cited 2012-06-14].
- [68] P. van Emde Boas. Preserving order in a forest in less than logarithmic time and linear space. *Inf. Process. Lett.*, 6(3):80–82, 1977.
- [69] J. Vuillemin. A data structure for manipulating priority queues. *Communications of the ACM*, 21(4):309–315, 1978.
- [70] J. Vuillemin. A unifying look at data structures. *Communications of the ACM*, 23(4):229–239, 1980.
- [71] D. E. Willard. Log-logarithmic worst-case range queries are possible in space $\Theta(N)$. *Inf. Process. Lett.*, 17(2):81–84, 1983.
- [72] J. Williams. Algorithm 232: Heapsort. *Communications of the ACM*, 7(6):347–348, 1964.

